Industr.IA

E-book

Dados em PD&I industrial

Condução de Projetos | Unidade 4

Prof.: Raimundo Valter



SUMÁRIO

1. Aquisição e qualificação operacionais 3
2. Governança operacional de dados 10
3. Regulatório e propriedade intelectual de dados 15
4. Conclusão 21

Unidade 4 | CDP-024

1. Aquisição e qualificação operacionais

Este tópico abre o eixo de dados do projeto e tem por objetivo que você organize a aquisição e a qualificação de dados em chave operacional: dimensionando esforço e custo, articulando a aquisição ao cronograma e tratando as dependências com a empresa parceira como o que elas são, dependências críticas com dono e mitigação (competência CP.B4.C1). No CRISP-DM adaptado do curso, estamos na fase de compreensão e preparação de dados, e a premissa do bloco é direta: o repertório técnico de data quality, error analysis e análise de viés, que o módulo M3 do curso base estabeleceu, é necessário mas não suficiente para conduzir o eixo de dados de um projeto industrial. O que falta, e é o que este bloco acrescenta, é a articulação dessas competências com cronograma, custo, dependências externas e regime regulatório. A chave da palavra operacional está aí: não vamos reapresentar o framework de qualidade; vamos ligá-lo às perguntas de condução que o B2 e o B3 deixaram na mesa.

Comece por um fato empírico que estrutura tudo o que segue: o eixo de dados é a fonte mais frequente de atraso e de descalibragem de expectativa em projetos de IA industrial. O estudo de Sambasivan e colegas sobre cascatas de dados documentou o padrão: equipes subinvestem sistematicamente no trabalho de dados, porque ele é percebido como preparação e não como entrega, e o custo desse subinvestimento aparece tarde, composto, nas fases em que corrigir é mais caro. A explicação de fundo é uma diferença de postura que você já conhece do bloco B1. Na régua da pesquisa, o dataset é um ponto de partida: alguém o construiu, publicou e documentou, e o trabalho começa depois dele. Na régua do PD&I industrial, o dataset é um entregável intermediário do próprio projeto, com dono, prazo, custo e qualidade a negociar. O pesquisador recém-chegado planeja como se os dados fossem o benchmark que ele conhece; o engenheiro de PD&I planeja a construção do dataset como planeja qualquer outro pacote de trabalho.

A primeira ferramenta operacional deste tópico ataca o ponto exato em que essa diferença de postura vira atraso: a pergunta os dados existem? A pergunta parece binária e não é. Entre o alguém disse que temos cinco anos de histórico e o acesso funcionando com acordo assinado há uma escada inteira de estados intermediários, e cada degrau autoriza um compromisso de cronograma diferente. O curso fixa essa escada como *prontidão de fonte*, uma classificação em cinco níveis que você aplica a cada fonte de dados do projeto, separadamente, antes de assumir qualquer prazo que dependa dela.

GLOSSÁRIO

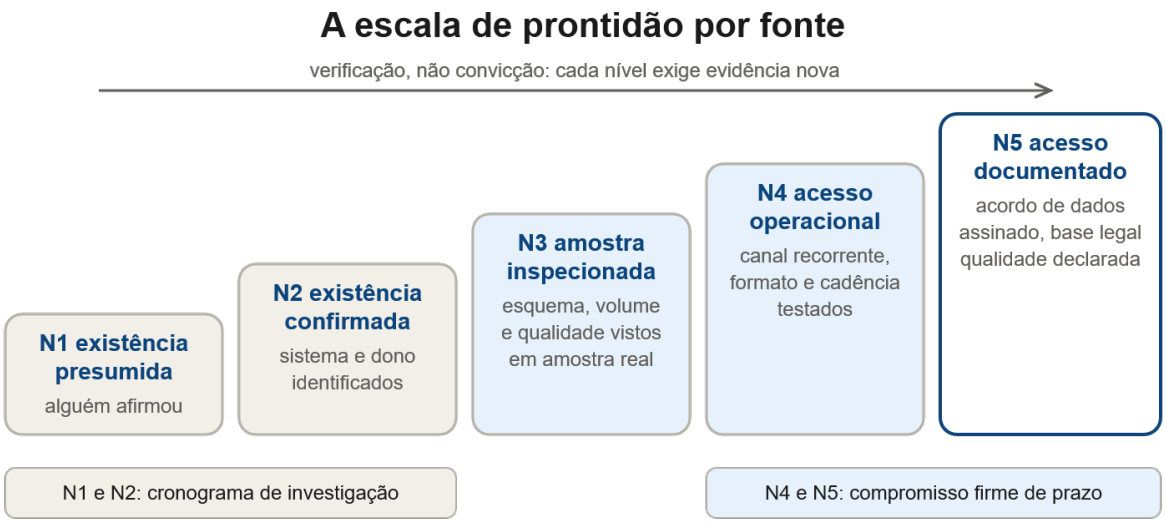
Prontidão de fonte

Classificação operacional de uma fonte de dados em cinco níveis, da existência presumida ao acesso documentado com base legal. Cada nível autoriza um compromisso de cronograma diferente: os níveis baixos sustentam apenas cronograma de investigação; só os altos sustentam compromisso firme de prazo. Planejar sobre nível baixo como se fosse alto é a origem mais comum de atraso no eixo de dados.

Os cinco níveis têm nome, evidência exigida e uma pergunta de verificação cada um. No nível 1, existência presumida, tudo o que o projeto tem é uma afirmação: alguém disse que os dados existem. Não há evidência nenhuma. A pergunta de verificação que orienta a transição para o nível seguinte é: quem é o responsável e onde os dados estão armazenados? No nível 2, existência confirmada, o sistema de origem foi identificado e uma pessoa responde por ele; a fonte tem endereço e dono, mas ninguém do projeto viu um registro sequer. No nível 3, amostra inspecionada, o squad examinou uma amostra real: viu o esquema como ele é, mediu o volume, observou a qualidade de fato, e quase sempre descobriu distâncias entre a descrição e o material. A pergunta característica deste nível é o que a amostra mostra que a conversa não mostrou?

No nível 4, acesso operacional, há um pipeline técnico recorrente em operação: a extração e a ingestão ocorrem de ponta a ponta, com formato e cadência validados, sem depender de intervenções manuais ou ad hoc. No nível 5, acesso documentado, o que funciona na prática está registrado por escrito: o acordo de dados com a parceira está assinado, a base legal do tratamento está identificada quando há dado pessoal, e a qualidade que a fonte entrega está declarada. A regra de leitura da escala é o que a torna instrumento de condução, e não taxonomia decorativa: níveis 1 e 2 sustentam apenas cronograma de investigação, com atividades de confirmação e amostragem; compromisso firme de prazo, aquele que entra no cronograma do B2 com milestone e critério de pronto, só se assume sobre fontes nos níveis 4 e 5. A figura 1 organiza a escala com a evidência de cada degrau.

Figura 1 - A escala de prontidão por fonte de dados: cinco níveis entre a existência presumida e o acesso documentado com base legal.



Fonte: autor. Arquivo: B4_fig-1_escala_prontidao_por_fonte.svg

Para cego ver: Imagem intitulada "Figura 1 A escala de prontidão por fonte de Dados", organizada em cinco níveis crescentes, representados por blocos em formato de degraus, da esquerda para a direita. Uma seta horizontal aponta para a direita e indica a progressão da verificação, acompanhada da frase: "verificação, não convicção: cada nível exige evidência nova". Os níveis são: N1 – existência presumida: alguém afirmou; N2 – existência confirmada: sistema e dono identificados; N3 – amostra inspecionada: esquema, volume e qualidade vistos em amostra real; N4 – acesso operacional: canal recorrente, formato e cadência testados; e N5 – acesso documentado: acordo de dados assinado, base legal e qualidade declarada. Na parte inferior, duas faixas destacam que N1 e N2 correspondem ao cronograma de investigação, enquanto N4 e N5 representam compromisso firme de prazo.

Com a escala na mão, o dimensionamento de esforço e custo deixa de ser chute e vira decomposição. Cada fonte entra no cronograma com as atividades que a levam do nível atual ao nível de que o projeto precisa: confirmar a existência, obter e inspecionar a amostra, estabelecer o canal de acesso, formalizar o acordo. Cada uma dessas atividades tem duração, responsável e, com frequência, dependência da parceira; é exatamente o material de que o cronograma do B2 é feito. A prontidão baixa não impede o planejamento, mas muda a natureza dele: uma fonte no nível 2 entra no cronograma como incerteza declarada, com um milestone de verificação cujo critério de pronto é alcançar o nível 3 ou 4 até uma data, e com um plano B registrado para o caso de a verificação frustrar. O que a escala proíbe é o meio-termo silencioso: a fonte presumida tratada como disponível, sem que ninguém tenha decidido correr esse risco.

O custo segue a mesma lógica de decomposição, e um componente merece atenção especial porque é o que os recém-chegados mais subestimam: a anotação humana. Em projetos supervisionados, o custo de rotular frequentemente domina o custo total do eixo de dados, e a estimativa séria não se faz por intuição, se faz por piloto: anote você mesmo, ou com a equipe que fará o trabalho, algumas dezenas de itens; meça o tempo por item, registre as dúvidas que surgiram e extrapole com margem para o volume necessário. O piloto entrega três coisas de uma vez: a estimativa de custo com base empírica, a primeira versão do guia de anotação e a lista de ambiguidades que o guia precisa resolver. E a aritmética resultante costuma surpreender: A 40 segundos por imagem, um lote de 10.000 imagens demanda mais de 110 horas de trabalho contínuo,

sem contar a revisão. É esse valor empírico, e não uma estimativa intuitiva, que entra no cronograma e no orçamento. Voltaremos à anotação adiante; antes, o instrumento que organiza a relação com a fonte mais importante do projeto.

A escala vale para toda fonte, não só para a parceira. Projetos reais combinam dados da empresa com dados públicos e dados licenciados de terceiros, e cada origem tem o seu caminho até o nível 5. Um dataset público chega rápido ao nível 3, porque a amostra está a um download de distância, mas o nível 5 dele é a leitura da licença: o que ela permite de uso comercial, de redistribuição e de derivação, na chave que o B3 fixou para o fornecedor de dados. Um dado licenciado de terceiro acrescenta contrato, custo e, com frequência, restrição de uso secundário. A regra de condução é registrar cada fonte no plano com a sua origem e o seu caminho próprio de prontidão, porque somar fontes de origens diferentes sem registrar as restrições de cada uma cria um conjunto de treino cuja licença efetiva é a mais restritiva de todas, descoberta tarde.

Na residência, a fonte mais importante quase sempre é a empresa parceira, e a relação com ela não pode viver de mensagens avulsas e boa vontade. O instrumento que o curso fixa é o acordo de dados: um registro operacional, negociado com a parceira, com quatro campos. O esquema diz o que vem: quais campos, em que formato, com que dicionário. O responsável tem nome e cargo: quem, do lado da parceira, responde pela entrega; entrega sem nome é entrega de ninguém. A cadência diz quando e com que frequência os dados chegam, em lotes definidos. E a qualidade declarada registra o que a parceira afirma sobre o material: completude esperada, período coberto, critérios de coleta, lacunas conhecidas. O acordo de dados não substitui o contrato jurídico entre as instituições; ele é o instrumento operacional que o contrato referencia, e a sua função aparece no dia em que a entrega diverge do combinado: sem registro, a divergência vira ruído de memória; com registro, vira fato tratável.

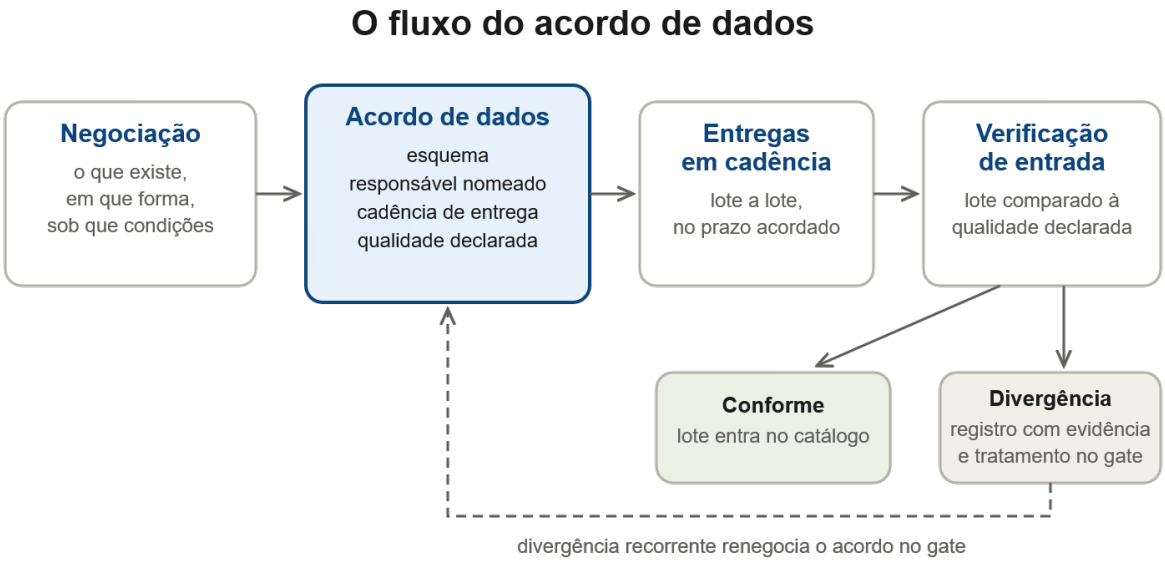
GLOSSÁRIO

Acordo de dados

Registro operacional negociado com a empresa parceira que formaliza a entrega de dados em quatro campos: esquema, responsável nomeado, cadência de entrega e qualidade declarada. Não substitui o contrato entre as instituições; é o instrumento contra o qual cada lote entregue é verificado e a referência objetiva para tratar divergências nos gates.

O quarto campo do acordo abre a distinção mais importante deste tópico: qualidade declarada não é qualidade efetiva. A declaração registra o que a parceira acredita e afirma; a verdade sobre o material só aparece quando o material chega. Por isso o acordo de dados vem acompanhado de um rito: a verificação de entrada. A cada lote entregue, o squad aplica o framework de data quality do M3 na chegada, com checagens objetivas de completude, consistência, validade e atualidade contra o que foi declarado, e registra o resultado. Lote conforme entra no catálogo do projeto, que o tópico 2 organiza. Lote divergente gera um registro com evidência: o que foi declarado, o que chegou, qual a diferença medida. E aqui a postura importa tanto quanto a técnica: divergência não é acusação, é fato de gestão. Ela é levada ao gate como qualquer risco materializado, onde as opções são renegociar o acordo, ajustar o cronograma ou revisar o escopo; o que não se faz é absorvê-la em silêncio e pagar o preço no final. A figura 2 desenha o circuito completo.

Figura 2 - O fluxo do acordo de dados com a empresa parceira: da negociação à verificação de entrada e ao tratamento de divergências nos gates.



Fonte: autor. Arquivo: B4_fig-2_fluxo_acordo_de_dados.svg

Para cego ver: Fluxograma horizontal intitulado "Figura 2 - O fluxo do acordo de dados", composto por quatro etapas principais conectadas por setas: Negociação, que define o que existe, em que formato e sob quais condições; Acordo de dados, que estabelece esquema, responsável, cadência de entrega e qualidade declarada; Entregas em cadência, realizadas lote a lote no prazo acordado; e Verificação de entrada, na qual cada lote é comparado à qualidade declarada. Após a verificação, há dois resultados possíveis: Conforme, quando o lote entra no catálogo, ou Divergência, quando o problema é registrado com evidências e tratado no gate. Uma linha tracejada retorna da divergência ao acordo de dados, indicando que divergências recorrentes levam à renegociação do acordo no gate.

Armadilha comum

A armadilha de postura desta parte é tratar a promessa de dados como dado disponível. O pesquisador, habituado a datasets prontos, ouve temos cinco anos de histórico e planeja como se a fonte estivesse no nível 5, quando ela está no nível 1. Semanas depois descobre que o histórico vive em três sistemas, com dois formatos e nenhuma base legal registrada. A consequência não é só o atraso: é a perda do momento de negociar, porque o cronograma foi assinado sem a incerteza declarada. Classifique a prontidão de cada fonte antes de assumir prazo; a escala existe para impedir exatamente esse salto.

Uma distinção de cadência completa o desenho da aquisição: a carga histórica e o fluxo contínuo são entregas diferentes, com riscos diferentes, e o acordo de dados trata as duas. A carga histórica é um lote grande e único, o passado da fonte; o risco dela é a heterogeneidade escondida, porque cinco anos de histórico atravessam trocas de sistema, mudanças de sensor e revisões de processo que a descrição não menciona e a amostra de um período só não revela. O fluxo contínuo é a cadência regular de lotes novos; o risco dele é a degradação silenciosa, a entrega que atrasa, o campo que some, o formato que muda sem aviso. A verificação de entrada cobre os dois, mas com perguntas distintas: no histórico, ela procura quebras internas de consistência entre períodos; no fluxo, ela compara cada lote com os anteriores e com a declaração. Um projeto que valida o histórico e esquece o fluxo descobre a mudança de formato em produção, que é onde ela custa mais.

Falta organizar a anotação, o componente de custo que o piloto estimou. A primeira decisão é de estratégia, e ela conversa com o mapa de fornecedores do B3: anotar internamente, com o próprio squad ou com a parceira, preserva conhecimento de domínio e confidencialidade, mas consome tempo escasso de gente cara; terceirizar para um fornecedor de anotação escala melhor, mas exige contrato com confidencialidade, PI sobre os rótulos e qualidade contratada com métrica, exatamente as questões que a taxonomia de fornecedores do bloco anterior mapeou; e a anotação assistida por modelo, em que um modelo pré-rotula e humanos revisam, reduz custo por item, ao preço de introduzir o viés do modelo na rotulagem, o que pede revisão desenhada para discordar, não para confirmar. As três estratégias se combinam; a escolha se registra com justificativa, como toda decisão deste curso.

A segunda decisão é de organização, e o curso fixa o padrão: anotação em lotes, com medição de concordância por lote. Em vez de rotular o volume inteiro de uma vez, o trabalho avança em lotes definidos; em cada lote, uma fração dos itens, tipicamente entre cinco e quinze por cento, é anotada por mais de uma pessoa, e a concordância entre anotadores é medida, seja como percentual simples de acordo, seja por um coeficiente que desconta o acaso, como o kappa, cujo detalhe técnico fica para os cursos da Fase 2. O número importa menos pela precisão do que pelo que ele diagnostica: Índices baixos de concordância raramente indicam baixo desempenho do anotador; refletem, em geral, um guia de anotação ambíguo ou uma tarefa com critérios insuficientemente delimitados. O rito, então, é fechar o lote, ler a concordância, revisar o guia com os casos limítrofes que geraram desacordo e só então liberar o lote seguinte. O guia de anotação é artefato vivo: cada versão datada, cada mudança registrada, porque rótulos produzidos sob guias diferentes não são o mesmo dataset.

Exemplo aplicado

Numa distribuidora de energia, o squad organizou a anotação de imagens de inspeção de linhas, capturadas por drone, em lotes semanais, com dez por cento das imagens rotuladas por dois técnicos. No primeiro lote, a concordância ficou abaixo de setenta por cento: o guia não definia quando corrosão leve virava defeito reportável. O guia ganhou exemplos limítrofes e a concordância passou de noventa por cento nos lotes seguintes. A revisão custou uma semana; descobrir a ambiguidade depois de dez mil imagens anotadas teria custado o reanote quase completo do dataset.

O último elemento do tópico é o que a palavra qualificação carrega de contínuo. Dados não são uma etapa vencida: a cada lote que chega, a verificação de entrada roda de novo; a cada rodada de modelagem, o error analysis por slices do M3 aponta onde o modelo falha, e essa evidência direciona a próxima rodada de aquisição e anotação, que vai buscar exatamente os casos em que o desempenho é pior. Essa realimentação entre avaliação e aquisição é a forma que a cadência de iteração do B2 assume no eixo de dados: cada iteração entre gates pode conter um incremento de dados com critério de pronto próprio, e o gate lê a evolução da qualidade como lê a evolução do modelo. Quem trata aquisição como fase que termina descobre, tarde, que ela só estava esperando.

Falta o passo que transforma a suspeita em evidência, e ele é barato. Antes de comprometer cronograma com uma fonte, roda-se um perfilamento sobre uma amostra dela: contagem de nulos por coluna, cardinalidade, faixas e unidades, distribuição das datas, duplicatas, e a taxa de preenchimento dos campos que a solução realmente vai consumir. O perfilamento não julga o dado, apenas o descreve, e é essa descrição que se compara com a qualidade declarada. Um histórico de cinco anos que se revela com dois anos utilizáveis, um sensor com trinta por cento de leituras ausentes no turno da noite, uma coluna de matrícula que ninguém tinha mencionado: são achados de meia hora de trabalho que mudam o cronograma, o custo de anotação e, às vezes, o regime regulatório aplicável. O plano de aquisição registra o perfilamento como evidência datada por fonte, e não como impressão: prontidão declarada sem perfilamento é promessa, e o bloco inteiro existe para não confundir as duas coisas.

O artefato do caderno deste tópico consolida tudo isso: o plano de aquisição de dados. Os eixos pré-mapeados seguem a lógica que você acabou de percorrer: cada fonte entra com o seu nível de prontidão e a evidência que o sustenta; as atividades que a levam ao nível necessário, com milestones e critérios de pronto articulados ao cronograma do B2; o esforço e o custo estimados, com a anotação decomposta a partir do piloto; a dependência com a parceira e a mitigação correspondente, na chave da matriz de risco

do B2; e o responsável por cada movimento. O plano preenchido no caderno traz o cronograma articulado, os custos estimados e as dependências mapeadas. A coerência cruzada é o critério de sempre: o plano lê o canvas do B3, porque os dados a adquirir são os que a arquitetura declarou consumir, e lê a ficha de escopo do B2, porque o lastro de dados registrado lá é o ponto de partida da classificação de prontidão. Adquirir, porém, é metade do problema; a outra metade é não perder o controle do que foi adquirido. É disso que trata o tópico 2.

2. Governança operacional de dados

Este tópico tem por objetivo que você implemente os fundamentos de governança operacional de dados em escala compatível com um projeto de PD&I industrial: um catálogo com papéis de dono e curador por conjunto, versionamento de dataset, rastreabilidade de transformações e o tratamento operacional de dados sensíveis (competência CP.B4.C1). A premissa é econômica antes de ser técnica: sem registro, o conhecimento sobre os dados vira conhecimento tribal, aquele que mora na cabeça de uma pessoa e sai do projeto junto com ela. E há uma formulação de postura que resume o risco: o projeto que não sabe dizer com que dados treinou o modelo que está no ar não tem um problema técnico, tem um problema de defesa. Nenhuma justificativa apresentada a um auditor, a um cliente ou a uma banca começa bem com a frase “a gente acha que foi a versão de março.”

Antes dos componentes, uma calibração de escala, porque a palavra governança evoca plataformas corporativas, comitês e ferramentas caras, e nada disso é o que um projeto de squad precisa. A governança operacional de um projeto de PD&I cabe, na maior parte dos casos, numa planilha bem mantida, um repositório com convenções e disciplina de registro. O que não pode faltar é a capacidade de responder a quatro perguntas a qualquer momento: que conjuntos de dados o projeto tem e quem responde por eles; com que dados, exatamente, cada modelo foi treinado; como cada conjunto foi produzido a partir do bruto; e se a última entrega da parceira correspondeu ao acordo. Cada pergunta tem um componente correspondente, e é por eles que este tópico avança.

O primeiro componente é o catálogo de dados do projeto: uma linha por conjunto, com campos mínimos que se preenchem em minutos e economizam semanas. Nome do conjunto; origem, apontando para a fonte do plano de aquisição; esquema resumido; volume e período coberto; sensibilidade, registrando se há dado pessoal e, quando há, a base legal, que o tópico 3 explica; versão corrente; e os dois papéis que dão endereço às decisões. O dono do conjunto é quem decide sobre ele: autoriza acesso, uso e mudança, e na residência está, com frequência, na empresa parceira, porque os dados são dela. O curador é quem cuida do conjunto no dia a dia: mantém a documentação, roda

a verificação de entrada, registra as transformações; é papel do squad, com nome, não com cargo genérico. A separação importa porque mistura papéis é o defeito clássico: o squad não pode decidir sobre dados que não são seus, e a parceira não vai curar dados dentro do projeto.

GLOSSÁRIO

Arquitetura conceitual

Representação da solução no nível do fluxo: de onde vêm os dados, que transformações sofrem, que componentes os processam, o que sai e para quem. Precede escolhas de implementação e serve de objeto comum de exame entre time técnico, empresa parceira e mentor; erros corrigidos nela custam minutos, não semanas.

Na prática, o catálogo é uma planilha ou uma página de repositório, e o que o mantém vivo não é a ferramenta, é o rito. Duas disciplinas bastam. A primeira: nenhum conjunto entra no projeto sem passar pelo catálogo; a entrada é o momento em que a sensibilidade é verificada, a base legal é registrada quando preciso e os dois papéis são nomeados, e é por isso que a verificação de entrada do tópico 1 despeja aqui. A segunda: o catálogo é lido nos gates, junto do cronograma e da matriz de risco, porque um conjunto que mudou de dono, uma base legal pendente ou uma fonte que regrediu de nível de prontidão são fatos de gestão, e o gate é o lugar deles. Um catálogo que ninguém lê nos gates envelhece em silêncio e, quando for consultado na auditoria, vai descrever um projeto que não existe mais.

O segundo componente responde à pergunta mais cara do bloco: com que dados, exatamente, este modelo foi treinado? A resposta exige versionamento de dataset: cada estado relevante do conjunto vira um snapshot imutável, com identificador próprio e uma nota curta do que mudou em relação à versão anterior. A regra de uso é uma só e não admite exceção: todo experimento, e todo modelo que avance para validação ou produção, registra a versão do dataset que o gerou. Sem isso, comparação entre experimentos é comparação entre memórias, e a reprodução de um resultado vira arqueologia. As ferramentas usuais, DVC e lakeFS, seguem a mesma ideia em alto nível: os dados vivem fora do repositório de código, referenciados por identificadores que o repositório versiona, de modo que recuperar o estado do código recupera junto o apontamento para o estado dos dados. O detalhamento operacional dessas ferramentas é objeto da Fase 2; o que este curso cobra é o mecanismo e a disciplina de registro.

Duas convenções tornam o versionamento operável sem burocracia. A primeira define o que gera versão nova: mudança de conteúdo, sempre; chegada de lote, incorporação de correção, mudança de guia de anotação que reanote itens, tudo isso corta versão, com a nota de uma linha dizendo o que mudou e por quê. Reprocessamento que não muda conteúdo não corta versão; ajuste de formato sem efeito semântico, tampouco. A segunda convenção é o congelamento: quando um modelo entra em validação para um gate, a versão de dataset que o sustenta congela, e qualquer evolução dos dados segue em versão nova, sem tocar a que está sob exame. O congelamento parece detalhe e é o que garante que a discussão do gate aconteça sobre um objeto estável: validar um modelo contra dados que continuam mudando é validar uma fotografia contra um rio.

O terceiro componente responde à pergunta de auditoria e à de engenharia ao mesmo tempo: como este conjunto foi produzido? A rastreabilidade de transformações registra a cadeia que leva do dado bruto ao conjunto de treino: cada limpeza, cada filtro, cada junção e cada recorte é um script versionado, com entrada e saída identificadas por versão de dataset. O que a regra proíbe tem nome e sobrenome em qualquer projeto real: a limpeza manual feita numa planilha, num fim de tarde, que ninguém consegue reproduzir. A linhagem registrada responde de onde veio este número, quando um auditor ou a parceira perguntam, e responde o que precisa rodar de novo, quando a fonte muda, que é a pergunta de engenharia que a operação do B5 fará toda semana. Para a cadeia fechar de verdade, dois detalhes acompanham os scripts: os parâmetros e as sementes aleatórias usados em cada passo, registrados junto da execução, e o ambiente em que os passos rodam, fixado por arquivo de dependências; sem eles, a linhagem descreve o caminho mas não permite refazê-lo. O teste prático é impessoal: outra pessoa do squad, seguindo apenas o que está registrado, reproduz o conjunto de treino a partir do bruto. Se a resposta é não, a rastreabilidade é narrativa, não é linhagem. O quadro B4.q-1 consolida os componentes e antecipa essa interface.

Quadro 1 - Componentes mínimos de governança operacional de dados em projeto de PD&I e sua interface com a operação do bloco B5.

Componente	O que registra	Pergunta que responde	Interface com o B5
Catálogo com dono e curador	Conjuntos existentes, origem, esquema, sensibilidade, base legal e responsáveis.	Que dados o projeto tem e quem responde por eles?	O runbook de operação aponta para o catálogo ao tratar incidentes que envolvem dados.
Versionamento de dataset	Snapshots imutáveis identificados e a nota do que mudou entre versões.	Com que dados, exatamente, este modelo foi treinado?	Cada experimento e cada modelo em produção referenciam a versão que os gerou.

Componente	O que registra	Pergunta que responde	Interface com o B5
Rastreabilidade de transformações	A cadeia de scripts versionados que leva do dado bruto ao conjunto de treino.	Como este conjunto foi produzido, e o que rodar de novo se a fonte mudar?	O pipeline de dados entra no mesmo regime de versionamento e monitoramento do modelo.
Verificação de entrada	O resultado da checagem de cada lote contra a qualidade declarada no acordo de dados.	A entrega da parceira correspondeu ao que foi acordado?	O monitoramento de drift estende a verificação de entrada para a operação contínua.

Para cego ver: Quadro 1 intitulado " Componentes mínimos de governança operacional de dados em projeto de PD&I e sua interface com a operação do bloco B5. O quadro contém quatro colunas e quatro linhas de conteúdo. A primeira linha apresenta Catálogo com dono e curador: registra conjuntos existentes, origem, esquema, sensibilidade, base legal e responsáveis; responde às perguntas "Que dados o projeto tem e quem responde por eles?"; na interface com o B5, o runbook de operação aponta para o catálogo ao tratar incidentes que envolvem dados. A segunda linha apresenta Versionamento de dataset: registra snapshots imutáveis identificados e a nota do que mudou entre versões; responde à pergunta "Com que dados, exatamente, este modelo foi treinado?"; no B5, cada experimento e cada modelo em produção referenciam a versão que os gerou. A terceira linha apresenta Rastreabilidade de transformações: registra a cadeia de scripts versionados que leva do dado bruto ao conjunto de treino; responde às perguntas "Como este conjunto foi produzido, e o que rodar de novo se a fonte mudar?"; no B5, o pipeline de dados entra no mesmo regime de versionamento e monitoramento do modelo. A quarta linha apresenta Verificação de entrada: registra o resultado da checagem de cada lote contra a qualidade declarada no acordo de dados; responde à pergunta "A entrega da parceira correspondeu ao que foi acordado?"; no B5, o monitoramento de drift estende a verificação da entrada para a operação contínua.

Governança inclui uma camada que costuma ficar implícita até dar errado: quem acessa o quê, e onde os dados podem estar. A regra operacional mínima tem três pontos. Primeiro, o controle de acesso reflete o catálogo: cada conjunto tem uma lista restrita de usuários autorizados, definida pelo dono. Conjuntos com dado pessoal ou sob NDA têm acesso estritamente limitado por padrão. Segundo, os dados moram no ambiente do projeto, não nas máquinas das pessoas: a cópia local avulsa, feita para agilizar, é o jeito mais comum de um dado sob NDA aparecer onde não devia, e de uma versão fantasma divergir do catálogo sem ninguém saber. Terceiro, a saída de dados do ambiente é evento registrado: o que saiu, para onde, autorizado por quem. Nada disso exige plataforma; exige convenção escrita e o hábito de tratá-la como se fosse cláusula, porque, para a parceira, é exatamente isso que ela é.

O quarto assunto do tópico é o tratamento de dados sensíveis, e ele começa por uma identificação que costuma surpreender: dado pessoal aparece onde não se espera. Logs de operação carregam matrícula de operador; vídeos de linha de produção carregam rostos; escalas de turno ligam registros a pessoas; até coordenadas e horários, combinados, apontam para alguém. A verificação se faz conjunto a conjunto, na entrada do catálogo, e quando o resultado é positivo o projeto tem duas famílias de resposta técnica, que a lei trata de modos muito diferentes. Anonimizar é remover a possibilidade razoável de reidentificação, considerando os meios disponíveis; feito de verdade, retira o dado do regime de dado pessoal. Pseudonimizar é substituir os identificadores diretos por códigos, guardando a tabela de correspondência em separado; reduz o risco, e por isso é a resposta realista na maioria dos projetos, mas o dado pseudonimizado continua sendo dado pessoal perante a LGPD e o GDPR. Operacionalmente, a diferença vira duas linhas no catálogo: a tabela de correspondência é um conjunto próprio, com dono definido e acesso restrito, e o conjunto pseudonimizado mantém a base legal registrada.

GLOSSÁRIO

Pseudonimização

Substituição dos identificadores diretos de um conjunto por códigos, com a tabela de correspondência guardada em separado e sob acesso restrito. Reduz o risco e viabiliza o trabalho técnico, mas o dado pseudonimizado continua sendo dado pessoal perante a LGPD e o GDPR; só a anonimização efetiva, sem possibilidade razoável de reidentificação, retira o dado desse regime.

Há ainda o caso em que o dado sensível, ou raro, simplesmente não pode ser usado como está, e a alternativa considerada é o dado sintético. O M3 do curso base já montou o critério técnico, incluindo o risco de auto-reforço quando o gerador e o modelo aprendem os mesmos vícios; este bloco acrescenta a camada operacional. Primeiro, a regra que não admite exceção: a validação final se faz contra um conjunto de teste de dados reais, sempre; sintético treina, sintético aumenta, sintético não atesta. Segundo, o registro: o conjunto sintético entra no catálogo como conjunto derivado, com o método de geração documentado, a versão do conjunto real que o originou e o dono definido, porque, como o tópico 3 vai mostrar, a propriedade de um sintético gerado a partir dos dados da parceira é exatamente o tipo de pergunta que precisa de resposta escrita antes de ser feita por um advogado.

Exemplo aplicado

Numa siderúrgica, o squad treinou um modelo de previsão de defeito de laminação sobre dados de sensores agregados por um script que um bolsista rodava na própria máquina, com limpezas manuais não registradas. O modelo passou na validação, a empresa pediu a reexecução sobre os dados do trimestre seguinte, e ninguém conseguiu reconstituir o conjunto de treino: o resultado defensável virou resultado inexplicável diante do cliente. A implementação posterior do catálogo e do versionamento exigiu dias de organização; no entanto, a reconstrução da linhagem perdida demandou seis semanas de trabalho. A governança operacional apresenta baixo custo de implementação inicial, mas alto custo de reconstituição a posteriori.

Feche o tópico olhando para frente, porque a governança montada aqui não é um fim. No bloco B5, o pipeline de dados entra no mesmo regime de versionamento e monitoramento do pipeline de modelo: a verificação de entrada vira monitoramento contínuo, o drift dos dados em operação é lido contra as versões registradas, e o runbook aponta para o catálogo quando um incidente envolve dados. E metade do mapa de governança

e regulatório, o artefato do caderno que este bloco produz, acabou de ficar pronta: os componentes de governança, com seu estado e seus responsáveis. A outra metade é a que dá nome ao artefato inteiro: o regime regulatório aplicável e a propriedade intelectual dos dados. É o tópico 3.

3. Regulatório e propriedade intelectual de dados

Este tópico fecha o bloco e tem por objetivo que você identifique o regime regulatório aplicável ao projeto, articule as obrigações operacionais que decorrem dele e mapeie a propriedade intelectual dos dados em quatro categorias, distinguindo o que pertence a quem e o que pode virar publicação acadêmica (competência CP.B4.C2). A premissa de condução vem antes do conteúdo jurídico: regulatório não é uma checagem final que o jurídico faz na véspera da entrega. É restrição de projeto, identificada cedo, porque cada obrigação regulatória vira tarefa com prazo, responsável e efeito sobre a arquitetura, e obrigação descoberta tarde é retrabalho com o pipeline já montado. O papel do squad não é substituir o advogado; é saber que regime incide, que obrigações operacionais ele gera e que perguntas precisam chegar a quem redige contratos, antes da assinatura.

O primeiro regime é o da casa: a LGPD, a Lei Geral de Proteção de Dados, que regula todo tratamento de dado pessoal no Brasil. O vocabulário operacional cabe em três noções. Dado pessoal é informação relacionada a pessoa identificada ou identificável, e o tópico 2 mostrou como ele se esconde em dados de operação. Tratamento é praticamente qualquer verbo aplicado a esse dado: coletar, armazenar, transformar, treinar um modelo. E todo tratamento exige uma base legal entre as que a lei prevê. Em PD&I industrial, o consentimento raramente é a via realista, porque colher e manter consentimento de cada operador é frágil e revogável; as bases mais comuns são a execução de contrato e o legítimo interesse, esta exigindo um teste de balanceamento documentado entre o interesse do projeto e os direitos do titular. A lei também distribui papéis: a empresa parceira, que determina as finalidades e os elementos essenciais do tratamento, atua como controladora. A instituição de pesquisa ou execução que trata os dados estritamente em nome da parceira atua como operadora (salvo nos casos de controladoria conjunta, em que ambas definem conjuntamente os objetivos do tratamento), relação que exige previsão contratual específica. As obrigações operacionais que descem disso são concretas: base legal registrada por conjunto no catálogo, minimização, que é coletar o necessário e não o disponível, prazo de retenção definido, e resposta possível a direitos do titular, como acesso e eliminação.

GLOSSÁRIO

Base legal

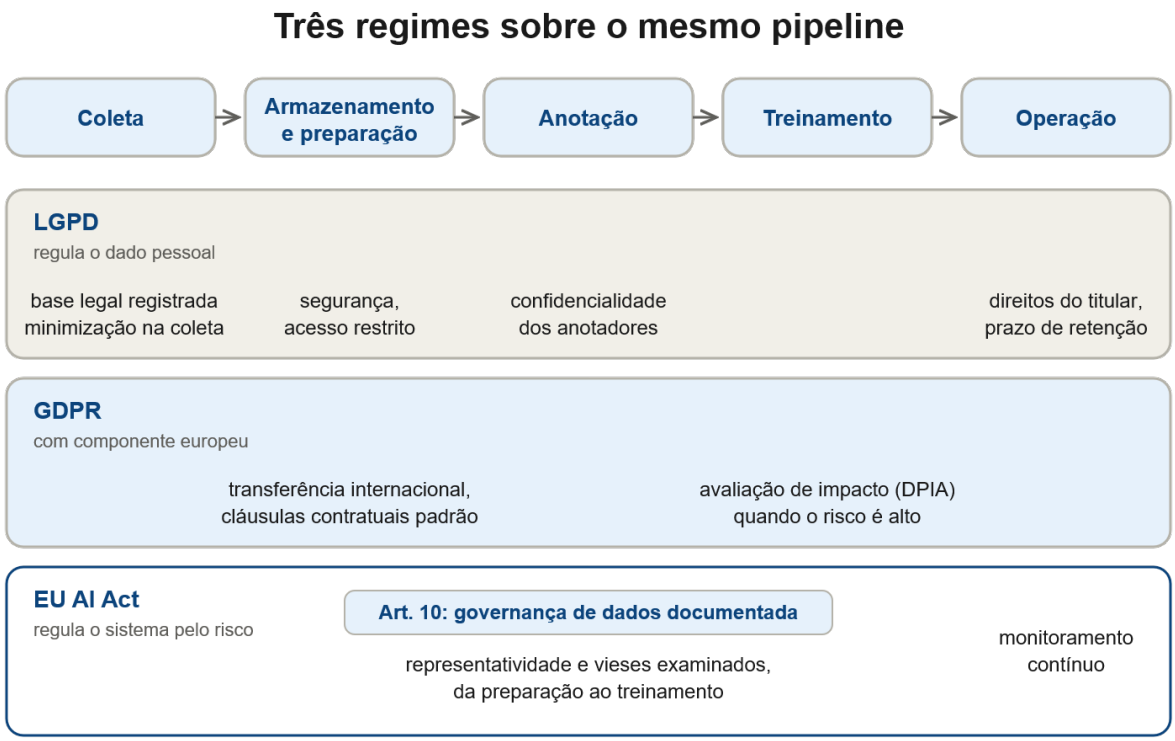
Fundamento jurídico, entre os previstos na LGPD e no GDPR, que autoriza um tratamento de dado pessoal. Em PD&I industrial, as vias mais comuns são a execução de contrato e o legítimo interesse, este exigindo teste de balanceamento documentado. Todo conjunto com dado pessoal entra no catálogo com a base legal registrada; tratamento sem base identificada é tratamento irregular, ainda que tecnicamente inofensivo.

Repare no movimento que transforma a lei em condução: cada obrigação vira uma tarefa com endereço. Registrar a base legal é uma linha do catálogo, preenchida na entrada de cada conjunto, sob responsabilidade do curador. Minimizar é uma decisão de coleta, tomada na negociação do acordo de dados: pedir as colunas necessárias, e não o dump inteiro, porque cada campo pessoal a mais é risco e obrigação sem retorno. O prazo de retenção entra no acordo e reaparece no encerramento do projeto, quando a cláusula de devolução ou descarte cobra a sua execução. E a capacidade de responder a um titular, que parece abstrata, se traduz em uma pergunta de engenharia: se um operador pedir a eliminação dos seus dados, o projeto consegue localizá-los nas versões e responder o que é possível e o que a base legal permite reter? Cada uma dessas tarefas tem um gate em que sua verificação acontece; obrigação sem gate é obrigação que se cumpre por sorte.

O segundo regime entra em cena quando o projeto tem componente europeu, e as portas de entrada são mais largas do que parecem: dados de titulares que estão na União Europeia, uma planta ou controladora europeia da parceira, um cliente europeu do sistema. O GDPR tem a mesma espinha da LGPD, que nele se inspirou: bases legais, direitos do titular, papéis de controlador e operador. As diferenças que importam para a condução são três. A transferência internacional de dados é regulada com rigidez: a exportação de dados da União Europeia para o Brasil exige respaldo em mecanismos válidos previstos no GDPR (Capítulo V), tais como Cláusulas Contratuais Padrão (SCCs), Normas Corporativas Globais (BCRs) ou decisões de adequação emitidas pela Comissão Europeia. A avaliação de impacto, a DPIA, é obrigatória quando o tratamento é de alto risco para os titulares, e treinar modelos com dados de trabalhadores pode se qualificar. E a régua de sanções é de outra ordem de grandeza, o que muda o apetite de risco de qualquer parceira com operação europeia. A regra prática de condução: havendo componente europeu, o projeto trata o GDPR como regime principal e verifica a LGPD em paralelo; os dois convivem, não se substituem.

O terceiro regime tem lógica diferente dos dois primeiros, e confundi-las é erro comum. O EU AI Act não regula o dado pela natureza; regula o sistema de IA pelo risco da aplicação. A lei europeia classifica sistemas em faixas, de práticas proibidas a risco mínimo, e concentra obrigações na faixa de alto risco, onde vivem aplicações como segurança de máquinas, infraestrutura crítica e decisões sobre trabalhadores. Para esses sistemas, o artigo 10 fala diretamente com este bloco: exige governança de dados de treinamento documentada, com práticas de gestão declaradas, exame de representatividade, de relevância e de vieses dos conjuntos, e qualidade adequada à finalidade. A vigência é escalonada e as obrigações de alto risco entram em aplicação ao longo de 2026, o que significa que um sistema da residência que mire mercado europeu em domínio de alto risco já nasce sob essa exigência. A consequência operacional é direta e confortável para quem fez o dever da parte 2: catálogo, versionamento, linhagem e verificação de entrada deixam de ser boa prática e viram evidência de conformidade. No Brasil, o PL 2338, em tramitação, segue a mesma lógica de classificação por risco; o squad acompanha, sem tratar como lei vigente. A figura 3 projeta os três regimes sobre o pipeline de dados do projeto.

Figura 3 - Os três regimes regulatórios projetados sobre o pipeline de dados: onde LGPD, GDPR e EU AI Act incidem operacionalmente.



Fonte: autor. Arquivo: B4_fig-3_mapa_regulatorio_pipeline.svg

Para cego ver: Diagrama horizontal intitulado "Figura 3 - Os três regimes regulatórios projetados sobre o pipeline de dados: onde LGPD, GDPR e EU AI Act incidem operacionalmente". Na parte superior, cinco etapas conectadas por setas formam o pipeline de dados: Coleta, Armazenamento e preparação, Anotação, Treinamento e Operação. Abaixo, três faixas representam os regimes regulatórios. A LGPD, que regula o dado pessoal, contempla base legal registrada e minimização na coleta; segurança e acesso restrito; confidencialidade dos anotadores; direitos do titular e prazo de retenção. O GDPR, indicado como regime com componente europeu, contempla transferência internacional e cláusulas contratuais padrão, além de avaliação de impacto, DPIA, quando o risco é alto. O EU AI Act, que regula o sistema pelo risco, destaca o Artigo 10, sobre governança de dados documentada, a representatividade e os vieses examinados da preparação ao treinamento e o monitoramento contínuo na operação.

A identificação do regime, na prática, é uma triagem de três perguntas, feita no início do projeto e revista nos gates. Primeira: há dado pessoal em algum conjunto? Se sim, a LGPD incide, e a resposta se dá conjunto a conjunto, na entrada do catálogo, nunca por suposição de domínio. Segunda: há componente europeu, nos titulares, na operação da parceira ou no mercado do sistema? Se sim, o GDPR entra como regime principal, e a transferência internacional vira item de contrato. Terceira: o sistema mira aplicação que o EU AI Act classifica como de alto risco, em mercado europeu? Se sim, o artigo 10 transforma a governança do tópico 2 em obrigação documentada. As três respostas, com a evidência de cada uma, são as primeiras linhas do mapa de governança e regulatório; e a revisão nos gates existe porque as respostas mudam, quando um conjunto novo entra, quando o mercado-alvo se amplia, quando a arquitetura passa a tocar decisão sobre pessoas.

Armadilha comum

A frase nossos dados são industriais, não temos dado pessoal. Dados de operação carregam pessoas: matrícula no log da máquina, rosto no vídeo da linha, escala que liga o turno ao operador. O squad que parte da suposição monta o pipeline inteiro sobre tratamento sem base legal e descobre o problema quando o mapa regulatório é cobrado, com o retrabalho de pseudonimização caindo sobre dados já transformados e versionados. A verificação de dado pessoal se faz conjunto a conjunto, na entrada do catálogo, e não por suposição sobre o domínio do projeto.

Entre o regime legal e a prática do projeto ficam as cláusulas contratuais sobre dados, e o squad precisa reconhecer as típicas para levar as perguntas certas a quem redige. A cláusula de finalidade define para que os dados podem ser usados, e a vedação de uso secundário, que o B3 registrou no vocabulário de fornecedores, impede que dados cedidos para um fim alimentem outro, inclusive o treinamento de modelos fora do escopo. A confidencialidade se estende a quem mais toca os dados, o que inclui o fornecedor de anotação: o NDA da parceira precisa alcançar os anotadores terceirizados, e essa composição de contratos é exatamente a que o mapa de fornecedores do B3 expõe. A devolução ou o descarte ao final do projeto vem com prazo e com forma, e conflita silenciosamente com a reprodutibilidade que o B5 vai exigir; o conflito se resolve por escrito, definindo o que pode ser retido, por quanto tempo e sob que guarda. E a cláusula de publicação, que trataremos ao final, define o caminho para o trabalho virar paper sem virar litígio.

A postura correta diante dessas cláusulas repete a que o B3 fixou para fornecedores: a coluna de questões não é desconfiança, é pauta. O squad não redige cláusula; leva ao jurídico das instituições uma lista de perguntas concretas, com o contexto técnico que só ele tem: estes conjuntos têm dado pessoal, e a base pensada é o legítimo interesse;

a anotação será terceirizada, e o material exposto está sob NDA; pretendemos gerar dados sintéticos a partir dos dados da parceira; queremos publicar ao final. Levar essa pauta antes da assinatura custa uma reunião; descobrir a lacuna depois custa renegociação com a posição enfraquecida. E o registro da pauta, com o que foi perguntado e o que foi acordado, entra no mapa de governança e regulatório, porque resposta de jurídico que mora em e-mail perdido não protege ninguém.

Com os contratos na mesa, a pergunta de propriedade intelectual pode ser feita com precisão, e a precisão começa por separar categorias, porque a resposta muda de uma para outra. O curso fixa quatro. Dados brutos são o que a parceira entrega como coletado dos seus processos: a titularidade é dela, quase sempre, e o que o projeto tem é uma licença de uso para a finalidade acordada. Dados anotados são trabalho do squad, ou de terceiros contratados, aplicado sobre matéria da parceira: sem cláusula, a propriedade dos rótulos é ambígua por construção, e a ambiguidade só é barata enquanto ninguém quer reutilizá-los. Dados sintéticos são gerados a partir dos dados dela: a pergunta é se a derivação conta como dado novo ou como transformação do original, e a resposta sensata não vem de princípio, vem de cláusula que diga se a geração é permitida, de quem é o sintético e que usos ele admite. E dados derivados, a categoria de maior risco de contencioso, englobam features, embeddings, vetores latentes e estatísticas extraídas dos dados originais. Embora constituam produto do trabalho de modelagem, podem permitir a reconstrução parcial da fonte ou derivar diretamente de informações confidenciais. A fronteira entre representação derivada e propriedade intelectual/segredo industrial autônomo do projeto precisa estar explicitada contratualmente antes do compartilhamento externo. O quadro B4.q-2 consolida as quatro categorias.

Quadro 2 - Propriedade intelectual de dados em quatro categorias e o que o acordo com a empresa parceira precisa dizer sobre cada uma.

Categoria	O que é	Pergunta de propriedade	O que precisa estar escrito
Dados brutos	O que a parceira entrega como coletado dos seus processos.	De quem é a matéria-prima e o que o projeto pode fazer com ela?	Finalidade de uso, vedação de uso secundário, devolução ou descarte ao final, com prazo.
Dados anotados	Rótulos produzidos pelo squad ou por terceiros sobre os dados brutos.	De quem é o trabalho de anotação aplicado sobre matéria alheia?	Titularidade dos rótulos, licença de uso pelo projeto e pela parceira, PI no contrato de anotação.

Categoria	O que é	Pergunta de propriedade	O que precisa estar escrito
Dados sintéticos	Conjuntos gerados a partir dos dados da parceira, por modelo ou simulação.	A derivação conta como dado novo ou como transformação do original?	Se a geração é permitida, de quem é o conjunto sintético e que usos ele admite.
Dados derivados	Features, embeddings, agregados e estatísticas extraídos dos dados.	O que carrega informação da fonte e o que é resultado do projeto?	A fronteira entre derivado e resultado, e o que pode circular fora do projeto.

Para cego ver: Quadro 2 Intitulado "Propriedade intelectual de dados em quatro categorias e o que o acordo com a empresa parceira precisa dizer sobre cada uma. Está organizado em quatro colunas: Categoria, O que é, Pergunta de propriedade e O que precisa estar escrito. Em Dados brutos, estão os dados que a parceira entrega como coletados em seus processos; deve-se definir de quem é a matéria-prima, o que o projeto pode fazer com ela, finalidade e vedação de uso secundário, além de devolução ou descarte ao final, com prazo. Em Dados anotados, estão os rótulos produzidos pelo squad ou por terceiros sobre os dados brutos; deve-se estabelecer a propriedade do trabalho de anotação, a titularidade dos rótulos, a licença de uso pelo projeto e pela parceira e a propriedade intelectual no contrato de anotação. Em Dados sintéticos, estão conjuntos gerados a partir dos dados da parceira, por modelo ou simulação; deve-se definir se a derivação constitui dado novo ou transformação do original, se sua geração é permitida, quem é o titular do conjunto sintético e quais usos são admitidos. Em Dados derivados, estão features, embeddings, agregados e estatísticas extraídos dos dados; deve-se distinguir o que carrega informação da fonte do que constitui resultado do projeto e estabelecer a fronteira entre derivado e resultado, inclusive o que pode circular fora do projeto.

Resta o tema que toca diretamente a sua trajetória: a publicação acadêmica derivada do trabalho de residência. A tensão aqui é legítima dos dois lados, e nomeá-la ajuda a resolvê-la: o pesquisador precisa publicar, porque publicação é a moeda da carreira que ele traz do mundo acadêmico; a parceira precisa proteger, porque os dados descrevem o processo que a diferencia dos concorrentes. A resolução operacional tem três peças. A primeira é temporal: a condição de publicação se negocia cedo, junto do acordo de dados, e não na véspera da submissão, quando a posição de negociar já se perdeu. A segunda é a cláusula de janela de revisão: a parceira recebe o manuscrito com antecedência definida, tipicamente de trinta a sessenta dias, e aponta o que precisa sair ou ser agregado; a janela protege os dois lados, porque dá previsibilidade ao pesquisador e controle à empresa. A terceira é a distinção de conteúdo, que o quadro de PI sustenta: publica-se método, arquitetura e resultados agregados; não se publicam os dados, nem amostras que permitam reconstituí-los, e métricas que exponham o processo produtivo passam por agregação combinada. Um paper que respeita essas três peças sai; um paper negociado depois de escrito, frequentemente, não. O mesmo mapeamento serve à pergunta vizinha, a da patente: quando o trabalho de residência gera invenção patenteável, a titularidade segue o contrato entre as instituições, e a janela de revisão ganha uma função extra, a de impedir que a publicação destrua a novidade antes do depósito; a decisão entre publicar e depositar é tomada com o mapa de PI na mesa, não depois do resumo submetido.

Exemplo aplicado

Num frigorífico, o squad desenvolveu um modelo de previsão de não conformidade sanitária sobre registros de inspeção que traziam matrícula e turno dos operadores. O mapeamento na entrada classificou os registros como dado pessoal, definiu pseudonimização antes do treinamento e registrou a base legal no catálogo. Quando o squad propôs publicar, a cláusula de janela de revisão já existia desde o acordo de dados: a parceira revisou em trinta dias, e o artigo saiu com método e métricas agregadas, sem amostras. O que parecia burocracia na primeira semana foi o que tornou a publicação possível sem litígio.

Para aprofundar

GEBRU, T. et al. Datasheets for Datasets. CACM, 2021, preprint em arXiv.org/abs/1803.09010, fixa o padrão de documentação de dataset que o datasheet do bloco B6 adota. O texto do EU AI Act, Regulamento (UE) 2024/1689, artigo 10, está em eur-lex.europa.eu. O detalhamento de pipelines, catálogo e governança em escala é objeto do curso de Engenharia de Dados da Fase 2 do programa.

O artefato do caderno que fecha o bloco reúne os tópicos 2 e 3: o mapa de governança e regulatório, com os regimes pré-mapeados. Os eixos seguem o percurso que você fez: o regime aplicável, com a evidência que o sustenta, porque dizer que a LGPD incide exige apontar o dado pessoal que a atrai, e dizer que o EU AI Act incide exige apontar o mercado e a classe de risco; a base legal por conjunto com dado pessoal, espelhando o catálogo; as obrigações operacionais decorrentes, cada uma com responsável e com o gate em que sua verificação acontece; o estado dos componentes de governança do tópico 2; a PI dos dados nas quatro categorias, cada uma apontando para a cláusula que a resolve; e as condições de publicação. O mapa preenchido no caderno traz o regime identificado com justificativa, as obrigações articuladas e o mapeamento de PI completo. A coerência cruzada fecha o circuito do bloco: o mapa lê o plano de aquisição do tópico 1 e o mapa de fornecedores do B3, e alimenta, adiante, o datasheet do dataset e o model card que o B6 produz como artefatos de transparência. No laboratório presencial do Encontro 3, é com esse repertório que o squad registra dados, restrições e regime para o caso simulado, junto da consolidação da decisão técnica.

4. Conclusão

Os três tópicos deste ebook operacionalizaram o eixo que mais atrasa projetos de IA industrial. O tópico 1 transformou a pergunta os dados existem? numa escala de cinco

níveis de prontidão por fonte, articulou aquisição e anotação ao cronograma e ao custo com base em piloto, e formalizou a relação com a empresa parceira no acordo de dados, com a verificação de entrada separando qualidade declarada de qualidade efetiva e levando divergências ao gate. O tópico 2 montou a governança na escala certa de um squad: catálogo com dono e curador, versionamento de dataset, rastreabilidade de transformações e o tratamento operacional de dados pessoais (incluindo sensíveis), com a distinção técnica entre anonimização (que retira o dado do escopo da LGPD, se irreversível) e pseudonimização (que mantém a incidência da lei), devidamente registrada no catálogo e vinculada à base legal. O tópico 3 projetou os três regimes sobre o pipeline, LGPD pelo dado pessoal, GDPR pelo componente europeu, EU AI Act pelo risco do sistema, traduziu cada um em obrigações com responsável e gate, e mapeou a propriedade intelectual dos dados em quatro categorias, com a publicação acadêmica resolvida por cláusula e janela, não por esperança.

O ganho do bloco é a mesma cadeia de coerência dos anteriores, agora passando pelos dados: o plano de aquisição realiza o que o canvas do B3 declarou consumir; o mapa de governança e regulatório sustenta o que o plano promete adquirir; e os dois alimentam o que vem adiante, a validação e a operação do B5, a transparência do B6. Quando alguém perguntar por que o cronograma reserva seis semanas para dados, ou por que o pipeline pseudonimiza antes de treinar, a resposta não será uma opinião: será um percurso por registros, do nível de prontidão à cláusula, que qualquer audiência crítica pode examinar. É a diferença, mais uma vez, entre a postura que herda dados prontos e a postura que os constrói, governa e defende como parte da entrega.

Antes de avançar, percorra no caderno os dois artefatos deste bloco (plano de aquisição de dados e mapa de governança e regulatório), que trazem o preenchimento comentado para os cenários de exemplo e a instrução de uso eixo a eixo. Feche o bloco com o quiz formativo. O bloco B5 começa onde este para: o pipeline de dados que você organizou entra, lá, no mesmo regime de versionamento e monitoramento do pipeline de modelo, e a pergunta deixa de ser como adquirir e governar os dados para ser como manter vivo, defensável e monitorado o sistema que eles alimentam.

REFERÊNCIAS

Bibliografia mínima

SAMBASIVAN, N. et al. Everyone Wants to Do the Model Work, Not the Data Work: Data Cascades in High-Stakes AI. CHI, 2021. Disponível em research.google.com/pubs/archive/49953.pdf. Estudo empírico sobre o subinvestimento sistemático em trabalho de dados, base do tópico 1 deste bloco.

GEBRU, T. et al. Datasheets for Datasets. CACM, 2021. Preprint em arXiv.org/abs/1803.09010. Referência de documentação de dataset, base do datasheet que o bloco B6 produz a partir do mapa deste bloco.

BRASIL. Lei n. 13.709, de 14 de agosto de 2018 (Lei Geral de Proteção de Dados Pessoais). Capítulos sobre bases legais de tratamento e direitos do titular. Texto integral em portais públicos da Presidência da República.

UNIÃO EUROPEIA. Regulamento (UE) 2024/1689 (EU AI Act). Artigo 10, Data and data governance. Texto integral em eur-lex.europa.eu. Referência direta da governança de dados de treinamento para sistemas de alto risco, tratada no tópico 3.

Industr.IA

Residência em TIC 49



Executor iRede

Executor Atlântico

Coordenador Softex

Financiador MCTI Futuro

Ministério da Ciência, Tecnologia e Inovação

Governo do Brasil — Do lado do povo brasileiro

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.