Industr.IA

Glossário

Dados em PD&I industrial

Condução de Projetos | Unidade 4

Prof.: Raimundo Valter

Industr.IA

CDP-028, Glossário

Bloco B4 | Dados em PD&I industrial

Convenções: cada entrada traz tag de origem no formato [B4: parte], indicando a parte do ebook CDP-024 em que o termo é introduzido. Termos introduzidos ou consolidados por artefato do caderno trazem a marca do artefato na tag (por exemplo [B4: parte 1, CDP-025]). Quando o ebook traz um box-glossário formal para o termo, a descrição reproduz o texto do box; para os demais termos, a definição é fiel à prosa. Termos já registrados nos glossários dos blocos B1 a B3 não se repetem neste; referências cruzadas aparecem como "veja X" e, quando o termo referido está em glossário de bloco anterior, o bloco é indicado. A ordem é alfabética, ignorando acentos e diferença entre maiúsculas e minúsculas.

Glossário de Termos

Termo	Descrição	Origem
Acordo de dados	Registro operacional negociado com a empresa parceira que formaliza a entrega de dados com base na especificação do esquema (schema), identificação do custodiante/responsável, cadência de ingestão (entrega) e SLA de qualidade declarada. Não substitui o contrato entre as instituições; é o instrumento contra o qual cada lote entregue é verificado e a referência objetiva para tratar divergências nos gates.	[B4: parte 1]
Anotação por lotes	Organização da rotulagem em lotes fechados, com uma fração dos itens (tipicamente cinco a quinze por cento) submetida à anotação redundante e o índice de concordância interanotadores medido por lote. Concordância baixa quase nunca significa anotador ruim: significa guia ambíguo ou tarefa mal definida. O rito é fechar o lote, ler a concordância, revisar o guia e só então liberar o seguinte.	[B4: parte 1]
Base legal	Fundamento jurídico, entre os previstos na LGPD e no GDPR, que autoriza um tratamento de dado pessoal. Em PD&I industrial, as hipóteses legais mais comuns são a execução de contrato e o legítimo interesse, este exigindo a elaboração e documentação do Relatório de Impacto à Proteção de Dados Pessoais (RIPD) e teste de balanceamento documentado (LIA). Todo conjunto com dado pessoal entra no catálogo com a base legal registrada; tratamento sem base identificada é tratamento irregular, ainda que tecnicamente inofensivo.	[B4: parte 3]

Termo	Descrição	Origem
Catálogo de dados	Registro central dos conjuntos do projeto, com dono e curador nomeados, sensibilidade e base legal verificadas na entrada de cada conjunto. Sua premissa é econômica antes de ser técnica: sem registro, o conhecimento sobre os dados vira conhecimento tribal, que mora na cabeça de uma pessoa e sai do projeto junto com ela.	[B4: parte 2]
Dado sintético	Conjunto gerado para substituir ou aumentar dados reais escassos ou sensíveis. A regra operacional do bloco não admite exceção: sintético treina, sintético aumenta (data augmentation), sintético não atesta; a validação final se faz contra um conjunto de teste de dados reais. Entra no catálogo como conjunto derivado, com método de geração, versão do conjunto real de origem e dono definidos.	[B4: parte 2]
Dono e curador	Papéis mínimos de governança por conjunto de dados no catálogo do projeto. O Data Owner detém a alçada decisória sobre o dataset, definindo políticas de acesso, escopo de uso e ciclo de vida. O Data Steward (curador) responde pela operacionalização da governança: manutenção dos metadados, verificação de conformidade na ingestão e alinhamento da linhagem de dados (data lineage). Todo conjunto tem os dois nomeados; conjunto sem dono é decisão sem endereço, e sem curador é documentação que envelhece.	[B4: parte 2]
Janela de revisão	Cláusula de publicação pela qual a empresa parceira recebe o manuscrito com antecedência definida, tipicamente de trinta a sessenta dias, e aponta o que precisa sair ou ser agregado. Protege os dois lados: dá previsibilidade ao pesquisador e controle à empresa, inclusive para resguardar a novidade em caso de patente.	[B4: parte 3, CDP-026]
Perfilamento de dados	Análise estatística da estrutura e conteúdo de uma amostra da fonte: identificação de valores nulos, cardinalidade, verificação de tipos e faixas de valores, inferência de esquema, taxa de duplicidade e completude dos atributos consumidos pelo modelo. O perfilamento não julga o dado, apenas o descreve; é essa descrição, datada, que se compara com a qualidade declarada e sustenta a prontidão registrada no plano de aquisição.	[B4: parte 1, CDP-025]
Prontidão de fonte	Classificação operacional de uma fonte de dados em cinco níveis, da existência presumida ao acesso documentado com base legal. Cada nível autoriza um compromisso de cronograma diferente: os níveis baixos	[B4: parte 1, CDP-025]

Termo	Descrição	Origem
	sustentam apenas cronograma de investigação; só os altos sustentam compromisso firme de prazo. Planejar sobre nível baixo como se fosse alto é a origem mais comum de atraso no eixo de dados.	
Pseudonimização	Processo de tratamento pelo qual um dado perde a possibilidade de associação a um indivíduo senão pelo uso de informação adicional, mantida separadamente pelo controlador sob medidas de segurança técnicas e administrativas. Reduz o risco e viabiliza o trabalho técnico, mas o dado pseudonimizado continua sendo dado pessoal perante a LGPD e o GDPR; só a anonimização efetiva, sem possibilidade razoável de reidentificação, retira o dado desse regime.	[B4: parte 2]
Rastreabilidade de transformações	Mapeamento da linhagem de dados (data lineage) e versionamento de pipelines, garantindo a reprodutibilidade determinística do dado bruto até o dataset de treinamento. O projeto que não sabe dizer com que dados treinou o modelo que está no ar não tem um problema técnico, tem um problema de defesa.	[B4: parte 2]
Teste de balanceamento	Avaliação formal de proporcionalidade e razoabilidade (LIA - Legitimate Interest Assessment) que pondera o interesse legítimo do controlador frente aos direitos e liberdades fundamentais do titular de dados. É o custo assumido dessa via: entra no catálogo junto da base legal do conjunto e sustenta a escolha perante auditoria.	[B4: parte 3, CDP-026]
Triagem regulatória	Identificação do regime aplicável por três perguntas, feita no início do projeto e revista nos gates: há dado pessoal em algum conjunto; há componente europeu nos titulares, na operação da parceira ou no mercado do sistema; o sistema se enquadra nas classificações de alto risco ou de risco inaceitável conforme a taxonomia do Regulamento de Inteligência Artificial da União Europeia (EU AI Act). Cada resposta se registra com a evidência que a sustenta, inclusive quando o regime não incide.	[B4: parte 3, CDP-026]
Verificação de entrada	Rito aplicado a cada lote entregue: checagens objetivas de completude, consistência, validade e atualidade contra o que foi declarado no acordo de dados, com registro do resultado. Lote conforme entra no catálogo; lote divergente gera registro com evidência, levado ao gate como risco materializado, e não absorvido em silêncio.	[B4: parte 1]

Industr.IA

Programa Brasileiro de Formação
Acadêmico-Industrial em IA

Executor Executor Coordenador Financiador

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.