Industr.IA

E-book

Decisão de solução e arquitetura



Condução de Projetos | Unidade 3

Prof.: Raimundo Valter

SUMÁRIO

1. Da hipótese à decisão build/buy/integrate 3
2. Arquitetura conceitual pelas cinco lentes 10
3. Fornecedores e propriedade intelectual 15
4. Conclusão 21

1. Da hipótese à decisão build/buy/integrate

Este tópico abre a segunda decisão estruturante de um projeto de PD&I em IA, depois da delimitação de escopo que o bloco B2 registrou, e tem por objetivo que você levante hipóteses técnicas, compare alternativas e justifique a escolha entre desenvolver, comprar e integrar uma solução, articulando trade-offs explícitos em seis eixos (competência CP.B3.C1). No CRISP-DM adaptado do curso, estamos na passagem da compreensão do problema para a concepção da solução. E a primeira coisa a estabelecer é uma regra de sequência: a decisão de solução não é o começo desta fase, é o fim dela. Antes da decisão vêm as hipóteses; antes da escolha vem a comparação.

A regra existe porque o erro mais comum desta fase não é escolher a técnica errada, é escolher cedo demais. O squad que sai da leitura do problema direto para a frase vamos usar um modelo de linguagem pulou duas etapas de trabalho, e o custo desse salto aparece depois, quando alguém pergunta por que não uma alternativa mais simples e a resposta honesta é que ela não chegou a ser considerada. A postura de PD&I que o bloco B1 estabeleceu cobra o contrário: a escolha precisa ser defensável, e defensável quer dizer vinculada a critérios que outra pessoa pode examinar. O caminho deste tópico é, portanto, uma cadeia com três elos antes do fechamento: hipóteses formuladas, experimentos que as testam, alternativas comparadas; só então a decisão.

Comece pelo primeiro elo. Uma hipótese técnica não é uma pergunta aberta nem uma aposta de preferência; é um enunciado com anatomia fixa, que o instrumento do kit de formação fixa em quatro componentes: a abordagem proposta, a condição sob a qual ela deve funcionar, o resultado esperado e o critério de teste que permite verificá-lo. Compare dois enunciados sobre o mesmo problema de inspeção de solda. O primeiro: acho que deep learning resolve. O segundo: um classificador de imagens treinado com as fotos já coletadas pela linha (abordagem), operando sobre a iluminação atual das câmeras (condição), deve sinalizar os três defeitos mais frequentes (resultado esperado), com recall mínimo de 85% em um conjunto de teste reservado (critério de teste). O primeiro enunciado não pode ser testado nem descartado; o segundo pode. Essa é a diferença entre palpite e hipótese, e ela decide se a semana seguinte de trabalho produz evidência ou apenas movimento.

GLOSSÁRIO

Hipótese técnica

Enunciado testável sobre a solução, com quatro componentes: abordagem proposta, condição sob a qual deve funcionar, resultado esperado e critério de teste. Diferencia-se do palpite por poder ser verificada e descartada com evidência; é a unidade de trabalho da fase de concepção da solução.

Dois complementos qualificam a hipótese. O primeiro é a justificativa: por que esta hipótese merece ser testada antes das outras. A justificativa adequada, no padrão que o curso vem cobrando desde o B1, nomeia a evidência que a motiva (características do problema, dados disponíveis, estado da prática) e reconhece o custo assumido ao priorizá-la. O segundo complemento é a pergunta que o instrumento do kit formula de modo memorável: este é um problema de X e não de Y? A pergunta obriga a registrar a evidência que distingue o tipo do problema. Que evidência indica que a inspeção de solda é detecção de anomalias, e não classificação supervisionada? Se as falhas graves são raras e mal rotuladas, a evidência aponta para anomalia; se há histórico rotulado e balanceado dos defeitos, aponta para classificação. Errar essa distinção no início contamina todas as decisões seguintes, e é por isso que ela é registrada como campo próprio, com evidência, e não como suposição implícita.

O segundo elo da cadeia é o experimento mínimo. Hipótese sem experimento é opinião com estrutura melhor; o que a transforma em conhecimento é o menor teste capaz de produzir a evidência do critério. Mínimo é a palavra operativa: o experimento não constrói a solução, constrói a informação para decidir sobre ela. Para a hipótese do classificador de solda, o experimento mínimo não é montar o pipeline completo; é treinar um modelo simples sobre as fotos existentes e medir o recall no conjunto de teste. Aqui o caderno do curso acrescenta, como aprofundamento sobre a espinha do instrumento do kit, dois eixos que vêm dos mecanismos de condução do bloco B2: o prazo fechado do experimento e o critério de descarte. O prazo fechado impede que o teste vire projeto dentro do projeto; o critério de descarte, declarado antes do resultado, define o que faz a hipótese ser abandonada, e transforma o abandono em cumprimento de acordo, não em derrota. Na régua da pesquisa, insistir numa hipótese por meses pode ser mérito; na régua do PD&I industrial, com prazo e custo declarados, insistir sem critério é o risco número um do cronograma.

O terceiro elo é a comparação estruturada, e o instrumento é a Matriz de Alternativas, cujo formato este curso adota exatamente como o kit de formação o fixa. As alternati-

vas entram nas linhas, ao menos duas, e cinco dimensões entram nas colunas: aderência ao problema, dados necessários, viabilidade, riscos e explicabilidade ou TRL. Cada célula exige uma justificativa curta; alta ou baixa, sozinhas, não contam como preenchimento, porque a matriz existe para expor o raciocínio, não para pontuar. Ao final, registra-se a abordagem recomendada com os seus pontos de incerteza. E há uma disciplina de sequência embutida no instrumento: a matriz recomenda, mas não fecha; a escolha é ato separado, tomado adiante com a matriz na mesa. Comparar e decidir no mesmo gesto é a receita para a comparação virar racionalização da preferência.

Vale percorrer as cinco dimensões, porque cada uma tem uma pergunta própria. Aderência ao problema pergunta o quanto a alternativa resolve o problema como ele foi delimitado no B2, e não uma versão conveniente dele. Dados necessários pergunta o que a alternativa exige de dados em volume, rotulagem e qualidade, e o quanto disso existe de fato; a resposta desta coluna conversa diretamente com o lastro de dados registrado na ficha de escopo. Viabilidade pergunta se o squad consegue executar a alternativa com a equipe, o tempo e a infraestrutura declarados. Riscos pergunta o que pode falhar de específico naquela alternativa, em qualquer categoria da taxonomia do B2. A dimensão de Explicabilidade ou TRL avalia dois aspectos correlatos: o nível de explicabilidade que a alternativa suporta (conforme abordado no módulo M5) e o grau de maturidade tecnológica da solução, visto que abordagens recentes e técnicas consolidadas há anos em produção possuem perfis de risco distintos.

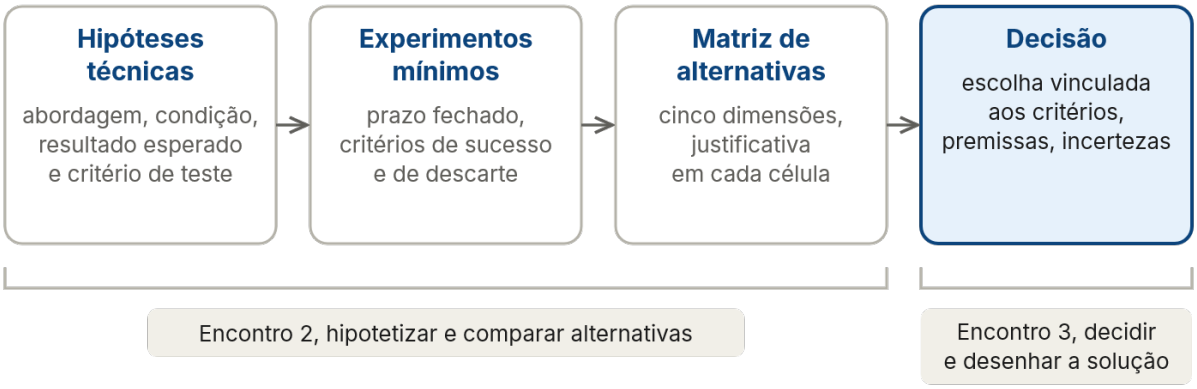
GLOSSÁRIO

TRL

Technology readiness level: escala de maturidade tecnológica, de 1 (princípio observado) a 9 (sistema comprovado em operação). Em PD&I industrial, o TRL de uma técnica calibra a expectativa de esforço: quanto menor o nível, maior a distância entre o resultado publicado e o sistema operável.

A figura 1 organiza a cadeia completa e a distribui no tempo da Formação 1. Os três primeiros elos, hipóteses, experimentos e matriz, são o trabalho do Encontro 2, hipotetizar e comparar alternativas; o fechamento é o trabalho do Encontro 3, decidir e desenhar a solução. A leitura importante da figura é a direção das setas: cada elo lê o anterior. O experimento testa a hipótese como ela foi enunciada; a matriz compara alternativas que as hipóteses e os experimentos qualificaram; a decisão se vincula aos critérios da matriz. Quando a cadeia é percorrida fora de ordem, o que se produz não é decisão, é justificativa retroativa.

Figura 1 - A cadeia da decisão de solução: hipóteses, experimentos, alternativas e decisão.



Fonte: autor.

Figura em formato de fluxograma intitulada " Figura 1 - A cadeia da decisão de solução". Quatro blocos retangulares estão organizados horizontalmente e conectados por setas da esquerda para a direita. O primeiro bloco, "Hipóteses técnicas", apresenta: abordagem, condição, resultado esperado e critério de teste. O segundo, "Experimentos mínimos", indica: prazo fechado, critérios de sucesso e de descarte. O terceiro, "Matriz de alternativas", informa: cinco dimensões e justificativa em cada célula. O quarto bloco, destacado em azul, é "Decisão" e apresenta: escolha vinculada aos critérios, premissas e incertezas. Abaixo dos três primeiros blocos, uma faixa indica "Encontro 2, hipotetizar e comparar alternativas". Abaixo do último bloco, outra faixa informa "Encontro 3, decidir e desenhar a solução".

Dois artefatos do caderno registram os antecedentes, e vale apresentá-los antes de seguir para a decisão. A ficha de hipóteses e experimentos adota a espinha do instrumento do kit, com os quatro componentes da hipótese, a justificativa e a evidência da distinção problema de X e não de Y, e acrescenta, como aprofundamento do curso, as colunas de experimento mínimo, prazo fechado, critério de sucesso e critério de descarte; o preenchimento do caderno traz duas hipóteses completas, porque uma hipótese sozinha não exercita a priorização que a justificativa exige. A matriz de alternativas técnicas adota as cinco dimensões do kit exatamente como o instrumento as fixa, com a justificativa por célula e a recomendação com pontos de incerteza ao final. Ao preencher, leia os artefatos do B2: a delimitação do problema decide o que conta como aderência, e o lastro de dados da ficha de escopo é a primeira resposta da coluna de dados necessários. Alternativa que compara bem contra um problema que não é o seu é a forma mais elegante de errar a decisão inteira.

Com a cadeia montada, entra a decisão que dá nome a este tópico, e ela tem uma natureza diferente da comparação técnica que a matriz registrou. A pergunta build/buy/integrate não é qual técnica funciona melhor; é de onde vem a solução. Desenvolver (build) é construir; comprar (buy) é adotar uma solução existente, produto comercial ou serviço gerenciado; integrar (integrate) é compor componentes existentes, abertos ou contratados, com desenvolvimento próprio na lacuna entre eles. Em PD&I industrial contemporâneo, com o ecossistema de modelos de fundação, APIs gerenciadas e bibliotecas maduras, a terceira via deixou de ser exceção: a maioria dos projetos reais é algum grau de integração, e a pergunta prática vira onde passa a fronteira entre o que se adota e o que se constrói.

A versão clássica da heurística pesa quatro eixos: custo, prazo, controle e dependência. Custo compara o desenvolvimento e a operação próprios com licenças e assinaturas; prazo compara o tempo de construir com o tempo de adotar; controle mede o quanto

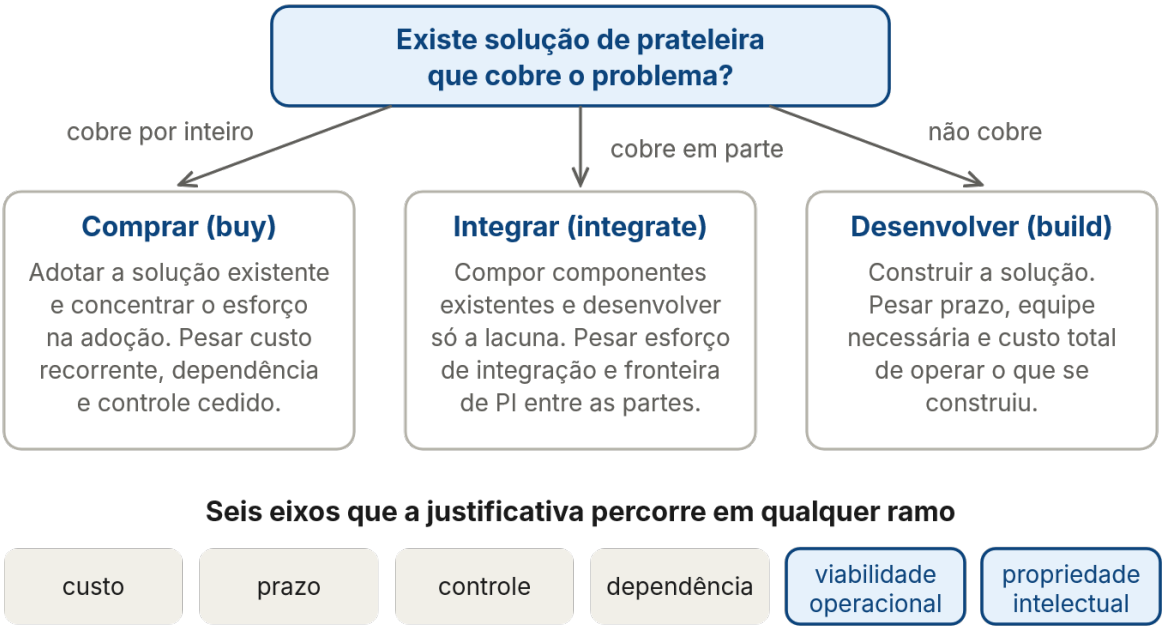
a organização governa o comportamento e a evolução da solução; dependência mede o inverso, o quanto ela fica amarrada às decisões de um terceiro. Esses quatro eixos continuam necessários, mas a experiência acumulada em projetos industriais mostra que eles não bastam, e este curso amplia a heurística com dois eixos deliberados: viabilidade operacional e propriedade intelectual. A ausência desses dois eixos na análise é uma das principais fontes de retrabalho em projetos reais, pois os problemas por eles capturados não surgem na fase de prototipagem, mas sim na operação e na formalização contratual.

Viabilidade operacional exige uma distinção que pesquisadores recém-chegados ao ambiente industrial costumam não fazer: viável tecnicamente e viável operacionalmente são julgamentos diferentes. A viabilidade técnica pergunta se a solução atinge o desempenho no ambiente de desenvolvimento; a viabilidade operacional pergunta se ela sobrevive ao ambiente real ao longo do tempo, e se decompõe em fatores concretos: manutenibilidade (quem corrige e evolui o sistema depois da entrega), dependência de equipe especializada (a operação exige um perfil que a empresa tem, ou que o mercado local oferece?), integração com a infraestrutura existente (a solução conversa com os sistemas, as redes e as restrições de segurança da planta?) e custo de operação (inferência, monitoramento, retreinamento, suporte). Um sistema excelente no benchmark e inviável de operar não é uma solução; é um protótipo com aparência de solução, e a diferença entre os dois é exatamente o que este eixo obriga a examinar antes da escolha.

Propriedade intelectual, o segundo eixo novo, pergunta a quem pertence o que a escolha produz e o que ela usa: quem é dono do modelo resultante, dos dados de treinamento, das melhorias feitas sobre componentes de terceiros, e o que o contrato permite publicar, reutilizar e comercializar. No ambiente acadêmico essas perguntas raramente decidem alguma coisa; em PD&I industrial elas decidem arquiteturas inteiras, e decidem tarde quando não foram feitas cedo. O tópico 3 deste ebook desenvolve o eixo em profundidade; por ora, o essencial é que ele entra na decisão com o mesmo peso dos demais, porque uma opção barata e rápida que entrega a PI do resultado ao fornecedor pode ser a mais cara das alternativas na régua do programa.

A figura 2 organiza a heurística ampliada como árvore de leitura. A pergunta de entrada é sobre a prateleira: existe solução que cobre o problema como ele foi delimitado? Se cobre por inteiro, a opção de partida é comprar, e o exame se concentra em custo recorrente, dependência e controle cedido. Se cobre em parte, a opção de partida é integrar, e o exame se concentra no esforço real de integração e na fronteira de PI entre o que é de terceiros e o que é do projeto. Se não cobre, a opção de partida é desenvolver, e o exame se concentra em prazo, equipe e custo total de operar o que se constrói. A árvore dá o ponto de partida, não o ponto de chegada: a decisão só fecha depois de a justificativa percorrer os seis eixos, e é comum que o exame mova a escolha para um ramo vizinho.

Figura 2 - A árvore build/buy/integrate e os seis eixos da justificativa.



Fonte: autor.

Figura 2 em formato de árvore de decisão intitulada "Build/buy/integrate: os três ramos e os seis eixos". No topo, um bloco azul apresenta a pergunta: "Existe solução de prateleira que cobre o problema?". A partir dele, três setas conduzem a diferentes alternativas. À esquerda, quando a solução "cobre por inteiro", aparece a opção "Comprar (buy)", que orienta adotar uma solução existente e concentrar o esforço na adoção, considerando custo recorrente, dependência e controle cedido. Ao centro, quando a solução "cobre em parte", está a opção "Integrar (integrate)", que propõe compor componentes existentes e desenvolver apenas a lacuna, considerando esforço de integração e fronteiras de propriedade intelectual entre as partes. À direita, quando a solução "não cobre", aparece a opção "Desenvolver (build)", que orienta construir a solução, avaliando prazo, equipe necessária, custo total de operação e os elementos que serão desenvolvidos. Na parte inferior, a figura apresenta os seis eixos que devem fundamentar a justificativa em qualquer uma das alternativas: custo, prazo, controle, dependência, viabilidade operacional e propriedade intelectual.

Três cenários industriais comentados mostram a árvore em uso. Primeiro cenário: uma transportadora precisa extrair campos estruturados de documentos fiscais digitalizados. Existem serviços comerciais maduros que fazem exatamente isso, com acurácia documentada nos formatos brasileiros. A prateleira cobre por inteiro; a partida é comprar. O exame dos eixos confirma: o custo por documento é menor que o custo de desenvolver e operar OCR próprio, o prazo cai de meses para semanas, e o controle cedido é aceitável porque o processo não é diferencial competitivo. A dependência é o eixo que pede atenção, e a resposta vai para o contrato: portabilidade dos dados extraídos e cláusula de saída.

Segundo cenário: uma indústria de embalagens quer detectar defeitos de impressão em linha. Modelos de visão pré-treinados e bibliotecas de inspeção cobrem boa parte do problema, mas os defeitos específicos do processo, o acoplamento com a esteira e a decisão de rejeição em tempo real não vêm de prateleira. A partida é integrar: componente de visão existente, ajustado com dados da linha, mais o desenvolvimento próprio da lógica de rejeição e da integração com o CLP. Os eixos críticos são viabilidade operacional (quem mantém o modelo ajustado quando o processo de impressão mudar) e PI (o ajuste fino com dados da empresa pertence a quem, se o componente base é de terceiro?). São perguntas que precisam de resposta antes do contrato, não depois.

Terceiro cenário: uma metalúrgica quer prever a qualidade de um processo proprietário de tratamento térmico, com física particular, dados que só ela tem e sigilo industrial for-

te. Não há prateleira que cubra; a partida é desenvolver. O exame dos eixos dimensiona o compromisso: prazo maior, necessidade de reter a equipe que constrói, e a viabilidade operacional inteira sob responsabilidade própria. Em troca, controle total e PI integral do resultado, que aqui é exatamente o ativo que a empresa quer criar. Note o padrão nos três cenários: nenhuma das escolhas decorre de preferência por construir ou por comprar; todas decorrem do encaixe entre a cobertura da prateleira e o peso relativo dos seis eixos naquele contexto.

> ⚠ ATENÇÃO
>
> A armadilha de postura deste tópico é tratar desenvolver como opção default. Na régua da pesquisa, construir é o mérito: o artefato próprio é a contribuição. Na régua do PD&I industrial, construir é o custo, e o mérito é resolver o problema dentro do prazo e do orçamento com o menor compromisso futuro. O squad que parte para o build sem examinar a prateleira gasta o cronograma reproduzindo o que existe e descobre o custo de operação quando já não há tempo de mudar de ramo.

O primeiro artefato do caderno deste tópico consolida a análise: a ficha de decisão build/buy/integrate, com os seis eixos pré-mapeados. Para cada eixo, a ficha pede a leitura das opções em jogo e uma justificativa de uma a três sentenças, no padrão de justificativa adequada do curso: nomeia a evidência, conecta ao cenário concreto, reconhece o custo assumido. A linha final é a síntese decisória, que declara a opção escolhida e a fronteira, quando a escolha é integrar: o que vem de fora, o que é construído, e onde passa a divisa. Antes dela, você terá preenchido a ficha de hipóteses e experimentos, com ao menos duas hipóteses completas, e a matriz de alternativas; a ficha de decisão lê as duas, e a coerência entre os três artefatos é critério de avaliação do bloco.

Exemplo aplicado

Numa fabricante de autopeças, o squad avaliou a previsão de demanda de reposição. A matriz de alternativas comparou um serviço comercial de forecasting, um modelo gradient boosting próprio e a integração de uma biblioteca aberta de séries temporais com features do ERP. Na ficha de decisão, custo e prazo favoreciam o serviço; controle, viabilidade operacional e PI favoreciam a integração, porque a equipe de dados interna existia e o histórico de vendas era ativo sigiloso. A síntese fechou em integrar, com a fronteira declarada: biblioteca aberta no núcleo, feature engineering e conectores próprios.

Falta o fechamento, e ele merece um nome próprio porque é o que os blocos e encontros seguintes lerão. Fechar a decisão é registrar quatro coisas: a escolha, a justificativa vinculada aos critérios que a sustentaram, as premissas assumidas e os pontos de incerteza que permanecem. A justificativa vinculada é o coração do registro: ela aponta para as células da matriz e para os eixos da ficha, e não para a autoridade de quem decidiu. As premissas declaram o que se assumiu como verdadeiro sem verificação completa, cada uma candidata a risco na matriz do B2. Os pontos de incerteza declaram o que ainda pode mover a decisão, e conectam-se aos gatilhos de reabertura que o curso vem usando desde o B1: Se uma premissa for invalidada, a decisão deve ser revisada - o que demonstra maturidade de gestão, e não fragilidade da escolha realizada.

No laboratório presencial, esse fechamento tem instrumento próprio: no Encontro 3, o fechamento se registra na Decisão Justificada, o instrumento do kit de formação que consolida exatamente esses campos, a escolha vinculada aos critérios da Matriz de Alternativas do Encontro 2, as premissas assumidas e os pontos de incerteza. Repare que a Decisão Justificada generaliza o que a ficha build/buy/integrate ensina: o padrão de fechamento vale para qualquer escolha estruturante de solução, seja ela a origem da solução, a técnica central ou um componente crítico. O que o curso demonstra nos cenários de exemplo, o squad executa no laboratório para o caso real, e a residência cobrará o mesmo padrão a cada decisão que precisar ser defendida diante da empresa parceira. Decidida a origem da solução, a pergunta seguinte é como ela se organiza por dentro, e esse é o assunto do tópico 2.

2. Arquitetura conceitual pelas cinco lentes

Este tópico tem por objetivo que você construa uma arquitetura conceitual de solução que mobilize as cinco lentes do curso base de forma articulada, identificando quais decisões pertencem a qual lente e em que ordem essas decisões são tomadas (competência CP.B3.C2). A decisão do tópico 1 respondeu de onde vem a solução; a arquitetura responde como ela se organiza por dentro, e responde num nível deliberado de abstração. Arquitetura conceitual não é diagrama de implantação nem lista de tecnologias: é a representação do fluxo, de onde vêm os dados, o que acontece com eles, o que sai e para quem. A instrução do instrumento do kit resume a postura correta: representar o fluxo, não implementar.

Por que gastar uma etapa inteira num desenho que não é a implementação? Porque a arquitetura conceitual é o primeiro objeto do projeto que todas as audiências conseguem examinar ao mesmo tempo. O time técnico verifica nela a coerência das partes; a empresa parceira verifica se o fluxo respeita as restrições da operação; o mentor verifica se a solução corresponde ao problema delimitado. É também o objeto em que os

erros custam menos: mover uma caixa no canvas custa minutos; mover um componente em produção custa semanas. O critério de qualidade que o kit de formação declara para o instrumento vale como teste permanente: um colega de outro eixo técnico deve entender o diagrama sem explicação oral. Se a arquitetura precisa de você ao lado para fazer sentido, ela ainda não está pronta.

GLOSSÁRIO

Arquitetura conceitual

Representação da solução no nível do fluxo: de onde vêm os dados, que transformações sofrem, que componentes os processam, o que sai e para quem. Precede escolhas de implementação e serve de objeto comum de exame entre time técnico, empresa parceira e mentor; erros corrigidos nela custam minutos, não semanas.

A espinha do canvas, no formato que este curso adota exatamente como o kit de formação o fixa, tem seis campos. Entrada de dados registra fonte e tipo: de onde os dados vêm, em que formato, com que frequência. Pré-processamento e preparação registra o que acontece entre a fonte e o modelo: limpeza, filtragem, transformação, anotação. Componentes e modelos registra as peças que processam: quais componentes existem e o que cada um resolve, na granularidade de responsabilidades, não de bibliotecas. Saída esperada registra o que o sistema produz, em que forma e para qual consumidor, humano ou sistema. Lógica e fluxo registra como as partes se conectam: a ordem, as condições, os caminhos alternativos. Pontos de risco e falha no fluxo registra onde a coisa quebra: quais transições são frágeis, que suposições cada seta carrega. Este último campo é o que separa um canvas honesto de um desenho publicitário; arquitetura sem pontos de falha declarados é arquitetura que ainda não foi pensada até o fim.

Uma nota de granularidade evita os dois defeitos de preenchimento mais comuns. O canvas excessivamente genérico registra um único componente chamado modelo de IA, e não decide nada: uma caixa que faz tudo é uma caixa que não foi pensada. O canvas excessivamente detalhado antecipa decisões de implementação ao especificar bibliotecas e versões de frameworks; se uma biblioteca for atualizada ou substituída, a representação gráfica torna-se obsoleta, mesmo que a arquitetura conceitual subjacente permaneça inalterada. A granularidade certa é a das responsabilidades: um componente por responsabilidade distinta, nomeado pelo que faz (detector de anomalias, classificador de modo de falha, fila de revisão humana), sem marca nem versão. O mesmo critério vale para as setas da lógica e fluxo: cada seta carrega uma suposição sobre formato, frequência e disponibilidade, e o exercício de nomear essas suposições

é o que alimenta o campo de pontos de risco. Um canvas em que as setas não têm suposições declaradas não está mais simples; está menos honesto.

Sobre essa espinha, o curso acrescenta a sua camada própria de leitura, e aqui está a conexão operacional entre a Condução e o curso base. As cinco lentes que os módulos M1 a M5 apresentaram como ângulos de leitura de qualquer problema de IA reaparecem agora como perguntas dirigidas ao canvas. A lente Generativa (M1) pergunta, diante do campo de componentes: este componente gera ou discrimina, e a decisão GenAI versus ML clássico foi tomada com os critérios daquele módulo? A lente Agentic (M2) pergunta, diante da lógica e fluxo: a orquestração é um workflow determinista ou um agente com autonomia de decisão, e o branching dinâmico justifica a segunda opção? A lente Data Centric (M3) pergunta, diante da entrada e do pré-processamento: que dados sustentam a solução e qual o teto de qualidade que eles impõem? A lente Edge (M4) pergunta, diante do fluxo inteiro: onde a inferência ocorre, e essa posição é compromisso de produto ou acidente de implementação? A lente Explainable (M5) questiona, diante da saída esperada: qual regime de explicabilidade é exigido: regulatório, de usabilidade do produto ou para depuração (debugging)?

A camada das lentes é aprofundamento do curso sobre a espinha do kit: no laboratório, o squad preenche os seis campos; no caderno, o canvas do curso acrescenta os slots por lente como registro explícito de quais decisões mobilizam quais lentes. O ganho não é burocrático. Quando as decisões são atribuídas às lentes, fica visível o que costuma ficar invisível: decisões que ninguém tomou (nenhum slot preenchido na lente Explainable de um sistema que opera em setor regulado) e decisões tomadas duas vezes com respostas incompatíveis (o slot Edge diz inferência local, o slot Generativa escolheu um modelo que só roda em API gerenciada). A arquitetura coerente não é a que tem as melhores respostas por lente; é a que tem respostas que se sustentam mutuamente.

Isso leva à pergunta da ordem, porque as lentes não são consultadas ao mesmo tempo. O princípio que organiza a sequência é simples de enunciar: decisões que restringem o espaço de solução vêm antes das decisões que otimizam dentro do espaço restante. Na prática dos projetos industriais, isso produz uma ordem típica. Primeiro a lente Data Centric, porque a disponibilidade e a qualidade dos dados são a restrição mais dura: não há escolha de modelo que sobreviva a dados que não existem. Cedo também a lente Explainable, na sua face regulatória: se o regime de exigência é de obrigação legal, classes inteiras de solução opaca saem do espaço antes de qualquer comparação de desempenho. Depois a lente Generativa, escolhendo o paradigma do componente central com o espaço já restringido; em seguida a Agentic, decidindo a orquestração sobre componentes já definidos; e por fim a Edge, posicionando a inferência, condicionada pelo que Data Centric e Explainable estabeleceram sobre soberania de dados e sobre a produção de explicações.

Duas ressalvas protegem a ordem de virar dogma. A primeira: por fim não significa como afterthought. A decisão de deployment é compromisso de produto, como o módulo M4 insistiu, e entra no canvas desde o primeiro rascunho; o que a ordem diz é que ela se decide condicionada pelas anteriores, não que se decide por último às pressas. A segunda: a ordem é típica, não rígida. Num projeto em que a restrição dominante é latência de chão de fábrica, a lente Edge sobe na fila e restringe as demais; num projeto de documento e linguagem, a lente Generativa pode ser a primeira pergunta relevante. O que não muda é o princípio: identifique qual lente carrega a restrição mais dura do seu problema e consulte-a antes das que apenas otimizam. A figura 3 consolida a espinha, a camada de leitura e a ordem típica.

Figura 3 - O canvas de arquitetura conceitual e a camada de leitura das cinco lentes.



Fonte: autor.

Figura em formato de diagrama intitulada " Figura 3 - O canvas de arquitetura conceitual e a camada de leitura das cinco lentes.

Na parte inferior com o subtitulo O canvas e a camada de leitura das cinco lentes. À esquerda, a "Espinha do canvas" apresenta quatro etapas organizadas verticalmente e ligadas por setas: "Entrada de dados", com fonte e tipo; "Pré-processamento", com preparação; "Componentes/modelo(s)", com o que resolve o quê; e "Saída esperada", indicando para quem e em que forma. Ao lado dessas etapas, aparecem dois blocos complementares: "Lógica/fluxo", que mostra como as partes se conectam, e "Pontos de risco", que identifica falhas localizadas no fluxo. À direita, a "Camada de leitura do curso" apresenta cinco lentes numeradas: 1. "Data Centric (M3)", sobre os dados que sustentam a solução e o limite de qualidade; 2. "Explainable (M5)", sobre o regime de exigência de explicação ou predição; 3. "Generativa (M1)", que verifica se a solução gera ou discrimina, usando inteligência artificial generativa ou aprendizado de máquina clássico; 4. "Agentic (M2)", que diferencia fluxo de trabalho determinista de agente com autonomia; e 5. "Edge (M4)", que analisa onde ocorre a inferência e como isso afeta o produto.

Um par de exemplos comentados mostra a diferença entre arquitetura coerente e incoerente. O caso coerente: manutenção preditiva de compressores numa planta química. Entrada: séries de vibração e temperatura dos sensores existentes, coletadas no historiador da planta. Pré-processamento: janelamento e extração de features no servidor local. Componentes: um modelo de detecção de anomalias e um classificador de modo de falha, ambos discriminativos; a lente Generativa foi consultada e respondeu que não há o que gerar. Saída: alerta com antecedência mínima e modo provável de falha, para o painel do planejador de manutenção. Lógica: workflow determinista, sem agente, por-

que não há branching que o justifique. Inferência on-premises (local), em conformidade com a política de segurança que proíbe o envio de dados operacionais da fábrica para fora do ambiente interno. A decisão da lente Edge diretamente condicionada pela lente Data-Centric. Pontos de falha declarados: deriva dos sensores após calibração e raridade de exemplos rotulados de falha grave. Cada resposta sustenta as vizinhas.

O caso incoerente, construído com erros reais recorrentes: no mesmo problema, o squad propõe um assistente conversacional com um modelo de linguagem de grande porte via API gerenciada, que responde perguntas do operador sobre a saúde dos compressores, com um agente que decide quais análises executar. A incoerência não está em nenhuma escolha isolada; está nos cruzamentos. O slot da lente Edge diz que os dados de processo não podem sair da planta, mas a API gerenciada os envia para fora. O slot da lente Explainable promete justificar cada alerta ao engenheiro de segurança; no entanto, o encadeamento de um agente com um modelo generativo inviabiliza uma explicação determinista e rastreável. O slot Data Centric admite poucos exemplos rotulados, mas a proposta depende de avaliar respostas em linguagem natural, que exige exatamente a rotulagem que não existe. Três decisões defensáveis uma a uma, e uma arquitetura indefensável no conjunto.

> ⚠ ATENÇÃO
>
> Tratar as lentes como checklist isolado: preencher um slot por lente, cada um com a resposta localmente melhor, e considerar a arquitetura pronta. O erro está em otimizar as respostas e ignorar os cruzamentos; a consequência é uma arquitetura que aprova em cada revisão temática e falha na primeira leitura de conjunto, tipicamente no gate em que alguém pergunta como o slot Edge convive com o modelo escolhido no slot Generativa.

Como se corrige uma incoerência? Não escolhendo o vencedor entre os slots, mas voltando à lente que carrega a restrição mais dura e propagando. No exemplo, a restrição dominante é a soberania dos dados da planta: a lente Data Centric mantém a inferência local; isso move a lente Generativa para modelos que rodam no servidor da planta ou de volta ao par discriminativo; a lente Agentic perde a justificativa do agente, porque as análises possíveis são enumeráveis num workflow; e a lente Explainable volta a ser satisfazível, porque as técnicas do módulo M5 se aplicam aos componentes discriminativos. O resultado corrigido é menos vistoso e mais defensável, e a sequência da correção é a própria ordem que este tópico ensinou.

Exemplo aplicado

Numa mineradora, o squad desenhou o canvas de um sistema de priorização de manutenção de frota. A primeira versão colocava um agente orquestrando chamadas a um modelo generativo para redigir ordens de serviço. A leitura pelas lentes expôs os cruzamentos: dados de telemetria sob restrição contratual de saída, regime de explicação exigido pela segurança operacional e branching enumerável. A versão final manteve o par discriminativo local com workflow determinista e deixou a redação de ordens como componente opcional isolado, fora do caminho crítico; o canvas registrou a decisão e o motivo em cada slot.

O artefato do caderno deste tópico é o canvas de arquitetura conceitual: a espinha de seis campos do kit mais os slots por lente como camada de aprofundamento, com um campo de justificativa por slot e a indicação da ordem em que as decisões foram tomadas naquele projeto. Dois vínculos de coerência cruzada são critério de avaliação. Para trás, o canvas precisa refletir a decisão do tópico 1: se a ficha build/buy/integrate fechou em integrar com fronteira declarada, os componentes de terceiros e os componentes próprios aparecem no canvas dos dois lados dessa fronteira. Para a frente, o canvas alimenta o que vem: o plano de aquisição de dados do bloco B4 lê a entrada e o pré-processamento; o plano de validação do B5 lê a saída esperada e os pontos de falha. No Encontro 3, o instrumento correspondente do kit é o Canvas de Arquitetura Conceitual, preenchido pelo squad para o caso real logo depois da Decisão Justificada, na mesma sessão de laboratório.

Resta um habitante do canvas que até aqui ficou implícito. Olhe de novo para os componentes do caso coerente: o historiador da planta é um produto comercial, o modelo de detecção pode vir de uma biblioteca de terceiros, a API gerenciada do caso incoerente pertencia a um provedor. Toda arquitetura real tem nomes de terceiros dentro dela, e cada nome carrega um contrato, uma dependência e uma pergunta de propriedade intelectual. Tornar esses nomes explícitos, e as restrições que eles trazem, é o assunto do tópico 3.

3. Fornecedores e propriedade intelectual como restrição arquitetural

Este tópico fecha o bloco e tem por objetivo que você mapeie os fornecedores e parceiros envolvidos numa arquitetura proposta e articule as restrições de propriedade intelectual de modelo e de dados que decorrem dessas dependências (competência CP.B3.

C3). O título anuncia a tese: fornecedores e PI não são um anexo jurídico que se resolve depois do desenho técnico; são restrição arquitetural, no mesmo sentido em que latência e disponibilidade de dados são. Uma cláusula contratual pode vetar um componente, mover a inferência de lugar e decidir entre comprar e desenvolver com mais força que qualquer benchmark. A diferença é que a cláusula ignorada não falha no teste; falha na reunião com o jurídico, meses depois, quando mudar custa caro.

Comece pela taxonomia. Projetos de IA em PD&I industrial mobilizam cinco categorias recorrentes de fornecedor, e cada categoria levanta questões contratuais características. O provedor de cloud fornece a infraestrutura de computação e armazenamento; as questões típicas são a localização dos dados, os custos de saída e os compromissos de disponibilidade. O provedor de modelo fornece o modelo de fundação ou o serviço de inferência por API; as questões típicas são a licença de uso, o destino dos dados enviados, a PI sobre ajustes finos e a estabilidade de versões e preços. O fornecedor de dados fornece dados externos que complementam os da empresa; as questões típicas são a licença de uso e de redistribuição, as restrições de uso secundário e a responsabilidade sobre a qualidade. O fornecedor de anotação fornece rotulagem como serviço; as questões típicas são a confidencialidade do que os anotadores veem, a PI sobre os rótulos e a qualidade contratada com métrica declarada. O parceiro técnico, integrador ou consultoria, fornece desenvolvimento e integração; as questões típicas são a PI sobre o que ele constrói, a exclusividade e a transferência de conhecimento ao final. O quadro 1 consolida a taxonomia.

Quadro 1 - Taxonomia de fornecedores em projetos de IA e questões características.

Categoria	O que fornece	Questões contratuais e de PI características
Provedor de cloud	Computação, armazenamento e serviços gerenciados de plataforma.	Localização e soberania dos dados; custos de saída (egress); disponibilidade contratada; dependência de serviços proprietários da plataforma.
Provedor de modelo	Modelo de fundação, pesos ou inferência por API.	Licença de uso comercial; destino e retenção dos dados enviados; PI sobre o ajuste fino feito com dados da empresa; estabilidade de versão e de preço.

Categoria	O que fornece	Questões contratuais e de PI características
Fornecedor de dados	Dados externos, públicos ou licenciados, que complementam os da empresa.	Licença de uso e de redistribuição; restrição de uso secundário; responsabilidade pela qualidade e pela origem lícita dos dados.
Fornecedor de anotação	Rotulagem de dados como serviço.	Confidencialidade do material exposto aos anotadores; PI sobre os rótulos produzidos; qualidade contratada com métrica e amostragem declaradas.
Parceiro técnico	Desenvolvimento, integração e sustentação por terceiros.	PI sobre o que é construído; exclusividade; transferência de conhecimento e de código ao final; dependência de sustentação.

A leitura do quadro pede duas observações. A primeira: as categorias se acumulam. Um mesmo projeto pode ter provedor de cloud, provedor de modelo e fornecedor de anotação ao mesmo tempo, e as restrições se compõem: o contrato de anotação precisa respeitar o NDA com a empresa parceira, que precisa conviver com o destino dos dados no provedor de modelo. A segunda: a coluna de questões não é lista de desconfiança, é pauta de conversa. Nenhuma dessas questões se resolve sozinha com boa vontade técnica; todas se resolvem com cláusula escrita, e o papel do squad não é redigir a cláusula, é saber que ela precisa existir e levar a pergunta a quem redige.

Entre as questões do quadro, duas merecem seção própria pela frequência com que decidem projetos. A primeira é a PI de modelo, e o seu caso central em PD&I contemporâneo é o modelo derivado: o modelo que resulta de ajuste fino, destilação ou continuação de treinamento de uma base pré-treinada de terceiros, usando dados do cliente e trabalho do squad. A quem pertence esse artefato? A resposta honesta é: depende do que está escrito, e de três camadas que precisam ser lidas juntas. A licença da base define o que se pode fazer com ela e com derivados; nem todo modelo aberto é livre, e licenças abertas populares carregam restrições de uso comercial, cláusulas de escala ou obrigações de atribuição. O contrato com o cliente define a quem pertence o resultado do trabalho pago. E os termos do provedor, quando o ajuste ocorre na plataforma

dele, definem o que ele retém. Um squad que treina sobre uma base de licença restritiva, com dados sob NDA, na plataforma de um terceiro, criou um objeto com três donos potenciais; se ninguém alinhou as camadas antes, criou um litígio com pesos.

GLOSSÁRIO

Modelo derivado

Modelo resultante de ajuste fino, destilação ou continuação de treinamento sobre uma base pré-treinada de terceiros. Sua propriedade e seus usos permitidos dependem de três camadas contratuais lidas em conjunto: a licença da base, o contrato com o cliente e os termos do provedor onde o ajuste ocorre.

O caso do modelo derivado torna necessária uma leitura mais fina do que a palavra aberto costuma receber. Modelo aberto não é sinônimo de modelo livre: aberto descreve o acesso aos pesos, e a licença descreve o que se pode fazer com eles. O espectro é largo. Há licenças permissivas, que autorizam uso comercial e derivados com poucas obrigações; há licenças abertas com cláusulas de escala, que restringem o uso acima de determinado volume de usuários ativos ou faturamento; há políticas de uso aceitável (Acceptable Use Policies, AUP), que proíbem domínios inteiros de aplicação; e há modelos de pesos disponíveis apenas para pesquisa, cujo uso comercial exige acordo separado. Para o projeto, a consequência é operacional: a leitura da licença entra na coluna de riscos da matriz de alternativas e no eixo de PI da ficha de decisão, antes da escolha, porque descobrir a cláusula de escala depois do deploy não é risco, é fato consumado. Quando a leitura deixar dúvida, a dúvida vai ao jurídico com a pergunta formulada; o que o squad não pode fazer é resolvê-la por otimismo.

A segunda questão é a PI de dados, e para quem vem do ambiente acadêmico ela costuma ser a mais contraintuitiva, porque envolve três regimes que a pesquisa raramente separa. O que pode virar publicação: resultados, métodos e agregados que o contrato com a empresa parceira autoriza expor, tipicamente após revisão dela. O que cai sob NDA: os dados brutos, os detalhes do processo produtivo e tudo o que o acordo de confidencialidade cobre, que não entra em artigo, repositório público nem apresentação externa. E o que tem restrição de uso secundário: dados cedidos para um propósito declarado não podem alimentar outro projeto, outro modelo ou outro cliente sem novo acordo, mesmo dentro da mesma instituição. A residência torna isso concreto: os direitos de publicação acadêmica derivada do trabalho, incluindo dissertações e artigos, precisam estar articulados no acordo com a empresa parceira antes de o trabalho começar, porque negociá-los depois, com o resultado na mão, é negociar sem alternativas.

> ⚠ ATENÇÃO
>
> A armadilha de postura deste tópico é assumir o direito de publicar. Na régua da pesquisa, publicar é o destino natural de todo resultado; em PD&I industrial, publicação é cláusula, não default. O pesquisador que promete um artigo ao orientador, ou um dataset público à comunidade, antes de ler o NDA, descobre no pior momento que prometeu o que não era seu, e a consequência recai sobre o squad, sobre a instituição e sobre a relação com a empresa parceira.

Com as duas questões centrais estabelecidas, o repertório contratual mínimo desta parte cabe em quatro cláusulas típicas, e o que importa para o engenheiro de PD&I é reconhecer qual decisão arquitetural cada uma afeta. O NDA define o perímetro do que circula: afeta onde os dados podem ser processados, o que restringe a escolha de cloud e de API externa, e conecta-se diretamente à lente Edge do tópico 2. A cláusula de PI sobre modelos derivados define a quem pertence o ajuste fino: afeta a decisão build/buy/integrate, porque integrar sobre uma base cujo derivado não será seu muda o valor da opção. Os direitos de publicação definem o que a equipe pode expor: afetam o cronograma (a revisão da parceira entra como dependência) e a motivação acadêmica do squad, que é legítima e precisa de canal contratado. A exclusividade define o que não pode ser reutilizado: afeta a arquitetura porque componentes desenvolvidos sob exclusividade não migram para o próximo projeto, o que muda o cálculo de custo de desenvolvê-los.

Há ainda uma restrição que não vem de cláusula, e sim da acumulação delas: a dependência de fornecedor, o vendor lock-in. A adoção de serviços proprietários, formatos de dados proprietários ou APIs sem equivalentes abertos eleva o custo de transição (switching cost). Essa dependência financeira e operacional costuma permanecer oculta até que ocorram reajustes de preços, alterações nos termos de serviço ou a descontinuidade da solução pelo fornecedor. A mitigação é arquitetural e contratual ao mesmo tempo: preferir formatos e interfaces abertos nas fronteiras entre componentes, isolar os serviços proprietários atrás de camadas de abstração que permitam troca, e negociar cláusulas de saída com portabilidade dos dados e dos artefatos. Nenhuma dessas medidas é gratuita; todas entram na ficha de decisão da parte 1, no eixo de dependência, com o seu custo declarado. O ponto de postura é o mesmo do bloco inteiro: dependência aceita conscientemente, com preço registrado, é decisão; dependência descoberta na operação é dívida.

SAIBA MAIS

WORLD INTELLECTUAL PROPERTY ORGANIZATION. WIPO Conversation on Intellectual Property and Artificial Intelligence: background paper. Genebra: WIPO, 2020. Panorama internacional das questões de PI levantadas por sistemas de IA, incluindo propriedade de modelos e de dados de treinamento. Disponível no portal público da WIPO (wipo.int).

Antes do artefato, uma ponte para trás fecha o circuito com o bloco B2. Cada fornecedor identificado é uma dependência crítica em potencial, e as questões contratuais em aberto são premissas com data de reavaliação: assumimos que o provedor mantém o preço, que a licença permite o derivado, que a parceira autoriza a publicação. Esses mapeamentos devem integrar a Matriz de Riscos Operacionais, especificamente nas categorias de Dependência Externa e Propriedade Intelectual, definindo como plano de mitigação o instrumento contratual correspondente. O squad que faz essa transposição ganha duas coisas: o risco de fornecedor entra na pauta dos gates, em vez de morar só no contrato, e a matriz de risco deixa de ser genérica, porque cada linha aponta para um nome, um contrato e um responsável.

O artefato do caderno deste tópico é o mapa de fornecedores e PI, com as categorias da taxonomia pré-mapeadas. O mapa preenchido no caderno traz três fornecedores identificados, cada um com a categoria, o que fornece na arquitetura, as questões contratuais aplicáveis e a restrição resultante articulada; a linha de síntese registra as restrições que precisam chegar ao jurídico antes do contrato. A coerência cruzada segue como critério: o mapa corresponde à arquitetura do tópico 2 (cada componente de terceiros do canvas tem linha no mapa) e reflete a decisão do tópico 1 (a fronteira do integrate é exatamente onde os fornecedores aparecem). No Encontro 3, a seção correspondente do kit é o mapa de governança e propriedade intelectual, que registra, por item de dado, modelo ou código, a restrição de uso, o responsável e a observação; o mapa do caderno é o exercício completo de que essa seção é a consolidação de laboratório.

Exemplo aplicado

Numa fabricante de eletrodomésticos, um integrador contratado ajustou um modelo de visão de base aberta com as fotos de defeitos da linha de montagem. O contrato, assinado sem revisão das cláusulas de PI, dava ao integrador a propriedade do modelo ajustado. Quando a empresa quis levar o modelo para a segunda fábrica, descobriu que precisaria pagar nova licença sobre um artefato treinado com os próprios dados. O mapa de fornecedores e PI existe para essa pergunta ser feita antes da assinatura: quem é o dono do derivado, e o que a empresa pode fazer com ele sem voltar à mesa.

4. Conclusão

Os três tópico deste ebook montaram a decisão estruturante que dá nome ao bloco. O tópico 1 estabeleceu a cadeia que torna a decisão defensável: hipóteses técnicas com anatomia completa, experimentos mínimos com prazo fechado e critério de descarte, a matriz de alternativas com justificativa em cada célula, a heurística build/buy/integrate ampliada para seis eixos, e o fechamento com escolha vinculada aos critérios, premissas e pontos de incerteza, que o Encontro 3 consolida na Decisão Justificada. O tópico 2 traduziu a decisão em arquitetura conceitual: a espinha de seis campos do canvas, a camada de leitura das cinco lentes do curso base, a ordem típica em que as decisões restringem e otimizam o espaço de solução, e o teste de coerência que examina os cruzamentos, não os slots isolados. O tópico 3 completou o desenho com o que toda arquitetura real contém: fornecedores com contratos, PI de modelo e de dados, cláusulas que restringem componentes e a dependência como custo declarado.

O ganho do bloco é a cadeia de coerência que os avaliadores do programa cobram e que a residência exigirá: a decisão reflete a matriz de alternativas, a arquitetura reflete a decisão, e o mapa de fornecedores corresponde à arquitetura. Nenhum dos cinco artefatos vale sozinho; o valor está em poder percorrer a cadeia nos dois sentidos e encontrar, em cada elo, a justificativa que sustenta o seguinte. Essa cadeia de evidências desloca a defesa das decisões do projeto da justificativa intuitiva para um histórico rastreável e auditável por qualquer banca ou parceiro corporativo.

Antes de avançar, percorra no caderno os cinco artefatos deste bloco (ficha de hipóteses e experimentos, matriz de alternativas técnicas, ficha de decisão build/buy/integrate, canvas de arquitetura conceitual e mapa de fornecedores e PI), que trazem o preenchimento comentado para o cenário de exemplo e a instrução de uso eixo a eixo. Feche o bloco com o quiz formativo. O bloco B4 começa onde este para: a arquitetura declarou que dados a solução consome, e a pergunta seguinte é como adquiri-los, qualificá-los e governá-los em chave operacional, com cronograma, custo e regime regulatório na mesa.

REFERÊNCIAS

Bibliografia mínima

HUYEN, C. Designing Machine Learning Systems. Sebastopol: O'Reilly, 2022. Capítulos 1 e 2, sobre a decisão inicial de arquitetura de sistemas de ML em produção, em diálogo direto com os tópicos 1 e 2 deste bloco; capítulo 10, que fecha com a discussão build versus buy em infraestrutura de ML e trata o custo de saída da nuvem, base do eixo de dependência do tópico 3.

ANTHROPIC. Building Effective Agents. Anthropic Engineering, 2024. Disponível em anthropic.com/engineering/building-effective-agents. Referência para a decisão entre orquestração determinista (workflow) e agente, mobilizada pela lente Agentic na leitura do canvas.

ORGANIZAÇÃO MUNDIAL DA PROPRIEDADE INTELECTUAL (OMPI). Revised Issues Paper on Intellectual Property Policy and Artificial Intelligence. WIPO, documento WIPO/IP/AI/2/GE/20/1 REV, 2020. Disponível em wipo.int. Levantamento das questões abertas de propriedade intelectual em IA, incluindo titularidade de obras e invenções geradas, dados de treinamento e segredo industrial, base do tratamento de PI de modelo e de dados no tópico 3.

Industr.IA

Residência em TIC 49



Executor iRede

Executor Atlântico

Coordenador Softex

Financiador MCTI Futuro

Ministério da Ciência, Tecnologia e Inovação

Governo do Brasil — Do lado do povo brasileiro

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.