Industr.IA

E-book

Do pesquisador ao engenheiro



Condução de Projetos | Unidade 1

Prof.: Raimundo Valter

SUMÁRIO

1. O contraste de posturas: pesquisa e PD&I industrial 3
2. A heurística usar-adaptar-pesquisar 7
3. O método e o caderno: CRISP-DM adaptado 11
4.Conclusão 16

Unidade 1

1. O contraste de posturas: pesquisa e PD&I industrial

Este tópico funda o bloco e tem por objetivo que você distinga a postura profissional do pesquisador da postura do engenheiro de PD&I industrial em quatro dimensões: horizonte de tempo, métrica de sucesso, tipo de entrega e relação com o destinatário (competência CP.B1.C1). É a peça mais importante do curso inteiro, porque tudo o que vem depois, do escopo à operação, pressupõe essa distinção. Sem ela, o curso de Condução se reduziria a uma coleção de técnicas de gestão; com ela, cada técnica ganha o seu porquê.

Comece por uma constatação sobre o público deste programa. A maior parte de quem chega ao Industr.IA, de bolsistas de iniciação científica e tecnológica a pós-doutores, foi formada dentro da universidade e treinada no regime de trabalho da pesquisa. Esse regime é valioso e não está em julgamento aqui. O ponto é outro: a residência tecnológica coloca você diante de uma empresa parceira, com um problema real, um prazo e um orçamento, e esse contexto opera sob um regime de trabalho diferente. Postura profissional, neste curso, não é traço de personalidade nem hierarquia de valor. É o conjunto de respostas práticas a três perguntas: o que conta como pronto, para quem se entrega, e em quanto tempo.

A primeira dimensão do contraste é o horizonte de tempo. Na pesquisa, o horizonte é aberto: o tempo segue a pergunta, e uma investigação que se mostra mais difícil do que o previsto pode, dentro de limites, alongar-se até render resultado. Em PD&I industrial, o horizonte é fechado: cronograma e custo foram acordados com um cliente antes de o trabalho começar, e o tempo passa a ser uma restrição de projeto, não uma variável livre. A consequência prática é dura e vale enunciar sem rodeios. Em contexto industrial, uma solução boa o suficiente entregue dentro do prazo vale mais do que uma solução ótima sem data. Decidir sob prazo, com informação incompleta, deixa de ser um defeito do processo e passa a ser o próprio trabalho.

O horizonte fechado transforma a relação do time com a incerteza. Na pesquisa, uma incerteza relevante justifica investigá-la até dissolvê-la. Em PD&I, incertezas são administradas, não eliminadas: algumas serão reduzidas por experimentos com prazo, outras serão aceitas e registradas como risco, outras serão devolvidas ao cliente como premissa a validar. E a régua do bom o suficiente não é uma sensação do time; é um acordo. O critério de sucesso negociado no escopo define quando parar de melhorar, e melhorar além dele consome prazo que outra parte do projeto precisará. Voltaremos a isso no bloco B2, quando o cronograma e os pontos de decisão derem forma operacional a essa disciplina.

A segunda dimensão é a métrica de sucesso. Na pesquisa, o sucesso típico é o achado publicável: um resultado novo, validado pelo escrutínio de pares, que faz a fronteira do conhecimento avançar um passo. Em PD&I industrial, o sucesso é a *entrega defensável*: uma solução que funciona no contexto do cliente e cuja qualidade você consegue sustentar com evidência quando questionado. Defensável não quer dizer perfeita. Quer dizer que cada decisão relevante tem justificativa registrada, que as limitações são conhecidas e declaradas, e que os critérios de sucesso acordados no escopo foram medidos e atendidos.

GLOSSÁRIO

Entrega defensável

Entrega cuja qualidade se sustenta diante de questionamento: as decisões relevantes têm justificativa registrada, as limitações são declaradas e os critérios de sucesso acordados foram medidos. É a métrica de sucesso característica de PD&I industrial, em contraste com o achado publicável da pesquisa.

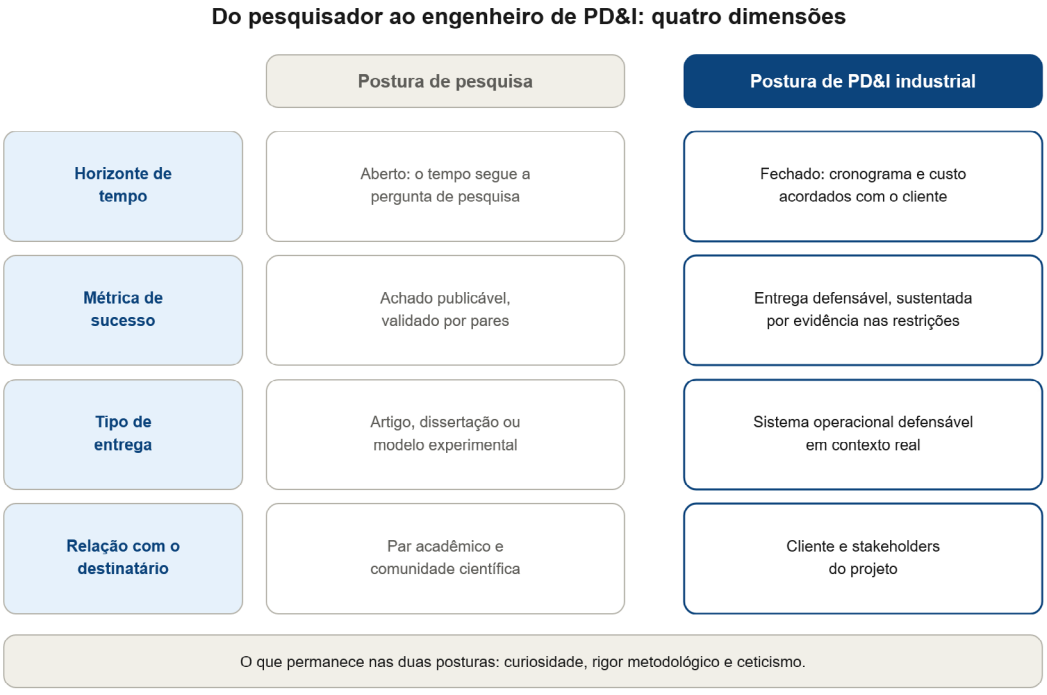
A terceira dimensão é o tipo de entrega. O produto final típico da pesquisa é um artigo, uma dissertação ou um modelo experimental que demonstra uma ideia em condições controladas. O produto final típico de PD&I industrial é um sistema operacional defensável: algo que roda no ambiente do cliente, com dados do cliente, sob as restrições do cliente, e que continua funcionando depois que o projeto termina. A distância entre os dois é maior do que parece. Um protótipo com métricas promissoras no notebook de quem o treinou ainda não é uma entrega; é um argumento de viabilidade. Transformá-lo em sistema exige trabalho de integração, validação, documentação e operação que a pesquisa raramente contabiliza.

A quarta dimensão é a relação com o destinatário. O destinatário da pesquisa é o par acadêmico: alguém com formação semelhante, que avalia o trabalho pela originalidade, pelo rigor do método e pela contribuição ao campo. O destinatário de PD&I industrial é o cliente: alguém que avalia o trabalho pelo valor que ele gera no seu contexto e pelo risco que ele traz. O cliente não premia novidade; premia problema resolvido. Isso muda o que você comunica e como comunica. Diante de um par, você defende a contribuição; diante de um cliente, você defende a decisão, o cronograma e o risco. O bloco B6 desenvolve essa diferença em profundidade; aqui, basta registrar que ela existe e que ignorá-la custa caro.

Destinatário, no plural do mundo real, quer dizer stakeholders. No contexto da residência, o squad responde ao mesmo tempo à empresa parceira, ao mentor, ao time técnico

e, com frequência, a áreas do cliente que não pediram o projeto mas serão afetadas por ele. Cada um desses públicos avalia a entrega com uma régua diferente, e parte do trabalho de condução é saber qual régua está em uso em cada conversa. Neste bloco apenas ficamos conhecendo o fenômeno; o mapeamento estruturado de stakeholders é artefato do bloco B2, e a comunicação calibrada por audiência é o tema do bloco B6.

Figura 1 - Contraste de posturas em quatro dimensões.



S

Fonte: autor. Arquivo: B1_fig-1_contraste_posturas.svg

Para cego ver: A imagem apresenta um quadro comparativo intitulado "Figura 1 – Contraste de posturas em quatro dimensões", com o subtítulo "Do pesquisador ao engenheiro de PD&I: quatro dimensões". O conteúdo é organizado em duas colunas centrais: à esquerda, "Postura de pesquisa", em fundo bege claro; à direita, "Postura de PD&I industrial", em fundo azul-escuro. À esquerda do quadro há quatro caixas azuis claras indicando as dimensões da comparação: Horizonte de tempo, Métrica de sucesso, Tipo de entrega e Relação com o destinatário. Na dimensão Horizonte de tempo, a postura de pesquisa é descrita como "Aberto: o tempo segue a pergunta de pesquisa", enquanto a postura de PD&I industrial apresenta "Fechado: cronograma e custo acordados com o cliente". Na Métrica de sucesso, a pesquisa valoriza "Achado publicável, validado por pares", enquanto a PD&I industrial prioriza "Entrega defensável, sustentada por evidência nas restrições". Em Tipo de entrega, a pesquisa produz "Artigo, dissertação ou modelo experimental", enquanto a PD&I industrial entrega um "Sistema operacional defensável em contexto real". Na dimensão Relação com o destinatário, a pesquisa tem como foco "Par acadêmico e comunidade científica", enquanto a PD&I industrial se relaciona com "Cliente e stakeholders do projeto". Na parte inferior, uma faixa horizontal destaca o ponto em comum entre as duas abordagens: "O que permanece nas duas posturas: curiosidade, rigor metodológico e ceticismo."

A figura organiza as quatro dimensões lado a lado e convém lê-la como um todo, não como quatro itens soltos. As dimensões se reforçam. O horizonte fechado só faz sentido porque há um cliente do outro lado, e a entrega defensável só é exigível porque o sucesso será cobrado nesse horizonte. O sistema operacional é a forma que a entrega assume quando o destinatário precisa usá-la, e não apenas lê-la. Quando um projeto industrial dá errado por razões não técnicas, é quase sempre porque uma dessas dimensões foi tratada com a régua da outra postura. Prazo tratado como estimativa revisável, sucesso como mérito técnico, entrega como demonstração, cliente como plateia.

Um exemplo tornará o contraste concreto. Imagine que uma indústria de manufatura apresenta o mesmo problema a duas equipes: reduzir o descarte causado por defeitos de pintura na linha de montagem. A equipe em postura de pesquisa lê o problema como uma oportunidade de investigação: que arquitetura de visão computacional detecta melhor esse tipo de defeito, e há espaço para um resultado publicável? A equipe em pos-

tura de PD&I lê o mesmo problema como um projeto: qual é o custo atual do descarte, que precisão mínima torna a solução economicamente viável, que dados existem hoje, em quanto tempo o cliente precisa ver resultado. As duas leituras não são inimigas, e a segunda frequentemente se beneficia do repertório da primeira. Mas apenas a segunda produz um escopo, um cronograma e um critério de sucesso que uma empresa consegue contratar.

As quatro dimensões também servem como instrumento de diagnóstico durante o projeto, e não apenas como quadro de abertura de curso. Quando uma conversa trava, vale perguntar qual régua cada lado está usando. Se o time defende mais duas semanas de experimento e o cliente pergunta pelo resultado prometido, o conflito é de horizonte de tempo. Se o time apresenta a métrica técnica e o cliente não se convence, o conflito é de métrica de sucesso: falta traduzir a métrica em valor no contexto dele. Se a demonstração impressiona mas a implantação não avança, o conflito é de tipo de entrega. Nomear a dimensão em jogo transforma um desconforto difuso em problema tratável, e esse hábito de leitura vale tanto no cenário de exemplo do curso quanto na residência.

Exemplo aplicado

Numa empresa de bens de consumo, um squad de PD&I recebeu o pedido de prever ruptura de estoque em centros de distribuição. A primeira reação do time, treinado em pesquisa, foi desenhar um estudo comparativo de modelos de séries temporais. O gestor do projeto redirecionou: antes de comparar modelos, o time mapeou o custo de cada ruptura, os dados disponíveis e o prazo de decisão do cliente. O estudo comparativo aconteceu, mas dimensionado pelo projeto, em duas semanas e com três candidatos, não como fim em si.

Resta o ponto que evita o mal-entendido mais comum sobre este bloco. A transição de postura não pede que você abandone a calibração intelectual de pesquisador; pede que a coloque a serviço de outro regime de trabalho. Curiosidade, rigor metodológico e ceticismo continuam sendo os seus melhores instrumentos. O que muda é o endereço em que o rigor se aplica. Na pesquisa, o rigor culmina na demonstração de que o achado é verdadeiro. Em PD&I, o rigor culmina na validação de que a solução funciona no contexto real e na honestidade sobre onde ela deixa de funcionar. Um engenheiro de PD&I cético é mais valioso do que um entusiasmado, porque o ceticismo bem dirigido é o que impede a entrega de prometer mais do que sustenta.

Armadilha comum

A confusão de postura mais cara do programa é tratar o caso industrial como problema de pesquisa: mergulhar na técnica antes de delimitar escopo, critérios de sucesso e dados disponíveis. O squad produz profundidade técnica admirável sobre o problema errado, o cronograma estoura nas fases finais e o cliente perde confiança justamente quando a solução mais precisa dele. Delimitar antes de aprofundar não é burocracia; é o que torna o aprofundamento útil.

Com as quatro dimensões firmes e com a garantia de que a calibração intelectual permanece, a pergunta seguinte é operacional. Diante de um problema concreto apresentado pela empresa parceira, que postura de solução adotar? É a essa pergunta que a heurística da próxima parte responde.

2. A heurística usar-adaptar-pesquisar

Este tópico pertence ao coração decisório do bloco e desenvolve a competência CP.B1.C2. O objetivo é que você aplique a heurística *usar-adaptar-pesquisar* a um problema apresentado, justificando a escolha em termos de cronograma e custo. Se o tópico 1 estabeleceu o contraste entre dois regimes de trabalho, este entrega o primeiro instrumento prático do novo regime: uma sequência de perguntas que organiza a decisão sobre quanto esforço original um problema realmente pede.

GLOSSÁRIO

Usar-adaptar-pesquisar

Heurística que ordena três posturas de solução diante de um problema: usar uma solução existente, adaptar uma solução existente ou pesquisar algo novo. A ordem importa: testa-se usar antes de adaptar, e adaptar antes de pesquisar, porque prazo, custo e risco crescem nessa direção.

As três opções descrevem posturas de solução, e todas as três são legítimas. Usar significa integrar uma solução que já existe, seja uma biblioteca madura, um serviço gerenciado ou um modelo pronto, concentrando o esforço do projeto em validar que ela funciona no contexto do cliente. Adaptar significa partir de uma solução existente e modificá-la de forma controlada: ajustar um modelo pré-treinado aos dados do domínio, estender uma ferramenta, recombinar componentes. Pesquisar significa desenvolver uma abordagem nova, porque nada do que existe atende ao problema. O que não se pode fazer é escolher qualquer uma delas por padrão, sem examinar as outras duas.

E há um default, com direção conhecida. O treino acadêmico premia originalidade: uma contribuição só é publicável se acrescenta algo que não existia, e anos de formação sob esse incentivo criam o reflexo de começar todo problema pela pergunta o que há de novo a fazer aqui. Transportado para o contexto industrial sem exame, esse reflexo descalibra o projeto. O squad reinventa, com semanas de esforço e resultado incerto, capacidades que uma biblioteca madura entrega em dias com qualidade conhecida. O cronograma, que é fechado, absorve o custo. A heurística existe precisamente para interceptar esse reflexo: ela obriga a testar as opções mais baratas antes de autorizar a mais cara.

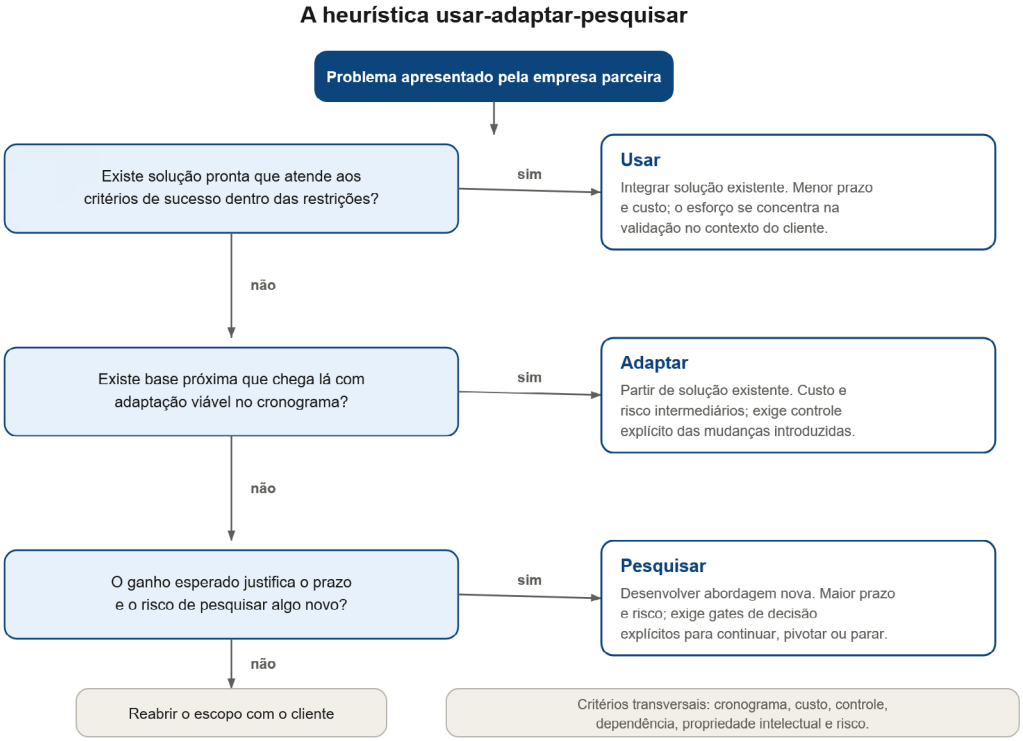
A ordem das perguntas segue o custo crescente das opções, e a figura 2 a apresenta como árvore de decisão. A primeira pergunta é: existe solução pronta que atende aos critérios de sucesso do projeto dentro das restrições? Se sim, a postura é usar. Note o que a pergunta exige de você: conhecer os critérios de sucesso e as restrições, que vêm do escopo, e conhecer o que existe, que vem de levantamento honesto do estado da prática. Responder não por desconhecimento do que existe é o modo de falha mais comum desta etapa, e é evitável com algumas horas de levantamento antes de qualquer linha de código.

Usar bem é menos trivial do que o nome sugere, e vale detalhar o que a opção exige. Primeiro, um levantamento honesto do estado da prática: o que existe em bibliotecas, serviços e modelos prontos, com que maturidade, com que licença, com que limites conhecidos. Segundo, critérios de aceitação escritos antes do teste: sem eles, a avaliação da solução pronta vira impressão. Terceiro, validação no contexto: a solução que funciona no benchmark público precisa provar que funciona nos dados, no volume e nas restrições do cliente. O esforço poupado no desenvolvimento migra para a validação e a integração; ele não desaparece, muda de lugar. É por isso que usar não é a opção preguiçosa da árvore: é a opção que troca risco de construção por trabalho de verificação.

Se a resposta é não, a segunda pergunta entra: existe uma base próxima que chega ao resultado com adaptação viável dentro do cronograma? Se sim, a postura é adaptar. A palavra que sustenta a pergunta é viável. Toda adaptação parece pequena antes de começar; a avaliação de viabilidade exige estimar o esforço de modificação, o esforço de validação do que foi modificado e o risco de a base escolhida não se comportar como esperado no domínio. Só quando as duas primeiras respostas são não é que a terceira pergunta se coloca: o ganho esperado justifica o prazo e o risco de pesquisar algo novo? Se sim, pesquisa-se, com salvaguardas que o restante do curso detalha: prazo fechado por tentativa, critérios de sucesso e de descarte definidos antes de começar, e pontos de decisão em que o projeto pode continuar, pivotar ou parar. Se nem isso se justifica, o caminho honesto é reabrir a conversa de escopo com o cliente.

Adaptar carrega um custo escondido que a experiência acadêmica tende a subestimar: o custo de validar o que foi modificado. Quando você adapta uma base existente, herda o comportamento dela nas partes que não tocou e responde pelo comportamento novo nas partes que tocou. A fronteira entre as duas nem sempre é limpa, e uma adaptação pequena pode alterar comportamentos distantes do ponto modificado. Por isso a estimativa de viabilidade de uma adaptação soma três parcelas: o esforço de modificar, o esforço de validar o conjunto modificado e o risco de a base escolhida se comportar mal no domínio. Quando a terceira parcela é alta, adaptar custa mais do que parecia, e a comparação com as opções vizinhas precisa ser refeita.

Figura 2 - Árvore de decisão usar-adaptar-pesquisar.



Fonte: autor. Arquivo: B1_fig-2_arvore_usar_adaptar_pesquisar.svg

Para cego ver: A imagem apresenta um fluxograma intitulado "Figura 2 – Árvore de decisão usar-adaptar-pesquisar", com o subtítulo "A heurística usar-adaptar-pesquisar". No topo, uma caixa azul-escura contém o texto "Problema apresentado pela empresa parceira", de onde parte um fluxo vertical de decisões. A primeira pergunta, em uma caixa azul-clara, é: "Existe solução pronta que atende aos critérios de sucesso dentro das restrições?". Se a resposta for "sim", o fluxo segue para a direita, levando à opção "Usar", descrita como "Integrar solução existente. Menor prazo e custo; o esforço se concentra na validação no contexto do cliente.". Se a resposta for "não", o fluxo desce para uma segunda pergunta: "Existe base próxima que chega lá com adaptação viável no cronograma?". Se a resposta for "sim", segue para a opção "Adaptar", com a descrição "Partir de solução existente. Custo e risco intermediários; exige controle explícito das mudanças introduzidas.". Se a resposta for "não", o fluxo continua para uma terceira pergunta: "O ganho esperado justifica o prazo e o risco de pesquisar algo novo?". Se a resposta for "sim", direciona para a opção "Pesquisar", descrita como "Desenvolver abordagem nova. Maior prazo e risco; exige gates de decisão explícitos para continuar, pivotar ou parar.". Se a resposta for "não", o processo termina na caixa "Reabrir o escopo com o cliente". Na parte inferior direita, uma caixa em tom bege apresenta os critérios transversais considerados ao longo de toda a decisão: "cronograma, custo, controle, dependência, propriedade intelectual e risco." O fluxograma utiliza caixas arredondadas em tons de azul e bege, conectadas por setas que orientam a sequência lógica das decisões.

As perguntas da árvore se decidem contra seis critérios, que valem para as três opções e reaparecem ao longo do curso. Cronograma: quanto tempo cada opção consome até resultado validado, incluindo o tempo de aprender, integrar e testar. Custo: o esforço de desenvolvimento e o custo de operação depois da entrega, que são coisas diferentes e frequentemente puxam em direções opostas. Controle: o que você consegue mudar em cada opção quando o comportamento precisar ser ajustado. Dependência: de que fornecedores, licenças, serviços ou pessoas cada opção passa a depender, e o que acontece se essa dependência falhar. Propriedade intelectual: de quem é o resultado, o

que o contrato do projeto exige e o que cada opção permite. Risco: a probabilidade de a opção simplesmente não chegar ao resultado no prazo.

Cronograma e custo merecem o posto de critérios de justificativa mínima, e é neles que a evidência de aprendizagem deste bloco se ancora. Uma classificação postural sem estimativa de tempo e de esforço é uma opinião; com estimativa, ainda que grosseira, vira uma decisão examinável. Os outros quatro critérios qualificam a decisão: controle e dependência aparecem com força no bloco B3, quando a heurística se especializa na decisão build, buy ou integrate de componentes da solução; propriedade intelectual atravessa B3 e B4; risco organiza o B2. A heurística deste bloco é a matriz geral de que essas decisões posteriores são casos particulares.

⚠ ATENÇÃO

Entre pesquisadores, usar solução pronta soa como derrota intelectual, como se o valor do trabalho estivesse na dificuldade do que foi construído. A consequência é um viés sistemático contra a opção mais barata da árvore, mesmo quando ela atende aos critérios de sucesso. Em PD&I industrial, a régua é outra: usar bem, com levantamento honesto, integração limpa e validação rigorosa no contexto, é competência de engenharia, não atalho. O cliente paga por problema resolvido, não por esforço heroico.

Três cenários curtos mostram a heurística em movimento. Primeiro cenário: uma distribuidora precisa prever demanda semanal por produto para reduzir estoque parado. Bibliotecas maduras de previsão de séries temporais atendem os critérios de precisão levantados no escopo; a postura é usar, e o esforço do projeto migra para qualidade dos dados históricos e validação por categoria de produto. Segundo cenário: uma metalúrgica quer detectar defeitos de solda em imagens de inspeção. Modelos de visão pré-treinados existem, mas o defeito específico e as condições de iluminação da planta pedem ajuste com dados locais; a postura é adaptar, com esforço concentrado em montar um conjunto de dados anotado e em validar a adaptação. Terceiro cenário: uma indústria química quer otimizar um processo proprietário para o qual não há literatura aplicável nem base próxima; a postura é pesquisar, com prazo por tentativa e critérios de descarte acordados antes de começar.

Um padrão atravessa os três critérios de justificativa e vale explicitar, porque ele volta em todos os artefatos do caderno. Uma justificativa adequada tem três propriedades: nomeia o critério que a sustenta, conecta o critério ao cenário concreto e reconhece o custo assumido pela escolha. Escrevemos que a opção adaptar cabe no cronogra-

ma não é justificativa; é afirmação. Estimamos quatro semanas para adaptar e validar, contra oito de desenvolvimento próprio, assumindo o risco de dependência do modelo base é justificativa: tem número, tem contexto e declara o preço. O curso cobrará esse padrão em cada template, e a residência cobrará depois, quando as decisões forem questionadas por quem não participou delas.

> **Para aprofundar**
>
> AMERSHI, S. et al. Software Engineering for Machine Learning: A Case Study. ICSE, 2019. Estudo empírico na Microsoft sobre como equipes industriais constroem sistemas de ML na prática, com diferenças explícitas em relação ao trabalho acadêmico. Disponível em microsoft.com/en-us/research.

Um último traço da heurística importa para o resto do programa: ela não é uma decisão única tomada no início do projeto. Cada decisão técnica relevante ao longo do ciclo reabre a árvore em escala menor. Escolher um componente de pré-processamento, um modelo de linguagem, um mecanismo de busca ou uma ferramenta de monitoramento é, a cada vez, perguntar de novo se cabe usar, adaptar ou pesquisar. Durante a residência, a árvore será consultada com frequência, e a qualidade das justificativas registradas é o que tornará as decisões do squad defensáveis meses depois, quando alguém perguntar por que este caminho e não outro.

É exatamente esse registro que o primeiro artefato do caderno instrumenta. A ficha de classificação postural, que você preencherá para o cenário de exemplo do curso ao final deste bloco, pede a classificação do problema em usar, adaptar ou pesquisar e a justificativa explícita em termos de cronograma e custo. Antes dela, porém, falta apresentar o método que organiza todos os artefatos do curso, e é o que o próxio tópico faz.

3. O método e o caderno: CRISP-DM adaptado

Este tópico fecha o bloco. O objetivo é que você reconheça a estrutura do CRISP-DM adaptado como vocabulário do curso e identifique a função de cada artefato do caderno na sequência metodológica. Ela não corresponde a uma competência avaliada isoladamente: é a base sobre a qual as competências CP.B1.C1 e CP.B1.C2, e todas as competências dos blocos seguintes, serão exercitadas. A transição de postura dos tópicos anteriores precisa de um repertório operacional para se sustentar; método e caderno são esse repertório.

Um método de condução responde a uma pergunta que o entusiasmo técnico costuma atropelar: em que ordem as decisões de um projeto de IA devem ser tomadas. As cinco lentes do curso base deram a você critérios de decisão por tema: quando vale uma solução generativa, quando vale um agente, o que exigir dos dados, onde a inferência ocorre, quando a transparência é obrigação. O que as lentes não dão é a ordem em que

esses critérios são mobilizados num projeto real, nem os artefatos que registram cada decisão de forma defensável. É essa camada que o método fornece. Sem ela, um squad tecnicamente forte toma boas decisões na ordem errada: escolhe arquitetura antes de entender os dados, otimiza o modelo antes de acordar o critério de sucesso, descobre a restrição regulatória na semana da entrega.

O método de referência deste curso é uma adaptação do *CRISP-DM*. O framework original, publicado em 2000 por um consórcio industrial liderado por SPSS e Daimler-Chrysler, organiza projetos de mineração de dados em seis fases: compreensão do negócio, compreensão dos dados, preparação dos dados, modelagem, avaliação e implantação (deployment). Duas propriedades explicam sua longevidade. A primeira é o realismo sobre iteração: as fases não formam uma linha reta, e o framework prevê explicitamente o retorno de fases posteriores a anteriores, como quando a avaliação revela que o problema de negócio foi mal compreendido. A segunda é a neutralidade tecnológica: as fases descrevem o que precisa ser decidido, não com que ferramenta, o que o mantém aplicável duas décadas e muitas gerações de técnica depois. Ele permanece a referência metodológica mais reconhecida em PD&I industrial no Brasil, e é por essa língua franca que o curso começa.

GLOSSÁRIO

CRISP-DM

Cross-Industry Standard Process for Data Mining. Modelo de processo publicado em 2000 que organiza projetos de dados em seis fases com retorno: compreensão de negócio, compreensão de dados, preparação de dados, modelagem, avaliação e deployment. É a base metodológica que este curso adapta ao contexto contemporâneo de projetos de IA.

Vale fixar o que cada fase decide, porque esse vocabulário reaparece em todos os blocos. Compreensão de negócio: o que o cliente precisa, com que critério de sucesso e sob que restrições. Compreensão de dados: que dados existem, com que qualidade e com que lacunas. Preparação de dados: o trabalho de tornar os dados utilizáveis, tipicamente a fase mais longa e menos glamourosa do projeto. Modelagem: a construção e o ajuste das soluções candidatas. Avaliação: a verificação de que a solução atende ao critério de sucesso do negócio, e não apenas a uma métrica técnica. Deployment: a passagem da solução ao ambiente real, onde ela começa a valer ou a falhar. O retorno entre fases não é exceção: um projeto saudável volta atrás várias vezes, e o método serve justamente para que essas voltas sejam decisões registradas, não improvisos.

O CRISP-DM original, porém, foi escrito para um mundo em que o projeto terminava no deployment e o sistema entregue era estático. Projetos contemporâneos de IA quebram essa premissa, e a adaptação deste curso acrescenta quatro preocupações que o framework original não cobre. A primeira é a gestão de cronograma, custo e stakeholders: o original supõe que a organização já sabe gerir projetos e não diz como; este curso trata a gestão como conteúdo, no bloco B2. A segunda são os sistemas de aprendizagem em produção: um modelo em operação degrada com o tempo, exige monitoramento, retreinamento e controle de débito técnico, e esse ciclo de vida é o objeto do bloco B5. A terceira é a comunicação técnica para audiências não acadêmicas, tratada como competência transversal e desenvolvida no bloco B6. A quarta é a condução iterativa do trabalho entre os pontos de decisão: iterações com prazo fechado, incrementos verificáveis com critério de pronto e revisões que decidem se o projeto continua, pivota ou para. Essa quarta preocupação não tem bloco próprio: ela vive embutida nos eixos dos artefatos do caderno, e você a encontrará dentro do cronograma, da ficha de hipóteses e do status report, não num capítulo separado.

Uma observação sobre o espírito da adaptação evita um mal-entendido. Acrescentar preocupações de gestão a um método não significa importar cerimônias, papéis e rituais de frameworks de mercado. A escolha deste curso é embutir os mecanismos, não a liturgia: você encontrará prazos fechados, incrementos verificáveis, critérios de pronto e revisões de processo dentro dos eixos dos próprios artefatos, com o vocabulário mais simples possível. O objetivo é que a condução iterativa seja uma propriedade dos documentos que o squad já produz, e não uma camada adicional de reuniões sobre o trabalho.

Para aprofundar

STUDER, S. et al. Towards CRISP-ML(Q): A Machine Learning Process Model with Quality Assurance Methodology. Machine Learning and Knowledge Extraction, 2021. Preprint em arXiv.org/abs/2003.05155. Base publicada da adaptação do CRISP-DM a sistemas de aprendizagem em produção. Complementarmente: MICROSOFT. Team Data Science Process Documentation, em learn.microsoft.com.

A adaptação não é invenção isolada deste curso. O CRISP-ML(Q), publicado por Studer et al. em 2021, reorganiza o CRISP-DM para projetos de aprendizado de máquina, incorporando mecanismos explícitos de garantia de qualidade ao longo do processo e um ciclo contínuo de monitoramento e manutenção em produção. O Team Data Science Process, da Microsoft, é um descendente industrial do CRISP-DM que acrescenta papéis, estrutura de repositório e cadência iterativa de trabalho. O método deste curso bebe dos dois, mas mantém o esqueleto do CRISP-DM pela razão prática já dita: é o vocabulário que as empresas parceiras da residência têm mais chance de reconhecer.

O quadro a seguir mapeia as fases adaptadas aos blocos do curso.

Quadro 1 - Mapeamento entre o método e os blocos do curso.

Bloco	Fase ou preocupação do método	O que o bloco entrega
B1	Fundação: postura profissional e método	Contraste de posturas, heurística usar-a-daptar-pesquisar, apresentação do caderno.
B2	Compreensão de negócio e gestão de projeto	Escopo, stakeholders, cronograma com gates e cadência, risco operacional.
B3	Modelagem em chave decisória e arquitetura	Hipóteses e experimentos, alternativas, decisão build/buy/integrate, arquitetura pelas cinco lentes, fornecedores e PI.
B4	Compreensão e preparação de dados em chave operacional	Plano de aquisição de dados, governança, regulatório e PI de dados.
B5	Avaliação, deployment e ciclo de vida em produção	Plano de validação e teste, avaliação contínua, prontidão para produção, runbook, débito técnico.
B6	Comunicação e transparência (transversal)	Status report por audiência, defesa de decisão, model card, datasheet.

Para cego ver: A imagem apresenta uma tabela intitulada "Quadro 1 – Mapeamento entre o método e os blocos do curso". A tabela possui três colunas: Bloco, Fase ou preocupação do método e O que o bloco entrega. São apresentados seis blocos, identificados de B1 a B6. No B1, a fase corresponde à Fundação: postura profissional e método, e as entregas incluem contraste de posturas, heurística usar-adaptar-pesquisar e apresentação do caderno. No B2, a fase é Compreensão de negócio e gestão de projeto, com entregas relacionadas a escopo, stakeholders, cronograma com gates e cadência, além de risco operacional. No B3, a fase trata da Modelagem em chave decisória e arquitetura, entregando hipóteses, decisão entre construir, comprar ou integrar soluções, arquitetura pelas cinco lentes, fornecedores e propriedade intelectual. No B4, a fase corresponde à Compreensão e preparação de dados em chave operacional, com entregas como plano de aquisição de dados, governança, aspectos regulatórios e plano de integração de dados. No B5, a fase aborda Avaliação, deployment e ciclo de vida em produção, entregando plano de validação e teste, avaliação contínua, prontidão para produção, runbook e gestão de débito técnico. No B6, a fase é Comunicação e transparência, indicada como transversal, com entregas como status report por audiência, defesa de decisão, model card e datasheet. A tabela utiliza cabeçalho em azul-claro, linhas brancas e bordas cinzas, organizando de forma estruturada a relação entre cada bloco do curso, sua finalidade e os principais resultados esperados.

Uma nota sobre a ordem de apresentação, para quem chega com o CRISP-DM canônico em mente: lá, a compreensão e a preparação dos dados vêm antes da modelagem; aqui, o quadro mostra o bloco de dados (B4) depois do bloco de decisão e arquitetura (B3). A inversão é deliberada e pedagógica: a decisão de solução estabelece o vocabulário com que as escolhas sobre dados serão registradas, e o plano operacional de dados depende da rota decidida, porque desenvolver, comprar e integrar mudam o que é preciso obter. Ela vale para a apresentação, não para a prática do método: a leitura do lastro de dados que antecede qualquer decisão acontece no B2, dentro da delimitação do escopo, e os experimentos que sustentam a decisão do B3 trabalham sobre os dados existentes confirmados ali.

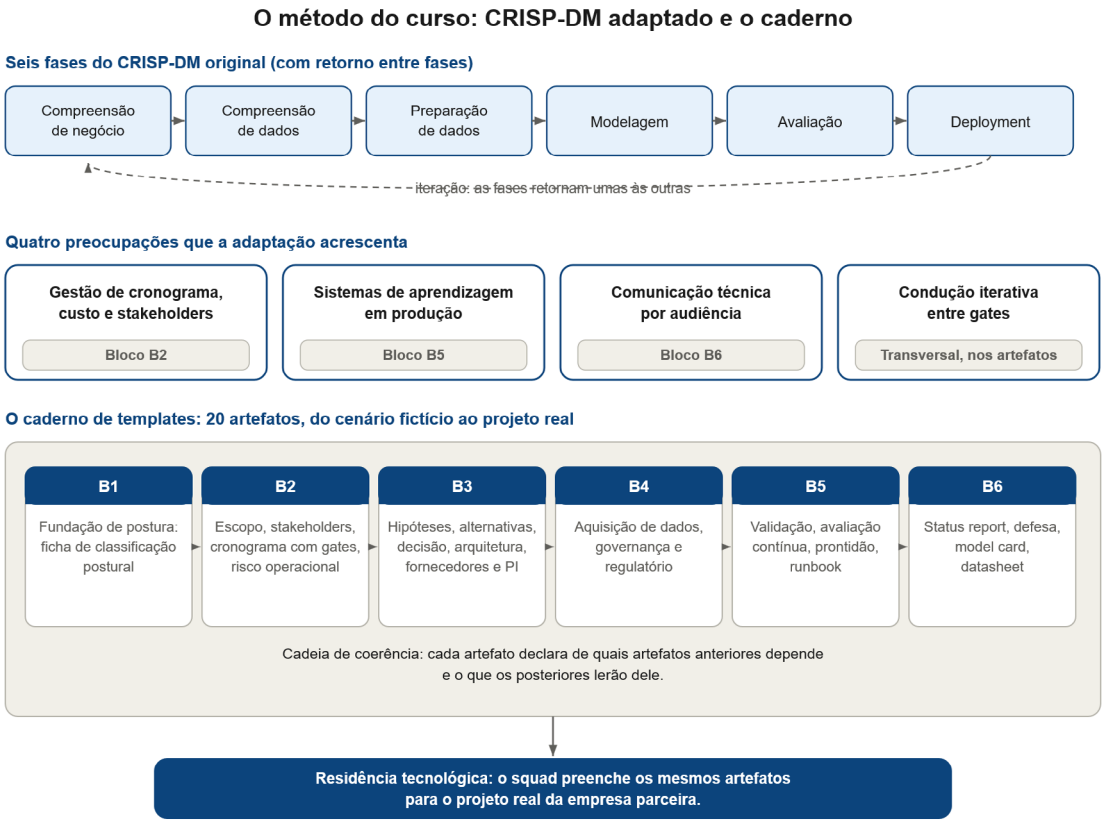
Falta o segundo elemento do repertório, e o mais concreto: o caderno de templates. O caderno é o artefato central do curso e reúne vinte artefatos, distribuídos pelos blocos conforme o quadro acima: um no B1, quatro no B2, cinco no B3, dois no B4, quatro no B5 e quatro no B6. Cada artefato vem preenchido e comentado, com exemplos do que uma decisão daquele tipo precisa registrar.

Duas propriedades do caderno merecem destaque desde já. A primeira é a cadeia de coerência: os artefatos não são fichas isoladas, e sim elos de uma sequência em que cada um declara de quais artefatos anteriores depende e o que os posteriores lerão dele. O escopo alimenta o cronograma e o risco; as hipóteses alimentam as alternati-

vas e a decisão; a decisão alimenta a arquitetura; a arquitetura condiciona os dados; os dados condicionam a validação; a validação sustenta a operação; e tudo isso desagua na comunicação e na transparência. Um artefato incoerente com os anteriores é um sinal de alerta tão sério quanto um teste que falha. A segunda propriedade é a função de ponte com a residência: os mesmos artefatos que o caderno apresenta serão também preenchidos pelo squad para o projeto real da empresa parceira. O caderno é, nesse sentido, a interface entre o curso e a residência, e o investimento em preenchê-lo bem agora é treino direto para o trabalho que importa depois.

Por que cenários de exemplo, e não o projeto real desde o início? Porque uma decisão registrada sobre um caso concreto ensina o que nenhuma descrição abstrata ensina: onde a justificativa se apoia, que custo ela assume e o que ficaria diferente se a premissa caísse. O caso simulado permite ver isso sem que um erro de leitura custe credibilidade com um cliente. E o instrumento demonstrado aqui é literalmente o mesmo que o squad preencherá no laboratório presencial e na residência, o que faz do caderno um treino direto, e não um exercício de curso.

Figura 3 - CRISP-DM adaptado e o caderno de templates.



Fonte: autor. Arquivo: B1_fig-3_crisp_dm_adaptado_caderno.svg

Para cego ver: A imagem apresenta um diagrama intitulado "Figura 3 – CRISP-DM adaptado e o caderno de templates", com o subtítulo "O método do curso: CRISP-DM adaptado e o caderno". Na parte superior, é exibido o fluxo das seis fases do CRISP-DM original, representadas por caixas azuis conectadas por setas: Compreensão de negócio, Compreensão de dados, Preparação de dados, Modelagem, Avaliação e Deployment. Uma seta curva pontilhada abaixo dessas etapas indica que as fases podem retornar umas às outras, destacando o caráter iterativo do método. Na região central, o diagrama apresenta quatro preocupações adicionais introduzidas pela adaptação do método, cada uma em uma caixa destacada. A primeira é Gestão de cronograma, custo e stakeholders, associada ao Bloco B2. A segunda é Sistemas de aprendizagem em produção, relacionada ao Bloco B5. A terceira é Comunicação técnica por audiência, vinculada ao Bloco B6. A quarta é Condução iterativa entre gates, indicada como um elemento transversal aos artefatos. Na parte inferior, há uma seção intitulada "O caderno de templates: 20 artefatos, do cenário fictício ao projeto real", composta por seis blocos identificados de B1 a B6. O B1 reúne os artefatos de fundação de postura e ficha de classificação postural. O B2 contempla escopo, stakeholders, cronograma com gates e risco operacional. O B3 reúne hipóteses, alternativas, decisão arquitetural, fornecedores e propriedade intelectual. O B4 aborda aquisição de dados, governança e aspectos regulatórios. O B5 trata de validação, avaliação contínua, prontidão para produção e runbook. O B6 reúne status report, defesa de decisão, model card e datasheet. Logo abaixo dos blocos, uma observação explica que existe uma cadeia de coerência, em que cada artefato declara de quais artefatos anteriores depende e quais artefatos posteriores utilizarão suas informações. Na parte inferior da figura, uma faixa azul destaca a mensagem: "Residência tecnológica: o squad preenche os mesmos artefatos para o projeto real da empresa parceira." O diagrama utiliza tons de azul, branco e bege, com caixas arredondadas e setas que evidenciam o fluxo metodológico e a relação entre o método, os blocos do curso e os artefatos produzidos.

Exemplo aplicado

Num projeto de manutenção preditiva para uma empresa de energia, o squad da residência reaproveitou os instrumentos do caderno como esqueleto do projeto real. A ficha de escopo virou a pauta da primeira reunião com o cliente; o cronograma com gates virou o plano acordado com o mentor; a matriz de risco antecipou a dependência crítica de dados de sensores que a empresa ainda precisava liberar. O caderno se pagou na primeira quinzena do projeto real.

Como este curso funciona na prática, então. Cada bloco combina um vídeo curto de orientação, um ebook como este, os templates do caderno correspondentes e um quiz formativo com aproveitamento mínimo de setenta por cento. Os quizzes privilegiam cenários de decisão sobre memorização: a pergunta típica descreve uma situação de condução e pede a leitura adequada dela, no espírito das partes deste bloco. O percurso recomendado dentro de cada bloco segue a ordem dos objetos: vídeo, ebook, templates, quiz. Para este bloco B1, o artefato do caderno é a ficha de classificação postural, que instrumenta diretamente a heurística do tópico 2: diante do cenário de exemplo do curso, a ficha classifica o problema em usar, adaptar ou pesquisar e sustentará a classificação com justificativa explícita de cronograma e custo.

A relação deste bloco com os momentos presenciais é direta. O Encontro 1 da Formação 1, Compreender o caso e delimitar o problema, coloca o squad diante do caso simulado pela primeira vez, e a qualidade dessa primeira leitura depende da postura com que ela é feita. Um squad em postura de pesquisa tende a aprofundar tecnicamente antes de delimitar; um squad em postura de PD&I começa pelo escopo, pelos critérios de sucesso e pelos dados disponíveis. O contraste do tópico 1 e a heurística do tópico 2 são, nesse sentido, a preparação assíncrona do primeiro encontro. E na residência, ao longo dos seis meses, a heurística será revisitada a cada decisão técnica relevante, com o caderno registrando as justificativas.

4. Conclusão

Os 3 tópicos deste ebook fundaram, em conjunto, a transição que dá nome ao bloco. O tópico 1 estabeleceu o contraste entre a postura do pesquisador e a postura do engenheiro de PD&I industrial em quatro dimensões: horizonte de tempo, métrica de sucesso, tipo de entrega e relação com o destinatário. O tópico 2 entregou o primeiro instrumento operacional da nova postura, a heurística usar-adaptar-pesquisar, com a árvore de decisão e os seis critérios que sustentam a justificativa, dos quais cronograma e custo são o mínimo exigível. O tópico 3 apresentou o repertório que organiza o resto do curso: o CRISP-DM adaptado, com as quatro preocupações que o original não cobre, e o caderno de templates como artefato central e ponte com a residência.

O ganho prático deste bloco é uma mudança de primeira pergunta. Diante de um problema industrial, a primeira pergunta deixa de ser o que há de tecnicamente interessante aqui e passa a ser o que este cliente precisa, em quanto tempo, com que critério de sucesso, e quanta originalidade isso de fato exige. Nada nessa mudança abandona o rigor de pesquisador; ela o redireciona para onde o contexto industrial o cobra: na validação, na justificativa das decisões e na honestidade sobre limitações.

Antes de avançar, percorra no caderno a ficha de classificação postural, que traz o preenchimento comentado para o cenário de exemplo e a instrução de uso eixo a eixo. Feche o bloco com o quiz formativo. O bloco B2 parte do ponto em que este termina: com a postura estabelecida, a primeira fase do método entra em cena. Você aprenderá a traduzir um problema de negócio em problema técnico delimitado e a estruturar o cronograma, os gates e o risco que tornam essa tradução conduzível.

REFERÊNCIAS

Bibliografia mínima

KARPATHY, A. Software 2.0. Medium, 2017. Disponível em medium.com/@karpathy/software-2-0-a64152b37c35. Referência sobre a transição cognitiva entre engenharia de software clássica e engenharia de sistemas baseados em ML.

AMERSHI, S. et al. Software Engineering for Machine Learning: A Case Study. In: International Conference on Software Engineering (ICSE), 2019. Estudo empírico sobre prática de engenharia de ML em ambiente industrial, com diferenças explícitas em relação à pesquisa acadêmica.

CHAPMAN, P. et al. CRISP-DM 1.0: Step-by-step data mining guide. SPSS Inc., 2000. Referência metodológica histórica do framework adaptado por este curso.

Bibliografia complementar

STUDER, S. et al. Towards CRISP-ML(Q): A Machine Learning Process Model with Quality Assurance Methodology. Machine Learning and Knowledge Extraction, 2021. Preprint em arXiv.org/abs/2003.05155. Base publicada para a adaptação do CRISP-DM a sistemas de aprendizagem em produção.

MICROSOFT. Team Data Science Process Documentation. learn.microsoft.com, edição em curso. Descendente do CRISP-DM com estrutura de repositório, papéis e cadência iterativa.

MARTÍNEZ-PLUMED, F. et al. CRISP-DM Twenty Years Later: From Data Mining Processes to Data Science Trajectories. IEEE Transactions on Knowledge and Data Engineering, 2021. Atualização crítica do CRISP-DM para o contexto contemporâneo.

SHEARER, C. The CRISP-DM model: the new blueprint for data mining. Journal of Data Warehousing, v. 5, n. 4, 2000. Apresentação original do framework.

BROWN, T. B. et al. Language Models are Few-Shot Learners. In: Advances in Neural Information Processing Systems (NeurIPS), 2020. Nota de contexto sobre a mudança de escala que pressiona a passagem para a postura de engenharia.

Industr.IA

Residência em TIC 49



Executor iRede

Executor Atlântico

Coordenador Softex

Financiador MCTI Futuro

Ministério da Ciência, Tecnologia e Inovação

Governo do Brasil — Do lado do povo brasileiro

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.