Industr.IA

E-book

Data-centric AI: qualidade de dados, análise de erro e viés

Curso base de IA | Unidade M3

Prof.: Arthur Nascimento



SUMÁRIO

1. O deslocamento data-centric 3
2. Vocabulário regulatório 5
3. Um framework de data quality 8
4. Error analysis estruturado por slices 10
5. Análise estruturada de viés 12
6. Conclusão 14

Unidade M3

1. O deslocamento data-centric

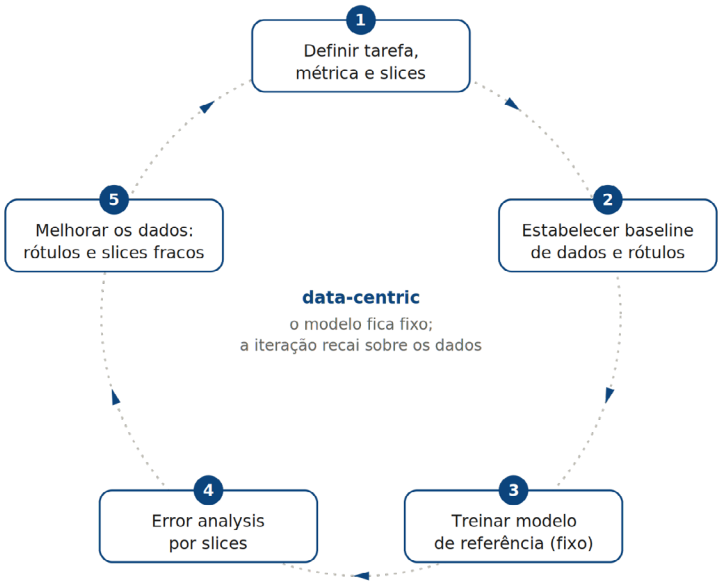
Esta seção pertence à camada conceitual e tem por objetivo que você reconheça o deslocamento do trabalho centrado no modelo para o trabalho centrado nos dados, e entenda por que, na maior parte dos problemas de PD&I industrial, são os dados que determinam o teto de qualidade de uma solução.

Por muitos anos, melhorar um sistema de aprendizado de máquina significou, na prática, mexer no modelo: trocar a arquitetura, ajustar hiperparâmetros, empilhar mais camadas, experimentar um algoritmo mais recente. Os dados eram tratados como um insumo fixo, congelado no início do projeto, sobre o qual nada mais se fazia. Essa postura tem um nome, abordagem centrada no modelo, e por muito tempo foi o reflexo automático de quem buscava ganho de desempenho.

A abordagem centrada em dados (data-centric) inverte essa ordem de prioridade. Em vez de manter os dados fixos e iterar sobre o modelo, mantém-se um modelo de referência (baseline model) fixo e itera-se de forma sistemática sobre os dados: corrigir rótulos errados, padronizar a coleta, cobrir os subgrupos mal representados, remover duplicatas e ambiguidades. A tese, popularizada por Andrew Ng, é simples de enunciar e desconfortável de aceitar: na maioria dos problemas aplicados, o caminho mais curto para um sistema melhor passa pelos dados, e não pela arquitetura.

A razão é que os dados determinam o teto de qualidade alcançável, e o modelo apenas decide quanto desse teto se alcança. Um conjunto de dados com rótulos inconsistentes, lacunas de cobertura e medições ruidosas impõe um limite que nenhuma arquitetura supera; trocar uma floresta aleatória por uma rede profunda sobre o mesmo dado defeituoso costuma render uma fração de ponto, enquanto sanear o dado pode render vários. Em muitos problemas tabulares e de visão industrial encontrados em PD&I, esse desequilíbrio é a regra, e não a exceção.

Figura 1. Ciclo data-centric.



Fonte: autor.

Para cego ver: Figura intitulada "Figura 1. Ciclo data-centric". O diagrama apresenta um ciclo circular composto por cinco etapas conectadas por setas pontilhadas, indicando um processo contínuo de melhoria dos dados. No topo está a etapa 1, com o texto: "Definir tarefa, métrica e slices". À direita, a etapa 2: "Estabelecer baseline de dados e rótulos". Na parte inferior direita, a etapa 3: "Treinar modelo de referência (fixo)". Na parte inferior esquerda, a etapa 4: "Error analysis por slices". À esquerda, a etapa 5: "Melhorar os dados: rótulos e slices fracos". No centro do ciclo, em destaque, aparece a expressão "data-centric", acompanhada da explicação: "o modelo fica fixo; a iteração recai sobre os dados". Todo o diagrama utiliza caixas de contorno azul com cantos arredondados, círculos azuis numerados e setas formando um ciclo fechado, reforçando a ideia de um processo iterativo focado na melhoria contínua da qualidade dos dados. Na parte inferior da figura consta a indicação "Fonte: autor."

No ciclo data-centric, o modelo de referência é mantido fixo e cada volta do laço melhora os dados, orientada pela análise de erro por slices.

O ciclo da figura organiza esse trabalho como um laço repetível: (1) Define-se a tarefa, a métrica e os slices de interesse; (2) estabelece-se um conjunto de dados e rótulos de partida;(3) treina-se um modelo de referência que permanecerá fixo; (4) conduz-se a análise de erro por slices, tema do tópico 4; e (5) a partir desta análise, melhora-se o dado onde ele é mais fraco, antes de fechar a volta e treinar de novo. Dentro do ciclo data-centric, o modelo serve de instrumento de diagnóstico do dado, e não de objeto de otimização.

GLOSSÁRIO

Dataset drift

Mudança, ao longo do tempo, na distribuição dos dados que o sistema recebe em produção em relação à distribuição sobre a qual foi treinado. Pode ser gradual (desgaste de equipamento que altera leituras de sensor) ou abrupta (troca de fornecedor, mudança de processo). É uma das razões pelas quais um modelo bom no lançamento degrada com o tempo, ainda que nada no código mude. Quando o que muda é a relação entre entradas e saídas, e não a distribuição das entradas, fala-se em concept drift, tratado nos cursos de Machine Learning da Fase 2

A abordagem data-centric não substitui a escolha de modelo em todos os casos; ela se mostra mais vantajosa em condições específicas, que vale reconhecer. Quando há poucos dados, cada exemplo pesa muito, e limpar ou enriquecer a amostra rende mais do que aumentar a capacidade do modelo. Quando o ruído de rótulo é alto, o modelo aprende o ruído, e nenhuma arquitetura corrige rótulos errados. Quando há distribution shift entre treino e produção, parte importante do ganho está em alinhar os dados de treino à realidade de uso. E, por fim, quando o problema tem uma cauda longa (long tail), isto é, muitos casos raros que, somados, pesam mais do que parecem, são poucos exemplos bem escolhidos, e não mais camadas, que fecham a lacuna.

Exemplo aplicado

Uma fábrica de autopeças treina um classificador de defeitos sobre fotos da linha de produção e estaciona em 88 por cento de recall, apesar de várias trocas de arquitetura. A análise de erro revela que metade dos defeitos não detectados ocorre sob um tipo de iluminação introduzido após a coleta original. Adicionar algumas centenas de imagens nessa condição, sem trocar o modelo, eleva o recall mais do que qualquer ajuste anterior. Neste caso, o gargalo era o dado, e não a rede.

Armadilha comum

A armadilha mais cara desta seção é o reflexo centrado no modelo: diante de um resultado insatisfatório, partir direto para uma arquitetura mais nova, gastando o orçamento de tempo e computação onde o retorno é menor. A consequência é um ciclo de experimentos de modelo que rende pouco enquanto o verdadeiro gargalo, um conjunto de dados com rótulos ruidosos ou cobertura desigual, permanece intocado. Antes de trocar o modelo, vale perguntar se o dado já está no seu melhor.

Com o deslocamento data-centric estabelecido como forma de organizar o esforço, falta fixar o vocabulário que delimita o que se pode e o que não se pode fazer com os dados, sobretudo quando envolvem pessoas.

2. Vocabulário regulatório

Esta seção pertence à camada conceitual e tem por objetivo que você reconheça os pontos em que LGPD, GDPR e EU AI Act incidem sobre um pipeline de dados para IA, e

saiba nomear a base legal de um tratamento e a proveniência dos dados. O curso trata IA responsável dentro deste módulo, por decisão estrutural, e é nos dados que a maior parte das obrigações regulatórias se materializa.

A escolha de tratar regulação junto com dados não é apenas organizacional. Quase toda obrigação legal relevante para um sistema de IA recai sobre o ciclo de vida do dado: que dado pode ser coletado, com que finalidade, por quanto tempo, com que garantias e com qual rastreabilidade. No Brasil, onde este curso se situa, a LGPD é a referência que governa esse ciclo, e é por ela que o trabalho começa; o GDPR e o EU AI Act entram como referência internacional, aplicável a quem atua com dados, clientes ou operações na Europa e útil como parâmetro técnico de governança mesmo a quem opera apenas em território nacional.

No Brasil, a Lei Geral de Proteção de Dados (LGPD) disciplina o tratamento de dados pessoais. Ela exige uma base legal para cada tratamento (consentimento, cumprimento de obrigação legal ou regulatória, execução de contrato, legítimo interesse, entre outras), impõe os princípios de finalidade, adequação e minimização, e dá tratamento reforçado aos dados pessoais sensíveis. Na Europa, o GDPR cumpre papel equivalente e acrescenta, no Artigo 22, limites a decisões inteiramente automatizadas com efeito significativo sobre a pessoa, um ponto que reaparece no módulo M5 sob a lente da transparência.

O EU AI Act, regulamento europeu publicado em 2024, organiza os sistemas por nível de risco e impõe aos sistemas de alto risco, no Artigo 10, requisitos diretos de governança de dados: os conjuntos de treino, validação e teste devem ser relevantes, suficientemente representativos e examinados quanto a erros e a vieses. O EU AI Act torna requisitos de qualidade e representatividade dos dados obrigações legais para sistemas de alto risco, e não apenas boas práticas de engenharia. No Brasil, o Projeto de Lei 2338 caminha em direção semelhante e deve ser acompanhado.

Quadro 1 - Onde cada instrumento regulatório incide no pipeline de dados.

Instrumento	Foco principal	Ponto de incidência no pipeline
LGPD (Lei 13.709/2018)	dados pessoais, base legal e finalidade	coleta, armazenamento, retenção e compartilhamento
GDPR (Reg. 2016/679)	dados pessoais e decisão automatizada	coleta, transferência internacional e uso em decisão (Art. 22)
EU AI Act (Reg. 2024/1689)	qualidade e representatividade do dado	construção dos conjuntos de treino, validação e teste (Art. 10)

Para cego ver: Quadro 1 intitulado "Onde cada instrumento regulatório incide no pipeline de dados." A figura apresenta uma tabela com três colunas: Instrumento, Foco principal e Ponto de incidência no pipeline, comparando três normas e regulamentações relacionadas à proteção de dados e à inteligência artificial.Na primeira linha, a LGPD (Lei nº 13.709/2018) tem como foco principal os dados pessoais, a base legal e a finalidade do tratamento. Sua atuação no pipeline de dados abrange as etapas de coleta, armazenamento, retenção e compartilhamento das informações.Na segunda linha, o GDPR (Regulamento 2016/679 da União Europeia) concentra-se na proteção de dados pessoais e na tomada de decisão automatizada. Sua incidência ocorre na coleta de dados, na transferência internacional de informações e no uso desses dados em decisões automatizadas, conforme previsto no Artigo 22. Na terceira linha, o EU AI Act (Regulamento 2024/1689) tem como foco principal a qualidade e a representatividade dos dados utilizados em sistemas de inteligência artificial. Sua atuação concentra-se nas etapas de construção dos conjuntos de treinamento, validação e teste dos modelos, conforme estabelecido no Artigo 10. A tabela utiliza cabeçalhos em azul-claro e organiza as informações em linhas, permitindo comparar de forma objetiva o foco de cada instrumento regulatório e o momento do pipeline de dados em que cada um exerce maior influência.

GLOSSÁRIO

Base legal de tratamento

Fundamento jurídico que autoriza tratar um dado pessoal. Sob a LGPD, todo tratamento precisa de pelo menos uma: consentimento, cumprimento de obrigação legal, execução de contrato, legítimo interesse, entre outras. *Não* basta ter o dado disponível; é preciso poder apontar a base legal que justifica usá-lo para a finalidade declarada.

Data lineage

Registro rastreável da origem de cada dado e de todas as transformações por que passou até chegar ao conjunto de treino. Sustenta auditoria, reprodutibilidade e resposta a pedidos de titulares, e é pré-requisito prático para demonstrar

Armadilha comum

Uma armadilha frequente é supor que anonimizar os dados encerra as obrigações legais. A reidentificação a partir de atributos combinados é possível com mais frequência do que se imagina, e dados apenas pseudonimizados continuam sob a lei. Outra é coletar primeiro e pensar na base legal depois: a finalidade precisa ser definida antes da coleta, e não justificada retroativamente quando o dado já foi usado.

SAIBA MAIS

O texto integral da LGPD está em portais públicos da Presidência da República; o Artigo 10 do EU AI Act, sobre governança de dados de sistemas de alto risco, está em eur-lex.europa.eu. O detalhamento operacional de conformidade em pipelines de produção, incluindo data lineage em escala, é tratado no curso de Engenharia de Dados da Fase 2 do programa.

Fixado o que a lei exige dos dados, o passo seguinte é dispor de um instrumento para medir, de forma sistemática, se um conjunto de dados está à altura da tarefa.

3. Um framework de data quality

Esta seção pertence à camada aplicada e tem por objetivo que você aplique um framework de qualidade de dados a um conjunto concreto, avaliando-o por seis dimensões objetivas. A qualidade de um dataset não é uma impressão geral, e sim um conjunto de propriedades verificáveis, cada uma com um teste próprio, e tratá-la assim transforma uma queixa difusa de dado ruim em uma lista de problemas endereçáveis.

As seis dimensões a seguir cobrem a maior parte das falhas observadas em dados de PD&I industrial. Completude pergunta se há valor onde deveria haver valor. Consistência pergunta se os campos e registros concordam entre si, sem contradições. Acurácia pergunta se o valor registrado corresponde ao mundo real. Atualidade pergunta se o dado reflete o estado vigente relevante para a decisão. Validade pergunta se cada valor respeita o formato e o domínio esperados. Unicidade pergunta se não há duplicatas indevidas inflando a amostra.

Quadro 2 - Seis dimensões de data quality, com teste objetivo e falha típica.

Dimensão	Teste objetivo	Falha típica
Completude	fração de campos preenchidos onde se espera valor	sensor sem leitura em parte dos registros
Consistência	ausência de contradição entre campos e fontes	data de reparo anterior à data de falha
Acurácia	correspondência com a medida real de referência	rótulo de defeito atribuído à peça errada
Atualidade	defasagem entre o dado e o estado atual	cadastro de equipamento desatualizado há meses
Validade	conformidade a formato, faixa e domínio	temperatura abaixo do zero absoluto
Unicidade	ausência de duplicatas não intencionais	mesmo evento registrado por dois sistemas

Para cego ver: Quadro 2 intitulado "Seis dimensões de data quality, com teste objetivo e falha típica." A figura apresenta uma tabela com três colunas: Dimensão, Teste objetivo e Falha típica, descrevendo seis critérios utilizados para avaliar a qualidade de dados em sistemas de informação. Na primeira linha, a dimensão Completude (Completeness) verifica a fração de campos preenchidos onde se espera a existência de um valor. Como exemplo de falha típica, apresenta um sensor sem leitura em parte dos registros. Na segunda linha, a dimensão Consistência avalia a ausência de contradições entre campos e diferentes fontes de dados. Um exemplo de falha é uma data de reparo registrada como anterior à data da falha. Na terceira linha, a dimensão Acurácia verifica a correspondência entre os dados registrados e a medida real de referência. A falha típica apresentada é um rótulo de defeito atribuído à peça errada. Na quarta linha, a dimensão Atualidade mede a defasagem entre a informação registrada e o estado atual do objeto ou processo. Como exemplo, é citado um cadastro de equipamento desatualizado há vários meses. Na quinta linha, a dimensão Validade verifica a conformidade dos dados com formatos, faixas de valores e domínios permitidos. A falha típica apresentada é o registro de uma temperatura negativa em escala absoluta, um valor fisicamente impossível. Na sexta e última linha, a dimensão Unicidade avalia a ausência de registros duplicados não intencionais. O exemplo de falha é o mesmo evento registrado simultaneamente por dois sistemas diferentes. A tabela utiliza cabeçalhos em azul-claro e organiza as informações em linhas, permitindo comparar de forma objetiva cada dimensão da qualidade de dados, seu critério de avaliação e um exemplo representativo de falha.

Aplicar o framework a um dataset concreto é um exercício direto. Tome o registro de manutenção preditiva de uma planta, com leituras de vibração, temperatura e corrente

por motor, mais uma coluna que marca falhas. A completude se mede pela fração de leituras ausentes por sensor; a consistência, verificando se nenhuma data de reparo precede a falha que a motivou; a acurácia, conferindo uma amostra de rótulos contra o registro de ordens de serviço; a atualidade, checando se o cadastro de equipamentos acompanha as trocas recentes; a validade, rejeitando temperaturas fora da faixa física plausível; a unicidade, removendo eventos contados duas vezes por integração entre sistemas. Cada dimensão vira uma verificação automatizável.

Exemplo aplicado

Numa distribuidora de energia, um modelo de previsão de demanda apresentava erro alto em dias específicos. A auditoria de qualidade encontrou duas falhas combinadas: registros duplicados de medidores reinstalados, ferindo a unicidade, e leituras com fuso horário trocado em uma subestação, ferindo a validade. Nenhuma exigia trocar o modelo; corrigidas, o erro nos dias problemáticos caiu pela metade.

Boa parte dessas verificações pode ser automatizada por ferramentas dedicadas, que vale conhecer em alto nível. Great Expectations permite declarar expectativas de qualidade (faixas válidas, ausência de nulos, unicidade de chaves) e testá-las a cada ingestão, como testes de unidade para dados. DVC e lakeFS versionam conjuntos de dados e suas transformações, dando suporte a data lineage e reprodutibilidade, o primeiro próximo do fluxo de um repositório de código e o segundo em escala de data lake sobre armazenamento de objetos. Cleanlab estima, de forma estatística, quais rótulos têm maior probabilidade de estar errados, automatizando parte da auditoria de acurácia. Os links para a documentação dessas ferramentas estão na bibliografia complementar, e o critério de escolha entre elas e a operação em produção ficam para o curso de Engenharia de Dados da Fase 2.

Armadilha comum

Um erro recorrente é medir a qualidade de forma agregada, sobre o dataset inteiro, e declarar o dado bom porque o número global é alto. A falha de qualidade quase sempre se concentra em um subconjunto, um sensor, uma linha de produção, uma faixa de clientes, e a média dilui o problema até ele desaparecer do relatório. A qualidade precisa ser olhada por recorte, o que conduz diretamente à análise de erro por slices.

SAIBA MAIS

Para aprofundar

Para o panorama dos desafios de coleta e qualidade sob a ótica data-centric, veja WHANG, S. E. et al., Data Collection and Quality Challenges in Deep Learning, em arxiv.org/abs/2112.06409. O versionamento de dados em escala e a engenharia de pipelines de validação são aprofundados no curso de Engenharia de Dados da Fase 2 do programa.

Medir qualidade por recorte exige um método para definir recortes e ler desempenho dentro de cada um. Esse método é a análise de erro estruturada por slices.

4. Error analysis estruturado por slices

Esta seção pertence à camada aplicada e tem por objetivo que você conduza uma análise de erro (*error analysis)* estruturada por slices, identifique disparidades de desempenho entre subgrupos e proponha uma intervenção orientada por evidência. É a etapa do ciclo data-centric que diz, com precisão, onde melhorar o dado.

Uma métrica global é uma média, e médias escondem onde o sistema falha. Um modelo com 92 por cento de acurácia geral pode ter 99 por cento em um subgrupo e 70 por cento em outro, e é justamente o subgrupo fraco que costuma importar na operação. Um slice é um subconjunto dos dados definido por um critério interpretável: uma faixa etária, uma região, um tipo de equipamento, um turno de produção, uma condição de iluminação. Analisar o erro por slice é medir a métrica dentro de cada um desses recortes, em vez de apenas no todo.

O procedimento é repetível em cinco passos. Primeiro, definir os slices relevantes a partir do conhecimento do domínio e dos atributos disponíveis. Segundo, medir a métrica que importa dentro de cada slice. Terceiro, ordenar os slices pelo tamanho do gap em relação ao desempenho global, ponderando pelo número de exemplos. Quarto, inspecionar manualmente uma amostra de erros dos slices piores, para entender a causa. Quinto, decidir a intervenção: coletar mais dados do slice, corrigir rótulos, criar um atributo que capture a distinção, ou, em alguns casos, aceitar o limite e documentá-lo.

Quadro 3 - Exemplo de leitura de desempenho por slice, com recall e tamanho do slice.

Slice	Exemplos (n)	Recall no slice	Gap vs. global
Global	20.000	0,91	referência
Equipamento tipo A	12.400	0,95	+0,04
Equipamento tipo B	5.900	0,88	-0,03
Equipamento tipo C	1.700	0,67	-0,24

Para cego ver: Quadro 3 intitulado "Exemplo de leitura de desempenho por slice, com recall e tamanho do slice." A figura apresenta uma tabela com quatro colunas: Slice, Exemplos (n), Recall no slice e Gap vs. global, ilustrando o desempenho de um modelo de inteligência artificial em diferentes grupos de dados. Na primeira linha, o Global representa o conjunto completo de dados, com 20.000 exemplos e recall de 0,91, utilizado como referência para comparação. Na segunda linha, o Equipamento tipo A possui 12.400 exemplos, recall de 0,95 e um gap de +0,04 em relação ao desempenho global, indicando desempenho superior ao da média do conjunto. Na terceira linha, o Equipamento tipo B apresenta 5.900 exemplos, recall de 0,88 e um gap de -0,03, indicando desempenho ligeiramente inferior ao valor global. Na quarta linha, o Equipamento tipo C reúne 1.700 exemplos, recall de 0,67 e um gap de -0,24, evidenciando um desempenho significativamente inferior ao observado no conjunto completo de dados. A tabela utiliza cabeçalhos em azul-claro e organiza as informações em linhas, permitindo comparar o tamanho de cada slice, seu desempenho medido por recall e a diferença em relação ao resultado global do modelo.

No quadro, o desempenho global de 0,91 esconde um slice crítico: o equipamento tipo C, com recall de 0,67 e gap de 0,24, concentra a falha. Como tem 1.700 exemplos, o problema é real e endereçável. A leitura sugere a intervenção: reunir e rotular mais casos do tipo C, ou investigar se seus rótulos são menos confiáveis, antes de qualquer mudança no modelo. A decisão entre intervir nos dados e trocar o modelo, que esta evidência prepara, é tratada formalmente no texto-base decisório do módulo.

GLOSSÁRIO

Slice

Subconjunto dos dados definido por um critério interpretável, como uma faixa de valores, uma categoria ou uma condição de coleta. Diferente de uma partição *aleatória*, o slice é escolhido por ter significado de domínio, o que permite ler o desempenho do modelo onde ele de fato importa e localizar a falha em um recorte específico.

Exemplo aplicado

Num sistema de triagem de crédito, o recall global parecia adequado, mas a análise por slice mostrou desempenho muito inferior para solicitantes de uma faixa de renda sub-representada na base histórica. A inspeção dos erros revelou rótulos inconsistentes nesse recorte, herdados de um processo manual antigo. A correção dos rótulos do slice, sem trocar o modelo, reduziu a disparidade e melhorou a métrica geral.

Armadilha comum

Uma armadilha sutil é otimizar a métrica média e, sem perceber, piorar um slice crítico. Uma intervenção que sobe a acurácia global em um ponto pode estar derrubando o desempenho em um subgrupo pequeno mas sensível, porque a média recompensa o slice majoritário. Acompanhar apenas o número global cega para esse efeito; sem leitura por slice, a regressão passa despercebida até aparecer em produção.

A análise por slice mostra onde o desempenho cai, mas não diz, por si só, por que cai. Quando a queda se concentra em subgrupos ligados a características de pessoas ou a condições de coleta, a causa costuma ser uma forma de viés que entrou no dado em algum ponto do pipeline. Organizar esses pontos é o tema do próximo tópico.

5. Análise estruturada de viés

Esta seção pertence à camada aplicada e tem por objetivo que você reconheça o viés como propriedade dos dados e do processo, e não apenas do modelo, e saiba localizar cada tipo de viés no ponto do pipeline em que ele entra. Tratar viés como uma taxonomia de origens, e não como um defeito monolítico, é o que permite detectá-lo e mitigá-lo com método.

Dizer que um modelo é enviesado costuma estar incompleto. O viés raramente nasce no modelo; ele entra nos dados e no processo, em pontos identificáveis, e o modelo apenas o reproduz e às vezes o amplifica. A figura a seguir organiza os principais tipos de viés pelo ponto do pipeline em que cada um se origina, do mundo que gera os dados até a implantação do sistema.

Figura 2. Taxonomia de vieses por ponto de entrada no pipeline.



Fonte: autor, adaptado de Suresh e Guttag (2021).

Para cego ver: Figura intitulada "Figura 2. Taxonomia de vieses por ponto de entrada no pipeline". O diagrama apresenta uma estrutura hierárquica organizada em caixas de texto conectadas por linhas. No topo, uma caixa azul-escura com o título "Viés em sistemas de IA". A partir dela, seis categorias principais são distribuídas horizontalmente: "Dados do mundo", "Coleta e amostragem", "Medição e rotulagem", "Modelagem", "Avaliação" e "Implantação". Abaixo de cada categoria aparecem os respectivos tipos de viés, acompanhados de uma breve explicação. Em Dados do mundo, está o "Viés histórico", descrito como: "o mundo já é desigual; os dados o refletem". Em Coleta e amostragem, aparece o "Viés de representação", com a descrição: "a amostra não cobre bem certos grupos". Em Medição e rotulagem, há dois tipos: "Viés de medição", descrito como "o atributo medido é um proxy imperfeito", e "Viés de anotação", descrito como "os rótulos carregam a subjetividade do anotador". Em Modelagem, encontra-se o "Viés de agregação", descrito como "um só modelo para grupos heterogêneos". Em Avaliação, aparece o "Viés de avaliação", com a descrição: "o benchmark não representa o uso real". Por fim, em Implantação, está o "Viés de implantação", descrito como "o uso em produção difere do previsto". O diagrama utiliza caixas retangulares em tons de azul e cinza, conectadas por linhas, evidenciando os diferentes pontos do pipeline onde vieses podem surgir em sistemas de inteligência artificial. Na parte inferior da figura consta a indicação "Fonte: autor."

Cada tipo de viés entra em uma etapa específica do pipeline, o que evidencia que o viés é propriedade dos dados e do processo, e não apenas do modelo.

Percorrendo a figura: o viés histórico vem do mundo, que já é desigual, e se reflete fielmente em dados corretos; o viés de representação surge na coleta, quando a amostra não cobre bem certos grupos; o viés de medição aparece quando o atributo registrado é um proxy imperfeito do que se queria medir; o viés de anotação entra na rotulagem, com a subjetividade do anotador; o viés de agregação pode ocorrer na modelagem, ao usar um único modelo para grupos heterogêneos; o viés de avaliação vem de um benchmark que não representa o uso real; e o viés de implantação surge quando o sistema é usado em produção de forma diferente da prevista.

A localização do viés sugere a forma de detectá-lo. O viés de representação pode ser examinado comparando a distribuição dos grupos na amostra com a da população de uso, em linha com os requisitos de governança de dados do EU AI Act para sistemas de alto risco. O viés de agregação se revela na análise por slice do tópico anterior, quando um subgrupo tem desempenho sistematicamente pior. O viés de anotação se investiga auditando uma amostra de rótulos, idealmente com mais de um anotador. Cada tipo tem um teste, e nenhum se resolve apenas trocando de modelo.

GLOSSÁRIO

Viés de representação

Distorção que surge quando a amostra de treino não cobre adequadamente certos grupos ou condições da população em que o sistema será usado. O modelo aprende bem o que está abundante na amostra e mal o que está raro, ainda que esse raro seja importante na operação. É detectável *antes* do treino, comparando a composição da amostra com a do uso pretendido.

Exemplo aplicado

Um sistema de inspeção visual treinado com imagens de uma única planta apresentou queda acentuada ao ser implantado em outra unidade, com iluminação e câmeras diferentes. O dado de treino sofria de viés de representação (uma só condição de coleta) e o uso revelou viés de implantação (contexto distinto do previsto). A correção concentrou-se nos dados, ampliando a amostra para cobrir as condições reais de operação.

Armadilha comum

Uma armadilha comum é acreditar que remover do dataset a coluna de um atributo sensível elimina o viés ligado a ele. Outros atributos costumam funcionar como proxy do que foi removido (o CEP correlacionado à renda, por exemplo), e o viés persiste por essa via indireta. Tratar viés como bug a ser apagado de uma vez, em vez de propriedade a ser medida e monitorada ao longo do tempo, leva a uma falsa sensação de resolução.

SAIBA MAIS

Para uma taxonomia rigorosa das origens de dano em sistemas de aprendizado, veja SURESH, H.; GUTTAG, J., A Framework for Understanding Sources of Harm in Machine Learning, em arxiv.org/abs/1901.10002. Para documentação estruturada de datasets e modelos, GEBRU, T. et al., Datasheets for Datasets, e MITCHELL, M. et al., Model Cards for Model Reporting. O aprofundamento em mitigação algorítmica de viés cabe aos cursos de Machine

6. Conclusão

Esta leitura cobriu a lente dos dados em duas camadas. Na conceitual, fixou o deslocamento data-centric, segundo o qual o teto de qualidade de uma solução é determinado pelos dados e o esforço de melhoria deve recair sobre eles antes da arquitetura, e organizou o vocabulário regulatório que delimita o que se pode fazer com dados pessoais, mostrando onde LGPD, GDPR e EU AI Act incidem sobre o pipeline. Na aplicada, ofereceu três instrumentos operacionais: um framework de qualidade com seis dimensões verificáveis, um procedimento de análise de erro por slices para localizar onde o modelo falha, e uma taxonomia que situa cada tipo de viés no ponto do pipeline em que ele entra.

O fio que une as cinco seções é a tese de que dados e processo, e não o modelo isolado, determinam tanto a qualidade quanto a conformidade de uma solução. A análise por slice conecta as três práticas aplicadas: ela revela falhas de qualidade concentradas em recortes, expõe o viés de agregação e orienta a intervenção nos dados de forma mensurável. Reconhecer um problema como sendo de dados, e saber em qual dimensão de qualidade ou em qual origem de viés ele se inscreve, é o que permite agir sobre a causa em vez de gastar esforço onde o retorno é menor.

A próxima peça do módulo desloca o foco do diagnóstico para a decisão. Com a evidência produzida aqui, o próximo e-book trata de escolher, de forma justificada perante stakeholders, entre intervir nos dados e trocar o modelo, de avaliar quando dados sintéticos são apropriados e quando representam risco de auto-reforço, e de identificar o regime regulatório aplicável a um dataset, fixando a relação entre disponibilidade de dados, cronograma realista e risco residual admitido.

REFERÊNCIAS

Bibliografia mínima

NG, A. A Chat with Andrew Ng on MLOps: From Model-centric to Data-centric AI. DeepLearning.AI, 2021. Vídeo em acesso aberto na plataforma DeepLearning.AI.

SAMBASIVAN, N. et al. Everyone Wants to Do the Model Work, Not the Data Work: Data Cascades in High-stakes AI. CHI, 2021. Disponível em https://research.google.com/pubs/archive/49953.pdf.

BRASIL. Lei n. 13.709, de 14 de agosto de 2018 (Lei Geral de Proteção de Dados Pessoais). Texto integral em portais públicos da Presidência da República.

Bibliografia complementar

NORTHCUTT, C. G.; ATHALYE, A.; MUELLER, J. Pervasive Label Errors in Test Sets Destabilize Machine Learning Benchmarks. NeurIPS, 2021. Preprint em https://arxiv.org/abs/2103.14749.

WHANG, S. E. et al. Data Collection and Quality Challenges in Deep Learning: A Data-centric AI Perspective. VLDB Journal, 2023. Preprint em https://arxiv.org/abs/2112.06409.

SURESH, H.; GUTTAG, J. A Framework for Understanding Sources of Harm Throughout the Machine Learning Life Cycle. EAAMO, 2021. Preprint em https://arxiv.org/abs/1901.10002.

MITCHELL, M. et al. Model Cards for Model Reporting. FAccT, 2019. Preprint em https://arxiv.org/abs/1810.03993.

GEBRU, T. et al. Datasheets for Datasets. CACM, 2021. Preprint em https://arxiv.org/abs/1803.09010.

UNIÃO EUROPEIA. Regulamento Geral sobre a Proteção de Dados (GDPR), Regulamento (UE) 2016/679. Texto integral em https://eur-lex.europa.eu.

UNIÃO EUROPEIA. Regulamento (UE) 2024/1689 (EU AI Act). Artigo 10, sobre governança de dados de sistemas de alto risco. Texto integral em https://eur-lex.europa.eu.

Ferramentas

GREAT EXPECTATIONS. Documentação oficial. Disponível em https://greatexpectations.io

DVC. Data Version Control: documentação oficial. Disponível em https://dvc.org.

LAKEFS. Documentação oficial. Disponível em https://lakefs.io.

CLEANLAB. Documentação oficial. Disponível em https://docs.cleanlab.ai.

Industr.IA

Residência em TIC 49



Executor iRede

Executor Atlântico

Coordenador Softex

Financiador MCTI Futuro

Ministério da Ciência, Tecnologia e Inovação

Governo do Brasil — Do lado do povo brasileiro

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.