Industr.IA

E-book

Data-centric AI:

a decisão dados versus modelo, dados sintéticos e regime regulatório



Curso base de IA | Unidade M3

Prof.: Arthur Nascimento

SUMÁRIO

1. Decidir entre intervenção nos dados e troca de modelo 3
2. Dados reais versus dados sintéticos 7
3. O regime regulatório aplicável ao dataset 12
4. Conclusão 16

Unidade M3

1. Decidir entre intervenção nos dados e troca de modelo

Esta seção pertence à camada decisória e tem por objetivo que você decida, com justificativa explícita, entre intervir nos dados e trocar de modelo diante da evidência de uma análise de erro (*error analysis*) estruturada. É a decisão que dá nome à lente dos dados: as seções do ebook anterior construíram o vocabulário e o instrumental para diagnosticar um sistema, e esta seção converte o diagnóstico em escolha defensável. A pergunta que a organiza é direta: quando o desempenho de uma solução estagna abaixo do necessário, o gargalo está nos dados ou no modelo, e o que a evidência disponível autoriza a concluir?

Vale recuperar o ponto de partida. A camada aplicada terminou com uma análise de erro por slices concluída: o desempenho da solução medido não apenas no agregado, mas em recortes relevantes do dataset, com os gaps de cada slice quantificados. Esse resultado é a entrada obrigatória da decisão desta seção. Sem ele, a escolha entre dados e modelo é feita por intuição, moda ou familiaridade da equipe com uma ou outra técnica, e nenhum desses critérios sobrevive à pergunta de um stakeholder sobre porque o caminho escolhido era o certo. Com ele, a decisão passa a ser uma leitura de evidência, e é essa leitura que o restante deste tópico organiza.

Há um instinto a ser nomeado antes de qualquer heurística. Quando um sistema estaciona em um patamar insatisfatório, a primeira reação de boa parte das equipes é trocar o modelo: testar uma arquitetura mais recente, um ensemble maior, um Foundation Model. É o reflexo model-centric que o deslocamento proposto por Andrew Ng, apresentado no ebook anterior, procura corrigir. O reflexo não é irracional, porque trocar de modelo é uma ação inteiramente sob controle da equipe técnica, enquanto melhorar dados costuma envolver anotadores, acesso a fontes e negociação com outras áreas. Mas conforto operacional não é evidência, e a experiência acumulada em PD&I industrial mostra que, em problemas com datasets pequenos, ruidosos ou desbalanceados, o ganho de corrigir os dados supera com frequência o ganho de trocar a arquitetura.

> ⚠ ATENÇÃO
>
> Uma confusão decisória frequente é responder a um erro concentrado em um slice com uma troca de arquitetura. Se a causa do erro está nos dados daquele recorte, com rótulos ruidosos ou exemplos insuficientes, o novo modelo herda exatamente o mesmo teto, porque aprende da mesma fonte defeituosa. A consequência típica são semanas de reengenharia e revalidação para um ganho marginal, enquanto a intervenção localizada nos dados do slice teria atacado a causa por uma fração do custo.

A primeira leitura da evidência distingue erro concentrado de erro difuso. Se a análise de erro mostra que o desempenho agregado esconde um ou poucos slices com gaps grandes, a hipótese mais econômica é que o problema está nos dados daqueles recortes, e não na capacidade geral do modelo. Um modelo que acerta 91% no conjunto, mas 60% em um slice específico, não é um modelo fraco: é um modelo treinado sobre uma representação fraca daquele recorte. Se, ao contrário, o erro se distribui de forma aproximadamente uniforme entre os slices, sem concentração explicável, a hipótese de limitação do modelo ganha força, embora ainda não seja a única.

Confirmada a concentração, o passo seguinte é perguntar qual propriedade dos dados explica o gap. As causas recorrentes já têm nome no vocabulário do módulo: sub-representação, quando o slice tem poucos exemplos no treino e o modelo não teve material para aprender sua estrutura; ruído de rótulo, quando os exemplos do slice existem, mas parte relevante está anotada errado; e drift, quando a fonte daquele recorte mudou depois da coleta e o treino descreve um mundo que não existe mais. Cada causa aponta uma intervenção distinta, coletar mais, reanotar ou recoletar, e todas são intervenções em dados, não em modelo. Quando nenhuma dessas causas se sustenta, e o slice falha mesmo com dados adequados, a limitação pode estar na capacidade do modelo de representar aquele padrão, e a troca de modelo volta à mesa.

GLOSSÁRIO

Erro irredutível

Erro irredutível é a parcela do erro que nenhum modelo elimina, porque decorre de ambiguidade ou ruído intrínsecos ao problema e aos dados disponíveis. Quando o erro observado se aproxima desse piso, trocar de modelo não traz ganho relevante; a margem restante só se move, se mover, com dados melhores ou com uma reformulação do problema.

O caminho simétrico também precisa de critério: quando a troca de modelo é a resposta certa? A evidência que a sustenta combina três sinais. Primeiro, o dataset atende o framework de data quality, no tópico 3 do ebook anterior, nas seis dimensões, de modo que não há intervenção óbvia pendente do lado dos dados. Segundo, o erro é difuso e estável entre slices, sem concentração que aponte causa local. Terceiro, existe referência externa ou piloto interno indicando que outra família de modelo captura padrões que a atual não captura, por exemplo interações não lineares que um modelo linear não representa. Na ausência dos três sinais, a troca é aposta; na presença de-

les, é decisão fundamentada, e deve vir acompanhada do plano de retreino e revalidação que a acompanha.

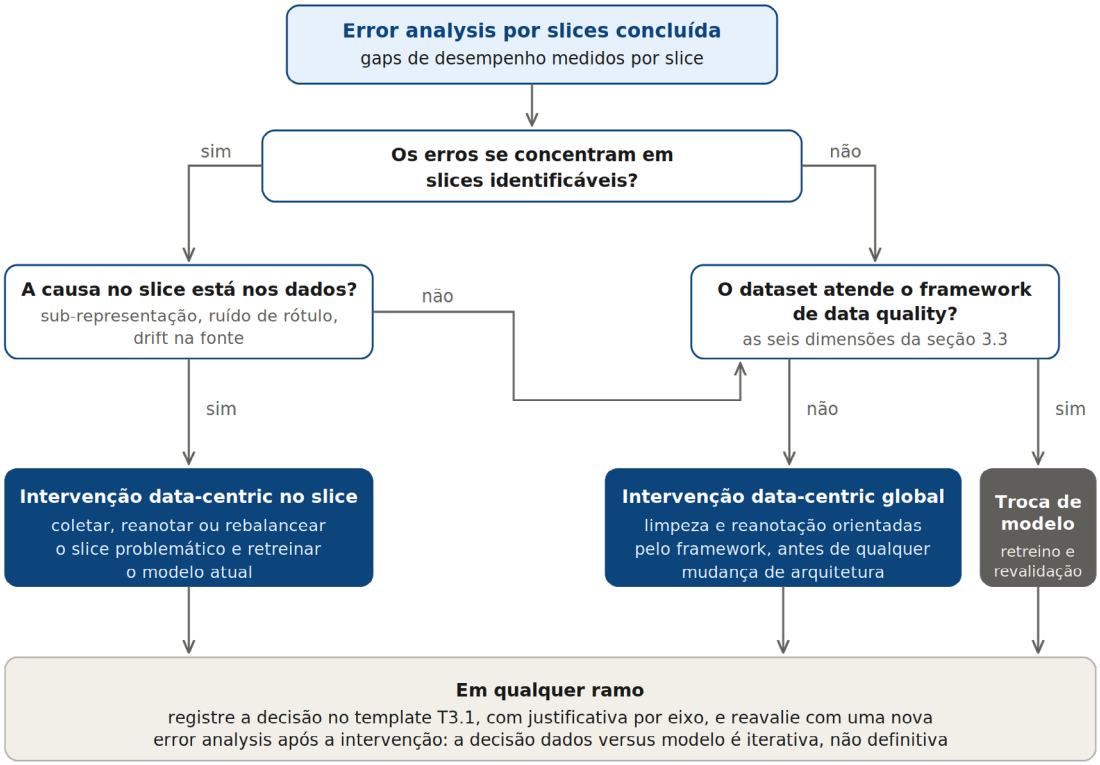
Os custos das duas alternativas são assimétricos, e a assimetria importa tanto quanto a evidência. A intervenção em dados custa coleta ou reanotação, reprocessamento do pipeline e um novo treino do modelo atual; seu custo é dominado por gente e acesso, e costuma ser subestimado justamente por isso. A troca de modelo custa seleção e treino do candidato, revalidação completa, integração com o sistema existente e, em setores regulados, novo ciclo de homologação; seu custo é dominado por engenharia e prazo. Há ainda uma diferença de natureza entre os ganhos: o ganho obtido ao melhorar dados transfere-se para qualquer modelo futuro, porque dados corrigidos servem a qualquer arquitetura, enquanto o ganho de uma troca de modelo não corrige nenhum defeito de dados e pode ser perdido na próxima troca. Em caso de empate na evidência, essa transferibilidade é um desempate legítimo a favor dos dados.

Evidência e custo alimentam o terceiro elemento da decisão, o ganho esperado, e ele precisa ser projetado, não presumido. Do lado dos dados, a projeção sai da própria análise de erro: o gap do slice multiplicado pelo peso do slice no volume dá o teto do ganho agregado que fechar aquele gap pode entregar. Um slice com 30 pontos de gap e 10 por cento do volume promete, no máximo, três pontos no agregado, e saber disso antes de intervir evita tanto a frustração quanto a promessa exagerada a stakeholders. Do lado do modelo, a projeção exige um piloto ou uma referência comparável, treinada e medida sobre os mesmos dados e a mesma métrica; um número de benchmark obtido sobre outra distribuição não projeta nada. A comparação honesta entre as duas alternativas usa a mesma métrica, o mesmo conjunto de teste e a mesma janela de tempo, e é essa comparação que o instrumento decisório do módulo pedirá por escrito.

O quarto elemento é o prazo, e ele costuma decidir empates que a evidência técnica não decide. A intervenção em dados tem prazo dominado pela logística de anotação e coleta, que depende de pessoas e de acesso; a troca de modelo tem prazo dominado pela cauda de revalidação e integração, que depende de engenharia e, em setores regulados, de homologação. Nenhum dos dois prazos aparece por inteiro na primeira estimativa, e a prática recomendada é dimensionar pelo pior caso plausível, não pela média otimista. No calendário da Formação 1, essa leitura conecta a decisão deste tópico aos encontros de decisão e de desenho da solução: a alternativa escolhida entra no plano do squad como compromisso datado, com o custo e o ganho projetado registrados, e é contra esse registro que o resultado será cobrado.

A figura a seguir organiza a decisão como uma árvore, partindo da análise de erro concluída e percorrendo as duas perguntas que a evidência precisa responder antes de a troca de modelo ser considerada.

Figura 1. Árvore de decisão: intervenção nos dados versus troca de modelo.



Fonte: autor.

Para cego ver: Figura 1 intitulada "Árvore de decisão: intervenção nos dados versus troca de modelo". O diagrama apresenta uma árvore de decisão composta por caixas conectadas por setas, orientando a escolha entre melhorar os dados ou substituir o modelo de inteligência artificial. No topo, uma caixa informa "Error analysis por slices concluída", acompanhada da descrição "gaps de desempenho medidos por slice". A seta conduz à pergunta central: "Os erros se concentram em slices identificáveis?". Se a resposta for "sim", o fluxo segue para a pergunta "A causa no slice está nos dados?", com exemplos como sub-representação, ruído de rótulo e drift na fonte. Havendo confirmação, a recomendação é "Intervenção data-centric no slice", envolvendo coletar, reanotar ou rebalancear o slice problemático e retreinar o modelo atual. Se a resposta inicial for "não", ou caso a causa não esteja nos dados, o fluxo direciona para a pergunta "O dataset atende o framework de data quality?", acompanhada da observação "as seis dimensões da seção 3.3". Quando a resposta é "não", a decisão indicada é "Intervenção data-centric global", com ações de limpeza e reanotação orientadas pelo framework antes de qualquer mudança de arquitetura. Quando a resposta é "sim", a recomendação é "Troca de modelo", seguida de retreinamento e revalidação. Na parte inferior, uma caixa horizontal comum a todos os caminhos apresenta a orientação: "Em qualquer ramo, registre a decisão no template T3.1, com justificativa por eixo, e reavalie com uma nova error analysis após a intervenção: a decisão dados versus modelo é iterativa, não definitiva." O fluxograma utiliza caixas em tons de azul e cinza, conectadas por setas e ramificações que representam as diferentes decisões possíveis. Na parte inferior da figura consta a indicação "Fonte: autor."

A árvore parte de uma análise de erro por slices concluída. A primeira pergunta é se os erros se concentram em slices identificáveis. Em caso afirmativo, pergunta-se se a causa no slice está nos dados, por sub-representação, ruído de rótulo ou drift; se sim, a saída é a intervenção data-centric no slice, com coleta, reanotação ou rebalanceamento e retreino do modelo atual. Se os erros são difusos, ou se a causa no slice não está nos dados, verifica-se se o dataset atende o framework de data quality: se não atende, a saída é a intervenção data-centric global, com limpeza e reanotação orientadas pelo framework; se atende, a saída é a troca de modelo, com retreino e revalidação. Em qualquer ramo, a decisão é registrada no template T3.1 e reavaliada com nova análise de erro.

Dois traços da árvore merecem destaque. O primeiro é a ordem das perguntas: a hipótese de dados é examinada antes da hipótese de modelo, e a troca só aparece como saída depois que o framework de qualidade foi verificado. Essa ordem não é preferência estética, é a tradução da assimetria de custos e da transferibilidade discutidas acima. O segundo é a faixa final, comum a todos os ramos: a decisão é registrada no template T3.1 com justificativa por eixo e reavaliada com uma nova análise de erro

depois da intervenção. A decisão dados versus modelo é iterativa por natureza, porque cada intervenção muda a evidência sobre a qual a próxima decisão será tomada.

A árvore admite ainda um caminho do meio que a prática industrial usa com frequência: a intervenção combinada, em que a equipe corrige os dados primeiro e define, desde já, um gatilho explícito para reavaliar a troca de modelo. O gatilho típico tem a forma: se, após a reanotação do slice e o retreino, o erro residual se mostrar difuso e o dataset atender o framework de qualidade, a troca entra em avaliação com piloto dedicado. Esse desenho preserva a ordem econômica das intervenções, dados antes de modelo, sem transformar a preferência por dados em dogma, e dá ao squad um critério de parada que não depende de opinião no calor do projeto. O que a combinação não autoriza é executar as duas intervenções ao mesmo tempo, porque mudar dados e modelo simultaneamente destrói a capacidade de atribuir o ganho observado a uma causa, e sem atribuição não há aprendizado para a próxima decisão.

> **Exemplo aplicado**
>
> Uma metalúrgica usa um classificador de defeitos de solda sobre imagens da linha de inspeção. A acurácia estagnou em 88 por cento e a equipe cogitava migrar para uma arquitetura maior. A análise de erro por slices mostrou que o erro se concentrava em uma única classe de defeito, com rótulos inconsistentes entre dois turnos de anotação. A reanotação de cerca de três mil imagens daquela classe, com critério unificado, elevou a acurácia acima da meta sem trocar o modelo, por uma fração do custo estimado da migração.

Registrada a decisão, resta explicitar o que ela pressupõe. Todo o raciocínio desta seção assume que existe um caminho viável para melhorar os dados reais: que há mais exemplos a coletar, rótulos a corrigir, fontes a recalibrar. Em parte dos projetos industriais essa premissa falha, porque o evento de interesse é raro, a coleta é cara ou os dados envolvem pessoas e não podem circular livremente. Nesses casos, a alternativa que se apresenta é gerar dados, e ela traz critérios e riscos próprios que não cabem na árvore desta seção.

2. Dados reais versus dados sintéticos

Esta seção pertence à camada decisória e tem por objetivo que você justifique tecnicamente quando dados sintéticos são apropriados e quando representam risco de auto-reforço ou de perda de fidelidade. O tópico anterior decidiu entre intervir nos dados e trocar de modelo assumindo que os dados reais podem ser melhorados; esta trata do caso em que essa premissa não se sustenta e a geração de dados entra como alternativa. A decisão aqui não é sintético sim ou não em abstrato, e sim para qual papel, em

qual proporção e com qual verificação.

Três motivações concentram a maior parte dos usos legítimos de dados sintéticos em PD&I industrial. A primeira é a escassez de casos raros: falhas graves de equipamento, defeitos de baixa incidência e eventos de segurança acontecem pouco por definição, e esperar que o processo real produza exemplos suficientes pode levar anos. A segunda é o custo de coleta e anotação, quando cada exemplo real exige ensaio destrutivo, parada de linha ou horas de especialista. A terceira é a restrição de privacidade, quando os dados envolvem pessoas e uma versão sintética permite desenvolver e compartilhar sem expor titulares, tema que o tópico 3 retoma pelo ângulo regulatório. Fora dessas três motivações, a proposta de usar dados sintéticos merece desconfiança inicial, porque costuma esconder a tentativa de evitar um trabalho de coleta que era viável.

Em alto nível, dados sintéticos chegam por dois caminhos. O primeiro é a simulação: um modelo físico ou um conjunto de regras do domínio gera exemplos com controle total dos parâmetros, como um simulador de processo que produz curvas de sensor para regimes de falha nunca observados. O segundo é a geração por modelo: um modelo generativo, da família apresentada no módulo M1, aprende a estrutura dos dados reais e amostra exemplos novos, sejam imagens, textos ou linhas tabulares. O detalhamento de cada técnica fica fora do escopo do curso base; o que importa para a decisão é que os dois caminhos herdam limites diferentes, a simulação limitada pela fidelidade

GLOSSÁRIO

do modelo de domínio, a geração limitada pela qualidade e pela cobertura dos dados reais que a alimentaram.

Auto-reforço

Auto-reforço é o ciclo em que um modelo é treinado, em proporção crescente, sobre dados produzidos por modelos, próprios ou de terceiros. A cada rodada, os exemplos sintéticos reforçam os padrões e os vieses do gerador e apagam a

variabilidade das caudas da distribuição real, degradando progressivamente a qualidade. É o fenômeno descrito na literatura como colapso de modelo.

O primeiro risco a avaliar é a perda de fidelidade. Um conjunto sintético é sempre uma aproximação da distribuição real, e a aproximação falha justamente onde o dado é mais valioso: nas caudas, nos casos limítrofes, nas correlações finas entre variáveis. Um gerador tabular pode produzir linhas individualmente plausíveis cujas correlações conjuntas não existem no processo real; um simulador pode produzir imagens de de-

feito visualmente convincentes que não carregam a textura que distingue o defeito verdadeiro na linha. Um modelo treinado sobre esses exemplos aprende a resolver um problema vizinho do problema real, e a diferença só aparece quando o sistema encontra dados de produção.

O segundo risco é o auto-reforço definido no glossário acima. Ele merece atenção especial por dois motivos. O primeiro é que se instala silenciosamente: à medida que conteúdo gerado por modelos se acumula nas fontes de onde as equipes coletam, torna-se difícil garantir que um corpus novo é de fato composto por dados reais. O segundo é que seus efeitos são cumulativos e de difícil reversão, com a diversidade da base encolhendo a cada geração. A consequência prática é uma regra de higiene: a origem de cada exemplo, real ou sintética, e a versão do gerador que o produziu devem ser regis-

SAIBA MAIS

tradas no lineage do dataset, para que a proporção sintética seja conhecida e controlável em qualquer ponto do ciclo.

O colapso de modelo por treinamento recursivo em dados gerados é demonstrado em SHUMAILOV, I. et al. AI models collapse when trained on recursively generated data. Nature, v. 631, 2024, DOI 10.1038/

s41586-024-07566-y. As estratégias operacionais de controle de lineage e de mistura real-sintético em pipelines de produção são tratadas no curso de Engenharia de Dados da Fase 2 do programa.

Desses riscos deriva a regra que não admite exceção neste curso: a validação final acontece sempre sobre dados reais. Dados sintéticos podem entrar no treino, na exploração e no balanceamento; não podem entrar no conjunto de teste que sustenta a afirmação de que o sistema funciona, porque um teste sintético mede o acordo entre dois artefatos, o modelo e o gerador, e não o desempenho no mundo. Da mesma regra decorre a prática de manter a proporção sintética do treino como parâmetro explícito do experimento, variando-a e observando o efeito sobre a métrica em dados reais, em vez de fixá-la por conveniência.

A verificação de fidelidade, mencionada como exigência, tem forma concreta mesmo em alto nível. O primeiro degrau é estatístico: comparar as distribuições marginais de cada variável e as correlações entre pares no conjunto sintético e na amostra real disponível, marcando divergências acima de um limiar acordado. O segundo é o olhar de especialista: quem conhece o processo examina uma amostra do sintético procurando o que não existiria na linha, e esse exame vale mais nos casos raros do que nos típicos. O terceiro é o teste por consequência: treinar o mesmo modelo com e sem a parcela sin-

tética e medir a diferença sobre dados reais, que é o único juiz que interessa. Nenhum dos três degraus exige ferramenta especializada, e a ausência dos três em um plano que propõe dados sintéticos é, por si, um sinal de alerta.

Entre os usos legítimos, convém separar dois papéis que a mesma palavra encobre. No papel de complemento, os dados sintéticos entram como augmentation, aqui no sentido de ampliação do conjunto de treino; a augmentation clássica por transformação de exemplos reais é técnica vizinha, tratada nos cursos de Machine Learning e Deep Learning da Fase 2. Nesse papel, a base real permanece a espinha do treino, enquanto a parcela gerada preenche regiões específicas (tipicamente as classes raras, em proporção controlada). No papel de substituto, o conjunto sintético pretende ocupar o lugar do real, seja porque o real não pode circular, seja porque não existe em volume. O complemento é o caso comum e o de menor risco, porque a distribuição real continua ancorando o aprendizado. O substituto é o caso excepcional e o de maior exigência, porque tudo o que o modelo aprende passa pelo filtro do gerador; quando esse papel for inevitável, a verificação de fidelidade deixa de ser etapa de qualidade e vira o centro do projeto, com comparações estatísticas entre o sintético e a amostra real disponível documentadas antes de qualquer treino.

O uso motivado por privacidade pede uma nota própria, porque carrega um trade-off que a intuição erra. Quanto mais fiel o gerador, mais útil o conjunto sintético, e também maior o risco de que exemplos gerados fiquem próximos demais de registros reais de treinamento, a ponto de permitir inferências sobre registros ou indivíduos específicos. Fidelidade e proteção puxam em direções opostas, e a escolha do ponto de operação é uma decisão de projeto, não um detalhe de ferramenta. A consequência prática para este curso é dupla: primeiro, sintetizar não é sinônimo de anonimizar, e a afirmação de que um conjunto sintético não expõe titulares precisa de verificação, não de fé no método; segundo, essa verificação e seus critérios pertencem ao regime regulatório do dataset de origem, o que antecipa o vínculo com o próximo tópico.

Com os papéis e os riscos postos, a heurística decisória cabe em três perguntas. O dado real é obtenível a custo e prazo compatíveis com o projeto? Se sim, prefira o dado real, e trate a proposta sintética como otimização prematura. A parcela sintética cobrirá regiões da distribuição que o dado real não cobre, como classes raras controladas por física conhecida ou cenários de privacidade? Se sim, o uso é defensável, no papel de complemento. Existe um conjunto real, protegido e rastreável, reservado para a validação? Se não, o uso sintético é indefensável em qualquer proporção, porque a afirmação de qualidade do sistema ficaria sem base. O quadro a seguir resume a comparação entre as duas origens de dados nos critérios que a decisão mobiliza.

Quadro 1 - Dados reais versus dados sintéticos nos critérios de decisão.

Critério	Dados reais	Dados sintéticos
Fidelidade à distribuição	referência por definição, incluindo caudas e correlações finas	aproximação; degrada nas caudas e nos casos limítrofes
Custo e prazo de obtenção	dominados por coleta e anotação; podem ser proibitivos em eventos raros	dominados por construção e verificação do gerador; escala barata depois
Cobertura de casos raros	limitada pela frequência natural do evento	controlável por parâmetro, quando a física ou as regras do caso são conhecidas
Privacidade	sujeitos ao regime do tópico 3 quando envolvem pessoas	reduzem exposição de titulares, sem eliminar por si o dever de verificação
Risco característico	viés e ruído herdados do processo de coleta	perda de fidelidade e auto-reforço, com rastreio obrigatório no lineage
Papel na validação	único aceitável para o teste final	inaceitável no teste final, em qualquer proporção

Para cego ver: Quadro 1 intitulado "Dados reais versus dados sintéticos nos critérios de decisão." A figura apresenta uma tabela com três colunas: Critério, Dados reais e Dados sintéticos, comparando as características de cada tipo de dado em diferentes aspectos relacionados ao desenvolvimento e à validação de modelos de inteligência artificial. Na primeira linha, o critério Fidelidade à distribuição indica que os dados reais são a referência por definição, preservando caudas estatísticas e correlações finas. Já os dados sintéticos representam uma aproximação, podendo apresentar degradação justamente nas caudas da distribuição e em casos limítrofes. Na segunda linha, o critério Custo e prazo de obtenção mostra que os dados reais dependem de coleta e anotação, processos que podem ser caros e demorados, especialmente em eventos raros. Os dados sintéticos, por sua vez, são produzidos por construção e verificação do gerador, permitindo geração em larga escala com menor custo após a implementação inicial. Na terceira linha, o critério Cobertura de casos raros informa que os dados reais são limitados pela frequência natural dos eventos observados, enquanto os dados sintéticos permitem uma cobertura controlada por parâmetros, desde que a física ou as regras do problema sejam conhecidas. Na quarta linha, o critério Privacidade destaca que os dados reais estão sujeitos às exigências legais quando envolvem dados pessoais. Os dados sintéticos reduzem a exposição de informações de titulares, embora não eliminem a necessidade de verificação e conformidade. Na quinta linha, o critério Risco característico mostra que os dados reais podem herdar viés e ruído provenientes do processo de coleta, enquanto os dados sintéticos apresentam o risco de perda de fidelidade e autorreforço, exigindo rastreabilidade obrigatória da sua origem e geração. Na sexta e última linha, o critério Papel na validação estabelece que os dados reais são o único recurso aceitável para o teste final de desempenho, enquanto os dados sintéticos são considerados inadequados para a validação final, independentemente da proporção utilizada, devendo ser empregados apenas como complemento durante o desenvolvimento. A tabela utiliza cabeçalhos em azul-claro e organiza as informações em linhas, permitindo comparar de forma direta as vantagens, limitações e aplicações de dados reais e dados sintéticos em projetos de inteligência artificial.

Exemplo aplicado

Uma fabricante de vidros planos treina um detector de inclusões, defeito que ocorre em menos de um em mil painéis. Dois anos de linha renderam 400 exemplos reais, insuficientes para a classe. A equipe gerou 6 mil imagens sintéticas por simulação óptica do defeito, usou a mistura apenas no treino, com origem registrada no lineage, e manteve a validação em um conjunto exclusivamente real. O recall da classe rara subiu de 61 para 83 por cento medido em dados reais, o único número reportado ao cliente.

A decisão atravessa os sete eixos do programa com sotaques diferentes, e vale reconhecê-los. Em Visão Computacional, o sintético aparece como imagem simulada ou aumentada para defeitos e condições raras, e o risco dominante é a fidelidade de textura. Em LLMs e NLP, aparece como texto gerado para ampliar corpus de fine-tuning ou de RAG, e o risco dominante é o auto-reforço, porque a fonte da geração e o consumidor do resultado são a mesma família de modelos. Em Engenharia de Dados e Machine Learning tabular, aparece como linhas sintéticas para balanceamento ou compartilhamento, e o risco dominante é a correlação espúria entre colunas. O vocabulário desta seção é o

mesmo nos três casos; o que muda é onde a verificação de fidelidade deve concentrar esforço, e reconhecer esse deslocamento é parte da leitura que a lente dos dados pede.

Resta situar o efeito da escolha sobre o cronograma, porque é nele que a proposta sintética costuma ser vendida. Gerar dados parece um atalho: elimina a espera pela coleta e a fila de anotação. O atalho, porém, desloca esforço em vez de eliminá-lo, porque introduz duas etapas novas, a construção ou adaptação do gerador e a verificação de fidelidade contra os dados reais disponíveis, e a segunda não pode ser cortada sem transformar o dataset em passivo. Em um plano de projeto honesto, a linha dados sintéticos aparece com essas duas etapas explícitas e com o conjunto real de validação como dependência de caminho crítico, e não como uma caixa única que promete dados prontos em uma semana.

Há, por fim, uma dimensão da escolha que a técnica não encerra. Quando os dados envolvem pessoas, optar por dados reais, sintéticos ou por uma mistura muda as obrigações jurídicas do projeto, as bases legais que o sustentam e a documentação que ele deve manter. Decidir a origem dos dados sem identificar o regime regulatório aplicável é decidir com informação incompleta.

3. O regime regulatório aplicável ao dataset

Esta seção pertence à camada decisória e tem por objetivo que você identifique o regime regulatório aplicável a um dataset e traduza essa identificação em decisões de projeto: qual base legal sustenta o tratamento, que documentação o pipeline precisa manter, o que entra no cronograma desde o início e qual risco residual o projeto admite. O vocabulário regulatório básico, LGPD, GDPR e EU AI Act, foi apresentado no tópico 2 do ebook anterior; aqui a pergunta muda de o que cada norma diz para qual norma incide sobre este dataset e o que isso muda no desenho da solução.

A mudança de pergunta importa porque o regime regulatório não é um filtro aplicado ao final do projeto, e sim uma propriedade do dataset que condiciona decisões anteriores: se uma fonte pode ser usada, se precisa ser anonimizada, se dados sintéticos são um caminho de redução de exposição, se a coleta exige consentimento ou se outra base legal a sustenta. Um squad que descobre tarde que seu dataset contém dados pessoais sem base legal registrada não enfrenta um problema jurídico abstrato: enfrenta retrabalho de pipeline, renegociação de acesso à fonte e, com frequência, o descarte de semanas de trabalho sobre dados que não podiam estar ali.

A LGPD é a âncora brasileira e o primeiro instrumento a verificar. Ela incide sempre que o dataset contém dados pessoais, isto é, informação relacionada a pessoa natural identificada ou identificável, e a experiência mostra que datasets industriais contêm dados pessoais com mais frequência do que as equipes supõem: matrícula do operador no

⚠ ATENÇÃO

registro de turno, voz em áudio de inspeção, rosto ao fundo de imagem de linha, padrão de digitação em log de sistema. Incidindo a lei, todo tratamento precisa de uma base legal entre as previstas na LGPD, como consentimento, obrigação legal, execução de contrato ou legítimo interesse, e a base escolhida deve estar registrada e defensável. Dados sensíveis, como saúde e biometria, têm rol próprio no artigo 11 e exigência mais estrita, ponto relevante para projetos com wearables, ergonomia ou controle de acesso. Um erro recorrente é tratar pseudonimização como anonimização. Substituir o nome do operador por um código remove o identificador direto, mas o dado continua pessoal se a reidentificação for razoavelmente possível cruzando turno, função e setor. A equipe que declara o dataset anônimo nessa condição opera sem base legal sem saber, e a descoberta costuma ocorrer em auditoria ou incidente, quando o custo de correção é máximo e envolve refazer o pipeline sob supervisão jurídica.

A escolha da base legal é, ela própria, uma decisão de projeto com consequências operacionais, e duas situações recorrentes em PD&I industrial ilustram o ponto. A primeira é a tentação de resolver tudo por consentimento: em dados de colaboradores, o consentimento é frágil, porque a assimetria da relação de emprego compromete a liberdade que o instituto pressupõe, e projetos apoiados nele herdam o risco de revogação a qualquer tempo. A segunda é o legítimo interesse, base frequente para dados operacionais, que não é um carimbo: exige o registro de um teste de balanceamento entre o interesse da organização e os direitos do titular, com medidas de minimização documentadas. Em ambos os casos, a decisão correta envolve a área jurídica ou o encarregado de dados da organização desde o desenho, e o papel da equipe técnica é chegar a essa conversa com o mapa do dataset pronto, não descobrir o problema depois do treino.

Quando a base legal não se sustenta ou o risco de exposição é alto demais, a anonimização entra como saída técnica, e ela também é uma decisão com custo. Anonimizar de verdade, a ponto de a reidentificação deixar de ser razoavelmente possível, quase sempre implica perder utilidade: agregar registros individuais em janelas, suprimir ou generalizar colunas que identificam indiretamente, adicionar ruído a valores finos. Cada uma dessas operações remove exatamente o tipo de detalhe que um modelo poderia explorar, e o ponto de equilíbrio entre proteção e utilidade precisa ser escolhido e registrado, não assumido. A alternativa de gerar dados sintéticos a partir da base pessoal, discutida na seção anterior, participa desse mesmo cálculo com a mesma exigência de verificação. O erro a evitar é o do meio do caminho: um dataset pseu-

donimizado tratado como anônimo, que carrega o risco jurídico integral com a falsa sensação de tê-lo eliminado.

O GDPR entra em cena quando o tratamento alcança titulares na União Europeia ou quando a organização opera dados no contexto de um estabelecimento europeu, situação comum em multinacionais e em projetos com clientes ou plantas na Europa. A lógica é próxima da LGPD, com bases legais, direitos de titular e deveres de documentação, e para efeito de decisão de projeto vale a regra prática: um pipeline desenhado para cumprir a LGPD com rigor fica perto da conformidade com o GDPR, mas a equivalência não é automática, e transferências internacionais de dados têm capítulo próprio nos dois instrumentos que precisa de análise específica quando o treinamento ou a inferência ocorrem fora do país de origem dos dados.

O EU AI Act pertence a outra família: ele regula o sistema de IA, não o dado pessoal, e incide segundo o risco da aplicação. Para os sistemas classificados como de alto risco, como os usados em infraestrutura crítica, emprego e crédito, o artigo 10 impõe obrigações diretamente sobre a governança dos dados de treino, validação e teste: práticas documentadas de gestão, dados relevantes e suficientemente representativos para o propósito, e exame explícito de possíveis vieses que afetem saúde, segurança ou direitos fundamentais. Repare que essas exigências correspondem, em essência, ao framework de data quality e à análise de viés (ambos discutidos no ebook anterior), convertidos em obrigação jurídica, com as disposições de alto risco entrando em aplicação ao longo de 2026. Para equipes que pretendem atuar com clientes europeus, a lente dos dados deste módulo é também preparação regulatória.

O quadro a seguir organiza os três instrumentos pelo ângulo que interessa à decisão: quando cada um incide sobre o dataset e o que exige do projeto na prática.

Quadro 2 - Instrumentos regulatórios pelo ângulo do dataset.

Instrumento	Quando incide sobre o dataset	O que exige do projeto na prática
LGPD (Lei 13.709/2018)	sempre que o dataset contém dados de pessoa natural identificada ou identificável tratados no Brasil ou sobre titulares no Brasil	base legal registrada por tratamento, regras mais estritas para dados sensíveis, direitos de titular atendíveis e lineage que demonstre origem e uso
GDPR (Regulamento 2016/679)	tratamento de dados de titulares na União Europeia ou no contexto de estabelecimento europeu da organização	bases legais e documentação análogas às da LGPD, com análise específica para transferências internacionais de dados
EU AI Act (Regulamento 2024/1689)	quando o sistema de IA alimentado pelo dataset se enquadra como de alto risco no mercado europeu	governança documentada dos dados de treino, validação e teste, representatividade adequada ao propósito e exame explícito de vieses (artigo 10)

Para cego ver: Quadro 2 intitulado "Instrumentos regulatórios pelo ângulo do dataset." A figura apresenta uma tabela com três colunas: Instrumento, Quando incide sobre o dataset e O que exige do projeto na prática, comparando três importantes normas relacionadas à proteção de dados e à inteligência artificial. Na primeira linha, a LGPD (Lei nº 13.709/2018) aplica-se sempre que o conjunto de dados contém dados pessoais de pessoa natural identificada ou identificável tratados no Brasil ou de titulares localizados no país. Na prática, exige que o projeto mantenha base legal registrada para cada tratamento, regras mais rigorosas para dados sensíveis, mecanismos para garantir os direitos dos titulares e documentação que demonstre a origem e o uso dos dados. Na segunda linha, o GDPR (Regulamento 2016/679 da União Europeia) incide quando há tratamento de dados de titulares localizados na União Europeia ou em contexto de estabelecimento europeu da organização. Como exigência prática, requer bases legais e documentação semelhantes às da LGPD, além de atenção especial às transferências internacionais de dados. Na terceira linha, o EU AI Act (Regulamento 2024/1689) aplica-se quando o sistema de inteligência artificial alimentado pelo dataset é classificado como de alto risco no mercado europeu. Nesse caso, exige governança documentada dos dados de treinamento, validação e teste, garantia de representatividade adequada ao propósito do sistema e avaliação explícita de possíveis vieses, conforme previsto no Artigo 10. A tabela utiliza cabeçalhos em azul-claro e organiza as informações em linhas, permitindo comparar de forma clara quando cada instrumento regulatório se aplica ao conjunto de dados e quais são as principais exigências práticas para os projetos de inteligência artificial.

Com o quadro em mãos, a identificação do regime cabe em três passos executáveis no início do projeto. Primeiro, mapear o conteúdo e o alcance do dataset: há pessoas identificáveis, diretas ou indiretas, e onde estão os titulares e a operação? Segundo, marcar os instrumentos incidentes: LGPD pelo conteúdo pessoal, GDPR pelo alcance europeu, EU AI Act pelo enquadramento de risco da aplicação. Terceiro, registrar as consequências: a base legal de cada tratamento, as lacunas de documentação e as ações de adequação, cada uma com dono e prazo. O pré-requisito técnico dos três passos é o data lineage apresentado na camada conceitual: sem saber de onde cada campo veio e por onde passou, não há como demonstrar base legal nem responder a uma solicitação de titular.

Os três passos precisam de um lugar onde viver, e a prática consolidada é documentá-los junto ao próprio dataset, no espírito das datasheets for datasets: um registro que acompanha a base e responde, para qualquer leitor futuro, de onde os dados vieram,

GLOSSÁRIO

quem são os titulares envolvidos, qual base legal sustenta cada uso, que transformações foram aplicadas e que limitações são conhecidas. No contexto dos squads, esse registro não é burocracia paralela: é o insumo direto do Mapa Técnico do Problema e a peça que permite a um integrante novo, ou a um avaliador, reconstruir as decisões de dados sem arqueologia de mensagens. A regra de ouro é que a resposta à pergunta podemos usar estes dados para isto deve estar escrita antes de a pergunta ser feita.

Risco residual

Risco residual é o risco que permanece depois de aplicadas as medidas de mitigação planejadas, e que o projeto decide aceitar de forma explícita e documentada. Na lente dos dados, é a lacuna de qualidade, viés ou adequação regulatória que não será fechada no ciclo atual, registrada com sua justificativa e com o gatilho que forçará sua revisão.

O quadro descreve o presente, mas o regime regulatório de IA é uma paisagem em movimento, e a decisão de projeto precisa incorporar esse fato. No Brasil, o marco regulatório específico de IA tramita no Congresso, com abordagem baseada em risco inspirada no modelo europeu, e sua aprovação mudaria as obrigações incidentes sobre sistemas hoje cobertos apenas pela LGPD; o módulo M5 retoma esse horizonte pelo ângulo da transparência. A consequência para o projeto não é paralisia, e sim

uma prática: registrar, junto ao mapa regulatório do dataset, a data da análise e os instrumentos considerados, e tratar a revisão desse mapa como atividade recorrente do ciclo, não como evento único. Projetos com dados bem governados, lineage completo e vieses examinados atravessam mudanças regulatórias com ajustes; projetos sem essa base recomeçam.

O último elo liga o regime ao cronograma e ao risco. Identificar o regime cedo permite tratar a adequação como linha de trabalho do projeto, com anonimização, coleta de consentimento ou documentação de legítimo interesse acontecendo em paralelo ao desenvolvimento técnico. Identificá-lo tarde transforma cada uma dessas ações em bloqueio de caminho crítico. E como nenhum projeto elimina todo risco, a saída honesta é o registro do risco residual admitido: quais lacunas permanecem, por que são aceitáveis neste ciclo e o que dispara sua revisão. Esse registro é o que diferencia uma equipe que decidiu conviver com um risco conhecido de uma equipe que simplesmente não olhou, e é ele que sustenta a conversa com stakeholders quando o assunto regulatório aparece.

Para aprofundar

O texto integral do artigo 10 do EU AI Act, sobre dados e governança de dados em sistemas de alto risco, está no Regulamento (UE) 2024/1689, disponível em https://eur-lex.europa.eu. A operacionalização de governança de dados em pipelines de produção, incluindo lineage instrumentado, é tratada no curso de Engenharia de Dados da Fase 2 do programa.

4. Conclusão

Este texto-base cobriu a camada decisória da lente dos dados em três blocos encadeados. O primeiro organizou a decisão entre intervir nos dados e trocar de modelo, ancorada na evidência da análise de erro por slices e formalizada na árvore da figura 1: hipótese de dados examinada antes da hipótese de modelo, troca considerada apenas com o framework de qualidade verificado, decisão registrada e reavaliada a cada iteração. O segundo tratou a escolha entre dados reais e sintéticos como decisão de papel e proporção, com as três motivações legítimas, os dois riscos característicos, perda de fidelidade e auto-reforço, e a regra sem exceção da validação em dados reais. O terceiro converteu o vocabulário regulatório em procedimento: mapear o dataset, marcar os instrumentos incidentes, registrar bases legais, lacunas e risco residual.

O fio que atravessa os três blocos é a relação entre disponibilidade de dados, cronograma realista e risco residual admitido. Cada decisão desta camada é também uma decisão de cronograma: reanotar um slice, verificar a fidelidade de um gerador ou documentar uma base legal são linhas de plano com custo e prazo, e escondê-las não as elimina, apenas as transfere para o pior momento do projeto. O participante que sai deste módulo deve ser capaz de olhar para um plano de projeto e apontar onde essas linhas estão faltando, porque é essa a leitura que os laboratórios de decisão técnica e a residência vão exigir.

O instrumento que registra a primeira e mais frequente dessas decisões é o template T3.1, matriz de decisão dados versus modelo, objeto IA-027 deste módulo. Ele estrutura a escolha em cinco eixos, evidência de error analysis, custo da intervenção em dados, custo da troca de modelo, ganho esperado e prazo, com justificativa explícita por eixo e síntese decisória ao final. O quiz do módulo retoma os três blocos desta camada em cenários curtos orientados a decisão, no mesmo espírito: menos definição, mais escolha justificada.

Vale lembrar, por fim, que a lente dos dados não se fecha em si mesma. A decisão dados versus modelo reaparece sempre que qualquer outra lente do curso encontrar desempenho insuficiente; a disciplina de lineage construída aqui é pré-requisito da rastreabilidade que a lente da transparência, no módulo M5, exigirá das explicações; e as obrigações do artigo 10 do EU AI Act, tratadas aqui pelo ângulo dos dados, voltarão no M5 pelo ângulo da explicabilidade. Dados são o ângulo de leitura deste módulo, mas o repertório decisório construído aqui acompanha o participante por todo o restante do programa.

REFERÊNCIAS

Bibliografia mínima

NG, A. A Chat with Andrew Ng on MLOps: From Model-centric to Data-centric AI. DeepLearning.AI, 2021. Vídeo em acesso aberto. Disponível em https://www.deeplearning.ai.

SAMBASIVAN, N. et al. Everyone Wants to Do the Model Work, Not the Data Work: Data Cascades in High-stakes AI. In: CHI Conference on Human Factors in Computing Systems, 2021. Disponível em https://research.google/pubs/pub49953.

BRASIL. Lei n. 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Diário Oficial da União, Brasília, 2018. Texto integral em https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm.

Bibliografia complementar

NORTHCUTT, C. G.; ATHALYE, A.; MUELLER, J. Pervasive Label Errors in Test Sets Destabilize Machine Learning Benchmarks. In: Advances in Neural Information Processing Systems (NeurIPS), 2021. Preprint em https://arxiv.org/abs/2103.14749.

WHANG, S. E. et al. Data Collection and Quality Challenges in Deep Learning: A Data-centric AI Perspective. The VLDB Journal, 2023. Preprint em https://arxiv.org/abs/2112.06409.

SHUMAILOV, I. et al. AI Models Collapse When Trained on Recursively Generated Data. Nature, v. 631, p. 755-759, 2024. DOI 10.1038/s41586-024-07566-y.

GEBRU, T. et al. Datasheets for Datasets. Communications of the ACM, v. 64, n. 12, 2021. Preprint em https://arxiv.org/abs/1803.09010.

UNIÃO EUROPEIA. Regulamento (UE) 2016/679 (Regulamento Geral sobre a Proteção de Dados, GDPR). Texto integral em https://eur-lex.europa.eu.

UNIÃO EUROPEIA. Regulamento (UE) 2024/1689 (EU AI Act). Artigo 10, dados e governança de dados. Texto integral em https://eur-lex.europa.eu.

Industr.IA

Residência em TIC 49



Executor iRede

Executor Atlântico

Coordenador Softex

Financiador MCTI Futuro

Ministério da Ciência, Tecnologia e Inovação

Governo do Brasil — Do lado do povo brasileiro

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.