Industr.IA

Glossário

Data-centric AI

Unidade M3 | Capítulo Único
Prof.: Nome do Professor

Industr.IA

Glossário
Unidade M3 | Capítulo Único

Convenções: cada entrada traz tag de origem no formato [M3: seção]. Quando o texto-base traz um box-glossário formal para o termo, a definição reproduz o texto do box. Termos introduzidos ou retomados pelo notebook do módulo trazem a marca do notebook na tag (por exemplo [M3: 3.3, IA-025]). Referências cruzadas aparecem como "veja X," sem definição. A ordem é alfabética, ignorando acentos e diferença entre maiúsculas e minúsculas.

Glossário de Termos

Termo	Descrição	Origem
Abordagem centrada no modelo	Postura em que os dados são tratados como insumo fixo e todo esforço de melhoria recai sobre o modelo: trocar a arquitetura, ajustar hiperparâmetros, testar um algoritmo mais recente. É o reflexo que a abordagem data-centric inverte, e a armadilha mais cara da seção 3.1.	[M3: 3.1]
Abordagem data-centric	Inversão da ordem de prioridade: mantém-se um modelo de referência fixo e itera-se de forma sistemática sobre os dados, corrigindo rótulos, padronizando a coleta e cobrindo subgrupos mal representados, com cada volta do ciclo orientada pela análise de erro por slices.	[M3: 3.1]
Acurácia (dimensão de qualidade)	Dimensão de data quality que pergunta se o valor registrado corresponde ao mundo real, como um rótulo de defeito atribuído à peça certa. Não confundir com a métrica de classificação de mesmo nome, definida no GLO-M0; aqui a propriedade é do dado, não do modelo.	[M3: 3.3]
Anonimização	Transformação que torna a reidentificação do titular impossível em termos razoáveis, retirando o dado do alcance da LGPD. Exige mais do que remover identificadores diretos: enquanto o cruzamento de atributos permitir reidentificar, o dado é apenas pseudonimizado e continua pessoal.	[M3: 3.2]
Atualidade	Dimensão de data quality que pergunta se o dado reflete o estado vigente relevante para a decisão. A falha típica é o cadastro de equipamento desatualizado há meses, que faz o treino descrever um mundo que já mudou.	[M3: 3.3]

Termo	Descrição	Origem
Augmentation	Papel de ampliação do conjunto de treino. No módulo, designa o uso de dados sintéticos como complemento da base real, preenchendo regiões específicas em proporção controlada; a augmentation clássica por transformação de exemplos reais é técnica vizinha, tratada nos cursos de Machine Learning e Deep Learning da Fase 2.	[M3: 3.7, IA-026]
Auto-reforço	Auto-reforço é o ciclo em que um modelo é treinado, em proporção crescente, sobre dados produzidos por modelos, próprios ou de terceiros. A cada rodada, os exemplos sintéticos reforçam os padrões e os vieses do gerador e apagam a variabilidade das caudas da distribuição real, degradando progressivamente a qualidade. É o fenômeno descrito na literatura como colapso de modelo.	[M3: 3.7, IA-026]
Base legal de tratamento	Fundamento jurídico que autoriza tratar um dado pessoal. Sob a LGPD, todo tratamento precisa de pelo menos uma: consentimento, cumprimento de obrigação legal, execução de contrato, legítimo interesse, entre outras. Não basta ter o dado disponível; é preciso poder apontar a base legal que justifica usá-lo para a finalidade declarada.	[M3: 3.2, IA-024]
Baseline	Veja modelo de referência.	
Colapso de modelo	Veja auto-reforço.	
Completude	Dimensão de data quality que pergunta se há valor onde deveria haver valor, medida pela fração de campos preenchidos. A falha típica é o sensor sem leitura em parte dos registros; no dataset do notebook, os valores marcados com interrogação.	[M3: 3.3, IA-025]
Concept drift	Mudança, ao longo do tempo, na relação entre entradas e saídas, distinta da mudança na distribuição das entradas (data drift). Mencionado no módulo apenas para delimitação; tratado nos cursos de Machine Learning e Deep Learning da Fase 2. Veja data drift.	[M3: 3.1, IA-024]
Consistência	Dimensão de data quality que pergunta se campos e registros concordam entre si, sem contradições entre fontes. A falha típica é a data de reparo anterior à data da falha que o motivou.	[M3: 3.3]

Industr.IA

Termo	Descrição	Origem
Dados sintéticos	Exemplos gerados por simulação de domínio ou por modelo generativo, em vez de coletados do processo real. Legítimos como complemento de treino para casos raros, custo de coleta ou privacidade, com origem registrada no lineage; inaceitáveis no conjunto de teste em qualquer proporção.	[M3: 3.7, IA-026]
Data drift	Mudança, ao longo do tempo, na distribuição dos dados que o sistema recebe em produção em relação à distribuição sobre a qual foi treinado. Pode ser gradual (desgaste de equipamento que altera leituras de sensor) ou abrupta (troca de fornecedor, mudança de processo). É uma das razões pelas quais um modelo bom no lançamento degrada com o tempo, ainda que nada no código mude. Quando o que muda é a relação entre entradas e saídas, e não a distribuição das entradas, fala-se em concept drift, tratado nos cursos de Machine Learning e Deep Learning da Fase 2.	[M3: 3.1, IA-024]
Data lineage	Registro rastreável da origem de cada dado e de todas as transformações por que passou até chegar ao conjunto de treino. Sustenta auditoria, reprodutibilidade e resposta a pedidos de titulares, e é pré-requisito prático para demonstrar conformidade quando um regulador pergunta de onde veio determinado dado.	[M3: 3.2, IA-024]
Distribution shift	Diferença de distribuição entre os dados de treino e os dados encontrados em produção, seja de origem, condição de coleta ou período. Quando essa diferença surge ao longo do tempo, recebe o nome de data drift; alinhá-la é um dos cenários em que a abordagem data-centric mais rende.	[M3: 3.1]
Drift	Veja data drift.	
Erro irredutível	Erro irredutível é a parcela do erro que nenhum modelo elimina, porque decorre de ambiguidade ou ruído intrínsecos ao problema e aos dados disponíveis. Quando o erro observado se aproxima desse piso, trocar de modelo não traz ganho relevante; a margem restante só se move, se mover, com dados melhores ou com uma reformulação do problema.	[M3: 3.6, IA-026]

Termo	Descrição	Origem
Error analysis	Análise de erro estruturada que mede o desempenho do sistema dentro de cada slice, em vez de apenas no agregado, seguindo cinco passos: definir os slices, medir a métrica por slice, ordenar pelos gaps ponderados pelo suporte, inspecionar erros dos piores slices e decidir a intervenção. É a evidência de entrada da decisão dados versus modelo.	[M3: 3.4, IA-025]
EU AI Act	Regulamento da Inteligência Artificial, Regulamento (UE) 2024/1689, que classifica sistemas de IA por nível de risco e regula o sistema, não o dado pessoal. Para sistemas de alto risco, o Artigo 10 impõe governança dos conjuntos de treino, validação e teste: relevância, representatividade suficiente e exame de erros e vieses, transformando qualidade de dados em obrigação legal.	[M3: 3.2]
Fidelidade (de dados sintéticos)	Grau em que um conjunto sintético aproxima a distribuição real, incluindo caudas, casos limítrofes e correlações finas entre variáveis. A perda de fidelidade é o primeiro risco do dado sintético, e sua verificação combina comparação estatística, exame de especialista e teste por consequência sobre dados reais.	[M3: 3.7, IA-026]
Framework de data quality	Instrumento que avalia um dataset por seis dimensões verificáveis, cada uma com teste objetivo: completude, consistência, acurácia, atualidade, validade e unicidade. Transforma a queixa difusa de dado ruim em uma lista de problemas endereçáveis, e sua verificação antecede a hipótese de troca de modelo na árvore de decisão do módulo.	[M3: 3.3, IA-025]
Gap de desempenho	Diferença entre a métrica medida em um slice e a métrica de referência, global ou de outro slice. Gaps grandes com suporte adequado indicam problema real e endereçável, e o produto do gap pelo peso do slice no volume projeta o teto do ganho agregado de uma intervenção.	[M3: 3.4, IA-025]
GDPR	Regulamento Geral sobre a Proteção de Dados, Regulamento (UE) 2016/679, com bases legais e deveres análogos aos da LGPD. Acrescenta, no Artigo 22, limites a decisões inteiramente automatizadas com efeito significativo sobre a pessoa, ponto retomado no módulo M5, e trata transferências internacionais em capítulo próprio.	[M3: 3.2]

Termo	Descrição	Origem
Intervenção combinada	Síntese decisória em que a equipe intervém nos dados primeiro e registra, desde já, um gatilho explícito de reavaliação da troca de modelo: se o erro residual se mostrar difuso com o framework de qualidade atendido, a troca entra em avaliação com piloto dedicado. Não autoriza executar as duas intervenções ao mesmo tempo.	[M3: 3.6, IA-027]
Intervenção data-centric	Ação de melhoria dirigida aos dados a partir da evidência da error analysis: coletar ou rebalancear exemplos do slice fraco, reanotar com critério unificado ou recoletar após drift. Seu ganho se transfere a qualquer modelo futuro, o que a coloca antes da troca de modelo na ordem econômica do módulo.	[M3: 3.6, IA-025]
LGPD	Lei Geral de Proteção de Dados Pessoais (Lei 13.709/2018), âncora brasileira do tratamento de dados pessoais. Exige uma base legal para cada tratamento, impõe os princípios de finalidade, adequação e minimização, e dá tratamento reforçado aos dados pessoais sensíveis (Artigo 11). Incide sempre que o dataset contém pessoa natural identificada ou identificável.	[M3: 3.2]
Long tail	Perfil de problema com muitos casos raros que, somados, pesam mais do que parecem. Nesses problemas, poucos exemplos bem escolhidos fecham a lacuna que mais camadas de modelo não fecham, o que torna a cauda longa um dos cenários típicos de vantagem da abordagem data-centric.	[M3: 3.1]
Modelo de referência (baseline model)	Modelo treinado no início do ciclo data-centric e mantido fixo ao longo das iterações, servindo de instrumento de diagnóstico dos dados: as métricas por slice medidas sobre ele localizam onde o dado é fraco e orientam a intervenção.	[M3: 3.1]
Proporção de positivos	Fração de exemplos da classe positiva dentro de um slice. Quando varia entre slices, a acurácia deixa de ser comparável entre eles, porque acertar a maioria negativa infla o número; é a coluna que explica um slice ter a maior acurácia e o pior recall ao mesmo tempo.	[M3: 3.4, IA-025]

Industr.IA

Termo	Descrição	Origem
Pseudonimização	Substituição de identificadores diretos por códigos, mantendo razoavelmente possível a reidentificação por cruzamento de atributos. O dado pseudonimizado continua pessoal e continua sob a LGPD; confundi-la com anonimização é a armadilha regulatória mais frequente do módulo.	[M3: 3.2]
Risco residual	Risco residual é o risco que permanece depois de aplicadas as medidas de mitigação planejadas, e que o projeto decide aceitar de forma explícita e documentada. Na lente dos dados, é a lacuna de qualidade, viés ou adequação regulatória que não será fechada no ciclo atual, registrada com sua justificativa e com o gatilho que forçará sua revisão.	[M3: 3.8, IA-026]
Ruído de rótulo	Presença de rótulos errados ou inconsistentes no dataset, como anotações divergentes entre turnos ou classes trocadas. O modelo aprende o ruído, e nenhuma arquitetura corrige rótulos errados; a mitigação é a auditoria de uma amostra e a reanotação com critério unificado.	[M3: 3.1]
Slice	Subconjunto dos dados definido por um critério interpretável, como uma faixa de valores, uma categoria ou uma condição de coleta. Diferente de uma partição aleatória, o slice é escolhido por ter significado de domínio, o que permite ler o desempenho do modelo onde ele de fato importa e localizar a falha em um recorte específico.	[M3: 3.4, IA-024]
Sub-representação	Escassez de exemplos de um grupo, condição ou classe dentro do treino, incluindo o caso da classe positiva escassa dentro de um slice específico. É a causa de gap que aponta para coleta ou rebalanceamento, e a forma localizada do viés de representação.	[M3: 3.6, IA-025]
Suporte	Número de exemplos de um slice no conjunto analisado. Com suporte pequeno, as métricas do slice viram ruído estatístico e pedem cautela antes de qualquer intervenção; por isso o suporte acompanha cada linha da tabela de error analysis.	[M3: 3.4, IA-025]
Teto de qualidade	Limite de desempenho que os dados impõem a qualquer modelo treinado sobre eles. Rótulos inconsistentes, lacunas de cobertura e medições ruidosas fixam esse teto; o modelo apenas decide quanto dele se alcança, e é essa assimetria que fundamenta o deslocamento data-centric.	[M3: 3.1]

Termo	Descrição	Origem
Unicidade	Dimensão de data quality que pergunta se não há duplicatas indevidas inflando a amostra, como o mesmo evento registrado por dois sistemas. No notebook do módulo, é verificada junto da completude antes do treino do classificador de referência.	[M3: 3.3, IA-025]
Validade	Dimensão de data quality que pergunta se cada valor respeita o formato, a faixa e o domínio esperados. A falha típica é a temperatura abaixo do zero absoluto, um valor fisicamente impossível que passa despercebido sem verificação declarada.	[M3: 3.3]
Viés de agregação	Viés que entra na modelagem, ao usar um único modelo para grupos heterogêneos que se comportam de forma distinta. Revela-se na análise por slices, quando um subgrupo tem desempenho sistematicamente pior que o agregado.	[M3: 3.5]
Viés de anotação	Viés que entra na rotulagem, pela subjetividade ou inconsistência do anotador. Investiga-se auditando uma amostra de rótulos, idealmente com mais de um anotador, e mitiga-se com critério de anotação unificado.	[M3: 3.5]
Viés de avaliação	Viés que entra na etapa de avaliação, quando o benchmark ou o conjunto de teste não representa o uso real do sistema. Um número alto medido sobre distribuição diferente da operação não sustenta afirmação de qualidade.	[M3: 3.5]
Viés de implantação	Viés que surge quando o sistema é usado em produção de forma diferente da prevista no desenho, como um modelo de inspeção treinado para uma planta e operado em outra, com câmeras e iluminação distintas.	[M3: 3.5]
Viés de medição	Viés que entra quando o atributo registrado é um proxy imperfeito do que se queria medir, de modo que o dado carrega distorção mesmo estando corretamente coletado e anotado.	[M3: 3.5]
Viés de representação	Distorção que surge quando a amostra de treino não cobre adequadamente certos grupos ou condições da população em que o sistema será usado. O modelo aprende bem o que está abundante na amostra e mal o que está raro, ainda que esse raro seja importante na operação. É detectável antes	[M3: 3.5, IA-024]

Termo	Descrição	Origem
	do treino, comparando a composição da amostra com a do uso pretendido.	
Viés histórico	Viés que vem do mundo que gera os dados: a desigualdade preexistente se reflete fielmente em dados corretos. Distingue-se dos demais por não ser um defeito de coleta ou de processo, o que muda a natureza da mitigação possível.	[M3: 3.5]

Industr.IA

Programa Brasileiro de Formação
Acadêmico-Industrial em IA

Executor iRede

Executor Atlântico

Coordenador Softex

Financiador MCTI Futuro · Ministério da Ciência, Tecnologia e Inovação · Governo do Brasil

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.