Industr.IA

Glossário

Edge AI: Glossário do Módulo

Unidade M4 | Capítulo Único

Prof.: Arthur Nascimento

Industr.IA

Glossário de Termos
Unidade M4 | Capítulo Único

Termo	Descrição	Origem
Arquitetura híbrida	Divisão deliberada da inferência entre pontos do continuum: a parte da solução amarrada a latência, privacidade ou operação offline roda no edge, e a parte que tolera espera ou exige um modelo maior roda na cloud. É o resultado frequente da árvore de decisão quando os gatilhos valem para parte do fluxo, não para o todo, e exige registrar qual parte roda onde e por quê.	[M4: 4.5]
Ativações	Valores intermediários que circulam entre as camadas de um modelo durante a inferência. Na quantização, as ativações também podem passar a inteiros, além dos pesos, o que permite executar a maior parte das contas em aritmética inteira.	[M4: 4.3]
Benchmark on-device	Medição de latência, memória e acurácia executada no dispositivo alvo, com o modelo no formato final e o dado da aplicação, em vez de no ambiente de desenvolvimento. É a evidência que valida uma decisão de compressão: números medidos em servidor, ou sobre dados de benchmark público, não transferem para a ponta, porque mudam o hardware, a aritmética e a distribuição dos dados ao mesmo tempo.	[M4: 4.6]
Calibração	Passagem de um pequeno conjunto de dados representativos pelo modelo para observar as faixas que pesos e ativações de fato ocupam e escolher bem os fatores de escala da quantização. A faixa observada no dado real é o que torna a quantização confiável.	[M4: 4.3]
Cloud (ponto do continuum)	Ponto do continuum em que a inferência ocorre num data center remoto, com computação ampla, elástica e compartilhada, a uma distância de rede que cobra seu preço em latência e em dependência de conectividade.	[M4: 4.1]

Termo	Descrição	Origem
Cold start	Componente da latência pago na carga do modelo em memória, dominante no primeiro uso e pago de novo a cada reinício do processo. Medir apenas a inferência subestima o total do pipeline quando o processo reinicia com frequência.	[M4: 4.6]
Continuum cloud-edge	Espectro de posições em que a inferência pode ocorrer, do data center remoto ao próprio sensor, com quatro pontos de referência: cloud, fog, edge e endpoint. Deslocar a inferência em direção à ponta reduz latência e exposição do dado bruto e aumenta a restrição de recursos disponíveis.	[M4: 4.1]
Custo total de propriedade (TCO)	Soma de tudo o que uma alternativa custa ao longo do ciclo de vida: aquisição, instalação, operação, manutenção, atualização e desativação. Na decisão Edge versus Cloud, o TCO evita a comparação enganosa entre o preço por chamada da nuvem e o preço de compra do dispositivo, que deixa de fora banda, gestão de frota, atualização de modelo e substituição de unidades.	[M4: 4.7]
Degradação de acurácia	Perda de qualidade preditiva causada pela compressão. Costuma ser pequena até INT8 e acelerar nos regimes agressivos, e pode se concentrar em slices específicos do dado, razão pela qual a validação exige leitura por slice no dado real da aplicação.	[M4: 4.3, IA-031]
Dequantização	Reconstrução do valor aproximado de um peso a partir do índice inteiro guardado, usando o fator de escala e o zero-point da camada. No notebook do módulo, é a etapa que devolve os pesos a ponto flutuante antes da multiplicação de matrizes.	[M4: 4.3, IA-031]
Edge	Veja Edge AI.	

Termo	Descrição	Origem
Edge AI	Execução de modelos de inteligência artificial em hardware próximo à fonte dos dados, como sensores, câmeras, gateways ou aparelhos do usuário, em vez de um data center remoto. Edge descreve a posição da inferência no continuum, não uma família de modelos: o mesmo modelo pode ser servido na nuvem ou no edge conforme a decisão de deployment.	[M4: 4.1]
Endpoint	Ponto do continuum em que o próprio sensor ou aparelho final, com recurso muito restrito, realiza a inferência sem depender de nada externo. É o regime do TinyML, com orçamento de memória e energia muito mais apertado que o do edge.	[M4: 4.1]
Exportação de modelo	Serialização de um modelo treinado num formato portável: um arquivo com o grafo de operações e os pesos, escrito de forma independente do framework de origem, para que o modelo possa rodar fora do ambiente de treino.	[M4: 4.2]
Fator de escala	Número único por camada que liga a faixa contínua dos pesos em ponto flutuante aos níveis inteiros da quantização, permitindo guardar cada peso como o índice do nível mais próximo e reconstruir o valor aproximado na hora de calcular.	[M4: 4.3, IA-031]
Fog	Camada intermediária na borda da rede, em que um gateway ou servidor de planta processa os dados de vários dispositivos perto de onde foram gerados, reduzindo a viagem até a nuvem.	[M4: 4.1]
Formato de modelo	Arquivo que guarda o grafo de operações e os pesos de um modelo já treinado, de forma independente do framework em que foi criado. Formatos comuns na ponta incluem ONNX, TFLite e GGUF. O formato não roda o modelo; ele só o descreve. Quem o executa é o runtime.	[M4: 4.2]

Termo	Descrição	Origem
FP32, FP16, INT8, INT4	Regimes de precisão numérica dos pesos: ponto flutuante de 32 e de 16 bits, inteiros de 8 e de 4 bits. Cada peso ocupa 4, 2, 1 e 0,5 byte, respectivamente, quando [RF1.1] armazenado de forma compacta. FP16 costuma preservar a qualidade do modelo; INT4 já exige verificação [RF2.1] cuidadosa no dado real.	[M4: 4.3, IA-031]
Gatilho de posicionamento	Teste que desloca a inferência para a ponta apenas quando existe compromisso nomeável: latência como compromisso de produto com orçamento medido, privacidade ou soberania como obrigação identificada por artigo ou cláusula, ou conectividade não assumível no ponto de operação. Gatilho sem evidência é preferência, não gatilho.	[M4: 4.5]
Grafo de operações	Descrição da sequência de operações (multiplicações de matrizes, convoluções, funções de ativação) que transformam a entrada de um modelo na saída. Junto com o conjunto de pesos, é o que um formato de modelo guarda e um runtime executa.	[M4: 4.2]
Kernels inteiros	Implementações de operações otimizadas para aritmética inteira no hardware alvo. O ganho de latência da quantização depende deles: guardar menos bits não acelera a inferência se o runtime executar as operações [RF3.1] em ponto flutuante, como o notebook do módulo demonstra em numpy.	[M4: 4.3, IA-031]
Knowledge distillation	Técnica em que um modelo pequeno (o aluno) é treinado para reproduzir as saídas de um modelo grande já treinado (o professor). O knowledge distillation não comprime o modelo grande diretamente; produz um modelo novo e menor que herda parte de sua competência, útil quando o alvo de deployment não comporta a rede original.	[M4: 4.3]
NPU	Unidade de processamento neural, um acelerador de hardware especializado em multiplicações de matrizes e convoluções, as operações dominantes em redes neurais. Diferente de uma CPU de uso geral, ela troca	[M4: 4.2]

Termo	Descrição	Origem
	flexibilidade por eficiência energética, entregando muitas inferências por watt, o que a torna adequada a dispositivos com orçamento de energia apertado.	
Orçamento do alvo	Levantamento do que o hardware alvo oferece: a memória disponível para pesos, ativações e runtime, a energia que o ciclo de trabalho comporta e a aritmética que o acelerador de fato suporta. É o segundo passo da sequência de decisão de compressão e runtime.	[M4: 4.6]
Ponto de equilíbrio	Volume de inferências em que o custo total das duas estruturas se iguala: abaixo dele, o custo variável da cloud custa menos; acima, o custo fixo do edge se dilui e passa a custar menos. Sua posição depende dos coeficientes do caso concreto e se move com o tempo.	[M4: 4.7]
Precisão numérica	Quantidade de bits com que cada peso ou ativação é representado. Reduzir a precisão encolhe o modelo e barateia as operações, ao custo de um erro de arredondamento que cresce conforme diminuem os níveis disponíveis.	[M4: 4.3, IA-031]
Pruning	Remoção de pesos ou unidades de baixa contribuição de uma rede treinada. O modo não estruturado zera pesos individuais e gera esparsidade irregular que nem todo hardware aproveita; o estruturado remove neurônios, canais ou filtros inteiros e acelera em hardware comum. Costuma exigir fine-tuning para recuperar a acurácia perdida na poda.	[M4: 4.3]
Quantização	Redução da precisão numérica dos pesos e ativações de um modelo, por exemplo de ponto flutuante de 32 bits (FP32) para inteiros de 8 bits (INT8) ou 4 bits (INT4). A quantização encolhe o modelo e acelera a inferência, ao custo de uma perda de acurácia que cresce conforme a precisão diminui. FP16 costuma ser quase indolor; INT4 já exige cuidado.	[M4: 4.3, IA-031]

Termo	Descrição	Origem
Quantização de faixa dinâmica	Modo de quantização pós-treino em que o conversor quantiza os pesos sem exigir dataset de calibração, determinando as faixas das ativações durante a própria execução. É o caminho demonstrado no apêndice TFLite do notebook do módulo.	[M4: 4.3, IA-031]
Quantização pós-treino	Conversão direta de um modelo já treinado para uma precisão menor, sem novo ciclo de treino. É rápida e barata, e por isso vem primeiro na ordem de decisão; quando falha na validação e o regime não pode subir, entra o treino consciente de quantização.	[M4: 4.3]
Regime mínimo de compressão	Heurística da camada decisória: começar pelo regime menos agressivo compatível com o alvo que faz o modelo caber [RF4.1]e descer degraus apenas quando a restrição obrigar e descer degraus apenas quando a restrição obrigar, validando a cada degrau, porque cada degrau adicional gasta	[M4: 4.6]
Retreino	Novo ciclo de treinamento de um modelo já implantado, tipicamente com dados mais recentes, para recuperar desempenho perdido com a mudança na distribuição dos dados. No posicionamento, o retreino não tem gatilho de latência: costuma rodar na cloud, separado da inferência, como na arquitetura híbrida.	[M4: 4.5]
Runtime	Software que carrega um modelo em formato portável e executa a inferência, traduzindo as operações do modelo para o hardware disponível (CPU, GPU, NPU, TPU). Um runtime não treina o modelo; apenas o roda. Exemplos: TFLite, ONNX Runtime, Core ML, llama.cpp.	[M4: 4.2, IA-031]
Runtime neutro	Runtime que executa um formato independente do framework de origem, como o ONNX Runtime, desacoplando a escolha do framework de treino da escolha do runtime de produção. Contrapõe-se ao runtime preso a um framework, como TFLite e Core ML, cuja vantagem é a integração mais estreita com o hardware do seu ecossistema.	[M4: 4.2]

Termo	Descrição	Origem
Saídas suaves	Distribuição de probabilidade que um modelo atribui a todas as classes, e não apenas o rótulo vencedor. É o alvo de treino do aluno no knowledge distillation, por carregar informação mais rica do que o rótulo duro.	[M4: 4.3]
Serving de inferência	Camada de serviço que expõe um modelo em execução a múltiplos clientes pela rede, tratando requisições, lotes e escala, como o Triton ou o TensorFlow Serving. Distingue-se do runtime, que apenas carrega e executa o modelo: na cloud o modelo costuma ser servido; na ponta, é executado pelo runtime local.	[M4: 4.2]
Soberania de dados	Exigência, por lei ou por contrato, de que certos dados permaneçam sob a jurisdição de um país ou de uma organização. Manter a inferência local evita que o dado bruto cruze fronteiras para ser processado, e costuma pesar em setores regulados e em contratos com órgãos públicos.	[M4: 4.1]
TinyML	Caso extremo de Edge AI em que o modelo roda em microcontroladores de pouquíssima memória e baixo consumo [RF7.1] de energia. Todo TinyML é Edge AI, mas nem todo Edge AI é TinyML, e a distinção importa porque o orçamento de recursos no endpoint é muito mais apertado do que no edge.	[M4: 4.1]
TPU de borda	Acelerador construído para aritmética inteira, que brilha com modelos quantizados em INT8 e não com ponto flutuante: seus circuitos de multiplicação foram desenhados para inteiros, de modo a economizar energia e área. Exemplo: o Coral, do Google.	[M4: 4.2]
Treino consciente de quantização	Ajuste do modelo já prevendo a perda de precisão da quantização, o que recupera parte da acurácia ao custo de um novo ciclo de treino, com dados, tempo de computação e calendário. Entra quando a quantização pós-treino falha na validação e o regime não pode subir.	[M4: 4.3]

Termo	Descrição	Origem
Zero-point	Deslocamento inteiro que, junto com o fator de escala, mapeia a faixa real dos pesos de uma camada nos níveis da quantização, permitindo representar com fidelidade faixas assimétricas em torno de zero.	[M4: 4.3, IA-031]

Industr.IA

Programa Brasileiro de Formação
Acadêmico-Industrial em IA

Executor iRede

Executor Atlântico

Coordenador Softex

Financiador MCTI Futuro · Ministério da Ciência, Tecnologia e Inovação · Governo do Brasil

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.