Industr.IA

Google Colabs

Edge AI: notebook de quantização de um modelo small

Unidade M4 | Capítulo Único
Prof.: Arthur Nascimento

Clique no link para acessar o Google Colab:

https://colab.research.google.com/drive/1KOU-ci5-PdBtzWM7yo6kqYByXdkM9zy1E?usp=sharing

Guia de Acesso ao Notebook

Curso base de IA | Unidade M4

Neste notebook, você abre a caixa da quantização implementando o mecanismo à mão, em numpy, sobre uma rede MLP treinada no dataset digits do scikit-learn: mapeia os pesos de cada camada em níveis inteiros por fator de escala e zero-point, e mede o que acontece com tamanho, latência e acurácia nos regimes FP32, INT8 e INT4. O notebook explica por que a latência quase não muda numa quantização simulada e um apêndice opcional demonstra a quantização real com TFLite sobre o MobileNetV2.

O objetivo é dar intuição concreta sobre o compromisso entre tamanho, latência e acurácia que sustenta a decisão de deployment do módulo, e sobre o papel do runtime na realização efetiva dos ganhos, distinção que alimenta o eixo de compressão e runtime da matriz Edge versus Cloud (T4.1).

Link: https://colab.research.google.com/drive/1KOU-ci5-PdBtzWM7yo6kqYByXdkM9zy1E?usp=sharing

O que você irá aprender

Palavra	Tradução
Modelo base em FP32	Treinamento de uma MLP no dataset digits e extração das matrizes de pesos para inspeção.
Passagem para frente em numpy	Reimplementação da inferência da rede fora do scikit-learn, tornando cada operação visível.
Mecanismo da quantização	Mapeamento da faixa de valores dos pesos em níveis inteiros por fator de escala e zero-point, com dequantização.
Tamanho, latência e acurácia	Medição do compromisso entre os três eixos nos regimes FP32, INT8 e INT4.
O papel do runtime	Por que a latência não cai só por quantizar em numpy e por que o ganho real depende de kernels inteiros, com apêndice opcional em TFLite.
Exercício de prática	Quantização em regime agressivo (2 bits) com solução comentada ao final.

Industr.IA

Residência em TIC 49



Executor iRede

Executor Atlântico

Coordenador Softex

Financiador MCTI Futuro

Ministério da Ciência, Tecnologia e Inovação

Governo do Brasil — Do lado do povo brasileiro

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.