Industr.IA

Template

Edge AI: matriz de decisão Edge versus Cloud



Unidade M4 | Capítulo Único

Prof.: Arthur Nascimento

Matriz de decisão: Edge versus Cloud

Curso base de IA | Unidade M4

Como usar:

A face 1 é o instrumento reutilizável que você preenche para o seu cenário; a face 2 explica como preencher cada eixo; a seção final traz um exemplo preenchido de ponta a ponta, como referência.

Este instrumento organiza a decisão tratada nas seções 4.5 a 4.7 do texto-base: registrar onde a inferência ocorre, como o modelo cabe nesse alvo e o que a configuração custa, numa justificativa defensável perante stakeholders. Os três eixos são lidos em conjunto, e o posicionamento no continuum é o eixo de entrada: sem os três gatilhos testados com evidência, os demais não têm base.

Face 1 - Instrumento (preencher)

Preencha cada célula com a avaliação do seu cenário. O texto em itálico é a instrução do que registrar ali, e deve ser substituído pelo conteúdo do seu caso.

Eixo de decisão	Edge	Cloud	Justificativa (1 a 3 frases)
Posicionamento no continuum. Algum gatilho dispara?	Teste os três gatilhos com evidência: latência como compromisso de produto (orçamento medido contra a viagem de rede no pior caso), privacidade ou soberania como obrigação nomeável (artigo, cláusula, norma), conectividade não assumível (levantamento do ponto de operação). Nomeie o ponto do continuum que o gatilho exige.	Nenhum gatilho dispara? Registre os três testes respondidos e a evidência de cada não, e siga para a pergunta econômica do eixo de custo.	Qual lado os testes favorecem, citando a evidência que decidiu: o número de latência, a cláusula, o mapa de conectividade.
Compressão e runtime. O modelo cabe no alvo com degradação tolerável?	Registre o alvo e seu orçamento (memória, energia, aritmética suportada), a cadeia formato e runtime, e o regime mínimo que fez o modelo caber, com os números do benchmark on-device: latência de pior caso, pico de memória e métrica no dado real, lida por slice.	Registre o que servir na nuvem exigiria (instância, acelerador, modelo sem compressão) e o que ela dispensa (conversão, validação por dispositivo, atualização unidade a unidade).	A degradação medida cabe na tolerância da tarefa? Justifique com o número do benchmark on-device, não com média de benchmark público. Registre o regime descartado e o número que o descartou.

Custo total. Qual estrutura domina no volume projetado?	Estime o custo fixo no horizonte da vida útil: dispositivos, instalação, gestão de frota, atualização remota e substituição de unidades.	Estime o custo variável no volume projetado de produção: inferência recorrente, banda de subida do dado bruto e saída de dados.	De que lado do ponto de equilíbrio o volume projetado está? Compare no mesmo horizonte e cite as respostas que decidiram o sinal (volume contínuo ou em rajadas, peso do dado, dispersão da frota, frequência de atualização).

Síntese decisória.

Marque a opção escolhida e justifique em uma a três frases, nomeando o caso e mostrando coerência com a leitura conjunta dos três eixos.

[ ] Edge (ao menos um gatilho dispara com evidência nomeada, ou o custo total no volume projetado favorece a ponta)

[ ] Cloud (nenhum gatilho dispara e o volume projetado fica aquém do ponto de equilíbrio)

[ ] Arquitetura híbrida (os gatilhos valem para parte do fluxo; registre qual parte roda onde e o custo de coordenação)

Justificativa da síntese: _____

Face 2 - Instrução de uso

O eixo de posicionamento no continuum é o critério de entrada. Faça o teste prático gatilho a gatilho: a latência tem compromisso nomeável (tempo de ciclo, SLA, requisito de segurança) e a viagem de rede no pior caso consome o orçamento medido? A privacidade ou a soberania têm obrigação identificada por artigo, cláusula ou norma, com registro de qual dado bruto fica e qual derivado pode subir? A conectividade do ponto de operação é estável, com banda suficiente, durante todo o período de uso? Um gatilho que dispara determina também o ponto do continuum exigido (fog, edge ou endpoint), e não apenas o lado. Sem os três testes respondidos com evidência, não preencha o restante da matriz.

O eixo de compressão e runtime segue a sequência do texto-base: alvo, orçamento do alvo, cadeia de formato e runtime, regime mínimo que faz caber, validação. Só vale número de benchmark on-device, medido no dispositivo alvo com o dado da aplicação, e a leitura por slice importa tanto quanto a agregada: a degradação da compressão não é

uniforme. Registre também o que foi descartado, com o número que o descartou; é esse registro que torna a decisão auditável e reabrível quando o modelo ou o alvo mudarem.

O eixo de custo total compara as duas estruturas no horizonte da vida útil dos dispositivos e no volume projetado de produção, nunca no volume do piloto. Quatro perguntas costumam decidir o sinal: o volume é contínuo ou em rajadas; o dado que subiria é pesado ou leve; a frota seria concentrada ou espalhada; o modelo muda com que frequência. Nomeie os custos escondidos relevantes dos dois lados (gestão de frota, atualização remota e heterogeneidade no edge; saída de dados, reprecificação e crescimento não projetado na cloud) e registre o perfil de desembolso, porque a preferência da organização entre investimento e custo recorrente também pesa.

O que constitui uma justificativa adequada.

Uma justificativa adequada cita uma evidência concreta do cenário, e não uma preferência geral. Em vez de escrever que o edge é mais rápido, escreva qual é o orçamento de latência, quanto a viagem de rede consome no pior caso medido, qual cláusula retém o dado bruto, ou de que lado do ponto de equilíbrio está o volume projetado. Uma a três frases por eixo são suficientes.

Lembrete sobre o condicionamento dos eixos.

Os três eixos não são independentes: o posicionamento define o alvo que condiciona a compressão, o regime de compressão muda a conta de custo, e a conta de custo pode devolver a decisão ao posicionamento. Quando a leitura de um eixo mudar, releia os outros dois antes de fechar a síntese. E registre a decisão como compromisso de produto no escopo, com os coeficientes explícitos (o orçamento de latência, a cláusula, o ponto de equilíbrio): são eles que permitem revisitar a decisão nos marcos do projeto quando algum compromisso mudar.

Exemplo preenchido

Cenário.

Uma cooperativa agroindustrial classifica grãos por câmera nas moegas de 12 unidades de recebimento. Na safra, cada unidade processa caminhões em fila, e o laudo de classificação precisa sair em menos de 2 segundos para não travar a balança, prazo fixado em cláusula do contrato de recebimento com os produtores. A conectividade rural é intermitente nas unidades mais distantes. O modelo é uma rede convolucional de porte médio, e a equipe avalia rodar a inferência num servidor na nuvem ou num dispositivo com GPU embarcada por moega.

Eixo de decisão	Edge	Cloud	Justificativa (1 a 3 frases)
Posicionamento no continuum. Algum gatilho dispara?	Latência dispara: o laudo em menos de 2 segundos é cláusula do contrato de recebimento, e a viagem de rede nas unidades remotas chega a 1,5 segundo no pior caso medido, consumindo grande parte do orçamento de latência. Conectividade dispara em 5 das 12 unidades, sem enlace estável durante a safra. Privacidade não dispara: imagem de grão não é dado pessoal. Ponto exigido: edge, um dispositivo por moega.	Nenhum teste favorece a nuvem: os dois gatilhos presentes são compromissos nomeados, por cláusula e por levantamento de campo.	Dois gatilhos com evidência decidem pelo edge; o contrato e a medição de rede no pior caso são a evidência central.
Compressão e runtime. O modelo cabe no alvo com degradação tolerável?	Alvo: módulo com GPU embarcada e 4 GB de memória. Modelo exportado para ONNX e executado pelo ONNX Runtime; INT8 pós-treino coube com folga e perdeu 0,3 ponto de acurácia no dado da safra anterior, de forma uniforme entre as variedades. Latência de pior caso no dispositivo: 320 milissegundos por caminhão.	Sem compressão, exigiria instância com GPU dedicada e não eliminaria a viagem de rede que estoura o orçamento de latência.	O benchmark on-device fecha o orçamento com margem; INT4 foi descartado por perda de 2,1 pontos na variedade de menor volume.
Custo total. Qual estrutura domina no volume projetado?	Doze dispositivos mais instalação, vida útil de 4 anos, atualização remota duas vezes por ano fora da safra; custo fixo dominante e conhecido.	O volume em rajadas sazonais favoreceria a elasticidade, mas a banda de subida das imagens das 12 unidades e a inferência recorrente crescem com o volume de operação da cooperativa.	O custo não decidiu: os gatilhos do primeiro eixo já haviam fechado a questão; a conta em 4 anos confirmou que o edge não é proibitivo no volume projetado.

Síntese do exemplo.

Para a classificação de grãos nas moegas, a escolha é edge, com um dispositivo por moega, modelo em INT8 servido pelo ONNX Runtime e agregados subindo quando há enlace. Dois gatilhos com evidência nomeada, a cláusula de 2 segundos e a conectividade não assumível em 5 unidades, decidem o posicionamento; o benchmark on-device valida a configuração com margem; e a conta em 4 anos confirma a viabilidade no volume projetado. Fica registrado o gatilho de reavaliação: se o contrato afrouxar o prazo do laudo e o enlace rural for modernizado, a comparação de custo total reabre no marco anual.

Industr.IA

Residência em TIC 49



Executor iRede

Executor Atlântico

Coordenador Softex

Financiador MCTI Futuro · Ministério da Ciência, Tecnologia e Inovação · Governo do Brasil

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.