Industr.IA

Roteiro de estudos

Quantização e borda

Nível da squad: Consolidado
Público: squad

Industr.IA

Roteiro de estudos

M4 · Quantização e borda · Para squads de nível Consolidado

O roteiro diz o que fazer antes, durante e depois de cada encontro. Em cada linha, a última coluna traz a pergunta que você precisa saber responder: ela é o teste do seu estudo, e é o tipo de pergunta que o instrutor faz no encontro. A coluna Quem diz se a linha é de cada participante, da squad reunida ou só da pessoa entregadora. A squad pode dividir o estudo, mas a defesa é por sorteio.

Primeira semana do desafio · Compreender, delimitar e decidir

Quando	Quem	O que fazer	Pergunta para levar
Até 4 dias antes do encontro 1	Cada participante	Ler a situação. Fazer a leitura principal: Leonarczyk et al., Proposta de Arcabouço Teórico para a Avaliação Sistemática de Modelos de Linguagem Quantizados, ERAMIA-RS 2025, em português: as dimensões de qualidade e de eficiência para avaliar um modelo quantizado.	O pedido da TI é um problema ou uma solução? Que limite do coletor o modelo precisa respeitar?
Até a véspera	Cada participante	DeepLearning.AI, Quantization Fundamentals with Hugging Face, em inglês, 1h14, gratuito por tempo limitado: tipos de dado, quantização linear e carregamento em precisão menor. ONNX Runtime, Quantize ONNX models, em inglês: seção de quantização dinâmica e a função `quantize_dynamic`; e o estimador de memória do Accelerate. No primeiro desafio, concluir a folha técnica.	O que muda num modelo quando os pesos passam de float32 para int8, e o que pode piorar?
Na véspera	Squad reunida	Conversar sobre a situação e escrever um rascunho: que decisão a empresa precisa tomar, qual é a restrição, o que ainda é hipótese.	Que medidas de eficiência e de qualidade o artigo propõe, e quais delas a situação exige?
No encontro 1	Squad reunida, com o instrutor	Delimitar o problema e decidir a abordagem. Preencher KIT-001, KIT-003 e KIT-004 Matriz de Alternativas, com o critério de aceite no KIT-003. Escolher a pessoa entregadora deste desafio: só ela entrega os artefatos no Classroom e grava no GitHub o notebook executado e os registros, pela célula de envio do fim do notebook. Cada participante guarda o texto exato do critério: ele vai para o notebook do desafio.	O critério tem métrica, recorte e valor?
Até 2 dias depois	Pessoa entregadora	No Classroom, entregar as atividades do encontro com os artefatos que a squad preencheu junta. As outras pessoas da squad não entregam: para elas, a atividade fica sem entrega, e isso é o esperado.	

Industr.IA

Segunda semana do desafio · Testar e defender

Quando	Quem	O que fazer	Pergunta para levar
Até 4 dias antes do encontro 2	Cada participante	Executar o notebook `01_estudo_memoria_e_precisao.ipynb` e responder às perguntas do fim. Abrir `02_desafio_quantizar_ou_trocar.ipynb` a partir do GitHub, copiar o critério do KIT-003 na etapa 1, completar o que o notebook pede e executar até o fim, com `ENVIAR = False` na célula de envio. O notebook do desafio exige a GPU T4 do Colab, por causa do treino do modelo atual na etapa 7, que leva cerca de um minuto nela; as medições de tempo rodam na CPU, com 2 threads, como no coletor.	Quanto o modelo atual ocupa e quanto tempo leva por relato em CPU?
Até 2 dias antes	Cada participante, depois a squad reunida	Cada participante responde sozinho às perguntas da conclusão. Depois, a squad confere as respostas e fecha um texto para cada pergunta.	O que a quantização mudou em tamanho, tempo e acurácia?
Até a véspera	Pessoa entregadora	Numa mesma sessão do Colab: executar o notebook do desafio inteiro, escrever na conclusão as respostas fechadas pela squad, trocar `ENVIAR = False` por `ENVIAR = True` e executar só a célula de envio. Conferir no GitHub que o notebook, `mlflow.db` e `execucoes.csv` chegaram à pasta do desafio, no commit "entrega de ... por" seguido da sua conta. As outras pessoas não executam a célula de envio.	A compra de coletores com GPU é necessária?
No encontro 2	Squad reunida, com o instrutor	Defender o resultado contra o critério. Quem apresenta é sorteado: todos precisam saber explicar o notebook. Preencher KIT-011 Matriz de Teste e KIT-007 Decisão Justificada.	O critério foi atendido? O que a squad recomenda?
Até 2 dias depois	Pessoa entregadora	No Classroom, entregar as atividades do encontro com os artefatos que a squad preencheu junta. As outras pessoas da squad não entregam: para elas, a atividade fica sem entrega, e isso é o esperado.	

Problema de conta, de token ou de acesso ao repositório vai ao instrutor da squad. A folha técnica tem o passo a passo e os problemas comuns. A GPU gratuita do Colab tem cota variável: rode o notebook no início da semana e desligue o ambiente ao terminar.

Industr.IA

Programa Brasileiro de Formação
Acadêmico-Industrial em IA

Executor Executor Coordenador Financiador

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.