Industr.IA

Situação

Quantização e borda

Nível da squad: Consolidado
Público: squad

Industr.IA

Situação

M4 · Quantização e borda · Para squads de nível Consolidado

Uma empresa de manutenção industrial atende fábricas de clientes com técnicos em campo. A cada ocorrência, o técnico digita um relato curto no coletor de dados, e o relato é classificado em uma de cinco classes: elétrica, mecânica, hidráulica (inclui pneumática), instrumentação ou segurança. A classe define a especialidade acionada e as peças consultadas no estoque.

Hoje a classificação é feita por um modelo de linguagem que só roda em servidor com GPU, e muitas plantas não têm conexão com a nuvem. A empresa quer que o próprio coletor classifique o relato, sem conexão. O coletor tem 8 GB de memória e nenhuma GPU, e a resposta precisa sair em menos de um segundo.

A área de TI propõe comprar coletores com GPU. Há dois caminhos no coletor atual: quantizar o modelo atual ou trocá-lo por um modelo menor. O dado indicado é `dados/relatos_de_campo.csv` do repositório, com um mês de relatos classificados. A squad fixa antes do teste o critério de aceite (tamanho, tempo de resposta e perda de qualidade toleráveis), mede antes e depois, e justifica a escolha.

O que a squad entrega

Entrega	Conteúdo	Onde
Encontro 1	KIT-001, KIT-003 e KIT-004 Matriz de Alternativas. O KIT-003 traz o critério de aceite. No encontro, a squad escolhe a pessoa entregadora do desafio, que faz as entregas no Classroom e no GitHub. Se este for o primeiro desafio da squad, também o KIT-020 Acordo de squad.	Classroom
Antes do encontro 2	Notebook `02_desafio_quantizar_ou_trocar.ipynb` executado, com o critério copiado do KIT-003, as saídas de todas as células e as respostas da conclusão, mais `mlflow.db` e `execucoes.csv`. Quem grava é a pessoa entregadora, pela célula de envio do notebook.	GitHub, pasta do desafio
Encontro 2	KIT-011 Matriz de Teste e KIT-007 Decisão Justificada, e a defesa do resultado. Quem apresenta é sorteado no encontro.	Classroom

Dado

Conjunto sintético, criado para este desafio. `relatos_de_campo.csv` tem 3.000 relatos de um mês; além das colunas abaixo, cada linha traz `id` e `data`.

Industr.IA

Coluna	Significado	Uso
`equipamento`	Equipamento da ocorrência (sete tipos)	Leitura
`texto`	Relato digitado pelo técnico, com abreviações e erros	Entrada
`classe`	Classe da ocorrência, sem acento	Alvo

Industr.IA

Programa Brasileiro de Formação
Acadêmico-Industrial em IA

Executor Executor Coordenador Financiador

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.