Industr.IA

E-book

Explicabilidade: Dimensão regulatória, Taxonomia de Técnicas e SHAP

Curso base de IA | Unidade M5

Prof.: Arthur Nascimento



SUMÁRIO

1. A dimensão regulatória da explicação 3
2.Taxonomia de técnicas 8
3. SHAP na prática 13
4.Limites para LLMs e IA generativa 18
5. Conclusão 23

Unidade M5

1. A dimensão regulatória da explicação

Esta seção pertence à camada conceitual e tem por objetivo que você distinga interpretabilidade de explicabilidade e reconheça os pontos em que a regulação passa a exigir explicação, situando cada exigência por categoria de risco. A pergunta que organiza toda a lente da transparência não é como gerar uma explicação, e sim quando ela é obrigatória, para quem e em que profundidade. A resposta a essa pergunta começa fora da técnica, na regulação, e é por ela que a seção começa. A sigla XAI, de explainable AI, ou IA explicável, nomeia justamente o conjunto de métodos e práticas que respondem a essa demanda de justificar predições.

Convém começar pelo motivo de a pergunta ter ficado inevitável. Ao longo dos módulos anteriores, você viu modelos ganharem capacidade à custa de estrutura interna cada vez mais complexa. Um modelo linear com vinte coeficientes pode ser lido diretamente: cada coeficiente diz o quanto uma variável empurra a saída, e o sinal diz em que direção. Um gradient boosting com milhares de árvores, ou uma rede neural com bilhões de parâmetros, não oferece essa leitura. A função existe e produz saídas corretas com frequência, mas o caminho de uma entrada específica até a saída passa por um número de operações grande demais para ser acompanhado por uma pessoa. Enquanto essa opacidade ficou restrita a sistemas de baixo impacto, como um recomendador de filmes, ela foi tolerada como preço do desempenho.

Essa tolerância desapareceu quando os mesmos modelos passaram a decidir crédito, triagem clínica, seleção de candidatos e priorização em serviços públicos. Nesses domínios, uma decisão sem justificativa não é apenas desconfortável: ela impede a pessoa afetada de contestar, impede o operador de auditar e impede o regulador de fiscalizar. A falta de explicação deixou de ser um detalhe técnico e virou, ao mesmo tempo, um problema jurídico, um risco de produto e uma barreira de confiança. É esse deslocamento que transforma a explicação em requisito, e não em refinamento opcional.

Antes de olhar as normas, fixe dois termos que a literatura e a prática costumam usar como sinônimos, embora não sejam. Interpretabilidade é uma propriedade intrínseca do modelo: o grau em que uma pessoa consegue acompanhar, a partir da própria estrutura, como a entrada se converte na saída. Um modelo é interpretável quando a sua forma já é a explicação. Explicabilidade é diferente: é a capacidade de produzir justificativas para as predições de um modelo que não é interpretável por dentro, quase sempre por meio de uma técnica externa aplicada depois do treinamento. Um modelo interpretável dispensa explicabilidade; um modelo opaco depende inteiramente dela. A

distinção importa porque, como se verá no tópico 2, escolher entre um modelo interpretável e um modelo opaco com explicação externa é, em si, uma decisão de projeto com consequências regulatórias.

GLOSSÁRIO

Interpretabilidade e Explicabilidade

Interpretabilidade é a propriedade de um modelo cuja lógica pode ser acompanhada diretamente por uma pessoa, como uma regressão linear, uma árvore rasa ou uma lista de regras. Explicabilidade é a geração de justificativas post-hoc para um modelo opaco, por meio de técnicas como SHAP ou LIME. A primeira é intrínseca ao modelo; a segunda é aplicada por fora, depois que o modelo já foi treinado.

Há uma tensão de fundo que explica por que nem sempre se escolhe o modelo mais transparente. Modelos mais expressivos, capazes de capturar relações não lineares e interações complexas entre variáveis, tendem a ajustar melhor dados difíceis, e é essa mesma expressividade que os torna opacos. Modelos simples, por sua vez, são legíveis, mas podem subajustar, deixando desempenho na mesa. Essa é a chamada tensão entre desempenho e interpretabilidade. Vale reter, desde já, que essa tensão é real mas nem sempre é grande: em muitos problemas tabulares, um modelo interpretável alcança desempenho próximo do de um modelo opaco, e a seção seguinte retoma esse ponto ao tratar do argumento de Rudin.

Fixado o vocabulário, veja onde a regulação entra. Quatro instrumentos concentram a exigência de explicação relevante para PD&I industrial no Brasil e na Europa, e convém tratá-los na ordem de proximidade com o público-alvo. A âncora brasileira é a LGPD, a Lei Geral de Proteção de Dados, Lei 13.709 de 2018. O seu artigo 20 assegura ao titular o direito de solicitar a revisão de decisões tomadas unicamente com base em tratamento automatizado que afetem os seus interesses, incluídas as decisões de perfil de consumo e de crédito. Um detalhe da história dessa norma importa ao profissional: a redação original exigia que a revisão fosse feita por pessoa natural, mas esse trecho foi vetado, e o veto foi mantido, de modo que hoje o texto garante o direito à revisão sem obrigar que ela seja humana. O parágrafo primeiro do mesmo artigo obriga o controlador a fornecer, quando solicitado, informações claras sobre os critérios e os procedimentos da decisão automatizada, resguardados os segredos comercial e industrial. A Autoridade Nacional de Proteção de Dados, a ANPD, incluiu inteligência artificial e

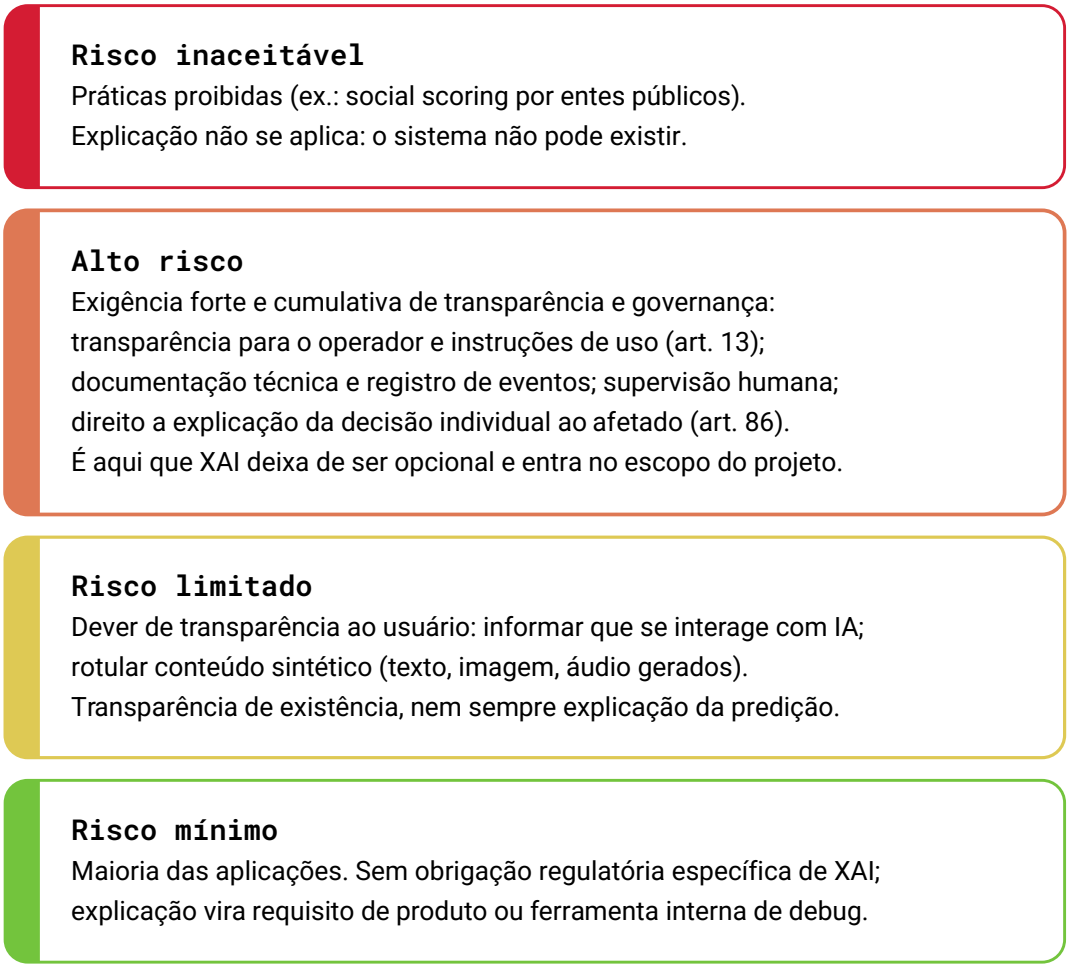
decisões automatizadas entre os focos prioritários de fiscalização para o biênio 2026 e 2027, o que torna o tema atual e não hipotético.

Ainda no âmbito brasileiro, e desta vez específico para IA, tramita o Projeto de Lei 2338 de 2023, o marco legal da inteligência artificial. Aprovado pelo Senado em dezembro de 2024, está em análise na Câmara dos Deputados em comissão especial, com texto ainda sujeito a ajustes. O projeto adota uma classificação por risco inspirada no modelo europeu, distinguindo sistemas de risco excessivo, que ficam proibidos, de sistemas de alto risco, submetidos a governança rigorosa, e assegura aos afetados o direito à explicação e à contestação de decisões automatizadas, sob a fiscalização de um Sistema Nacional de Regulação e Governança de IA coordenado pela ANPD. Enquanto não é aprovado, ele já orienta o planejamento de conformidade das empresas, e vale acompanhá-lo, porque eleva o patamar de exigência de explicação no Brasil, hoje ancorado sobretudo na LGPD.

No plano europeu, a referência de proteção de dados é o GDPR, o regulamento europeu, aplicável a quem opera com escopo europeu. O seu artigo 22 limita decisões tomadas exclusivamente com base em tratamento automatizado que produzam efeitos jurídicos ou afetem significativamente a pessoa, e assegura salvaguardas, entre elas o direito de obter intervenção humana e de contestar a decisão. O considerando 71 menciona o direito de obter uma explicação, mas há debate acadêmico sobre a extensão desse direito, já que o texto vinculante fala em informação significativa sobre a lógica envolvida, e não em uma explicação completa da decisão. Para o profissional, a leitura prudente é que o GDPR garante ao menos informação sobre a lógica e a possibilidade de revisão humana, sem definir com precisão a profundidade técnica da explicação exigida.

A norma mais recente e a mais específica para IA é o EU AI Act, o Regulamento (UE) 2024/1689. Ao contrário das duas anteriores, ele organiza as obrigações por categoria de risco da aplicação, e não por tipo de dado, e tem alcance extraterritorial, aplicando-se a qualquer sistema cujos resultados afetem pessoas na União Europeia, ainda que a empresa e a infraestrutura estejam fora dela. Dois artigos interessam de perto à lente da transparência. O artigo 13 impõe transparência e instruções de uso ao operador do sistema, o deployer, para que ele compreenda e monitore a ferramenta. O artigo 86 cria um direito individual: a pessoa afetada por uma decisão baseada em um sistema de alto risco tem direito a obter do operador explicações claras e significativas sobre o papel do sistema na decisão e sobre os seus elementos principais. A figura a seguir organiza esse escalonamento por risco.

Figura 1 - Mapa de obrigações de XAI por categoria de risco no EU AI Act.



Fonte: autor.

Figura intitulada "Mapa de obrigações de XAI por categoria de risco no EU AI Act". O conteúdo é apresentado em quatro faixas horizontais coloridas, organizadas do maior para o menor nível de risco.
A primeira faixa, em tom vermelho, representa o Risco inaceitável. Ela informa que práticas proibidas, como o uso de sistemas de pontuação social por órgãos públicos, não são permitidas. Nesse caso, não há obrigação de explicação, pois o sistema não pode existir.
A segunda faixa, em tom alaranjado, apresenta o Alto risco. Nessa categoria, são exigidas medidas rigorosas e cumulativas de transparência e governança, incluindo transparência para o operador e instruções de uso, documentação técnica e registro de eventos, supervisão humana e direito à explicação de decisões individuais. Também informa que a equipe de Inteligência Artificial Explicável (XAI) deve ser opcional e incorporada ao escopo do projeto.
A terceira faixa, em amarelo, corresponde ao Risco limitado. O texto destaca o dever de transparência com o usuário, como informar quando há interação com inteligência artificial e identificar conteúdos sintéticos, como textos, imagens e áudios gerados por IA. A transparência está relacionada à existência da IA, não sendo sempre necessária a explicação detalhada da predição.
A quarta e última faixa, em verde, representa o Risco mínimo. Ela informa que essa categoria abrange a maioria das aplicações, sem obrigação regulatória específica relacionada à XAI. Nesses casos, a explicação passa a ser um requisito do produto ou uma ferramenta de apoio interno para depuração e desenvolvimento.
Na parte inferior da figura está a indicação "Fonte: autor."

A figura escalona quatro categorias de risco. No topo, as práticas de risco inaceitável são proibidas, e a pergunta pela explicação nem chega a se colocar, porque o sistema não pode existir. Logo abaixo, os sistemas de alto risco concentram a exigência forte e cumulativa: além da transparência ao operador e das instruções de uso do artigo 13, somam-se documentação técnica, registro de eventos, supervisão humana e o direito individual a explicação do artigo 86. É nessa faixa que XAI deixa de ser opcional e entra no escopo do projeto desde o início.

Nas duas faixas inferiores, a exigência afrouxa. Para risco limitado, vale o dever de transparência de existência, como informar que se interage com uma IA e rotular conteúdo sintético, o que nem sempre implica explicar cada predição. Para risco mínimo, que abrange a maioria das aplicações, não há obrigação regulatória específica de XAI, e a explicação, quando aparece, vem como requisito de produto ou como ferramenta interna de depuração, e não como imposição legal.

Três esclarecimentos tornam essa figura utilizável na prática. Primeiro, o que caracteriza o alto risco não é uma avaliação subjetiva, mas uma lista, o Anexo III, que inclui usos como crédito e seguros, emprego e recrutamento, educação, serviços públicos essenciais, biometria e aplicação da lei. Segundo, as obrigações recaem de forma diferente sobre quem constrói o sistema, o provider, e quem o utiliza em um contexto concreto, o deployer: o direito a explicação do artigo 86, em particular, é dever do operador que toma a decisão, ainda que o modelo venha de um terceiro. Terceiro, o cronograma. As obrigações para sistemas de alto risco do Anexo III tinham aplicação prevista para agosto de 2026, mas o pacote de revisão conhecido como Digital Omnibus, aprovado pelos colegisladores em meados de 2026, adiou esses prazos: dezembro de 2027 para os sistemas autônomos do Anexo III e agosto de 2028 para a IA embarcada em produtos do Anexo I. As obrigações de transparência do artigo 50, como informar que se interage com uma IA, não foram adiadas e aplicam-se a partir de agosto de 2026. As penalidades reforçam a seriedade: violações de práticas proibidas alcançam trinta e cinco milhões de euros ou sete por cento do faturamento mundial, e o descumprimento das obrigações de alto risco alcança quinze milhões de euros ou três por cento.

Exemplo aplicado

Em uma fintech que automatiza análise de crédito, o classificador de inadimplência se enquadra como sistema de alto risco. Isso obriga, antes de qualquer linha de código de modelagem, a decidir como a recusa será explicada ao solicitante, qual estratégia de registro sustenta a auditoria e como a revisão entra no fluxo. Há um detalhe técnico incômodo: responder a um pedido de explicação meses depois exige reconstruir qual versão do modelo, com quais pesos, decidiu aquele caso, o que só é possível se o registro da decisão tiver sido projetado junto com o modelo, e não improvisado depois de uma reclamação. A escolha entre um modelo opaco de desempenho marginalmente maior e um modelo interpretável de desempenho próximo passa a ser, também, uma decisão de conformidade.

O quadro regulatório, somado, deixa uma conclusão de projeto clara: a exigência de explicação não é uniforme. Ela varia por norma aplicável, por categoria de risco e pelo destinatário da explicação. Um sistema de recomendação de conteúdo e um sistema de concessão de crédito não estão sujeitos ao mesmo nível de obrigação, e tratar os dois do mesmo modo custa caro em um caso e é insuficiente no outro. Reconhecer esse regime variável é o primeiro passo da lente da transparência, e ignorá-lo é a armadilha mais comum de quem chega ao tema.

ATENÇÃO

Tratar XAI como exigência uniforme. Quem supõe que todo sistema precisa do mesmo nível de explicação superexige onde a lei não pede, encarecendo o projeto sem ganho de conformidade, ou subexige em um sistema de alto risco e descobre tarde que a explicação era obrigatória e que o registro necessário não foi construído. A exigência de XAI é um regime variável por categoria de risco e por stakeholder, não um requisito único, e confundir os dois desloca custo e atrasa a entrega.

SAIBA MAIS

Para aprofundar

Os textos regulatórios estão em acesso público: EU AI Act em https://eur-lex.europa.eu (Regulamento UE 2024/1689, artigos 13 e 86), LGPD em https://www.planalto.gov.br (Lei 13.709/2018, artigo 20) e GDPR em https://eur-lex.europa.eu (artigo 22 e considerando 71). Para a discussão de fundo sobre preferir modelos interpretáveis em decisões de alto risco, ver Rudin (2019), na bibliografia. O aprofundamento em conformidade operacional de sistemas de alto risco cabe fora do curso base.

Estabelecido quando a explicação é exigida e para quem, a pergunta seguinte é com qual técnica atendê-la. A próxima seção organiza o repertório de técnicas de XAI em uma taxonomia que permite escolher a ferramenta certa para cada exigência.

2.Taxonomia de técnicas

Esta seção pertence à camada conceitual e tem por objetivo que você reconheça a taxonomia das técnicas de explicação e saiba situar as mais comuns nos eixos que a organizam. O campo é amplo e cresce rápido, mas três distinções dão conta da maior parte das decisões práticas, e é em torno delas que a seção se organiza: intrínseco contra post-hoc, local contra global, e model-specific contra model-agnostic. Dominadas essas três distinções, qualquer técnica nova encontra o seu lugar sem esforço.

A primeira distinção separa duas estratégias de fundo. Em um modelo intrinsecamente interpretável, a explicação é o próprio modelo. Uma regressão linear ou logística expõe

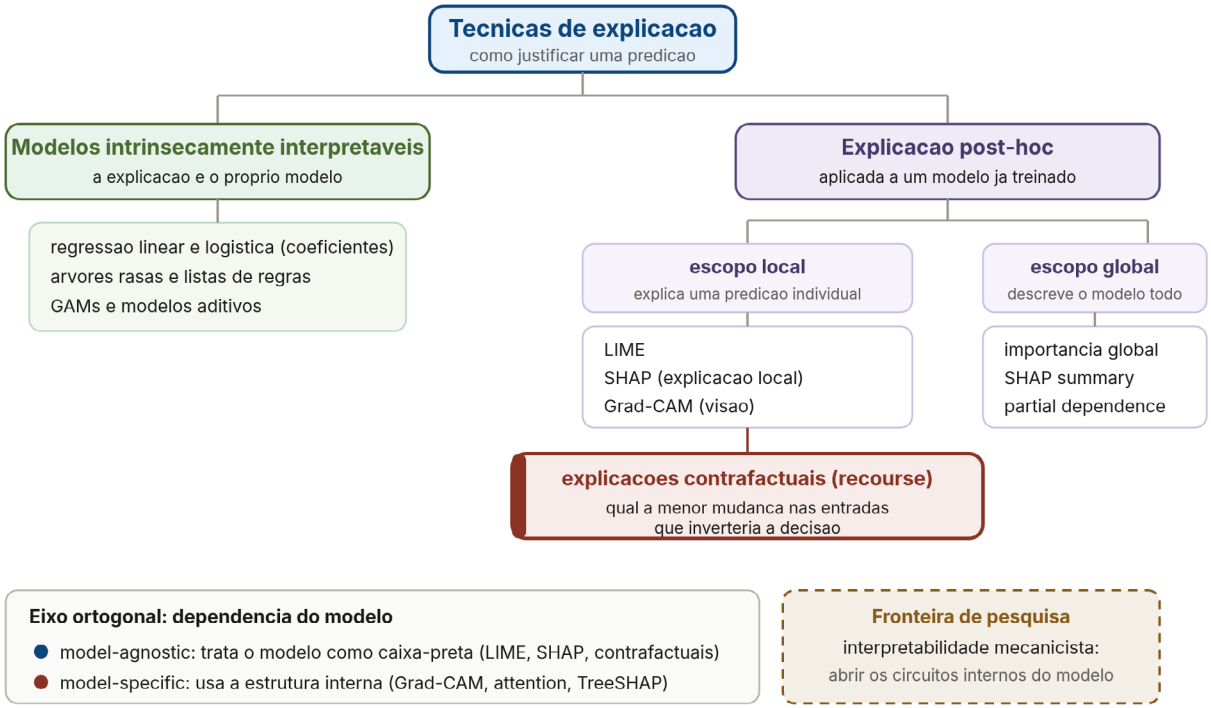
os seus coeficientes, e cada coeficiente é a contribuição direta de uma variável. Uma árvore de decisão rasa expõe os seus cortes, e o caminho da raiz até a folha é a justificativa da predição. Uma lista de regras expõe as condições que disparam cada resposta. Os modelos aditivos generalizados, ou GAMs, generalizam a regressão linear permitindo que cada variável contribua por uma curva própria, e continuam legíveis porque a contribuição de cada variável pode ser lida isoladamente. Em todos esses casos, não há um passo extra de explicação: ler o modelo já é explicar a decisão.

Na estratégia oposta, a técnica post-hoc, o modelo é treinado primeiro, com foco em desempenho, e a explicação vem depois, produzida por uma ferramenta externa que tenta reconstruir o que pesou em cada predição. Cynthia Rudin, em trabalho influente, argumenta que, para decisões de alto risco, vale preferir modelos interpretáveis sempre que o desempenho for comparável, e sustenta que essa condição se verifica com mais frequência do que se supõe, sobretudo em dados tabulares estruturados. O ponto dela é forte: uma explicação post-hoc é sempre uma aproximação do modelo real, construída por outro método, e por isso pode divergir do que o modelo de fato faz. Preferir um modelo já interpretável elimina esse intermediário. A tensão entre desempenho e interpretabilidade, mencionada na seção anterior, é portanto real, mas com frequência menor do que a intuição sugere, e vale medir o custo real em desempenho antes de aceitar a opacidade como inevitável.

A segunda distinção é de escopo, e é a que mais gera confusão na prática. Uma explicação local responde a uma pergunta sobre um caso individual: por que esta predição, para este cliente, saiu assim. É a explicação que importa quando uma pessoa contesta uma decisão que a afetou, e é o objeto do direito do artigo 86 e do artigo 20 da LGPD vistos na seção anterior. Uma explicação global descreve o comportamento do modelo como um todo: quais variáveis pesam em média, em que direção, com que força. É a explicação que importa para auditoria, documentação e diagnóstico de viés. As duas respondem a perguntas diferentes e não são intercambiáveis, e boa parte dos erros de uso de XAI nasce de responder a uma com a outra.

A terceira distinção é ortogonal às duas primeiras, o que significa que se combina livremente com elas. Uma técnica model-agnostic trata o modelo como caixa-preta: ela só observa entradas e saídas, sem olhar a estrutura interna, e por isso funciona com qualquer modelo, de uma floresta aleatória a uma rede profunda. Uma técnica model-specific explora a estrutura interna, como os gradientes de uma rede ou os pesos de atenção de um transformer, e por isso é mais precisa e mais barata quando aplicável, mas fica presa a uma família de modelos. Dizer que uma técnica é local ou global, portanto, é independente de dizer que ela é agnostic ou specific: SHAP, por exemplo, é agnostic e serve tanto ao local quanto ao global, enquanto Grad-CAM é specific e local. A figura a seguir organiza essas relações.

Figura 2 - Taxonomia das técnicas de explicabilidade.



Toda explicacao post-hoc envolve a tensao entre faithfulness (fidelidade a computacao) e plausibility (plausibilidade ao leitor).

Fonte: autor.

A árvore parte da distinção intrínseco contra post-hoc e detalha o ramo post-hoc, que é o que exige ferramentas próprias. Nele, o escopo local reúne LIME, a explicação local do SHAP e o Grad-CAM; o escopo global reúne a importância global de variáveis, o gráfico summary do SHAP e as curvas de partial dependence. Um nó em destaque, logo abaixo do escopo local, marca as explicações contrafactuais, uma família com lógica própria tratada nesta seção. À parte, o eixo da dependência do modelo distingue as técnicas agnostic, que tratam o modelo como caixa-preta, das specific, que usam a estrutura interna, e um nó tracejado marca a interpretabilidade mecanicista como fronteira de pesquisa.

A rodapé da figura registra a tensão que atravessa toda técnica post-hoc, entre ser fiel à computação do modelo, a faithfulness, e ser convincente para quem lê, a plausibility. Essa tensão organiza o tópico 4 deste ebook e vale mantê-la em vista desde já: uma técnica bem posicionada na taxonomia ainda pode entregar uma explicação plausível que não corresponde ao que o modelo fez.

Entre as técnicas post-hoc, uma merece detalhe por ser a mais usada como porta de entrada e por ilustrar bem o mecanismo de um explicador local model-agnostic: o LIME, de local interpretable model-agnostic explanations. A ideia é simples e engenhosa. Para explicar uma predição individual, o LIME gera muitas variações da entrada em torno do caso, perturbando os seus valores, e observa como a saída do modelo muda. Em seguida, ajusta um modelo simples e interpretável, tipicamente uma regressão linear, sobre

esse conjunto de variações, dando mais peso às que estão próximas do caso original. O modelo simples resultante não descreve o modelo inteiro, apenas a sua vizinhança local, e os coeficientes desse modelo simples viram a explicação. É local porque vale só ao redor daquele ponto, e é agnostic porque nunca precisou olhar dentro do modelo, apenas perturbar entradas e ler saídas.

A engenhosidade, no entanto, tem um preço. As variações são amostradas ao acaso em torno do caso, e em dados tabulares de alta dimensão parte delas cai fora da região que os dados reais de fato ocupam. O resultado é instabilidade: duas execuções sobre o mesmo caso podem produzir coeficientes levemente diferentes. Na prática, fixa-se a semente aleatória e agregam-se várias execuções, e essa fragilidade é um dos motivos de o SHAP, com garantias formais, ser a técnica central deste módulo.

As demais técnicas da figura se descrevem rápido, porque duas serão retomadas depois. O SHAP, tratado em detalhe na próxima seção, atribui a cada variável uma contribuição com base na teoria dos jogos, e é a técnica central da camada aplicada deste módulo. O Grad-CAM usa os gradientes de uma rede convolucional para destacar as regiões de uma imagem que mais influenciaram a predição, produzindo um mapa de calor sobre a imagem, o chamado saliency map, útil em visão computacional. Os pesos de atenção, comuns em modelos de linguagem, são por vezes lidos como explicação, uma leitura que o tópico 4 vai qualificar com cuidado. Vale ainda registrar, no horizonte, a interpretabilidade mecanicista, que busca abrir os circuitos internos de um modelo e mapear que computação cada componente realiza, em vez de apenas atribuir importância a entradas. É trabalho de pesquisa promissor, ainda distante de uma ferramenta de prateleira, e por isso aparece como fronteira, não como recurso aplicável hoje.

Duas famílias completam o mapa da figura, uma no escopo global e outra no local. No lado global, além da importância agregada de variáveis, as curvas de partial dependence mostram o efeito médio de uma variável sobre a predição ao longo da sua faixa de valores, e um surrogate global aproxima o modelo opaco por um único modelo interpretável treinado para imitá-lo, útil como visão de conjunto ainda que aproximada. No lado local, ganha destaque uma família com lógica própria, tratada a seguir: as explicações contrafactuais.

As explicações contrafactuais, também chamadas de recourse, não medem a contribuição de cada variável, e sim respondem a uma pergunta acionável: qual a menor mudança nas entradas que teria invertido a decisão. Em vez de dizer que renda pesou tanto, uma contrafactual diz que, se a renda fosse um valor e o prazo fosse outro, o crédito teria sido aprovado. São locais, porque tratam de um caso, e model-agnostic, porque só exploram entradas e saídas, e são a forma de explicação mais próxima do que a pessoa afetada de fato quer saber, o que as liga diretamente ao direito de contestação da LGPD e do EU AI Act. O nó em destaque da figura anterior marca essa família.

GLOSSÁRIO

Explicação Contrafactual

Uma explicação contrafactual descreve a menor alteração nas variáveis de entrada capaz de mudar a decisão do modelo, por exemplo o crédito seria aprovado se a renda subisse a um patamar e a dívida caísse a outro. É local e model-agnostic, e responde à pergunta de recourse, o que fazer para obter outro resultado, em vez de atribuir contribuições. É especialmente relevante para a contestabilidade exigida pela LGPD e pelo EU AI Act, porque entrega à pessoa um caminho concreto, e não apenas um diagnóstico.

Reunidas as duas estratégias de fundo, a intrínseca e a post-hoc, e situadas a atribuição e a contrafactual lado a lado no escopo local, um exemplo mostra como a escolha entre elas se dá na prática.

Exemplo aplicado

Uma seguradora precisa modelar risco de sinistro sobre uma base tabular com algumas dezenas de variáveis. A equipe testa um gradient boosting opaco e uma regressão logística regularizada, e encontra diferença de desempenho pequena, dentro da margem de incerteza da validação. Como o produto opera em contexto regulado e a explicação será cobrada caso a caso, a equipe opta pelo modelo interpretável: o ganho marginal do modelo opaco não compensa o custo de manter, auditar e validar um explicador post-hoc por cima dele. Essa é a decisão intrínseco contra post-hoc na prática, e ela nem sempre favorece o modelo mais complexo.

A escolha entre técnicas, porém, não se esgota na taxonomia: ela também depende das ferramentas disponíveis e do nível de suporte de cada uma. A curadoria a seguir orienta por onde começar, com a ressalva de que a comparação instrumentada entre bibliotecas é matéria dos cursos por eixo da Fase 2.

SAIBA MAIS

Para aprofundar

SHAP é a referência para atribuição por valores de Shapley em modelos tabulares, com implementação eficiente para árvores. LIME cobre explicações lo-

cais model-agnostic. Captum oferece métodos baseados em gradiente para modelos em PyTorch, úteis em visão e linguagem. InterpretML reúne modelos de vidro, os glassbox, e explicadores post-hoc em uma interface única. Alibi cobre explicações e ainda detecção de drift. A comparação instrumentada entre essas bibliotecas e a implementação avançada de cada método são tratadas nos cursos de Machine Learning e de Deep Learning da Fase 2 do programa. Referência conceitual de base: Molnar (2022), na bibliografia.

Com a taxonomia fixada e as ferramentas situadas, resta nomear a confusão de escopo que mais aparece em quem começa, porque ela tem consequência regulatória direta.

Armadilha comum

Confundir importância global com explicação local. Dizer que renda é a variável mais importante do modelo é uma afirmação global e não explica por que o cliente X foi recusado, que é uma pergunta local. Responder a uma com a outra produz justificativas que não sustentam contestação. Em sistemas de alto risco, a pessoa afetada tem direito à explicação do seu caso, não ao perfil médio do modelo, e trocar uma pela outra é um erro decisório com consequência regulatória, além de técnico.

Situadas as técnicas, a seção seguinte desce a um caso concreto e aplicado, o SHAP, para mostrar como uma técnica de atribuição se lê na prática, o que ela entrega e onde estão os seus limites de leitura.

3. SHAP na prática

Esta seção pertence à camada aplicada e tem por objetivo que você saiba aplicar e ler SHAP sobre um classificador tabular, comparando a explicação local, a global e a importância de variáveis do próprio modelo. O notebook IA-037 conduz a execução passo a passo, sobre um conjunto de dados público de crédito; aqui interessa o que cada saída significa, como lê-la e o que ela não autoriza concluir. A escolha do SHAP como técnica central não é arbitrária: ele combina fundamento teórico sólido, aplicabilidade a praticamente qualquer modelo e leitura visual acessível, o que o tornou o padrão de fato para explicação de modelos tabulares.

O SHAP, de SHapley Additive exPlanations, atribui a cada variável de uma predição uma

contribuição numérica, partindo dos valores de Shapley, um conceito da teoria dos jogos cooperativos. A analogia ajuda a fixar a ideia. Imagine as variáveis como jogadores de um time que, juntos, produzem um resultado, a predição. A pergunta é como dividir o crédito por esse resultado de forma justa entre os jogadores. A resposta de Shapley é medir, para cada jogador, quanto ele acrescenta ao resultado quando entra no time, considerando todas as ordens possíveis de entrada dos jogadores, e tirar a média dessas contribuições. Transposto para o modelo, isso significa medir quanto cada variável acrescenta à predição em relação a uma linha de base, ponderando todas as ordens em que as variáveis poderiam ser consideradas. É essa média sobre todas as ordens que dá ao valor de Shapley as suas boas propriedades de equidade.

Essa definição tem um custo. Considerar todas as ordens possíveis de um conjunto de variáveis é combinatório, e cresce de forma explosiva com o número de variáveis, o que torna o cálculo exato inviável para casos reais. Por isso o SHAP não calcula os valores exatos, mas os aproxima. Há duas rotas principais. A primeira, KernelSHAP, é agnostic: aproxima os valores por amostragem, tratando o modelo como caixa-preta, e serve para qualquer modelo ao custo de mais computação. A segunda, TreeSHAP, é specific para modelos de árvore, como florestas e boosting, e explora a estrutura dessas árvores para calcular os valores de forma exata e muito mais rápida. Na prática tabular, com modelos de árvore, é TreeSHAP que roda por baixo, e é isso que torna o SHAP viável em bases reais.

GLOSSÁRIO

SHAP

SHAP (SHapley Additive exPlanations) é um método de atribuição que distribui a diferença entre a predição de um caso e o valor esperado do modelo entre as variáveis de entrada, usando valores de Shapley da teoria dos jogos. É model-agnostic na forma geral (KernelSHAP) e tem variante exata e eficiente para modelos de árvore (TreeSHAP). Serve tanto a explicações locais, para um caso, quanto, por agregação de muitos casos, a explicações globais.

O resultado do SHAP tem uma propriedade que torna a leitura confiável: a aditividade, chamada de local accuracy na literatura do SHAP e correspondente ao axioma da eficiência dos valores de Shapley. As contribuições das variáveis somam exatamente a diferença entre a predição do caso e o valor base do modelo. O valor base, escrito E[f(x)], é a predição média do modelo sobre um conjunto de referência, o background, e representa

o que o modelo diria na ausência de informação sobre o caso. Assim, partindo do valor base e somando as contribuições de cada variável, chega-se exatamente à predição do caso. Nada fica sem explicação e nada é contado duas vezes, e essa garantia é o que permite auditar uma explicação SHAP: basta verificar que as parcelas fecham a conta.

Essa estrutura aditiva é exatamente o que o gráfico de waterfall mostra, e vale aprender a lê-lo antes de encontrá-lo no notebook. A figura a seguir esquematiza a sua anatomia.

Figura 3 - Anatomia de um gráfico waterfall do SHAP.



Fonte: autor.

Figura 3 intitulada "Anatomia de um gráfico waterfall do SHAP", que ilustra como diferentes variáveis contribuem para aumentar ou reduzir a predição de um modelo de inteligência artificial. À esquerda, há um quadro explicativo com a legenda "Como ler", informando que as barras em vermelho representam fatores que empurram a predição para cima, enquanto as barras em azul representam fatores que a empurram para baixo. Também é indicado que a soma das contribuições corresponde à diferença entre a predição final e o valor base do modelo.
No centro do gráfico, as variáveis aparecem listadas de baixo para cima: renda, histórico de crédito, dívida atual, idade da conta e demais atributos. Na parte inferior está o valor base da previsão, identificado como E[f(x)] = 0,30, descrito como a predição média do conjunto de dados.
A partir desse valor inicial, uma barra vermelha associada à variável renda acrescenta +0,18 à predição. Em seguida, outra barra vermelha referente ao histórico de crédito adiciona +0,12. Depois, uma barra azul correspondente à dívida atual reduz a predição em −0,05. As variáveis idade da conta e demais atributos também contribuem para o resultado final, uma aumentando e outra reduzindo levemente a predição, representadas por barras menores em vermelho e azul.
À direita do gráfico, uma linha vertical tracejada destaca o resultado final, identificado como f(x) = 0,56, representando a predição obtida para o caso analisado após a soma de todas as contribuições individuais das variáveis.
No rodapé da figura consta a indicação "Fonte: autor."

O gráfico de waterfall explica um caso individual. Na base fica o valor esperado do modelo, o E[f(x)]. De baixo para cima, cada barra é a contribuição SHAP de uma variável para aquele caso: as barras de uma cor empurram a predição para cima, as de outra cor a empurram para baixo, e o comprimento da barra é a magnitude da contribuição. Ao final, o acúmulo das barras leva do valor base até a predição do caso, f(x), no topo. Ler o waterfall é, portanto, seguir a conta da aditividade de forma visual.

Esse é o formato da explicação local por excelência, e é ele que sustenta uma justificativa contestável: diante de uma recusa, o waterfall diz quais variáveis, e em que medida, empurraram aquela decisão. O plot real, gerado sobre o conjunto de dados do módulo, aparece no notebook IA-037; o esquema acima serve para que você chegue lá sabendo ler cada elemento.

Ao lado do waterfall, uma segunda saída concentra a leitura global: o gráfico de summary, também chamado de beeswarm. Nele, cada ponto é um caso do conjunto, distribuído no eixo horizontal pela sua contribuição SHAP, e a cor do ponto codifica o valor da variável naquele caso, do baixo ao alto. As variáveis aparecem empilhadas, ordenadas pela importância. Lido em conjunto, o summary revela não só quais variáveis pesam mais no modelo como um todo, mas também a direção do efeito: se valores altos de uma variável tendem a empurrar a predição para cima ou para baixo. É a fotografia global do comportamento do modelo, complementar ao retrato local do waterfall.

A terceira saída não vem do SHAP, mas do próprio modelo: o atributo feature_importances_, disponível em florestas e boosting, que dá uma medida nativa de importância de variáveis. É tentador tomar essas três saídas como intercambiáveis, mas elas respondem a perguntas distintas, e confundi-las gera erro. O quadro a seguir separa o que cada uma responde.

Quadro 1 - Três leituras de importância e o que cada uma responde.

Saída	Escopo	Pergunta que responde
SHAP waterfall	local	por que este caso recebeu esta predição
SHAP summary	global	quais variáveis pesam no modelo e em que direção
feature_importances_	global	quanto cada variável reduziu impureza durante o treino

imagem de um quadro em formato de tabela intitulado "Quadro 1. Três leituras de importância e o que cada uma responde." A tabela possui três colunas: Saída, Escopo e Pergunta que responde.
Na primeira linha, a saída é SHAP waterfall, com escopo local, respondendo à pergunta: "Por que este caso recebeu esta predição?".
Na segunda linha, a saída é SHAP summary, com escopo global, respondendo à pergunta: "Quais variáveis pesam no modelo e em que direção?".
Na terceira linha, a saída é feature importances, também com escopo global, respondendo à pergunta: "Quanto cada variável reduziu a impureza durante o treino."

A divergência entre o SHAP global e o feature_importances_ costuma surpreender e tem explicação técnica. A importância nativa de modelos de árvore mede, em geral, quanto cada variável reduziu a impureza nas divisões durante o treino. Essa métrica tem vieses conhecidos: favorece variáveis com muitas categorias ou alta cardinalidade, porque elas oferecem mais pontos de corte, e mistura o efeito real da variável com a frequência com que ela foi usada. O SHAP, por sua vez, mede a contribuição marginal de cada variável à predição, com fundamento teórico mais firme e melhor comportamento quando as variáveis são correlacionadas. Esse fundamento inclui a propriedade de consistência: se o modelo muda de forma que a contribuição real de uma variável aumenta, o valor atribuído a ela não diminui. A importância por impureza não oferece essa garantia, e pode, paradoxalmente, atribuir importância menor a uma variável que passou a pesar mais no modelo. Quando as duas discordam, a leitura prudente é confiar no SHAP para fins de explicação e tomar a divergência como sinal de que a importância nativa pode estar inflada por esses vieses.

Exemplo aplicado

Em um classificador de risco de crédito treinado sobre o German Credit, o waterfall de um caso recusado mostra, por exemplo, que histórico de crédito e duração do empréstimo empurraram a predição para o lado da recusa, enquanto a finalidade do crédito a empurrou levemente para o lado oposto. Essa leitura caso a caso é o que sustenta uma justificativa contestável, do tipo que o artigo 20 da LGPD e o artigo 86 do EU AI Act exigem, ao contrário do ranking médio de variáveis, que descreve o modelo e não a decisão individual.

Três ressalvas de leitura fecham a seção. A primeira diz respeito a variáveis correlacionadas: quando dois atributos são fortemente correlacionados, o SHAP tende a repartir a contribuição entre eles, e o resultado pode depender do método de aproximação e do conjunto de fundo escolhido, de modo que convém ler grupos de variáveis correlacionadas em conjunto, e não atributo a atributo. A segunda é de escala: em classificadores, os valores SHAP são calculados no espaço interno do modelo, tipicamente em log-odds ou margem, e não diretamente em probabilidade. Isso significa que uma contribuição de mesmo tamanho em log-odds pode corresponder a variações diferentes de probabilidade dependendo de onde o caso está, e ignorar esse detalhe leva a comparar contribuições como se fossem pontos percentuais, o que elas não são. A terceira ressalva prepara a próxima seção e é conceitualmente mais importante.

O SHAP explica fielmente a função aprendida pelo modelo, mas não estabelece causa no mundo. Dizer que renda contribuiu para a predição significa que a função do modelo usou renda daquele modo, não que renda cause o desfecho real que se quer prever. Essa distinção entre ser fiel à computação do modelo, a faithfulness, e descrever a realidade causal é sutil e decisiva. O SHAP tem alta faithfulness em relação ao modelo, e é justamente por isso que ele não deve ser lido como mapa causal do mundo: ele é fiel ao modelo, e o modelo pode ter aprendido correlações que não são causas.

⚠ ATENÇÃO

Ler atribuição como causalidade. Quem toma uma contribuição do SHAP por relação causal no mundo decide intervir na variável errada e justifica ações que o método não sustenta. O SHAP responde como o modelo usou a variável, não se mudar a variável mudaria o desfecho real. Confundir as duas leituras é a falha decisória mais comum em quem usa a técnica pela primeira vez, e ela sobrevive até em relatórios técnicos bem feitos.

Compreendido o que SHAP entrega e o que não entrega em modelos tabulares, a última seção leva a mesma pergunta para o terreno mais difícil, o dos modelos de linguagem e da IA generativa, onde as ferramentas de explicação ainda são frágeis e, pior, enganam com facilidade.

4.Limites para LLMs e IA generativa

Esta seção reúne camada conceitual e aplicada e tem por objetivo que você reconheça os limites específicos da explicação de modelos de linguagem e de IA generativa, distinguindo faithfulness de plausibility e evitando a armadilha de tratar o raciocínio exibido pelo modelo como explicação fiel da computação que produziu a resposta. É a seção mais importante para calibrar expectativa, porque é onde a tentação de aceitar uma explicação convincente é maior e o risco de aceitar uma explicação falsa também.

Convém primeiro nomear o objeto do maior risco. Chama-se raciocínio em cadeia, ou chain-of-thought, a prática de induzir um modelo de linguagem a exibir passos intermediários até a resposta, em vez de responder direto. Essa exibição melhora o desempenho em muitas tarefas e, por isso, tornou-se comum. O problema surge quando se lê a cadeia de passos como se ela fosse a explicação fiel de como o modelo chegou à resposta, e é esse ponto que a seção precisa desmontar. Antes, porém, fixe a distinção conceitual que organiza tudo o que segue.

GLOSSÁRIO

Faithfulness e Plausibility

Faithfulness é o grau em que uma explicação reflete de fato a computação que o modelo realizou. Plausibility é o grau em que a explicação parece convincente para um leitor humano. As duas são independentes: uma explicação pode ser plausível e infiel, descrevendo bem o que esperaríamos e mal o que o modelo fez. Em sistemas de alto risco, faithfulness é o que sustenta auditoria; plausibility, sozinha, pode mascarar o problema em vez de revelá-lo.

Em modelos tabulares, como se viu, a função aprendida é acessível o bastante para que métodos como SHAP entreguem atribuições com faithfulness razoável. Em modelos de linguagem, três fatores quebram essa garantia. O primeiro é a escala: uma atribuição exata sobre bilhões de parâmetros e sobre sequências longas de tokens é computacionalmente proibitiva. O segundo é a ausência de referência: não existe um rótulo que diga qual seria a explicação correta de uma geração, o que impede validar uma expli-

cação contra a verdade. O terceiro é a sensibilidade ao prompt: pequenas variações na formulação da pergunta mudam tanto a resposta quanto a justificativa oferecida, o que impede tratar qualquer explicação como estável. Juntos, esses fatores fazem da explicação de LLMs um problema em aberto, e não uma tarefa resolvida com ferramentas maduras.

Esses três fatores não impedem que se tente. A família de atribuição do tópico 2 tem versões para modelos de linguagem: perturbar ou ocluir trechos do prompt e medir o efeito na saída, ou propagar gradientes da saída até os embeddings de entrada para estimar o peso de cada token. Em entradas curtas e em depuração pontual, essas técnicas ajudam a levantar hipóteses sobre o que pesou na geração. O problema é que os três fatores as atingem em cheio. O custo cresce com o comprimento da entrada e com o número de perturbações necessárias. Não existe referência contra a qual validar o mapa de atribuição resultante. E o próprio mapa muda quando o prompt muda. O resultado é uma ferramenta de investigação para o desenvolvedor, útil em escala pequena, e não um mecanismo de justificativa que se possa oferecer a um auditor ou a uma pessoa afetada por uma decisão.

O caso do chain-of-thought concentra o perigo. Quando um modelo exibe uma sequência de passos plausíveis até a resposta, é natural tomá-los como o caminho real do cálculo. A literatura, porém, mostra que esse texto é muitas vezes uma narrativa construída, e não um traço fiel da computação interna. Um resultado experimental ilustrativo: ao introduzir um viés no prompt, por exemplo sempre marcando a mesma alternativa como correta em exemplos anteriores, o modelo passa a escolher aquela alternativa e, ao explicar, produz uma justificativa articulada que não menciona o viés que de fato moveu a escolha. A cadeia de raciocínio parece impecável e é infiel: ela racionaliza a resposta em vez de reportar a sua causa. Tratar essa cadeia como explicação fiel é confiar em plausibility exatamente onde a auditoria exige faithfulness.

A consequência prática não é descartar toda cadeia de raciocínio, e sim tratá-la como afirmação a testar. Dois testes baratos ajudam a detectar infidelidade. O primeiro é o teste de perturbação: se a justificativa cita uma evidência, remova ou altere essa evidência no prompt e observe se a resposta muda. Uma resposta que sobrevive à remoção da razão declarada denuncia que a razão declarada não era a causa. O segundo é a checagem de consistência: reformule a mesma pergunta de maneiras equivalentes e compare respostas e justificativas. Variação grande sob reformulações equivalentes indica que a explicação acompanha o texto do prompt, e não uma computação estável. Nenhum dos dois testes prova faithfulness. Ambos são assimétricos: conseguem revelar que uma explicação é infiel, mas não conseguem garantir que ela é fiel. Para triagem em PD&I, essa assimetria já tem valor, porque elimina narrativas que não sustentariam auditoria antes que elas cheguem a um relatório.

⚠ ATENÇÃO

Tomar chain-of-thought por explicação fiel. Quem aceita os passos relatados por um LLM como o cálculo real do modelo audita uma narrativa, não o sistema, e pode aprovar uma saída enviesada cujo relato omite o viés. Em decisão regulada, isso é falha grave: a explicação parece sólida, convence o revisor e não sustenta o caso quando o viés vem à tona. Para IA generativa, prefira avaliação de comportamento, registro de procedência e controles de saída a explicações post-hoc que podem enganar.

Os pesos de atenção sofrem de um problema aparentado, e vale conhecer os dois lados do debate para não cair em nenhum extremo. Por muito tempo os mapas de atenção foram exibidos como aquilo em que o modelo olhou, e portanto como explicação. Jain e Wallace, em trabalho de título direto, mostraram que distribuições de atenção bem diferentes podem produzir a mesma predição, o que enfraquece a leitura da atenção como explicação, já que se a atenção fosse a razão da resposta ela não poderia variar tanto sem mudar a saída. Wiegreffe e Pinter responderam matizando: dependendo da definição de explicação que se adote, a atenção ainda carrega informação útil, e descartá-la por completo é excessivo. Técnicas que agregam a atenção ao longo das camadas, como o attention rollout, produzem mapas mais legíveis, mas herdam a mesma ressalva, porque continuam a descrever fluxo de atenção, não causa da resposta. O ponto prático que sobra do debate é de cautela: a atenção pode sugerir hipóteses sobre o que o modelo usou, mas não serve como justificativa fiel sem verificação adicional. O quadro a seguir resume por que as duas pseudo-explicações mais comuns falham.

Quadro 2. Duas leituras que parecem explicação e não são fiéis por si sós.

Recurso	O que parece dizer	Por que não basta
Chain-of-thought	O caminho do raciocínio do modelo	Pode racionalizar a resposta sem reportar a causa real
Pesos de atenção	Onde o modelo olhou	Distribuições diferentes dão a mesma predição

imagem de um quadro em formato de tabela intitulado "Quadro 2. Duas leituras que parecem explicação e não são fiéis por si sós." A tabela possui três colunas: Recurso, O que parece dizer e Por que não basta.
Na primeira linha, o recurso é chain-of-thought. A coluna central informa que ele parece mostrar o caminho do raciocínio do modelo, enquanto a última coluna explica que isso pode racionalizar a resposta sem reportar a causa real.
Na segunda linha, o recurso é pesos de atenção. A coluna central indica que eles parecem mostrar onde o modelo olhou, mas a última coluna esclarece que distribuições diferentes podem levar à mesma predição, o que significa que, isoladamente, os pesos de atenção não explicam de forma confiável a decisão do modelo.

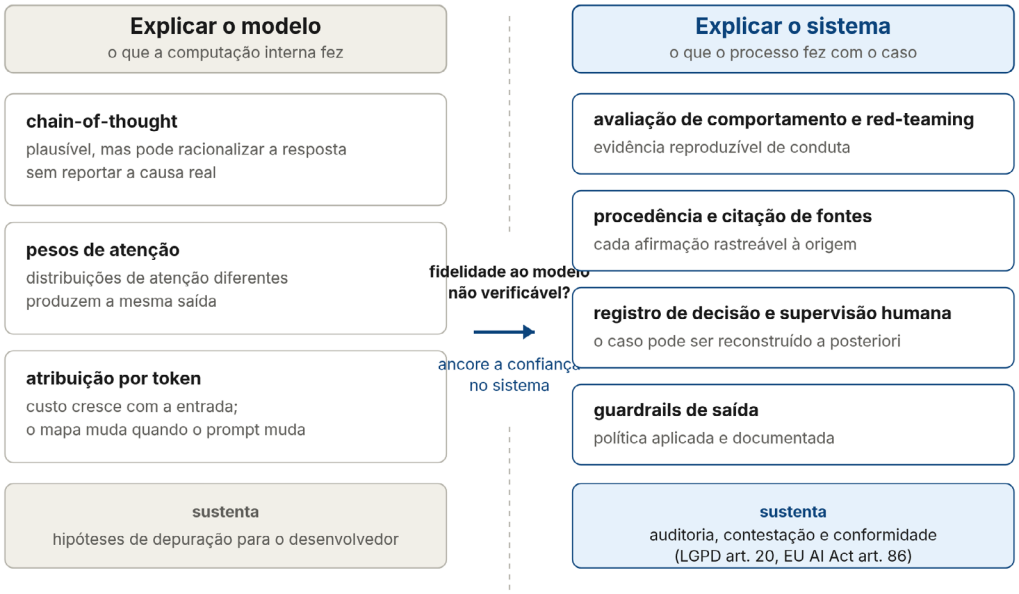
Há ainda um custo prático que entra na decisão de oferecer explicações para IA generativa. Gerar uma explicação por chamada, em produção, adiciona inferência e latência, e às vezes mais de uma chamada por resposta, o que precisa entrar na conta de quem projeta o sistema. Explicabilidade não é gratuita, e para sistemas de alto volume esse custo pode ser da mesma ordem do custo da própria predição.

No horizonte, a interpretabilidade mecanicista tenta atacar o problema pela raiz, entendendo os circuitos internos dos modelos de linguagem em vez de atribuir importância a entradas. Trabalhos recentes mostram progresso em isolar, dentro da rede, características interpretáveis, ou seja, direções na representação interna que correspondem a conceitos legíveis por humanos. É a direção mais promissora para recuperar faithfulness em modelos grandes, mas está longe do uso operacional e não resolve, hoje, a necessidade prática de justificar uma saída em produção.

Há um deslocamento de estratégia que organiza tudo o que esse cenário permite fazer. Quando explicar o modelo é inviável, a alternativa é explicar o sistema: documentar quais entradas o sistema recebeu, de quais fontes a resposta partiu, quais controles filtraram a saída e em que ponto um humano interveio. A distinção tem respaldo direto na camada regulatória do tópico 1. O artigo 86 do EU AI Act dá à pessoa afetada o direito a explicações sobre o papel do sistema na decisão e sobre os seus elementos principais, e o artigo 20 da LGPD fala em critérios e procedimentos da decisão automatizada. Nenhum dos dois exige a reconstrução da computação interna de um modelo de linguagem. Os dois exigem que o operador saiba dizer o que o sistema fez com o caso, a partir de quais dados e sob quais controles. Para IA generativa, portanto, a conformidade se sustenta no nível do sistema, e é essa a estratégia que o parágrafo seguinte e a figura adiante detalham.

Diante desse quadro, a postura defensável para o profissional de PD&I é honesta e concreta. Reconheça que explicar IA generativa é problema aberto e não apresente narrativas do próprio modelo como prova. Ancore a confiança em avaliação de comportamento, com conjuntos de avaliação e teste adversarial dirigido, o red-teaming, que sonda o sistema em busca de falhas. Registre a procedência da saída, isto é, de onde vieram os dados e as fontes que a embasaram, com marca d'água em conteúdo gerado quando cabível. E, quando a tarefa admitir, prefira arquiteturas que tornem a origem rastreável, como a recuperação de contexto com citação da fonte, que ao menos permite verificar de onde saiu cada afirmação, ainda que não explique a computação interna. Controles de saída, os guardrails, completam o arranjo, filtrando respostas fora de política antes de chegarem ao usuário.

Figura 4 - Explicar o modelo contra explicar o sistema: os recursos de cada estratégia, os seus limites e o que cada coluna sustenta.



Fonte: autor.

Figura 4 intitulada "Explicar o modelo contra explicar o sistema: os recursos de cada estratégia, os seus limites e o que cada coluna sustenta". O conteúdo é organizado em duas colunas paralelas que comparam duas abordagens complementares de explicabilidade em sistemas de inteligência artificial.
À esquerda, em caixas de fundo bege, está a coluna "Explicar o modelo", subtitulada como "o que a computação interna fez". São apresentados três tipos de recursos. O primeiro é chain-of-thought, descrito como uma justificativa plausível para a resposta, mas que pode racionalizar o resultado sem necessariamente revelar sua causa real. O segundo é pesos de atenção, indicando que diferentes distribuições de atenção podem produzir a mesma saída do modelo. O terceiro é atribuição por token, destacando que o custo computacional cresce com o tamanho da entrada e que o mapa de importância pode variar conforme o prompt utilizado. Ao final da coluna, um bloco resume que essa abordagem sustenta hipóteses de depuração para o desenvolvedor.
À direita, em caixas de fundo azul, está a coluna "Explicar o sistema", subtitulada como "o que o processo fez com o caso". Nessa abordagem são apresentados quatro elementos: avaliação de comportamento e red-teaming, para produzir evidências reproduzíveis sobre a conduta do sistema; procedência e citação de fontes, permitindo rastrear cada afirmação até sua origem; registro de decisão e supervisão humana, possibilitando reconstruir posteriormente como uma decisão foi tomada; e guardrails de saída, relacionados às políticas aplicadas e documentadas para controlar as respostas do sistema. Ao final da coluna, um bloco informa que essa estratégia sustenta auditoria, contestação e conformidade, citando como exemplos a Lei Geral de Proteção de Dados (LGPD), o artigo 20, e o artigo 86 do EU AI Act.
Entre as duas colunas há uma seta apontando da esquerda para a direita com a mensagem de que a fidelidade do modelo não é verificável, indicando que esse limite reforça a necessidade de ancorar a confiança no sistema como um todo, e não apenas na interpretação do modelo.
No rodapé da figura consta a indicação "Fonte: autor."

A figura organiza o contraste que os últimos parágrafos construíram. À esquerda estão os três recursos que tentam explicar a computação do modelo, cada um com o limite discutido nesta seção: a cadeia de raciocínio pode racionalizar a resposta, a atenção varia sem que a saída mude, e a atribuição por token não escala nem se estabiliza. O lugar legítimo dessa coluna é a depuração: fonte de hipóteses para o desenvolvedor, nunca justificativa para fora. À direita estão as práticas que explicam o sistema, e elas produzem exatamente o que a coluna oposta não produz: evidência reproduzível de comportamento, procedência rastreável de cada afirmação e um caso que pode ser reconstruído depois, o material de que auditoria e contestação precisam. A seta central fixa a regra de bolso da seção: quando a fidelidade ao modelo não é verificável, a confiança se ancora no sistema.

Exemplo aplicado

Uma equipe constrói um assistente que responde dúvidas regulatórias a partir de uma base documental da empresa. Em vez de pedir ao modelo que explique o seu raciocínio, a equipe estrutura o sistema com recuperação de contexto e citação: cada resposta aponta os trechos dos documentos que a embasam. A auditoria não verifica uma narrativa interna do modelo, que seria infiel, e sim se as fontes citadas de fato sustentam a resposta. A confiança vem da rastreabilidade da procedência, não de uma explicação post-hoc da computação do LLM.

O exemplo condensa a coluna direita da figura em operação: a confiança vem do que se pode verificar, e não do que o modelo narra sobre si. As referências a seguir documentam cada peça do argumento desta seção.

SAIBA MAIS

Sobre a definição e a avaliação de faithfulness, ver Jacovi e Goldberg (2020). Sobre a infidelidade do chain-of-thought, ver Turpin et al. (2023). Sobre o debate da atenção como explicação, ver Jain e Wallace (2019) e Wiegreffe e Pinter (2019). Sobre a fronteira mecanicista, ver Anthropic (2024). Todas as referências estão na bibliografia. O aprofundamento em interpretabilidade de Deep Learning e NLP cabe aos cursos por eixo da Fase 2.

5. Conclusão

Os 4 tópicos deste texto-base percorreram a base conceitual e aplicada da lente da transparência. O tópico 1 fixou a explicação como decisão de escopo condicionada pela regulação, distinguiu interpretabilidade de explicabilidade e situou as obrigações por categoria de risco, ancorando o tratamento na LGPD e complementando com o GDPR e o EU AI Act. O tópico 2 organizou a taxonomia das técnicas em três eixos, intrínseco contra post-hoc, local contra global e model-specific contra model-agnostic, e situou LIME, SHAP, Grad-CAM, atenção e a fronteira da interpretabilidade mecanicista. O tópico 3 desceu ao SHAP, mostrando como ler o waterfall, o summary e a comparação com a importância nativa do modelo, e introduziu a distinção entre faithfulness e plausibility. O tópico 4 levou essa distinção aos modelos de linguagem, onde o raciocínio exibido e os pesos de atenção enganam com facilidade.

O fio comum é que transparência não é um verniz aplicado no fim, e sim uma exigência que aparece cedo, com intensidade variável conforme o risco e o destinatário. Esse repertório conversa diretamente com a lente dos dados do M3, já que explicar uma decisão pressupõe conhecer o viés e a procedência dos dados que a sustentam: uma explicação fiel de um modelo treinado sobre dados enviesados apenas descreve, com precisão, um comportamento problemático. As duas lentes, dos dados e da transparência, materializam a decisão do curso de tratar IA responsável dentro dos módulos técnicos, e não em um tema apartado.

O e-book seguinte do módulo converte essa base em escolha justificada: qual regime de exigência se aplica, qual técnica entregar a cada stakeholder e em que profundidade, do usuário final ao regulador, ao desenvolvedor e ao auditor. É nela que a transparência deixa de ser reconhecimento de técnicas e passa a ser decisão defensável diante de quem cobra a explicação, no formato de matriz de decisão que estrutura a camada decisória de todos os módulos deste curso.

REFERÊNCIAS

Bibliografia mínima

RIBEIRO, M. T.; SINGH, S.; GUESTRIN, C. Why should I trust you? Explaining the predictions of any classifier. In: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD). San Francisco: ACM, 2016. Preprint em https://arxiv.org/abs/1602.04938.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: Advances in Neural Information Processing Systems (NeurIPS). Long Beach: Curran Associates, 2017. Preprint em https://arxiv.org/abs/1705.07874.

RUDIN, C. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. Nature Machine Intelligence, v. 1, p. 206-215, 2019. Preprint em https://arxiv.org/abs/1811.10154.

BRASIL. Lei n. 13.709, de 14 de agosto de 2018 (Lei Geral de Proteção de Dados Pessoais). Artigo 20. Brasília: Presidência da República, 2018. Texto integral em https://www.planalto.gov.br.

UNIÃO EUROPEIA. Regulamento (UE) 2024/1689 (EU AI Act). Artigos 13 e 86 (transparência e explicabilidade). Bruxelas, 2024. Texto integral em https://eur-lex.europa.eu.

BRASIL. Senado Federal. Projeto de Lei n. 2338, de 2023 (marco legal da inteligência artificial). Aprovado pelo Senado em 2024, em tramitação na Câmara dos Deputados. Texto em https://www.camara.leg.br.

Bibliografia complementar

MOLNAR, C. Interpretable machine learning: a guide for making black box models explainable. 2. ed. Munique: Leanpub, 2022. Disponível gratuitamente em https://christophm.github.io/interpretable-ml-book.

SELVARAJU, R. R. et al. Grad-CAM: visual explanations from deep networks via gradient-based localization. In: IEEE International Conference on Computer Vision (ICCV). Veneza: IEEE, 2017. Preprint em https://arxiv.org/abs/1610.02391.

WACHTER, S.; MITTELSTADT, B.; RUSSELL, C. Counterfactual explanations without opening the black box: automated decisions and the GDPR. Harvard Journal of Law and Technology, v. 31, n. 2, 2018. Preprint em https://arxiv.org/abs/1711.00399.

JACOVI, A.; GOLDBERG, Y. Towards faithfully interpretable NLP systems: how

should we define and evaluate faithfulness? In: Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL). 2020. Preprint em https://arxiv.org/abs/2004.03685.

JAIN, S.; WALLACE, B. C. Attention is not explanation. In: Proceedings of NAACL--HLT. Mineápolis: ACL, 2019. Preprint em https://arxiv.org/abs/1902.10186.

WIEGREFFE, S.; PINTER, Y. Attention is not not explanation. In: Proceedings of EMNLP-IJCNLP. Hong Kong: ACL, 2019. Preprint em https://arxiv.org/abs/1908.04626.

TURPIN, M. et al. Language models don't always say what they think: unfaithful explanations in chain-of-thought prompting. In: Advances in Neural Information Processing Systems (NeurIPS). 2023. Preprint em https://arxiv.org/abs/2305.04388.

DOSHI-VELEZ, F.; KIM, B. Towards a rigorous science of interpretable machine learning. arXiv:1702.08608, 2017.

ANTHROPIC. Mapping the mind of a large language model. Anthropic Research, 2024. Disponível em https://www.anthropic.com/research.

UNIÃO EUROPEIA. Regulamento (UE) 2016/679 (GDPR). Artigo 22 e considerando 71. Bruxelas, 2016. Texto integral em https://eur-lex.europa.eu.

Industr.IA

Residência em TIC 49



Executor iRede

Executor Atlântico

Coordenador Softex

Financiador MCTI Futuro

Ministério da Ciência, Tecnologia e Inovação

Governo do Brasil — Do lado do povo brasileiro

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.