Industr.IA

E-book

Explicabilidade:

regime de exigência, stakeholder e profundidade de entrega



Unidade M5 | Capítulo Único

Prof.: Arthur Nascimento

SUMÁRIO

1. O regime de exigência 3
2. A técnica certa para cada stakeholder 7
3. Profundidade de entrega 11
4. Conclusão 15

Unidade M5

1. O regime de exigência

Esta seção pertence à camada decisória e tem por objetivo que você identifique o regime de exigência de XAI de um sistema: obrigação regulatória, requisito de produto ou ferramenta interna de depuração. O texto-base IA-036 respondeu quando a norma exige explicação, com quais técnicas se explica e onde estão os limites. A pergunta desta seção vem antes de qualquer escolha de técnica: quem cobra a explicação deste sistema, e com que força. A resposta define um piso de entrega, e é desse piso que as duas decisões seguintes derivam, a técnica por stakeholder e a profundidade. Errar o regime contamina tudo o que vem depois; acertá-lo cedo transforma XAI de custo imprevisto em requisito dimensionado.

A ordem importa, e vale explicitar por quê. Técnica e profundidade são decisões condicionadas: a técnica certa depende de quem lê a explicação, e a profundidade certa depende de quanta garantia esse leitor pode exigir. O regime responde às duas condições de uma vez, porque diz se a cobrança vem da norma, do mercado ou da própria equipe. Há aqui um espelho direto da lição do módulo M4: assim como a decisão de deployment tratada como otimização final estoura projetos que começaram pela arquitetura, a exigência de explicação tratada como acabamento estoura projetos que começaram pelo modelo. Nos dois casos, o que parece detalhe de engenharia é compromisso de produto, e compromissos de produto se assumem no escopo. O regime de exigência é o nome desse compromisso.

O primeiro regime é a obrigação regulatória, e o seu gatilho é objetivo. Se a aplicação está no Anexo III do EU AI Act, casos como crédito e seguros, emprego e recrutamento, educação e serviços públicos essenciais, o sistema é de alto risco e as obrigações dos artigos 13 e 86 se aplicam. Se a decisão é tomada unicamente com base em tratamento automatizado e afeta interesses do titular, o artigo 20 da LGPD garante o direito à revisão dessas decisões e à obtenção de informações sobre os critérios e os procedimentos utilizados. Se o setor tem regulação própria, como o financeiro e o de saúde, normas setoriais podem impor deveres adicionais de justificativa. Nesse regime, o piso de entrega não é negociável: explicação local contestável caso a caso, registro que permita reconstruir a decisão a posteriori, validação documentada do mecanismo de explicação e supervisão humana onde a norma pedir. O custo é o mais alto dos três regimes e precisa entrar no cronograma desde o requisito, porque parte dele, como o registro por decisão, não admite retrofit.

No contexto brasileiro, dois movimentos mantêm esse gatilho em evolução. A ANPD incluiu decisões automatizadas e inteligência artificial entre as prioridades de fisca-

lização, o que aumenta a chance de o artigo 20 ser exercido na prática e não apenas em tese. E o PL 2338, em tramitação, adota lógica de classificação por risco inspirada no modelo europeu e reforça os direitos de explicação e contestação. Um sistema que hoje está fora de qualquer gatilho pode entrar em um amanhã por mudança de norma, sem que uma linha de código mude. Por isso a identificação do regime não é decisão única de início de projeto: é cláusula de reavaliação periódica, revisitada quando muda a norma, o mercado de atuação ou o uso do sistema.

Identificar o regime também não é tarefa que o time técnico encerra sozinho, e reconhecer isso faz parte da decisão. O enquadramento jurídico, se a aplicação cai no Anexo III, se a norma setorial alcança o caso, pertence ao jurídico e ao compliance; o que o profissional de PD&I leva à mesa é o enquadramento técnico que alimenta essa análise: o que exatamente o sistema decide, sobre quem, com que grau de autonomia e com que intervenção humana. Essa última resposta merece precisão especial, porque tanto o artigo 20 da LGPD quanto o artigo 22 do GDPR giram em torno de decisões tomadas unicamente por tratamento automatizado. Uma revisão humana significativa, que pode de fato alterar o resultado, pode mudar o enquadramento; uma revisão de fachada, que apenas confirma o que o modelo decidiu, não. Descrever com honestidade onde o humano está no fluxo é a contribuição técnica mais importante para acertar o regime.

O segundo regime é o requisito de produto. Nenhuma norma obriga, mas a adoção depende da explicação. Um médico não incorpora à rotina um apoio à decisão que não justifica as suas sugestões. Um operador industrial ignora o alerta de um sistema de manutenção que não aponta causa provável. Um cliente corporativo condiciona o contrato à capacidade de explicar as saídas, transformando a exigência em cláusula com força equivalente à de uma norma para aquele projeto. Nesse regime, o piso é negociado com o stakeholder: uma explicação plausível, bem calibrada e honesta sobre os próprios limites pode bastar, desde que sustente a confiança de quem usa. O custo é intermediário e o risco característico é de subestimação: tratar a explicação como recurso de interface, quando ela é condição de adoção.

O terceiro regime é a ferramenta interna de depuração. A audiência é a própria equipe, e a explicação serve à investigação: entender onde o modelo erra, detectar vazamento de informação entre variáveis, priorizar coleta de dados, comparar hipóteses de melhoria. É o uso que o notebook IA-037 exercitou ao confrontar a explicação global com a importância nativa do modelo. Nesse regime não há piso externo: a profundidade se ajusta à pergunta da investigação, nada precisa ir para produção e o custo é marginal, pago apenas quando a análise roda. É também o regime que existe em praticamente todo projeto, mesmo quando os outros dois não existem, e por isso é o piso silencioso de qualquer sistema de IA bem conduzido.

O regime também condiciona uma decisão que o IA-036 apresentou como taxonômica e que aqui se revela econômica: a escolha entre modelo intrinsecamente interpretável e modelo opaco com explicador post-hoc. Em regime regulatório, o argumento de Rudin ganha peso de orçamento. Um modelo interpretável de desempenho próximo elimina a necessidade de validar e manter um explicador post-hoc, porque a explicação é a leitura do próprio modelo, e reduz a superfície de auditoria a um artefato em vez de dois. Um modelo opaco de desempenho marginalmente melhor carrega o explicador como segundo sistema a versionar, validar e defender. A conta certa compara o ganho de desempenho com o custo recorrente do segundo sistema pela vida útil da solução, e em regime regulatório essa conta favorece o interpretável com mais frequência do que a intuição de quem otimiza métricas sugere.

GLOSSÁRIO

Regime de exigência

Regime de exigência é o enquadramento que define quem cobra a explicação de um sistema e com que força: a norma, no regime de obrigação regulatória; o mercado e o contrato, no regime de requisito de produto; a própria equipe, no regime de ferramenta interna de depuração. O regime fixa o piso de entrega; a técnica e a profundidade derivam dele.

Os três regimes não são mutuamente exclusivos: eles se acumulam. Um classificador de crédito pode estar nos três ao mesmo tempo, porque a equipe depura com SHAP, o produto comunica recusas ao solicitante e a norma pode exigir contestabilidade e registro. A decisão, portanto, não é escolher um regime, e sim identificar o mais exigente que se aplica, porque é ele que define o piso, e mapear o que cada um dos demais acrescenta. O quadro a seguir resume os três regimes com o gatilho típico de cada um e o piso de entrega correspondente.

Quadro 1 - Os três regimes de exigência de XAI.

Regime	Gatilho típico	Piso de entrega
obrigação regulatória	Anexo III do EU AI Act; decisão unicamente automatizada sob o artigo 20 da LGPD; norma setorial	explicação local contestável, registro por decisão, validação documentada do explicador
requisito de produto	adoção condicionada à confiança; cláusula contratual de explicação	explicação negociada com o stakeholder, honesta sobre limites, estável entre versões

Regime	Gatilho típico	Piso de entrega
ferramenta interna	necessidade de depurar, priorizar dados ou comparar hipóteses	sem piso externo; profundidade a serviço da investigação

Para cego ver: imagem de um quadro em formato de tabela intitulado "Quadro 1. Os três regimes de exigência de XAI." A tabela possui três colunas: Regime, Gatilho típico e Piso de entrega. Na primeira linha, o regime é obrigação regulatória. O gatilho típico inclui o Anexo III do EU AI Act, uma decisão unicamente automatizada prevista no artigo 20 da LGPD ou uma norma setorial. O piso de entrega exige explicação local contestável, registro da decisão e validação documentada do explicador. Na segunda linha, o regime é requisito de produto. O gatilho típico é a adoção condicionada à confiança ou a existência de cláusula contratual de explicação. O piso de entrega consiste em uma explicação negociada com as partes interessadas, com clareza sobre seus limites e estabilidade entre diferentes versões do sistema. Na terceira linha, o regime é ferramenta interna. O gatilho típico é a necessidade de depurar o modelo, priorizar dados ou comparar hipóteses. Nesse caso, não há um piso externo de entrega, e a profundidade da explicação é definida conforme as necessidades da investigação.

A leitura do quadro sugere a heurística operacional da seção, aplicável em minutos a qualquer cenário. Primeiro, pergunte se existe gatilho regulatório: a aplicação está em lista de alto risco, a decisão é automatizada sobre pessoa, o setor tem norma própria. Se a resposta for sim, o regime dominante é o regulatório, o piso é o da norma e o custo entra no cronograma desde o início. Se não houver gatilho, pergunte se a adoção depende de explicação: quem usa, aceita ou contrata o sistema precisa da justificativa. Se sim, o regime dominante é o de produto e o piso se negocia com esse stakeholder. Se nem isso, o regime é interno, e a decisão de XAI vira escolha de ferramenta de depuração, importante para a equipe e invisível para fora.

Exemplo aplicado

Uma indústria mantém um classificador de falha iminente em compressores, treinado sobre séries de vibração e temperatura. No uso original, o sistema alerta o operador da linha: regime de produto, porque o operador só interrompe a produção se confiar no alerta, e a explicação entregue é a causa provável em linguagem de manutenção. Meses depois, a mesma predição passa a ser usada para escalar e avaliar técnicos de manutenção. O modelo não mudou uma linha, mas a decisão passou a afetar pessoas em contexto de emprego, e o enquadramento desliza para o território de alto risco do EU AI Act. O regime mudou com o uso, e quem não reavaliou descobriu a obrigação depois dela existir.

O custo de errar essa identificação é assimétrico, e a assimetria orienta a prudência. Superestimar o regime, tratando como regulatório um sistema que era só interno, gera custo sem retorno: registro, validação e documentação que ninguém cobra. Subestimar é pior: um sistema que precisava de registro por decisão e não o tem não consegue responder a uma contestação, porque a decisão do passado não é reconstruível, e nenhum esforço posterior recupera o que não foi registrado. Entre os dois erros, o segundo é irreversível, e é ele que a identificação precoce do regime existe para evitar.

Por fim, a própria decisão de regime merece registro. Uma nota curta, datada e justificada, dizendo qual regime foi identificado, com base em que gatilhos e com que revisão prevista, custa minutos e vale muito: é ela que permite, meses depois, distinguir uma mudança de circunstância de um erro de avaliação, e é ela que a cláusula de reavaliação consulta. Regime identificado e não registrado tende a virar lembrança de corredor, e lembrança de corredor não sustenta auditoria.

Armadilha comum

Escolher a técnica antes do regime. Quem começa perguntando se usa SHAP ou um modelo interpretável decide o como antes do para quem e do sob que força, e descobre tarde que o piso real exigia registro por decisão e validação do explicador que a técnica escolhida não previa. A confusão é decisória: técnica é consequência do regime, e invertê-la produz ou retrabalho de conformidade impossível de retroagir, ou superentrega cara onde ninguém cobrava.

Identificado o regime e fixado o piso, a pergunta seguinte é a quem a explicação se destina. A mesma computação não serve a todos os leitores, e é essa tradução por destinatário que a próxima seção organiza.

2. A técnica certa para cada stakeholder

Esta seção pertence à camada decisória e tem por objetivo que você mapeie os quatro destinatários típicos de uma explicação, usuário final, regulador, desenvolvedor e auditor, aos formatos de entrega adequados a cada um. O erro que a seção ataca já foi nomeado na taxonomia do IA-036: responder a uma pergunta local com uma resposta global. Aqui ele ganha a forma decisória completa, porque cada stakeholder faz uma pergunta diferente, e a técnica que responde bem a um responde mal a outro.

O princípio que organiza a decisão é simples: explicação é um ato de comunicação, e comunicação tem destinatário. A computação por trás pode ser a mesma, os valores SHAP de um caso, por exemplo, mas a entrega muda de formato, de linguagem e de garantia conforme quem lê. Ignorar isso produz dois fracassos simétricos: o plot técnico entregue a quem não lê log-odds, que informa nada, e a narrativa amigável entregue a quem precisa verificar, que não sustenta auditoria. A decisão desta seção é, para cada destinatário do sistema em questão, escolher o formato que responde à pergunta que ele de fato faz.

Vale notar que essa decisão é a taxonomia do IA-036 projetada sobre pessoas. Cada stakeholder fixa, ao mesmo tempo, o escopo da pergunta, local para quem contesta um caso, global para quem avalia o modelo, e o grau de garantia da resposta, plausível para quem precisa entender, verificável para quem precisa conferir. Os eixos que lá organizavam técnicas aqui organizam destinatários, e é por isso que a matriz desta seção se lê como a face humana daquela árvore: escolher a célula certa é aplicar a taxonomia com o leitor em mente.

O usuário final, ou a pessoa afetada pela decisão, pergunta duas coisas: “por que eu, e o que posso fazer agora?”. A primeira pede uma explicação local traduzida, com as variáveis do caso em linguagem natural e sem escala interna do modelo, na linha do waterfall do IA-037 convertido em frases sobre o caso. A segunda pede uma explicação contrafactual, o recourse apresentado no IA-036: a menor mudança que inverteria a de-

cisão, que é a única forma de explicação que entrega um caminho de ação. É esse par que pode sustentar a contestação prevista no artigo 20 da LGPD e no artigo 86 do EU AI Act, e é para esse destinatário que a honestidade importa mais: uma explicação traduzida que omite incerteza ou promete precisão que o modelo não tem cria confiança falsa, o oposto do que a entrega existe para fazer.

Duas ressalvas completam a entrega ao usuário final. A primeira é de acionabilidade: um contrafactual só cumpre a função de recourse se a mudança sugerida for possível ao afetado. Sugerir que a aprovação viria com outra idade ou outro histórico de dez anos não entrega caminho nenhum; a busca contrafactual precisa ser restrita às variáveis sobre as quais a pessoa tem agência, como prazo, valor ou composição da proposta. A segunda é de estabilidade: explicações que mudam entre versões do modelo para o mesmo caso corroem a confiança que deveriam construir, e a comunicação ao afetado precisa sobreviver ao retreino ou declarar a mudança. As duas ressalvas são decisões de projeto da entrega, não detalhes da técnica.

O regulador pergunta outra coisa: o sistema cumpre a norma. A entrega principal não é um plot, é documentação estruturada: a descrição do sistema e dos dados, na linha dos model cards e datasheets vistos no módulo M3, a política de explicação ao afetado, a evidência de validação do explicador e o desenho da supervisão humana. Explicações locais entram como capacidade demonstrável sob demanda, não como pilha de gráficos: o que o regulador verifica é que, diante de um caso concreto, o operador consegue produzir a justificativa e o registro correspondente. A explicação global apoia essa documentação ao descrever o comportamento médio do modelo, mas não a substitui.

Essa entrega ao regulador tem ainda uma dimensão temporal que costuma escapar. A documentação é viva: acompanha cada versão do modelo, e um dossiê congelado na implantação descreve um sistema que já não existe. E a capacidade de explicar sob demanda tem prazo, porque o direito do artigo 86 se exerce diante de um caso concreto e a resposta precisa chegar em tempo útil. Vale tratar essa capacidade como se trata um plano de recuperação: ensaiada periodicamente, com um caso real sorteado, o registro consultado e a justificativa produzida de ponta a ponta. O ensaio que falha em ambiente controlado é barato; a contestação real que encontra o registro incompleto não é.

O desenvolvedor pergunta onde o modelo erra e por quê, e é o único destinatário que consome a saída crua das ferramentas. Para ele, o summary do SHAP, as curvas de dependência parcial e a análise de erro por slices do módulo M3 são o formato certo, na profundidade máxima disponível, porque a pergunta é investigativa: detectar vazamento de variável, entender uma divergência entre importâncias, decidir se o próximo esforço vai para dados ou para modelo. Traduzir para esse destinatário seria perder informação; o que para o usuário final é ruído ilegível é, para o desenvolvedor, exatamente o sinal.

Para esse destinatário, a explicação rende mais quando acoplada à disciplina de análise de erro do módulo M3. Importâncias calculadas por slice, e não só na média, revelam se o modelo usa variáveis diferentes em subgrupos distintos, um sinal de comportamento díspar que o summary agregado esconde e que antecipa tanto problema de equidade quanto fragilidade sob drift. A combinação é natural: os slices dizem onde o desempenho diverge, e a explicação por slice sugere por quê.

O auditor, interno ou externo, faz a pergunta mais exigente: posso verificar que a explicação é verdadeira. Para ele, o formato importa menos que a garantia: a explicação precisa ser reproduzível, mesma entrada, mesma versão do modelo, mesma explicação, verificável por propriedade, como a aditividade do SHAP checada numericamente no IA-037, e rastreável, com a trilha que liga cada decisão à versão do modelo e do explicador que a produziu. O auditor é o destinatário que separa faithfulness de plausibility na prática: uma narrativa convincente sem verificação não passa, e uma explicação técnica verificável passa mesmo sendo árida. A figura a seguir cruza os quatro destinatários com os formatos de entrega.

A matriz concentra os quatro destinatários canônicos, mas cenários reais costumam ter leitores secundários que vale mapear com a mesma lógica. O gestor que decide sobre o sistema quer agregados e custo, uma leitura global resumida com as consequências de negócio. O suporte de primeira linha quer um roteiro derivado da explicação local, suficiente para responder ao afetado sem improvisar. Nenhum deles muda a estrutura da decisão: identifica-se a pergunta que o leitor faz, o escopo e a garantia correspondentes, e deriva-se a entrega. A matriz ensina o método; a lista de linhas cresce com o cenário.

Figura 1 - Matriz de adequação entre stakeholders e formatos de entrega da explicação.



Fonte: autor.

Arquivo:M5_fig-6_stakeholder_vs_entrega.svg

Para cego ver: A imagem apresenta uma matriz em formato de tabela intitulada "Figura 1 – Matriz de adequação entre stakeholders e formatos de entrega da explicação". Na primeira coluna estão os perfis dos públicos envolvidos (stakeholders): usuário final, com a descrição "por que eu, e o que eu posso fazer agora"; regulador, "o sistema cumpre a norma"; desenvolvedor, "onde o modelo erra e por quê"; e auditor, "posso verificar que a explicação é verdadeira". Nas colunas superiores aparecem os diferentes formatos de entrega da explicação: contrafactual (recourse), local traduzida (linguagem do caso), local técnica (waterfall, LIME), global (summary, PDP) e documentação e procedência. Cada cruzamento entre público e formato é representado por um símbolo: círculo azul preenchido, indicando que aquele formato é a entrega principal; círculo azul parcialmente preenchido, indicando que é útil como apoio; e círculo branco vazado, indicando que é inadequado como entrega principal. A matriz mostra que usuários finais se beneficiam principalmente de explicações contrafactuais e locais traduzidas; reguladores utilizam documentação como principal apoio, complementada por explicações contrafactuais, locais traduzidas e globais; desenvolvedores dependem principalmente de explicações técnicas locais e globais, com apoio de explicações contrafactuais e documentação; e auditores utilizam principalmente explicações técnicas locais e documentação, tendo explicações globais como apoio. Na parte inferior há uma legenda explicando o significado dos três tipos de círculos utilizados na matriz.

A matriz se lê por linha, e três leituras merecem destaque. Primeira: nenhuma coluna serve a todas as linhas, o que confirma que não existe a explicação do sistema, e sim uma entrega por destinatário. Segunda: as linhas do usuário final e do desenvolvedor são quase complementares, e é exatamente entre elas que ocorre o erro mais comum, o plot técnico entregue à pessoa afetada. Terceira: em regime regulatório, o sistema precisa cobrir várias linhas ao mesmo tempo, porque a norma cria simultaneamente o direito do afetado, a fiscalização do regulador e a necessidade de auditoria, e o custo dessa cobertura múltipla é parte do que a seção anterior mandou colocar no escopo. Os círculos pela metade importam tanto quanto os cheios: marcam formatos que apoiam uma entrega principal sem poderem substituí-la.

Exemplo aplicado

No classificador de crédito do módulo, uma única recusa gera quatro entregas a partir da mesma computação SHAP. O solicitante recebe os principais fatores do seu caso em linguagem natural e um contrafactual: o que precisaria mudar para a aprovação. O regulador recebe a documentação do sistema e a política de explicação, com a capacidade de produzir a justificativa de qualquer caso sob demanda. O time de modelagem usa o summary e a análise por slices para investigar disparidades. O auditor reexecuta a explicação do caso contestado sobre a versão registrada do modelo e verifica que as parcelas fecham a predição. Uma computação, quatro formatos, quatro perguntas respondidas.

Essa multiplicidade tem uma implicação de engenharia que convém decidir cedo: separar a computação da explicação da sua apresentação. A computação, o explicador versionado junto com o modelo, é uma; as apresentações, o texto ao afetado, o dossiê ao regulador, o notebook do desenvolvedor, a trilha do auditor, são camadas sobre ela. Projetar assim evita a tentação de manter quatro mecanismos de explicação distintos, que divergiriam entre si, e faz da consistência entre entregas uma propriedade da arquitetura, e não um esforço manual de sincronização.

Na prática, essa separação em camadas se sustenta com três disciplinas. A computação roda uma vez por caso e fica registrada, e as apresentações consomem o registro, o que garante que solicitante, regulador e auditor leem derivações do mesmo cálculo, e não cálculos paralelos. A versão do explicador acompanha a versão do modelo no mesmo registro, para que reproduzir uma explicação antiga seja carregar um par versionado, e não reconstruir um ambiente. E a consistência entre apresentação e computação vira teste: a frase gerada para o afetado é conferida contra as contribuições que a originaram, automaticamente, a cada versão. São disciplinas baratas quando nascem com o sistema e proibitivas quando tentadas depois, o mesmo padrão de custo que tópico 1 deste ebook identificou no registro por decisão.

Armadilha comum

Uma explicação para todos. Quem define um único formato de explicação e o entrega a todos os destinatários erra nas duas pontas: o usuário final recebe um gráfico em log-odds que não sustenta contestação nenhuma, e o auditor recebe uma narrativa amigável que não pode verificar. A confusão é decisória: tratar o formato da explicação como detalhe de interface, quando ele é uma decisão de projeto com destinatário, garantia e custo próprios. O sintoma típico é a frase o sistema já tem explicabilidade, dita sem que ninguém pergunte para quem.

Para aprofundar

Sobre explicações contrafactuais como instrumento de contestação, ver Wachter, Mittelstadt e Russell (2018), na bibliografia. Molnar (2022) dedica capítulos aos métodos agnósticos citados na matriz e ao exemplo contrafactual. A implementação instrumentada dessas entregas, incluindo a comparação entre bibliotecas, é matéria dos cursos de Machine Learning e Deep Learning da Fase 2 do programa.

Definidos o regime e o destinatário, resta a terceira decisão: quanto rigor pagar em cada entrega.

3. Profundidade de entrega

Esta seção pertence à camada decisória e tem por objetivo que você calibre a profundidade de cada entrega de explicação, do plausível suficiente ao fiel e verificável, pagando o custo de rigor que o regime e o stakeholder exigem, e não mais. A distinção entre faithfulness e plausibility, apresentada no primeiro ebook deste módulo como propriedade das técnicas, reaparece aqui como eixo de decisão: não como um binário entre explicação verdadeira e falsa, e sim como um gradiente de garantia com degraus de custo bem distintos.

O gradiente tem três degraus úteis para decisão. No primeiro, a explicação é plausível e útil: orienta o leitor, é honesta sobre não carregar garantia formal, e serve à exploração e à comunicação preliminar. No segundo, a explicação é fiel com simplificação controlada: a computação por trás é fiel ao modelo, como os valores SHAP, e a apresentação traduz e resume declarando o que omite, o formato típico do requisito de produto. No terceiro, a explicação é fiel e verificável: além de computada com fidelidade, é reproduzível sobre versão registrada, validada por propriedade e acompanhada de trilha, o forma-

to que auditoria e obrigação regulatória exigem. Cada degrau contém o anterior, e o erro de calibragem é sempre o mesmo: entregar um degrau diferente do que o caso pede.

Ajuda a fixar os degraus pensar no artefato físico que cada um entrega. No primeiro, o artefato é uma nota de análise: importâncias aproximadas, ressalvas declaradas, circulação interna. No segundo, é o par mensagem e registro: o texto que o destinatário lê e, guardada, a computação fiel que o gerou, com a versão do modelo anotada. No terceiro, é um pacote reproduzível: versão do modelo e do explicador, parâmetros e semente, a explicação gerada e a trilha que liga tudo ao caso, capaz de ser reexecutado por um terceiro meses depois. Perguntar qual artefato o cenário exige é, muitas vezes, o caminho mais rápido para acertar o degrau.

O custo de subir degraus é concreto e se distribui em quatro contas. A computacional: gerar explicação por predição em produção adiciona inferência, e uma busca contrafactual custa mais que a predição que explica; em alto volume, essa conta rivaliza com a do próprio modelo, como o IA-036 registrou para IA generativa. A de engenharia: no degrau verificável, o explicador passa a ser artefato versionado junto do modelo, com registro por decisão, o que altera o desenho do sistema. A de validação: fidelidade se demonstra, não se declara, e demonstrá-la exige testes próprios, da verificação de aditividade à estabilidade da explicação sob perturbações da entrada. E a de manutenção: cada retreino do modelo arrasta a revalidação do explicador, para sempre. Quem promete o terceiro degrau assina as quatro contas pela vida útil do sistema.

A conta de validação merece detalhe, porque validar um explicador é tarefa menos óbvia do que validar um modelo. Quatro verificações formam o kit mínimo. O teste de sanidade: sobre um modelo de pesos aleatórios, o explicador deve produzir importâncias difusas, e um explicador que encontra estrutura onde não há denuncia artefato do método. O teste de estabilidade: pequenas perturbações na entrada devem produzir explicações semelhantes, desde que não atravessem fronteiras de decisão ou regiões de alta sensibilidade do modelo. O teste de remoção: retirar ou neutralizar a variável apontada como decisiva tende a mover a predição na direção prevista, o mesmo raciocínio que o tópico 4 do primeiro ebook deste módulo aplicou às narrativas de modelos de linguagem. E a verificação por propriedade quando a técnica a oferece, como a aditividade do SHAP conferida numericamente no IA-037. Nenhum desses testes é caro isoladamente; o custo real é mantê-los rodando a cada versão, e é essa recorrência que o degrau verificável assina.

A heurística de calibragem segue direto do que os dois tópicos anteriores fixaram: entregue a profundidade mínima que o regime e o stakeholder exigem, e declare explicitamente qual é ela. O mínimo, porque profundidade acima do exigido é custo recorrente sem retorno, e profundidade abaixo do exigido em regime regulatório é falha de confor-

midade, o erro irreversível do tópico 1. E declarada, porque parte da entrega honesta é dizer ao destinatário que garantia a explicação carrega: um relatório que apresenta importâncias aproximadas como se fossem verificadas empurra o leitor a decisões que o método não sustenta. O quadro a seguir cruza os regimes com a profundidade mínima correspondente.

A profundidade escolhida também determina quando a explicação é computada, e essa decisão tem consequência direta de latência e de produto. Explicar sincronicamente, junto com a predição, adiciona o custo do explicador ao caminho crítico de cada resposta, o que um contrafactual, que é uma busca, raramente comporta. As alternativas são explicar por demanda, gerando a justificativa completa apenas quando o caso é contestado, desde que o registro permita reconstruí-lo, ou por lote, pré-computando explicações fora do horário crítico para os casos que a política definir. Em regime regulatório, a escolha é condicionada: o que a norma pode exigir é a capacidade de explicar cada decisão, não necessariamente a geração antecipada de todas, e o registro por decisão é o que converte a explicação por demanda em promessa cumprível.

Resta levar essa conta a quem aprova o orçamento, porque a decisão de profundidade raramente é do time técnico sozinho. A tradução que funciona converte degraus em itens de custo reconhecíveis: a validação recorrente do explicador como serviço contínuo, e não esforço de implantação; o registro por decisão como armazenamento e engenharia dimensionados por volume; a explicação síncrona como acréscimo de latência com número. Um stakeholder que recusa o custo do terceiro degrau diante dessa tradução está, na prática, decidindo sobre o regime que aceita operar, e é melhor que essa decisão seja tomada às claras no escopo do que descoberta na primeira contestação.

Quadro 2 - Profundidade mínima de entrega por regime de exigência.

Regime	Profundidade mínima	O que validar
obrigação regulatória	fiel e verificável: reproduzível sobre versão registrada, com trilha por decisão	aditividade ou propriedade equivalente, estabilidade da explicação, reconstrução de casos passados
requisito de produto	fiel com simplificação controlada, declarando o que a tradução omite	consistência entre a apresentação e a computação subjacente, estabilidade entre versões
ferramenta interna	plausível e útil, ajustada à pergunta da investigação	apenas o suficiente para não enganar a própria equipe

Para cego ver: A imagem apresenta um quadro intitulado "Quadro 2 – Profundidade mínima de entrega por regime de exigência", organizado em uma tabela com três colunas: Regime, Profundidade mínima e O que validar. A tabela compara o nível de detalhamento esperado das explicações conforme o contexto de uso.Na primeira linha, referente à obrigação regulatória, a profundidade mínima exige uma explicação fiel e verificável, reprodutível sob versão registrada e acompanhada de trilha por decisão. O objetivo da validação é verificar aditividade ou propriedade equivalente, estabilidade da explicação e a reconstrução de casos passados. Na segunda linha, correspondente ao requisito de produto, a explicação deve ser fiel, porém com simplificação controlada, deixando explícito o que a tradução omite. Nesse caso, a validação busca garantir a consistência entre a apresentação e a computação subjacente, além da estabilidade entre versões. Na terceira linha, destinada ao uso como ferramenta interna, a profundidade mínima é uma explicação plausível e útil, ajustada à pergunta da investigação. A validação verifica se há apenas o nível de informação suficiente para não induzir a própria equipe ao erro.O quadro utiliza fundo branco, cabeçalho em azul-claro e linhas cinza delimitando as células, sem elementos gráficos adicionais além da estrutura tabular.

Uma linha do quadro merece nota à parte: a de IA generativa. Como o tópico 1 do primeiro ebook deste módulo (IA-036) estabeleceu, o degrau fiel e verificável não está disponível para explicar a computação interna de um modelo de linguagem, e nenhuma

cláusula contratual o torna disponível. Quando um componente generativo entra em um sistema sob regime regulatório ou contratual, a profundidade se transfere para o nível do sistema: procedência com citação de fontes, avaliação de comportamento documentada, registro de entradas e saídas. A decisão honesta registra essa transferência explicitamente, em vez de prometer para o modelo uma fidelidade que só o sistema pode oferecer.

A profundidade entregue também degrada no tempo se ninguém a vigiar. O modelo em produção sofre drift, como o módulo M3 estabeleceu para os dados, e o explicador acompanha o modelo: importâncias que migram entre retreinos, explicações que mudam para casos equivalentes, contrafactuais que deixam de ser acionáveis quando a distribuição se move. A resposta é tratar a explicação como um sinal monitorado, ao lado da acurácia: a distribuição das importâncias globais entre versões é um termômetro útil, e um deslocamento abrupto nela pode indicar mudanças no modelo ou nos dados antes que as métricas de desempenho as revelem. Profundidade prometida sem monitoramento é promessa com prazo de validade não declarado. O quadro anterior, relido sob essa luz, ganha uma coluna implícita: cada profundidade prometida carrega o monitoramento que a mantém verdadeira ao longo das versões.

Armadilha comum

Prometer profundidade indisponível. Um contrato que exige explicação fiel das saídas de um componente de linguagem assina um piso que nenhuma técnica atual atinge, e a falha só aparece quando um caso é contestado e a narrativa entregue não resiste a verificação. O erro decisório está na assinatura, não na execução: a profundidade prometida deve ser a que o estado da técnica sustenta para aquele componente, e para IA generativa isso significa prometer verificabilidade do sistema, não do modelo.

Exemplo aplicado

Um hospital contrata um apoio à triagem de urgência baseado em classificador tabular. O regime é duplo: produto, porque a equipe clínica só adere se confiar, e regulatório em perspectiva, pelo enquadramento de saúde. A calibragem resultante: para a equipe clínica, explicação local traduzida com os fatores do paciente, no segundo degrau; para o comitê de conformidade, explicador versionado com verificação de aditividade e trilha por triagem, no terceiro; para o time de dados, acesso cru ao summary e aos slices. O custo do terceiro degrau foi orçado no contrato, porque a validação contínua do explicador entrou como serviço recorrente, e não como esforço único de implantação.

Para aprofundar

Sobre a definição rigorosa do que conta como avaliação de interpretabilidade, ver Doshi-Velez e Kim (2017). Sobre critérios de faithfulness e a sua avaliação, ver Jacovi e Goldberg (2020). Ambas na bibliografia. O detalhamento da validação de explicadores em produção é matéria dos cursos de Machine Learning e Deep Learning da Fase 2 do programa.

4. Conclusão

Os três tópicos deste texto-base converteram a base do módulo em decisão. o tópico 1 fixou o regime de exigência como a primeira pergunta, porque é ele que define o piso: obrigação regulatória, requisito de produto ou ferramenta interna, com gatilhos objetivos, acumulação entre regimes e cláusula de reavaliação. O Tópico 2 mapeou os quatro destinatários da explicação às entregas adequadas, do contrafactual acionável do usuário final à trilha verificável do auditor, com a separação entre computação e apresentação como decisão de arquitetura. O tópico 3 calibrou a profundidade em três degraus de garantia e quatro contas de custo, com a heurística do mínimo exigido e declarado, e com a transferência explícita da fidelidade para o nível do sistema quando o componente é generativo. O fio das três decisões é o mesmo que atravessa as camadas decisórias de todos os módulos do curso: substituir a pergunta técnica isolada, que técnica de XAI usar, pela pergunta de projeto completa, quem cobra, para quem se entrega e com que garantia.

REFERÊNCIAS

Bibliografia mínima

RIBEIRO, M. T.; SINGH, S.; GUESTRIN, C. **Why should I trust you?** Explaining the predictions of any classifier. In: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD). San Francisco: ACM, 2016. Preprint em https://arxiv.org/abs/1602.04938.

LUNDBERG, S. M.; LEE, S.-I. **A unified approach to interpreting model predictions**. In: Advances in Neural Information Processing Systems (NeurIPS). Long Beach: Curran Associates, 2017. Preprint em https://arxiv.org/abs/1705.07874.

RUDIN, C. **Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead**. Nature Machine Intelligence, v. 1, p. 206-215, 2019. Preprint em https://arxiv.org/abs/1811.10154.

BRASIL. **Lei n. 13.709, de 14 de agosto de 2018** (Lei Geral de Proteção de Dados Pessoais). Artigo 20. Brasília: Presidência da República, 2018. Texto integral em https://www.planalto.gov.br.

UNIÃO EUROPEIA. **Regulamento (UE) 2024/1689** (EU AI Act). Artigos 13 e 86 (transparência e explicabilidade). Bruxelas, 2024. Texto integral em https://eur-lex.europa.eu.

BRASIL. Senado Federal. **Projeto de Lei n. 2338, de 2023** (marco legal da inteligência artificial). Aprovado pelo Senado em 2024, em tramitação na Câmara dos Deputados. Texto em https://www.camara.leg.br.

Bibliografia complementar

MOLNAR, C. **Interpretable machine learning**: a guide for making black box models explainable. 2. ed. Munique: Leanpub, 2022. Disponível gratuitamente em https://christophm.github.io/interpretable-ml-book.

WACHTER, S.; MITTELSTADT, B.; RUSSELL, C. **Counterfactual explanations without opening the black box**: automated decisions and the GDPR. Harvard Journal of Law and Technology, v. 31, n. 2, 2018. Preprint em https://arxiv.org/abs/1711.00399.

JACOVI, A.; GOLDBERG, Y. **Towards faithfully interpretable NLP systems**: how should we define and evaluate faithfulness? In: Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL). 2020. Preprint em https://arxiv.org/abs/2004.03685.

DOSHI-VELEZ, F.; KIM, B. **Towards a rigorous science of interpretable machine learning**. arXiv:1702.08608, 2017.

UNIÃO EUROPEIA. **Regulamento (UE) 2016/679** (GDPR). Artigo 22 e considerando 71. Bruxelas, 2016. Texto integral em https://eur-lex.europa.eu.

Industr.IA

Residência em TIC 49



Executor iRede

Executor Atlântico

Coordenador Softex

Financiador MCTI Futuro

Ministério da Ciência, Tecnologia e Inovação

Governo do Brasil — Do lado do povo brasileiro

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.