Industr.IA

Glossário

Explicabilidade:
Glossário do módulo

Unidade M5 | Capítulo Único
Prof.: Arthur Nascimento

Industr.IA

Glossário de Termos

Unidade M5

Convenções: cada entrada traz tag de origem no formato [M5: seção]. Quando o texto-base traz um box-glossário formal para o termo, a definição reproduz o texto do box. Termos introduzidos ou retomados pelo notebook do módulo trazem a marca do notebook na tag (por exemplo [M5: 5.3, IA-037]). Referências cruzadas aparecem como "veja X," sem definição. A ordem é alfabética, ignorando acentos e diferença entre maiúsculas e minúsculas.

Glossário de Termos

Termo	Descrição	Origem
Aditividade (local accuracy)	Propriedade dos valores SHAP pela qual o valor base somado às contribuições de todas as variáveis reproduz exatamente a predição do modelo para o caso. É verificável numericamente, como o notebook do módulo demonstra para todos os casos de teste de uma vez, e é o que distingue a explicação auditável de uma narrativa apenas plausível.	[M5: 5.3, IA-037]
Alto risco (Anexo III)	Categoria do EU AI Act definida por lista, o Anexo III, que inclui usos como crédito e seguros, emprego e recrutamento, educação e serviços públicos essenciais. Concentra a exigência forte e cumulativa: documentação técnica, registro de eventos, supervisão humana e o direito à explicação da decisão individual do artigo 86.	[M5: 5.1]
Atribuição por token	Família de técnicas que estima o peso de cada trecho da entrada de um modelo de linguagem, perturbando ou ocluindo partes do prompt ou propagando gradientes até os embeddings. Útil em entradas curtas e depuração pontual; o custo cresce com o comprimento da entrada, não há referência para validar o mapa resultante e o mapa muda quando o prompt muda.	[M5: 5.4]
Background	Conjunto de dados de referência sobre o qual o explicador calcula o valor esperado do modelo. No notebook do módulo, o background é o próprio conjunto explicado; a escolha do background desloca o valor base e, com ele, a leitura das contribuições.	[M5: 5.3, IA-037]

Termo	Descrição	Origem
Chain-of-thought	Sequência de passos intermediários que um modelo de linguagem exibe antes da resposta. Parece o caminho do raciocínio, mas pode racionalizar a resposta sem reportar a causa real da computação: é plausível sem garantia de ser fiel, e tomá-lo por explicação fiel é a armadilha central dos limites de XAI para IA generativa.	[M5: 5.4]
Decisão unicamente automatizada	Decisão tomada sem revisão humana significativa, gatilho central do artigo 20 da LGPD e do artigo 22 do GDPR. Uma revisão humana que pode de fato alterar o resultado muda o enquadramento; uma revisão de fachada, que carimba o que o modelo decidiu, não muda.	[M5: 5.1]
Dependência parcial (PDP)	Curva post-hoc global que descreve o efeito médio de uma variável sobre a predição do modelo. Complementa o summary ao mostrar a forma do efeito, e não apenas a sua magnitude; no mapa de entregas do módulo, apoia as leituras do desenvolvedor e do regulador.	[M5: 5.6]
Dever de transparência	Obrigação da faixa de risco limitado do EU AI Act: informar que se interage com uma IA e rotular conteúdo sintético. É transparência de existência, que nem sempre implica explicar cada predição; as obrigações correspondentes do artigo 50 aplicam-se a partir de agosto de 2026 e não foram adiadas pelo Digital Omnibus.	[M5: 5.1]
Direito à explicação	Direito da pessoa afetada de obter explicações sobre o papel do sistema na decisão e sobre os seus elementos principais, previsto no artigo 86 do EU AI Act para alto risco, com paralelo no artigo 20 da LGPD, que fala em critérios e procedimentos da decisão automatizada. É dever do operador que toma a decisão, ainda que o modelo venha de um terceiro.	[M5: 5.1]
Explicabilidade	Veja interpretabilidade.	[M5: 5.1]
Explicação contrafactual	Uma explicação contrafactual descreve a menor alteração nas variáveis de entrada capaz de mudar a decisão do modelo, por exemplo o crédito seria aprovado se a renda subisse a um patamar e a dívida caísse a outro. É local e model-agnostic, e responde à pergunta de recourse, o que fazer para obter outro resultado, em vez de atribuir contribuições. É especialmente relevante para a contestabilidade exigida pela LGPD e pelo EU AI Act, porque entrega à	[M5: 5.2]

Termo	Descrição	Origem
	pessoa um caminho concreto, e não apenas um diagnóstico.	
Explicação global	Explicação do comportamento médio do modelo sobre muitos casos: quais variáveis pesam em geral e em que direção. Não responde por que um caso individual recebeu a sua predição; responder a uma contestação local com um ranking global é a confusão mais comum da prática.	[M5: 5.2]
Explicação local	Explicação de uma predição individual: quais variáveis, com quais valores, empurraram este caso para este resultado. É o formato que sustenta a contestação caso a caso prevista na regulação, e a leitura por excelência do gráfico waterfall.	[M5: 5.2]
Explicação sob demanda	Estratégia de computar a justificativa completa apenas quando o caso é contestado, em vez de junto com cada predição. Exige registro por decisão que permita reconstruir o caso; em muitos cenários regulatórios, o exigido é a capacidade de explicar cada decisão, e não necessariamente a geração antecipada de todas.	[M5: 5.7]
Explicar o sistema	Estratégia alternativa a explicar a computação interna do modelo: documentar quais entradas o sistema recebeu, de quais fontes a resposta partiu, quais controles filtraram a saída e onde um humano interveio. Para IA generativa é onde a conformidade se sustenta, porque o degrau fiel e verificável não está disponível para a computação interna de um modelo de linguagem.	[M5: 5.4]
Faithfulness	Faithfulness é o grau em que uma explicação reflete de fato a computação que o modelo realizou. Plausibility é o grau em que a explicação parece convincente para um leitor humano. As duas são independentes: uma explicação pode ser plausível e infiel, descrevendo bem o que esperaríamos e mal o que o modelo fez. Em sistemas de alto risco, faithfulness é o que sustenta auditoria; plausibility, sozinha, pode mascarar o problema em vez de revelá-lo.	[M5: 5.4]

Termo	Descrição	Origem
feature_importances_	Importância nativa dos modelos de árvore, configurada no módulo como ganho: a redução média de perda que cada variável produziu nas divisões durante o treino. Descreve o que foi útil ao construir as árvores, não o quanto cada variável desloca as predições; quando diverge do SHAP global, a leitura prudente para fins de explicação confia no SHAP.	[M5: 5.3, IA-037]
Formato de entrega	Forma que a explicação assume para um destinatário: contrafactual, local traduzida, local técnica, global, ou documentação e procedência. É decisão de projeto com destinatário, garantia e custo próprios, e não detalhe de interface; a matriz da figura M5.fig-6 cruza formatos e stakeholders.	[M5: 5.6]
Grad-CAM	Técnica post-hoc local e model-specific que usa os gradientes de uma rede convolucional para destacar as regiões de uma imagem que mais influenciaram a predição, produzindo um mapa de calor sobre a imagem, o chamado saliency map. Útil em visão computacional.	[M5: 5.2]
Interpretabilidade	Interpretabilidade é a propriedade de um modelo cuja lógica pode ser acompanhada diretamente por uma pessoa, como uma regressão linear, uma árvore rasa ou uma lista de regras. Explicabilidade é a geração de justificativas post-hoc para um modelo opaco, por meio de técnicas como SHAP ou LIME. A primeira é intrínseca ao modelo; a segunda é aplicada por fora, depois que o modelo já foi treinado.	[M5: 5.1]
Interpretabilidade mecanicista	Linha de pesquisa que tenta entender os circuitos internos dos modelos em vez de atribuir importância a entradas, isolando na representação interna características que correspondem a conceitos legíveis. É a direção mais promissora para recuperar faithfulness em modelos grandes, mas está longe do uso operacional e não resolve, hoje, a necessidade prática de justificar uma saída em produção.	[M5: 5.4]

Termo	Descrição	Origem
LIME	Técnica post-hoc local e model-agnostic (local interpretable model-agnostic explanations): gera variações da entrada em torno do caso, observa como a saída muda e ajusta um modelo simples, tipicamente uma regressão linear, ponderando as variações mais próximas do caso original. A explicação vale apenas na vizinhança do caso e depende da amostragem, o que a torna menos estável que métodos com garantia de propriedade.	[M5: 5.2]
Log-odds	Escala interna em que vivem as contribuições SHAP de um classificador de árvore: a margem do modelo antes da conversão em probabilidade. Comparar barras entre si é seguro; lê-las como pontos percentuais não é, porque o efeito em probabilidade depende da posição do caso na curva.	[M5: 5.3, IA-037]
Model-agnostic	Técnica de explicação que trata o modelo como caixa-preta, observando apenas entradas e saídas, e por isso funciona com qualquer modelo, de uma floresta aleatória a uma rede profunda. Contrasta com model-specific, que explora a estrutura interna de uma família, ganhando precisão e custo menor ao preço da generalidade.	[M5: 5.2]
Model-specific	Veja model-agnostic.	[M5: 5.2]
Pesos de atenção	Distribuições internas dos transformers, por vezes lidas como explicação de onde o modelo olhou. Distribuições de atenção diferentes podem produzir a mesma saída, o que limita a sua fidelidade: valem como sinal de investigação para o desenvolvedor, não como justificativa para fora.	[M5: 5.4]
Piso de entrega	Nível mínimo de explicação que o regime de exigência impõe: da explicação local contestável com registro por decisão, no regime regulatório, à profundidade livre da ferramenta interna. O piso não se negocia dentro do regime; o que se decide é o regime aplicável e o que se entrega acima dele.	[M5: 5.5]
Plausibility	Veja faithfulness.	[M5: 5.4]
Profundidade de entrega	Grau de garantia que uma explicação carrega, em três degraus: plausível e útil, fiel com simplificação controlada, fiel e verificável. Cada degrau contém o anterior e assina contas próprias de computação, engenharia, validação e manutenção; a regra é entregar o mínimo que o regime e o stakeholder exigem, declarando qual é.	[M5: 5.7]

Termo	Descrição	Origem
Provider e deployer	Papéis do EU AI Act: provider é quem constrói o sistema; deployer é quem o utiliza em um contexto concreto. As obrigações recaem de forma diferente sobre cada um, e o direito à explicação do artigo 86 é dever do operador que toma a decisão, ainda que o modelo venha de um terceiro.	[M5: 5.1]
Recourse	Veja explicação contrafactual.	[M5: 5.2]
Regime de exigência	Regime de exigência é o enquadramento que define quem cobra a explicação de um sistema e com que força: a norma, no regime de obrigação regulatória; o mercado e o contrato, no regime de requisito de produto; a própria equipe, no regime de ferramenta interna de depuração. O regime fixa o piso de entrega; a técnica e a profundidade derivam dele.	[M5: 5.5]
Registro por decisão	Trilha que liga cada decisão do sistema à versão do modelo e do explicador que a produziu, com os dados do caso, permitindo reconstruir e reexplicar a decisão a posteriori. Não admite retrofit: a decisão do passado que não foi registrada não é reconstruível, e é por isso que esse custo entra no cronograma desde o requisito.	[M5: 5.5]
SHAP	SHAP (SHapley Additive exPlanations) é um método de atribuição que distribui a diferença entre a predição de um caso e o valor esperado do modelo entre as variáveis de entrada, usando valores de Shapley da teoria dos jogos. É model-agnostic na forma geral (KernelSHAP) e tem variante exata e eficiente para modelos de árvore (TreeSHAP). Serve tanto a explicações locais, para um caso, quanto, por agregação de muitos casos, a explicações globais.	[M5: 5.3]
Summary (beeswarm)	Gráfico global do SHAP em que cada ponto é um caso: a posição horizontal é a contribuição, a cor codifica o valor da variável e as variáveis se ordenam pela média do módulo das contribuições. É a fotografia do modelo como um todo, e não responde perguntas sobre um caso individual.	[M5: 5.3, IA-037]
Técnica post-hoc	Estratégia em que o modelo é treinado primeiro e a explicação é gerada por fora, depois, por um método que interroga o modelo pronto. Contrasta com a interpretabilidade intrínseca; é o que permite explicar modelos opacos, ao custo de a explicação ser uma aproximação cuja fidelidade precisa ser validada.	[M5: 5.2]

Termo	Descrição	Origem
Teste de perturbação	Teste barato de infidelidade: se a justificativa cita uma evidência, remove-se ou altera-se essa evidência na entrada e observa-se se a resposta muda. Uma resposta que sobrevive à remoção da razão declarada denuncia que a razão declarada não era a causa. É assimétrico: revela infidelidade, não garante fidelidade.	[M5: 5.4]
TreeSHAP	Variante do SHAP exata e eficiente para modelos de árvore, que calcula os valores de Shapley explorando a estrutura das árvores em vez de amostrar coalizões. É a implementação usada no notebook do módulo sobre o classificador XGBoost.	[M5: 5.3, IA-037]
Validação do explicador	Conjunto de testes que fornece evidências da fidelidade de um mecanismo de explicação: sanidade sobre modelo aleatório, estabilidade sob perturbações pequenas, remoção da variável apontada e verificação por propriedade quando disponível, como a aditividade do SHAP. Fidelidade se demonstra, não se declara, e a validação se repete a cada versão do modelo.	[M5: 5.7]
Valor base (expected value)	Predição média do modelo sobre o background, ponto de partida da conta aditiva do SHAP: é dele que as contribuições das variáveis partem até chegar à predição do caso. No waterfall aparece como E[f(x)], na base do gráfico.	[M5: 5.3, IA-037]
Valores de Shapley	Conceito da teoria dos jogos que reparte um resultado entre jogadores conforme a contribuição marginal média de cada um, considerando todas as ordens de chegada possíveis. Aplicado a modelos, reparte a diferença entre a predição do caso e o valor esperado entre as variáveis de entrada; é a base do SHAP.	[M5: 5.2]
Waterfall	Gráfico local do SHAP que parte do valor base e empilha as contribuições de cada variável, com sinal e magnitude, até chegar à predição do caso. É o formato da explicação local por excelência; a anatomia está na figura M5.fig-3 e o plot real, no notebook do módulo.	[M5: 5.3, IA-037]

Industr.IA

Programa Brasileiro de Formação
Acadêmico-Industrial em IA

Executor iRede

Executor Atlântico

Coordenador Softex

Financiador MCTI Futuro · Ministério da Ciência, Tecnologia e Inovação · Governo do Brasil

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.