Industr.IA

Template

IA Agêntica:
Matriz de Modos de Falha e Mitigações



Curso base de IA | Unidade M2

Prof.: Arthur Nascimento

Matriz de modos

Curso base de IA | Unidade M2

Como usar:

A face 1 é o instrumento reutilizável que você preenche para a solução agêntica do seu cenário; a face 2 explica como avaliar e mitigar; a seção final traz um exemplo preenchido de ponta a ponta, como referência.

Este instrumento organiza os modos de falha tratados na seção 2.8 do texto-base. Ele parte de quatro modos recorrentes, já mapeados, e pede que você avalie, para o seu cenário, como cada um apareceria, com que risco e com que mitigação.

Face 1 - Instrumento (preencher)

Preencha cada célula para a solução agêntica do seu cenário. O texto em itálico é a instrução do que registrar ali, e deve ser substituído pelo conteúdo do seu caso. Probabilidade e severidade usam a escala baixa, média ou alta.

Modo de falha	Como apareceria no seu caso	Probabilidade	Severidade	Mitigação adotada
Loop. O agente repete ações sem progredir no objetivo.	Como um loop apareceria na sua solução?	baixa, média ou alta	baixa, média ou alta	Ação concreta entre a observação e a próxima decisão.
Seleção de ferramenta errada. O agente escolhe a tool inadequada, ou a tool certa com argumentos errados.	Onde a tool ou os argumentos errados apareceriam?	baixa, média ou alta	baixa, média ou alta	Ação concreta de restrição ou validação.
Prompt injection. Conteúdo vindo do ambiente desvia o agente do objetivo.	Que conteúdo do ambiente poderia desviar o agente?	baixa, média ou alta	baixa, média ou alta	Ação concreta de isolamento ou validação.
Cascading error. Um erro inicial vira entrada do passo seguinte e se amplifica.	Como um erro inicial se propagaria no laço?	baixa, média ou alta	baixa, média ou alta	Ação concreta de validação da observação.
Outro modo identificado (opcional).	Descreva um modo específico do seu caso, se houver.	baixa, média ou alta	baixa, média ou alta	Ação concreta.

Síntese de mitigação.

Indique o modo de maior risco no seu cenário (a maior combinação de probabilidade e severidade) e a mitigação prioritária que será registrada como compromisso no desenho da solução.

Modo de maior risco: _____ Mitigação prioritária: _____

Face 2 - Instrução de uso

O que cada modo de falha significa.

O loop é a repetição de ações sem avanço, como pedir a mesma busca várias vezes ou alternar entre duas ações sem convergir. A seleção de ferramenta errada ocorre quando o agente escolhe a tool inadequada para o que precisa, ou a tool certa com argumentos errados. A injeção de prompt (prompt injection) ocorre quando texto vindo do ambiente, como um documento recuperado ou a saída de uma tool, contém instruções que desviam o agente. O erro em cascata (cascading error) ocorre quando uma observação ruim contamina as decisões seguintes, porque a saída de um passo é a entrada do próximo. Os quatro estão detalhados na seção 2.8 do texto-base e resumidos no quadro M2.q-4.

Como avaliar probabilidade e severidade.

A probabilidade estima quão frequente o modo tende a ser no cenário, dada a natureza das entradas e das tools. A severidade estima o impacto quando ele ocorre: uma resposta levemente pior é baixa, uma ação incorreta sobre um sistema externo é alta. O modo prioritário é o que combina as duas avaliações mais altas, e é nele que a mitigação precisa ser mais firme.

O que constitui uma mitigação adequada.

Uma mitigação adequada descreve uma ação concreta, e quase sempre age no mesmo lugar: entre a observação e a próxima decisão. Exemplos por modo: limitar o número de iterações e detectar repetição de estado mitiga o loop; restringir o conjunto de tools e validar os argumentos mitiga a seleção errada; tratar todo texto do ambiente como dado, e nunca como instrução, mitiga a injeção de prompt; validar a observação com checagens simples antes de seguir mitiga o erro em cascata. Evite registrar apenas a intenção, como melhorar o prompt, sem dizer qual verificação concreta será adicionada.

Exemplo preenchido

Cenário: Um agente responde perguntas técnicas consultando documentos recuperados de uma base externa. Ele busca trechos, lê o que recupera e redige a resposta. Como lê texto de origem não totalmente confiável e age sobre ele, está exposto aos quatro modos de falha, em graus diferentes.

Modo de falha	Como apareceria no seu caso	Probabilidade	Severidade	Mitigação adotada
Loop. O agente repete ações sem progredir no objetivo.	Repete a mesma busca quando não acha o trecho esperado, sem reformular a consulta.	média	baixa	Limitar a seis iterações e detectar repetição da mesma consulta, encerrando com aviso ao usuário.
Seleção de ferramenta errada. O agente escolhe a tool inadequada, ou a tool certa com argumentos errados.	Chama a busca com termos vagos, ou tenta resumir antes de recuperar o documento.	média	média	Restringir as tools a busca e leitura, e validar que a consulta tem termos mínimos antes de executar.
Prompt injection. Conteúdo vindo do ambiente desvia o agente do objetivo.	Um documento recuperado traz uma instrução embutida, como ignore as regras anteriores, que o agente poderia seguir.	média	alta	Tratar o conteúdo recuperado como dado entre delimitadores explícitos, nunca como instrução, e validar a ação antes de executá-la.
Cascading error. Um erro inicial vira entrada do passo seguinte e se amplifica.	Um trecho recuperado fora de contexto leva o agente a partir de uma premissa errada e a aprofundá-la.	média	alta	Validar a relevância do trecho recuperado antes de usá-lo, conferindo a correspondência com a pergunta.
Outro modo identificado: alucinação por obsolescência de contexto (resposta desatualizada).	Responde com base em um manual já revisado, sem perceber que há versão mais recente.	média	média	Incluir a data do documento na observação e priorizar a versão mais recente na recuperação.

Síntese do exemplo.

No agente que consulta documentos de uma base externa, o modo de maior risco é a injeção de prompt (prompt injection), pela combinação de probabilidade média e severidade alta. A mitigação prioritária é isolar o conteúdo recuperado como dado, nunca como instrução, e validar a ação antes de executá-la, registrada como requisito de segurança no desenho da solução.

Industr.IA

Residência em TIC 49



Executor iRede

Executor Atlântico

Coordenador Softex

Financiador MCTI Futuro

Ministério da Ciência, Tecnologia e Inovação

Governo do Brasil — Do lado do povo brasileiro

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.