Industr.IA

Checklist

IA Generativa

Curso base de IA | Unidade M1

Prof.: Arthur Nascimento

Industr.IA

Checklist

Curso base de IA | Unidade M1

Este checklist é um guia, e não um exercício de avaliação. Abaixo ele aparece preenchido para o mesmo cenário de exemplo usado em T1.1 e T1.2 (assistente de dúvidas sobre normas regulatórias, GenAI com RAG), mostrando o estado de uma avaliação pronta para produção. Cada item marcado indica uma verificação satisfeita. Em um caso real, um item não satisfeito vira lacuna a resolver ou risco a registrar de forma explícita na matriz T1.2.

1. Conjunto de avaliação (eval set)

- ☑ Existe um conjunto de avaliação separado, que não foi usado para ajustar prompts nem para fine-tuning.
- ☑ O conjunto cobre os casos típicos e também os casos difíceis e de borda esperados em produção.
- ☑ O conjunto inclui exemplos por slice relevante (tipo de norma e categoria de produto), e não apenas o caso médio.
- ☑ O tamanho do conjunto é suficiente para que uma diferença de qualidade não seja apenas ruído.

2. Métricas e critérios de qualidade

- ☑ A métrica escolhida é adequada à tarefa, e não uma métrica genérica aplicada por hábito.
- ☑ Os critérios de qualidade estão escritos de forma que duas pessoas avaliem a mesma saída de modo semelhante.
- ☑ Há um limiar mínimo de aprovação definido antes de olhar os resultados, e não ajustado depois para passar.
- ☑ Como a tarefa usa RAG, a qualidade da recuperação é avaliada separadamente da qualidade da geração.

3. Avaliação por modelo juiz (LLM-as-judge), quando aplicável

- ☑ O uso de um modelo juiz é justificado pela inviabilidade de avaliação só por métrica direta ou só por humano.
- ☑ O modelo juiz foi calibrado contra julgamento humano em uma amostra, e a concordância é aceitável.
- ☑ O prompt do juiz tem critérios explícitos e é versionado junto com o resto da avaliação.
- ☑ Há consciência de que o juiz também erra, e casos sensíveis ainda passam por revisão humana.

4. Suite de regressão

☑ Existe um conjunto de casos que já funcionaram, guardado para detectar regressões.
☑ A suite roda quando muda o prompt, o modelo, a versão do provedor ou a base de conhecimento.
☑ Uma falha na regressão bloqueia o deploy até ser investigada, em vez de ser ignorada.

5. Riscos, custo e conformidade

☑ Os riscos estruturais foram mapeados na matriz T1.2 (alucinação, viés, propriedade intelectual, custo, deriva temporal).
☑ O custo por inferência foi medido com prompts de tamanho realista, e não com o protótipo de baixo volume.
☑ Como há exigência regulatória e de privacidade, a avaliação cobre também conformidade, e não apenas qualidade.
☑ A rastreabilidade necessária (citação de fonte, log de entrada e saída) está disponível para auditoria.

6. Prontidão para deploy

☑ Existe um plano de reavaliação periódica para detectar deriva temporal após o deploy.
☑ Há um responsável nomeado pelo monitoramento contínuo da qualidade em produção.
☑ Existe um caminho de rollback ou de intervenção humana caso a qualidade caia.
☑ A decisão de avançar para produção foi registrada, com as lacunas remanescentes assumidas de forma explícita.

-

Industr.IA

Programa Brasileiro de Formação
Acadêmico-Industrial em IA

Executor iRede Inovação e Tecnologia

Executor Atlântico

Coordenador Softex

Financiador MCTI Futuro · Ministério da Ciência, Tecnologia e Inovação · Governo do Brasil — Do lado do povo brasileiro

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.