Industr.IA

Template

IA Generativa:

matriz de decisão GenAI versus ML clássico



Curso base de IA | Unidade M1

Prof.: Arthur Nascimento

Matriz de decisão

Curso base de IA | Unidade M1

Este material é um guia preenchido, e não um exercício de avaliação. A face 1 traz a matriz já preenchida para um cenário de exemplo, para mostrar o padrão de raciocínio esperado. A face 2 explica o que cada Weixo mede e o que constitui uma justificativa adequada, e traz um segundo exemplo com desfecho oposto.

Face 1 - matriz preenchida (exemplo de referência)

Cenário avaliado: assistente que responde a dúvidas técnicas de clientes sobre normas regulatórias de equipamentos médicos. A base documental reúne as normas aplicáveis, revistas a cada poucos meses. Volume estimado de 2.000 consultas por dia. Há exigência de rastreabilidade da fonte e de não exposição de dados sensíveis.

No exemplo a seguir, cada linha traz o peso, a alternativa favorecida e a justificativa preenchidos para o cenário. O peso reflete a importância do eixo (1 baixo, 2 médio, 3 alto). A justificativa se ancora em evidência do cenário, não em preferência geral.

Eixo de decisão	Peso (1 a 3)	Alternativa favorecida	Justificativa no caso
Custo (gasto por inferência e operação)	2	GenAI	A 2.000 consultas por dia o volume é moderado; o custo por inferência da GenAI é aceitável e não inverte a decisão, mas deve ficar sob monitoramento.
Latência (tempo de resposta exigido)	1	Empate	A tarefa não é de tempo real; uma resposta na casa de segundos é tolerada, então a latência não decide o caso.
Reprodutibilidade (mesma entrada, mesma saída; auditabilidade)	3	ML clássico	O eixo puro favorece um modelo determinístico; como a tarefa não é classificável, a exigência de auditoria é atendida por RAG com citação da fonte, e não por ML clássico.
Precisão (qualidade da saída na tarefa)	3	GenAI	A tarefa é gerar resposta em linguagem aberta com citação; um classificador não produz esse tipo de saída, então a GenAI é a única que atende.
Disponibilidade de dados (volume e estabilidade de dados rotulados)	3	GenAI	Não há dataset rotulado de perguntas e respostas; o conhecimento está nos documentos de norma, o que favorece GenAI com RAG na partida a frio.

Síntese decisória:

Campo	Preenchimento
Decisão recomendada	GenAI com RAG (contexto recuperado e citação obrigatória da fonte)
Eixos que mais pesaram	Precisão e disponibilidade de dados (a natureza da saída e a ausência de rótulos), com reprodutibilidade atendida pela citação
Justificativa integrada	A tarefa é síntese de linguagem aberta sobre conhecimento documental volátil, sem rótulos disponíveis, e o ML clássico não gera a resposta. A GenAI com RAG atende precisão e dados, e a auditoria é coberta pela citação da fonte. O custo é aceitável no volume atual e fica sob monitoramento.
Premissas a revisitar	Se o volume crescer a ponto de o custo por inferência dominar, reabrir a alocação de custo (modelo menor, cache). Se a tarefa migrar para classificação de chamados, reabrir a favor de ML clássico.

Face 2 - Instrução de uso

O que cada eixo mede e o que o puxa para cada lado

- **Custo.** Mede o gasto recorrente por inferência mais o custo de operação. Puxa para ML clássico quando o volume é alto e a tarefa é estreita, porque um modelo treinado custa quase nada por chamada. Puxa para GenAI quando o volume é baixo ou a tarefa exige síntese aberta que o modelo clássico não entrega.
- **Latência.** Mede o tempo de resposta tolerado pela aplicação. Puxa para ML clássico em cenários de tempo real ou alto volume, em que milissegundos importam. Puxa para GenAI quando a tarefa tolera respostas na casa de centenas de milissegundos a segundos.
- **Reprodutibilidade.** Mede se a mesma entrada produz a mesma saída e se o resultado é auditável. Puxa para ML clássico quando há exigência de auditoria, testes de regressão estáveis ou rastreabilidade. Puxa para GenAI apenas quando a variabilidade de saída é aceitável.
- **Precisão.** Mede a qualidade da saída na tarefa concreta. Em tarefas tabulares estreitas, GenAI e ML clássico costumam empatar, e nesse caso o eixo não decide; a decisão migra para os outros quatro. Puxa para GenAI sobretudo em tarefas de linguagem aberta.
- **Disponibilidade de dados.** Mede o volume e a estabilidade de dados rotulados representativos. Puxa para ML clássico quando há dataset rotulado abundante e estável. Puxa para GenAI na partida a frio, quando ainda não há rótulos, via few-shot ou RAG.

O que conta como justificativa adequada

Uma justificativa adequada é específica do cenário e aponta a evidência que sustenta a tendência. Frases como “GenAI é mais moderna” ou “ML clássico é mais simples” não servem, porque não se ligam ao caso. Uma justificativa adequada diz, por exemplo, qual é o volume estimado, se há dados rotulados, qual latência o produto exige ou se há obrigação de auditoria. Quando dois eixos apontam para lados opostos, o peso decide, e o conflito deve aparecer na síntese, não ser escondido.

Segundo exemplo, com desfecho oposto

Cenário: classificar 50 mil chamados de manutenção por dia em categorias conhecidas, com histórico rotulado abundante. Aqui o desfecho se inverte e o ML clássico vence, porque há dados rotulados, a saída é um rótulo discreto e o custo por inferência domina no alto volume.

Eixo de decisão	Peso	Alternativa favorecida	Justificativa no caso
Custo	3	ML clássico	A 50 mil chamadas diárias, o custo por inferência domina; um classificador treinado custa uma fração de uma chamada a LLM por item.
Disponibilidade de dados	3	ML clássico	Há histórico rotulado abundante e estável, condição ideal para um modelo discriminativo.

Observações de uso

- Ordene mentalmente os eixos por peso antes de decidir; é o peso que transforma esta matriz de um checklist genérico em um argumento específico.
- A árvore de decisão da figura M1.fig-4 (texto-base IA-011) complementa esta matriz: use-a para chegar a uma hipótese de decisão e use a matriz para justificá-la eixo a eixo.
- Trate a decisão como revisitável. Registre, na síntese, a premissa que, se mudar, reabriria a escolha.
- A decisão registrada aqui se conecta às demais decisões correlatas do módulo (modelo aberto versus API, in-context versus fine-tuning, RAG versus contexto fechado, alocação de custo) e deve ser lida em conjunto com elas.

Industr.IA

Residência em TIC 49



Executor iRede

Executor Atlântico

Coordenador Softex

Financiador MCTI Futuro

Ministério da Ciência, Tecnologia e Inovação

Governo do Brasil — Do lado do povo brasileiro

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.