Industr.IA

Template

IA Generativa:
Matriz de riscos de soluções generativas



Curso base de IA | Unidade M1

Prof.: Arthur Nascimento

Matriz de riscos

Curso base de IA | Unidade M1

Este material é um guia preenchido, e não um exercício de avaliação. A face 1 traz a matriz de riscos já preenchida para o mesmo cenário de exemplo usado em T1.1, para mostrar o padrão de raciocínio esperado. A face 2 explica como avaliar probabilidade e severidade e o que conta como mitigação adequada. As categorias e as mitigações típicas são fixas; a coluna de mitigação adotada mostra a escolha feita para este caso.

Face 1 - Matriz de riscos preenchida (exemplo de referência)

Cenário avaliado: assistente que responde a dúvidas técnicas de clientes sobre normas regulatórias de equipamentos médicos, com base documental volátil, volume de 2.000 consultas por dia, exigência de rastreabilidade da fonte e de não exposição de dados sensíveis. Solução escolhida em T1.1: GenAI com RAG.

Risco	Probabilidade (B/M/A)	Severidade (B/M/A)	Mitigações típicas (referência)	Mitigação adotada no caso
Alucinação (saída plausível, mas factualmentein-correta)	Alta	Alta	RAG com atribuição de fonte; verificação humana em casos críticos; restringir o escopo da resposta	RAG sobre o repositório oficial de normas, com cita-ção obrigatória do artigo, e revisão humana quando a confiança da recuperação for baixa.
Viés (saída que reproduz ou ampli-fica preconceitos dos dados)	Média	Média	avaliação por slices; conjunto de teste ba-lanceado; revisão de prompts; articulação com o módulo M3	Avaliação por slices (tipo de norma e categoria de produ-to), revisão dos prompts e conjunto de teste balance-ado entre as normas mais consultadas.
Propriedade intelectual (uso indevido de con-teúdo protegido na entrada ou na saída)	Baixa	Média	política de uso de da-dos; filtros de saída; rastreabilidade da fonte; cláusulas com o provedor	A base usa normas oficiais de uso permitido; a citação da fonte garante rastreabi-lidade e há cláusula de uso de dados com o provedor do modelo.
Custo (gasto em produção acima do previsto)	Média	Média	teto de tokens; cache de respostas; mode-lo menor; monitora-mento de custo por chamada	Teto de tokens por resposta, cache das perguntas mais frequentes, modelo menor na maioria dos casos e monitoramento de custo por chamada no volume de 2.000 por dia.
Deriva temporal (queda de quali-dade conforme dados e mundo mudam)	Alta	Alta	reavaliação perió-dica; reindexação do RAG; suite de regressão; alarme de degradação	Reindexação do RAG a cada atualização de norma, suite de regressão sobre pergun-tas conhecidas e alarme de degradação de qualidade em produção.

Síntese de riscos:

Campo	Preenchimento
Riscos prioritários (alta probabilidade e alta severidade)	Alucinação e deriva temporal; ambos exigem mitigação ativa antes do deploy.
Riscos residuais aceitos (e por quê)	Propriedade intelectual, dada a baixa probabilidade (base de normas oficiais) e a rastreabilidade já garantida pela citação.
Responsável pelo monitoramento contínuo	Time de produto para qualidade e custo; jurídico e conformidade para citação e propriedade intelectual.
Gatilho de reavaliação (o que dispara revisão do risco)	Publicação de nova versão de norma, ou queda de qualidade detectada pela suite de regressão.

Face 2 - Instrução de uso

Como avaliar probabilidade e severidade

- **Probabilidade** é quão provável o risco se materializar neste cenário, dado o modelo, os dados e o uso. Avalie em três níveis: baixa, média ou alta. Por exemplo, alucinação tende a ter probabilidade alta em perguntas sobre fatos de nicho e baixa em tarefas de reescrita de texto fornecido.
- **Severidade** é o tamanho do dano se o risco ocorrer. Uma alucinação em um rascunho interno tem severidade baixa; a mesma alucinação em uma resposta a cliente em setor regulado tem severidade alta. A severidade depende do uso, não apenas do modelo.
- O produto informal de probabilidade por severidade ordena a atenção. Riscos de alta probabilidade e alta severidade entram em “riscos prioritários” e exigem mitigação antes do deploy; riscos de baixo impacto podem ser aceitos como residuais, desde que registrados.

O que conta como mitigação adequada

Uma mitigação adequada é concreta, verificável e proporcional ao risco. “Tomar cuidado com alucinação” não é mitigação; “ancorar respostas em RAG com citação da fonte e exigir revisão humana antes do envio ao cliente” é. Uma mitigação adequada também nomeia quem a executa e quando, para que não fique no plano da intenção. Mitigações que reduzem um risco às custas de agravar outro, como encurtar prompts para cortar custo ao preço de mais alucinação, devem tornar essa troca explícita.

Observações de uso

- Esta matriz é o complemento da matriz de decisão T1.1: a T1.1 escolhe a abordagem, a T1.2 mapeia os riscos dessa escolha. Leia as duas em conjunto.
- O eixo de custo aqui dialoga com a alocação de custo da seção 1.12: subestimar o custo de produção é, ele próprio, um risco.
- Viés e propriedade intelectual conectam-se à IA responsável tratada no módulo M3; registre nessas linhas a dependência com aquele módulo quando ela existir.
- Trate a matriz como viva. O “gatilho de reavaliação” existe porque os riscos mudam com volume, dados e regulação.

Industr.IA

Residência em TIC 49



Executor iRede

Executor Atlântico

Coordenador Softex

Financiador MCTI Futuro

Ministério da Ciência, Tecnologia e Inovação

Governo do Brasil — Do lado do povo brasileiro

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.