Industr.IA

Glossário

Panorama de IA Aplicada

Curso base de IA | Unidade M0

Prof.: Arthur Nascimento

Industr.IA

Glossário

Curso base de IA | Unidade M0

Convenções: cada entrada traz tag de origem no formato [M0: seção]. Quando o texto-base traz um box-glossário formal para o termo, a tag inclui a marca box. Termos introduzidos no notebook do módulo, e não no texto-base, trazem a marca do notebook na tag (por exemplo [M0: 0.2, IA-003]). Referências cruzadas aparecem como "veja X," sem definição. A ordem é alfabética, ignorando acentos e diferença entre maiúsculas e minúsculas.

GLOSSÁRIO DE TERMOS

Termo	Descrição	Origem
Ação	No aprendizado por reforço, a escolha que o agente faz em cada passo e que afeta o ambiente. A sequência de ações é guiada pela política e avaliada pelas recompensas que produz.	[M0: 0.3]
Acurácia	Fração de acertos sobre o total de exemplos. Métrica básica em classificação; em conjuntos desequilibrados, pode parecer alta sem que o modelo seja útil (veja precisão e recall).	[M0: 0.1]
Agente	No aprendizado por reforço, a entidade que observa o estado do ambiente, escolhe ações segundo uma política e aprende com as recompensas recebidas. No contexto agêntico (módulo M2), o termo se estende a um sistema que envolve um modelo de linguagem em um laço de decisão com ferramentas e memória.	[M0: 0.3]
Agentic	Lente transversal sobre comportamento agêntico e autonomia operacional. Pergunta se o sistema decide e age dentro de um laço (consulta ferramentas, mantém memória, persegue objetivo em vários passos) ou apenas responde a uma solicitação isolada. Desenvolvida no módulo M2.	[M0: 0.4]
AlexNet	Rede convolucional grande, treinada em placas gráficas sobre o ImageNet, cuja vitória em um torneio de visão computacional em 2012 é tida como o marco visível do início da era do Deep Learning.	[M0: 0.2]
Alvo (target)	A saída que o modelo deve prever, conhecida nos exemplos de treino. Em classificação é uma categoria; em regressão, um número. O termo em inglês, target, é igualmente comum.	[M0: 0.1, IA-003]
Ambiente	No aprendizado por reforço, o sistema externo sobre o qual o agente atua e que, em resposta a cada ação, devolve um novo estado e uma recompensa.	[M0: 0.3]
Aprendizado auto-supervisionado	Paradigma em que os rótulos são gerados a partir dos próprios dados, sem anotação humana. Um modelo de linguagem aprende prevendo o próximo elemento de uma sequência: o dado é, ao mesmo tempo, entrada e resposta. Viabiliza o treinamento de Foundation Models em escala.	[M0: 0.3, box]

Aprendizado não supervisionado	Paradigma em que os dados não trazem rótulos e o modelo busca estrutura por conta própria, como grupos de exemplos parecidos ou regularidades na distribuição.	[M0: 0.3]
Aprendizado por reforço	Paradigma em que um agente aprende por tentativa e erro a partir de recompensas, ajustando uma política de ação para maximizar o retorno ao longo do tempo. Típico de problemas de controle.	[M0: 0.3]
Aprendizado supervisionado	Paradigma em que cada exemplo de treinamento vem com a resposta correta (rótulo). O modelo aprende a reproduzir essa associação entre entrada e saída.	[M0: 0.3]
Árvore de decisão	Modelo de ML clássico que organiza decisões em uma sequência de testes sobre atributos. Adequada a dados tabulares; serve de base para florestas aleatórias.	[M0: 0.2]
Atributo (feature)	Coluna de entrada de um modelo, o dado a partir do qual ele faz a previsão. Em dados tabulares, cada exemplo é descrito por um conjunto de atributos; o termo em inglês, feature, é igualmente comum.	[M0: 0.1, IA-003]
Attention	Mecanismo que pondera as relações entre elementos de uma sequência, permitindo que cada posição leve em conta as demais. Núcleo da arquitetura transformer.	[M0: 0.2]
Backpropagation	veja Retropropagação	
Balanceamento de classes	Grau em que as categorias de um problema de classificação aparecem em proporções parecidas. Quando uma classe é muito mais frequente que a outra, a acurácia perde sentido como métrica isolada, e recorre-se a precisão, recall e F1, além de estratégias como sobreamostragem, subamostragem ou pesos diferentes por classe.	[M0: 0.1]
Batch (lote)	Subconjunto do conjunto de treino usado em um único ajuste de parâmetros. Dividir o treino em lotes evita carregar todos os exemplos de uma vez na memória; cada lote processado corresponde a uma iteração de treinamento..	[M0: 0.1]
BERT	Modelo de linguagem baseado em transformer, lançado em 2018, treinado para representar contexto de forma bidirecional. Foi um dos modelos que impulsionaram a evolução dos grandes modelos de linguagem e dos atuais Foundation Models.	[M0: 0.2]
Classificação	Tarefa em que o modelo atribui uma entrada a uma categoria entre opções discretas, como defeito ou não defeito.	[M0: 0.3]
Clustering	Tarefa em que o modelo agrupa exemplos por semelhança, sem categorias predefinidas. Típica do aprendizado não supervisionado.	[M0: 0.3]
CNN	veja Rede convolucional	

Codificação one-hot (one-hot encoding)	Representação que transforma uma coluna categórica em várias colunas binárias, uma por categoria, para que modelos numéricos como a floresta aleatória possam usá-la. Descartar uma das colunas geradas evita redundância entre elas.	[M0: 0.3, IA-003]
Coeficiente de determinação (R^2)	Métrica de regressão que indica que fração da variação dos dados o modelo explica. Vai de 0 (sem explicação) a 1 (explicação perfeita) e pode ser negativo quando o modelo é pior que a média.	[M0: 0.1]
Conjunto de teste	Parte dos dados reservada para uma estimativa final e honesta da generalização. Usado uma única vez, depois que o modelo está fechado; orientar o ajuste pelo teste causa vazamento de dados.	[M0: 0.1]
Conjunto de treino	Parte dos dados usada para ajustar os parâmetros do modelo durante o treinamento.	[M0: 0.1]
Conjunto de validação	Parte dos dados usada para comparar modelos e escolher hiperparâmetros entre rodadas de treino. Não entra no ajuste de parâmetros.	[M0: 0.1]
Controle	Tarefa em que o modelo escolhe ações que afetam um ambiente ao longo do tempo. Típica do aprendizado por reforço.	[M0: 0.3]
Curva de aprendizado	Gráfico do erro do modelo em treino e em validação ao longo das épocas. A separação entre as duas curvas, quando o erro de validação para de cair e começa a subir, sinaliza o início do overfitting e fundamenta a parada antecipada.	[M0: 0.1]
Data-centric	Lente transversal sobre os dados. Pergunta se o ganho da solução vem de mexer no modelo ou de melhorar o conjunto de dados (qualidade, cobertura, balanceamento, rotulagem). Desenvolvida no módulo M3.	[M0: 0.4]
Data leakage	veja Vazamento de dados	
Deep Learning	Família arquitetural baseada em redes neurais profundas que aprendem representações em camadas a partir de dados brutos. Tornou-se dominante em visão e linguagem a partir de 2012. O programa também adota Deep Learning como um dos sete eixos técnicos.	[M0: 0.2]
Descida do gradiente (gradient descent)	Algoritmo padrão de ajuste de parâmetros no treinamento. Calcula o gradiente, a direção em que o erro diminui mais rápido, e move cada parâmetro um passo nessa direção; o tamanho do passo é dado pela taxa de aprendizado.	[M0: 0.1]
Dropout	Técnica de regularização que desliga aleatoriamente uma fração dos neurônios durante o treinamento, forçando a rede a não depender de poucas unidades. Foi um dos truques de engenharia que tornaram o treinamento de redes profundas estável na prática.	[M0: 0.2]
Edge	Lente transversal sobre o local de execução. Pergunta se o sistema roda perto do equipamento,	[M0: 0.4]

	com restrições de memória, energia, conectividade e latência, ou em um servidor com folga. Desenvolvida no módulo M4.	
Eixo técnico	Recorte por tecnologia ou área de competência usado no programa. São sete: LLMs, Visão Computacional, Machine Learning, Real Time Processing, Deep Learning, NLP e Engenharia de Dados. Responde "com que tecnologia se resolve", em contraste com a lente transversal, que responde "que pergunta se faz a qualquer problema".	[M0: 0.4]
Engenharia de Dados	Eixo técnico do programa, dedicado à construção e operação de pipelines que ingerem, transformam e disponibilizam dados para os demais sistemas.	[M0: 0.4]
Época	Uma passagem completa pelo conjunto de treino inteiro durante o treinamento. Um treinamento costuma envolver muitas épocas; dentro de cada uma, os ajustes ocorrem lote a lote, em iterações.	[M0: 0.1]
Erro absoluto médio (MAE)	Métrica de regressão. Média do valor absoluto dos erros entre saída prevista e saída real; trata todos os erros com peso linear.	[M0: 0.1]
Estado	No aprendizado por reforço, a descrição da situação do ambiente que o agente observa em cada passo antes de escolher uma ação.	[M0: 0.3]
Explainable	Lente transversal sobre transparência. Pergunta se é possível justificar uma decisão a quem é afetado por ela e quem responde por essa decisão. Desenvolvida no módulo M5.	[M0: 0.4]
Exploração versus explotação	Dilema central do aprendizado por reforço. Explorar é testar ações pouco conhecidas, que podem render mais no longo prazo; explotar é repetir as ações que já se mostraram boas. O equilíbrio entre as duas é decidido por hiperparâmetros e estratégias próprias do paradigma.	[M0: 0.3]
F1	Métrica de classificação que sintetiza precisão e recall em um único número (média harmônica das duas). Útil quando as classes são desequilibradas e nenhuma das duas métricas isolada conta a história.	[M0: 0.1]
Falso negativo	Caso positivo real que o modelo classificou como negativo. Em detecção de falhas ou triagem de doenças, costuma ser o erro mais caro, e por isso o recall ganha peso.	[M0: 0.1]
Falso positivo	Caso negativo real que o modelo classificou como positivo. Em filtros de correio indesejado, por exemplo, é o erro mais incômodo, e por isso a precisão ganha peso.	[M0: 0.1]
Feature	veja Atributo	
Ferramenta	No contexto agêntico, recurso externo que o modelo pode acionar dentro do laço de decisão, como busca na web, execução de código, consulta a banco de	[M0: 0.2]

	dados ou envio de mensagens. Detalhada no módulo M2.	
Few-shot	Uso de um Foundation Model com alguns exemplos resolvidos dentro do prompt para orientar a resposta, um caso de in-context learning. Sem nenhum exemplo, fala-se em zero-shot.	[M0: 0.2, IA-003]
Fine-tuning	Adaptação de um Foundation Model pré-treinado mediante treinamento adicional sobre dados específicos da tarefa-alvo, ajustando todos os parâmetros ou um subconjunto. Variantes econômicas, como LoRA, ajustam apenas matrizes pequenas somadas aos pesos originais.	[M0: 0.2]
Floresta aleatória	Modelo de ML clássico que combina muitas árvores de decisão treinadas com variações aleatórias. Escolha robusta para muitos problemas tabulares.	[M0: 0.2]
Foundation Model	Modelo de grande escala, treinado em volume amplo de dados gerais, que serve de base para muitas tarefas diferentes mediante adaptação leve, em vez de ser treinado do zero para cada tarefa. Termo popularizado por um relatório de Stanford em 2021.	[M0: 0.2, box]
Generalização	Capacidade do modelo de ir bem em exemplos novos, que não estavam no treinamento. É o único desempenho que interessa na prática.	[M0: 0.1]
Generativa	Lente transversal sobre criação. Pergunta se o sistema produz um artefato novo (texto, imagem, áudio, código, dados sintéticos) e o que decorre disso em avaliação, governança e controle. Desenvolvida no módulo M1.	[M0: 0.4]
Geração	Tarefa em que o modelo produz um artefato novo (texto, imagem, áudio, código). Típica do aprendizado auto-supervisionado em escala.	[M0: 0.3]
GPT	Família de modelos de linguagem baseados em transformer, treinados de forma generativa em larga escala. Marco do que veio a se chamar Foundation Models de linguagem.	[M0: 0.2]
GPU	Placa gráfica (graphics processing unit). Originalmente desenhada para jogos, oferece o tipo de paralelismo adequado ao treinamento de redes profundas, e sua disponibilidade por volta de 2010 foi um dos fatores que viabilizaram o Deep Learning.	[M0: 0.2]
Gradient boosting	Método de ML clássico que combina muitas árvores de decisão simples treinadas em sequência, cada uma corrigindo os erros da anterior. Frequentemente competitivo com redes profundas em dados tabulares, a um custo muito menor.	[M0: 0.2]
Gradient descent	veja Descida do gradiente	
Gradiente	Direção, calculada para todos os parâmetros ao mesmo tempo, em que o erro do modelo diminui mais rápido. É o que orienta cada passo de ajuste no treinamento (veja descida do gradiente).	[M0: 0.1]

Hiperparâmetro	Valor de configuração definido antes do treinamento e não ajustado por ele. Exemplos: taxa de aprendizado, profundidade máxima de uma árvore, número de camadas de uma rede. A escolha costuma ser decidida por experimentação sobre o conjunto de validação.	[M0: 0.1, box]
ImageNet	Grande base de imagens anotadas manualmente, compilada entre 2009 e 2010, que forneceu a escala de dados necessária para treinar redes profundas de visão. Foi o conjunto sobre o qual a AlexNet venceu em 2012.	[M0: 0.2]
In-context learning (aprendizado em contexto)	Ajuste do comportamento de um Foundation Model apenas pelos exemplos e instruções presentes no próprio prompt, sem nenhuma atualização de pesos. Difere do treinamento porque nada do que foi mostrado persiste para a chamada seguinte sem ser reenviado (veja prompting, few-shot).	[M0: 0.2, IA-003]
Inferência	Uso do modelo já treinado: apresenta-se uma entrada nova e lê-se a saída, sem alterar mais parâmetros. Em oposição ao treinamento, costuma ser o que acontece em produção e concentra decisões de custo e latência.	[M0: 0.1]
Iteração	Um único ajuste de parâmetros durante o treinamento, baseado em um lote (batch) de exemplos. Várias iterações compõem uma época.	[M0: 0.1]
Lente transversal	Ângulo de leitura que se aplica a qualquer problema de IA, qualquer que seja o eixo técnico envolvido. Diferente de um eixo técnico, não nomeia uma tecnologia; nomeia uma pergunta recorrente (sobre geração, autonomia, dados, execução ou transparência) que atravessa todos os eixos. O programa define cinco: Generativa, Agentic, Data Centric, Edge e Explainable.	[M0: 0.4, box]
LLMs	Eixo técnico do programa, dedicado a modelos de linguagem grandes (Large Language Models). Apoia-se em arquitetura transformer e em paradigma auto-supervisionado de pré-treino.	[M0: 0.4]
LoRA	Técnica de fine-tuning econômico (low-rank adaptation) que adapta um Foundation Model ajustando matrizes pequenas somadas aos pesos originais, em vez de reajustar todos os parâmetros. Reduz muito o custo de adaptação.	[M0: 0.2]
LSTM	Arquitetura de rede recorrente, introduzida em 1997, projetada para lidar com dependências de longo prazo em dados sequenciais. Dominou texto e séries temporais no Deep Learning antes dos transformers.	[M0: 0.2]
Machine Learning	Eixo técnico do programa. No recorte do programa, abrange métodos de aprendizado (clássicos e profundos) aplicados a problemas tabulares e estruturados. O termo também é usado	[M0: 0.4]

	genericamente no campo para qualquer aprendizado a partir de dados.	
MAE	veja Erro absoluto médio	
Máquina de vetores de suporte (SVM)	Método de ML clássico que encontra a fronteira de decisão que separa classes com a maior margem possível. Eficiente em conjuntos de tamanho pequeno a moderado.	[M0: 0.2]
Matriz de confusão	Tabela que organiza acertos e erros de classificação por categoria. Torna legíveis as fontes de erro e dá base para precisão, recall, F1 e métricas derivadas.	[M0: 0.1]
Memória	No contexto agêntico, o componente que persiste entre passos do laço de decisão, permitindo que o sistema lembre o que já fez e o que descobriu. Detalhada no módulo M2.	[M0: 0.2]
ML clássico	Família arquitetural anterior ao Deep Learning, que reúne métodos de aprendizado sobre dados tabulares: árvores de decisão, florestas aleatórias, máquinas de vetores de suporte, métodos de regressão. Continua sendo a escolha certa para muitos problemas industriais com dados tabulares e volume moderado.	[M0: 0.2]
MLP	veja Perceptron multicamadas	
Modelo	Função com valores ajustáveis (parâmetros) que recebe uma entrada e produz uma saída. O que o caracteriza é ter os valores aprendidos a partir de exemplos, em vez de escritos à mão por um programador.	[M0: 0.1]
NLP	Eixo técnico do programa, dedicado ao processamento de linguagem natural (Natural Language Processing). Abrange representação de texto, modelagem de sequências e tarefas linguísticas em geral.	[M0: 0.4]
Normalização de batch (batch normalization)	Técnica que estabiliza o treinamento de redes profundas reescalando as ativações dentro de cada lote. Foi um dos truques de engenharia que tornaram o Deep Learning viável na prática.	[M0: 0.2]
Overfitting	Situação em que o modelo vai muito bem nos dados de treinamento e mal em dados novos, porque ajustou-se a ruído e a particularidades irrelevantes. O extremo oposto é o underfitting; técnicas de regularização ajudam a conter o overfitting.	[M0: 0.1, box]
Parada antecipada (early stopping)	Técnica que interrompe o treinamento quando o erro de validação para de cair e começa a subir, evitando que o modelo entre em overfitting. Apoia-se na leitura da curva de aprendizado.	[M0: 0.1]
Paradigma de aprendizagem	Descrição de a partir de que tipo de sinal o modelo aprende. O M0 trata quatro: supervisionado, não supervisionado, auto-supervisionado e por reforço. Eixo independente da tarefa.	[M0: 0.3]

Parâmetro	Valor interno do modelo, ajustado durante o treinamento para reduzir o erro nos exemplos vistos. Varia de poucas dezenas, numa regressão linear, a centenas de bilhões, num modelo de linguagem grande.	[M0: 0.1]
Perceptron	Modelo de 1958, capaz de aprender a separar duas classes ajustando pesos sobre entradas numéricas. Marco inicial das redes neurais; limitado a problemas linearmente separáveis.	[M0: 0.2]
Perceptron multicamadas (MLP)	Rede neural totalmente conectada, em que cada neurônio de uma camada se liga a todos os da camada seguinte, sem assumir estrutura espacial ou sequencial na entrada. A arquitetura mais geral do Deep Learning; perde para CNN e RNN quando os dados têm estrutura própria.	[M0: 0.2]
Política	No aprendizado por reforço, a regra que o agente usa para escolher uma ação a partir do estado atual. É o que se aprende, com o objetivo de maximizar a soma das recompensas ao longo do tempo.	[M0: 0.3]
Pré-treino	Primeira e mais cara etapa de construção de um Foundation Model: treinamento em larga escala sobre dados gerais, em geral de forma auto-supervisionada, que produz o modelo base depois adaptado por fine-tuning ou usado via prompting.	[M0: 0.2]
Precisão	Métrica de classificação. Mede que fração das previsões positivas estava correta. Conta junto com recall e é resumida no F1.	[M0: 0.1]
Prompting	Uso de um Foundation Model por meio de uma instrução em linguagem natural, possivelmente com exemplos, sem nenhum treinamento adicional. O modelo produz a saída apenas com base no contexto fornecido.	[M0: 0.2]
R^2	veja Coeficiente de determinação	
RAG (retrieval-augmented generation)	Pipeline que compõe duas tarefas: primeiro recupera de um acervo os trechos mais relevantes para uma pergunta (recuperação), depois usa um modelo de linguagem para gerar a resposta com base nesses trechos (geração). Exemplo canônico de tarefa composta.	[M0: 0.3]
Raiz do erro quadrático médio (RMSE)	Métrica de regressão. Raiz quadrada da média dos erros ao quadrado; penaliza erros grandes mais do que o erro absoluto médio.	[M0: 0.1]
RandomForest	veja Floresta aleatória	
Ranking	Tarefa de ordenar candidatos por relevância, frequentemente composta sobre uma classificação prévia. Aparece em busca, recomendação e recuperação.	[M0: 0.3]

Real Time Processing	Eixo técnico do programa, dedicado a sistemas com restrições de latência e a processamento em fluxo (streaming, eventos, controle).	[M0: 0.4]
Recall	Métrica de classificação. Mede que fração dos casos positivos reais o modelo capturou. Em problemas com falsos negativos caros, como detecção de falhas, costuma ser a métrica que importa.	[M0: 0.1]
Recompensa	No aprendizado por reforço, o sinal (positivo ou negativo) que o ambiente devolve ao agente após cada ação. O objetivo do agente é maximizar a soma das recompensas ao longo do tempo, não a de cada passo isolado.	[M0: 0.3]
Recuperação	Tarefa em que o modelo encontra, num acervo, os itens mais relevantes para uma consulta. Núcleo de sistemas de busca e de mecanismos como recuperação aumentada por geração.	[M0: 0.3]
Rede convolucional (CNN)	Arquitetura de Deep Learning que explora a estrutura espacial de imagens, processando regiões locais e compondo padrões cada vez mais abstratos. Padrão em visão computacional.	[M0: 0.2]
Rede neural profunda	Rede neural com várias camadas de processamento. Aprende representações em camadas a partir dos dados brutos, em vez de depender de atributos definidos à mão.	[M0: 0.2]
Rede recorrente (RNN)	Arquitetura projetada para dados em sequência, que mantém um estado interno entre passos. A LSTM é uma de suas variantes mais conhecidas.	[M0: 0.2]
Regressão	Tarefa em que o modelo produz um número contínuo (preço, vibração, temperatura). Difere de classificação, que produz categoria.	[M0: 0.3]
Regularização	Conjunto de técnicas que penalizam complexidade no treinamento para conter o overfitting. Inclui restrições sobre os parâmetros, dropout, parada antecipada, entre outras.	[M0: 0.1]
ReLU	Função de ativação (rectified linear unit) que deixa passar valores positivos e zera os negativos. Simples e barata, foi um dos truques que tornaram prático treinar redes profundas.	[M0: 0.2]
Representação aprendida	Forma interna como o modelo codifica os dados, desenvolvida como subproduto do treinamento (em especial do auto-supervisionado) e reaproveitada nas adaptações posteriores via fine-tuning ou prompting.	[M0: 0.3]
Retropropagação	Algoritmo introduzido em 1986 que tornou prático treinar redes com várias camadas. Calcula, para cada parâmetro, a contribuição ao erro e indica a direção do ajuste.	[M0: 0.2]
RMSE	veja Raiz do erro quadrático médio	
RNN	veja Rede recorrente	

Sistemas agênticos	Sistemas que envolvem um modelo (em geral de linguagem) em um laço de decisão com ferramentas e memória, perseguindo um objetivo ao longo de vários passos. Ganham tração a partir de 2023; tratados em detalhe no módulo M2, sob a lente Agentic.	[M0: 0.2]
Sobreamostragem (oversampling)	Estratégia para lidar com classes desequilibradas que aumenta a presença da classe rara no treinamento, replicando ou sintetizando exemplos. Oposto da subamostragem.	[M0: 0.1]
Subamostragem (undersampling)	Estratégia para lidar com classes desequilibradas que reduz a presença da classe abundante no treinamento, descartando parte de seus exemplos. Oposto da sobreamostragem.	[M0: 0.1]
SVM	veja Máquina de vetores de suporte	
Tarefa	Descrição do que o modelo produz, independentemente de como aprendeu. O M0 trata seis: classificação, regressão, clustering, geração, recuperação e controle. Eixo independente do paradigma.	[M0: 0.3]
Target	veja Alvo	
Taxa de aprendizado (learning rate)	Hiperparâmetro que define o tamanho do passo em cada ajuste da descida do gradiente. Passo grande demais faz o ajuste oscilar sem convergir; pequeno demais torna o treinamento lento e sujeito a parar cedo.	[M0: 0.1]
Token	Unidade em que um texto é fragmentado para um modelo de linguagem (palavra, pedaço de palavra ou caractere). O treinamento auto-supervisionado de um modelo de linguagem consiste, em larga medida, em prever o próximo token de uma sequência.	[M0: 0.2]
Transformer	Arquitetura introduzida em 2017 que processa uma sequência inteira em paralelo e modela relações de longa distância entre seus elementos por meio do mecanismo de attention. Base dos Foundation Models atuais.	[M0: 0.2]
Treinamento	Processo de ajustar os parâmetros do modelo para que as saídas se aproximem das saídas desejadas nos exemplos disponíveis. Em oposição à inferência: costuma ser caro, demorado e feito poucas vezes.	[M0: 0.1]
Underfitting	Situação oposta ao overfitting: o modelo é simples demais para capturar o padrão dos dados e vai mal tanto no treino quanto em dados novos.	[M0: 0.1]
Validação cruzada	Procedimento que reaproveita os dados em múltiplas partições rotativas para estimar desempenho quando o conjunto é pequeno demais para sustentar uma divisão fixa entre treino, validação e teste.	[M0: 0.1]
Vazamento de dados	Erro em que informação do conjunto de teste influencia, ainda que indiretamente, o treinamento ou	[M0: 0.1]

	a escolha de hiperparâmetros. Resultado: estimativa de desempenho inflada que não se confirma em produção. Exemplo comum: normalizar todos os dados juntos antes de separá-los em treino, validação e teste.	
Visão Computacional	Eixo técnico do programa, dedicado a problemas em que a entrada é uma imagem ou vídeo (detecção, classificação, segmentação).	[M0: 0.4]
Zero-shot	Uso de um Foundation Model sem nenhum exemplo no prompt, apoiado só na instrução e no conhecimento geral do modelo. Oposto, quanto ao número de exemplos, do few-shot.	[M0: 0.2, IA-003]

Industr.IA

Programa Brasileiro de Formação
Acadêmico-Industrial em IA

Executor Executor Coordenador Financiador

Projeto apoiado pelo Ministério da Ciência, Tecnologia e Inovações, com recursos da Lei nº 8.248, de 23 de outubro de 1991.